

Rapport de clôture

De la donnée hydrologique dispersée à la prévision explicable

Construction d'un entrepôt de données et d'une plateforme
d'expérimentation en apprentissage automatique
pour les eaux souterraines

Nicolas Ringuet

Postdoctorant

Laboratoire d'Informatique Fondamentale et Appliquée de Tours (LIFAT)
Université de Tours

Supervision scientifique : Nicolas Labroche (LIFAT)
Collaboration : Hugo Breuillard, Augustin Thomas (BRGM)

Période couverte : 15 septembre 2025 — 30 juin 2026
Travaux de documentation et de passation prolongés jusqu'au 24 août 2026

Résumé exécutif

Ce postdoctorat, mené au LIFAT (Université de Tours) du 15 septembre 2025 au 30 juin 2026 dans le cadre du programme JUNON, portait initialement sur **l’explicabilité des modèles de prévision appliqués aux eaux souterraines**. Il s’est heurté d’emblée à un obstacle qui n’était pas de nature méthodologique : **le terrain expérimental n’existait pas**.

La donnée hydrologique française est ouverte — Hub’Eau expose les chroniques piézométriques et hydrométriques, Copernicus diffuse la réanalyse climatique ERA5-Land, le BRGM publie le référentiel hydrogéologique BDLISA — mais elle est dispersée entre des services hétérogènes, jamais jointe au forçage climatique, dépourvue d’historique consolidé et d’indicateurs normalisés. Expliquer un modèle suppose d’abord qu’un modèle puisse être entraîné, donc qu’un jeu de données existe. Construire ce jeu de données est devenu le premier travail, et une réunion de cadrage entre le BRGM et l’Université de Tours en a explicitement confié le pilotage.

Deux réalisations logicielles en découlent, conçues comme une chaîne unique.

Un entrepôt de données hydro-climatiques (`hubeau_data_integration`) organise l’ingestion automatisée de quatre jeux de données publics — piézométrie et hydrométrie depuis 1967, réanalyse ERA5-Land depuis 1950, référentiel hydrogéologique — selon une architecture médaillon (Bronze, Silver, Gold) sur PostgreSQL, TimescaleDB et PostGIS, orchestrée par Dagster. Les stations sont rattachées à leur maille climatique par jointure spatiale et enrichies du référentiel hydrogéologique. Les tables analytiques finales sont directement interrogeables en SQL, ce qui rend la donnée exploitable par n’importe quel consommateur sans réimplémenter la chaîne d’extraction.

Une plateforme d’expérimentation (`time-serie-explo`) exploite cet entrepôt selon trois usages articulés : un *observatoire* d’exploration spatiale et climatique, un *laboratoire de modélisation métier* fondé sur les modèles à fonction de transfert (Pastas) avec évaluation selon les critères STOWA et scénarios prospectifs de pompage, et un *laboratoire d’apprentissage automatique* donnant accès à une douzaine d’architectures de prévision profonde, avec optimisation d’hyperparamètres et traçabilité des expériences. L’explicabilité y occupe une place structurante et non accessoire : attributions par gradients, valeurs de Shapley adaptées aux séries temporelles, poids d’attention, et surtout des **explications contrefactuelles sous contrainte physique** qui refusent de proposer un scénario alternatif thermodynamiquement incohérent.

Le résultat principal est architectural. La chaîne absorbe environ 658 millions de lignes en couche brute, ne duplique rien lorsqu’on la relance, conserve les lignes écartées au nettoyage avec le motif de leur exclusion, empêche deux traitements de se recouvrir, et reprend après interruption sans perte. Ces propriétés déterminent si un jeu de données peut servir de référence commune à plusieurs équipes, ou seulement à l’expérience qui l’a produit.

Trois résultats méthodologiques sont établis et mesurés.

- **L’évapotranspiration potentielle de référence a dû être recalculée.** La variable d’évaporation potentielle fournie par ERA5-Land ne désigne pas la même grandeur que l’évapotranspiration de référence au sens de la FAO : employée telle quelle, elle produit $1\,756\text{ mm an}^{-1}$ contre 818 mm an^{-1} par la formule de Hargreaves (FAO-56), un facteur 2,15 qui plaçait l’intégralité du territoire en déficit hydrique permanent. Seule la seconde valeur est compatible avec les références publiées pour la France.

- **L'ajustement statistique de l'indice de bilan hydrique standardisé a été corrigé.** La loi log-logistique de la formulation d'origine ne converge que sur 74,6 % du domaine. L'instrumentation des rejets a montré qu'ils proviennent tous d'une asymétrie négative que cette loi ne peut structurellement pas représenter. La logistique généralisée, retenue par l'implémentation de référence du SPEI, atteint 100 % de couverture sans modifier aucune valeur là où la première fonctionnait.
- **Les indices standardisés produits sont conformes à leur définition.** Vérifié sur 41 960 400 valeurs couvrant 11 496 mailles, selon un critère d'acceptation fixé avant la mesure.

Ces travaux répondent à des besoins distincts et convergents : aux hydrogéologues, ils fournissent des indicateurs normalisés et un outil de scénarisation ancré dans leur cadre métier ; aux chercheurs en apprentissage automatique, un jeu de données hydro-climatique consolidé et un banc d'expérimentation instrumenté ; au programme JUNON, une chaîne complète de la source ouverte au service interprétable, qui constitue une brique directement mobilisable pour les jumeaux numériques de la ressource en eau.

Le dernier chapitre argumente en quoi cet ensemble forme un **socle réutilisable** pour les travaux d'explicabilité qui prendront la suite, et à quelles conditions.

Portée et limites de ce rapport

Les expériences d'apprentissage profond sont rapportées au niveau de leurs protocoles, de leurs capacités et de leurs choix de conception. Les jeux de données et les points de sauvegarde de modèles ont été purgés des dépôts lors de la passation ; aucun tableau de performances n'est donc avancé, par choix d'honnêteté plutôt que par reconstitution approximative. Les valeurs chiffrées présentées dans ce rapport sont exclusivement celles mesurées et consignées dans les dépôts au cours des travaux.

Table des matières

Résumé exécutif	2
1 Contexte et positionnement	7
1.1 Le programme JUNON	7
1.2 La mission initiale : l'explicabilité	7
1.3 Le glissement de mission, et pourquoi il était nécessaire	8
1.4 Périmètre du rapport	8
2 Le verrou : une donnée ouverte mais inexploitable	10
2.1 Ce que la donnée ouverte offre réellement	10
2.2 Ce qui manque	10
2.2.1 La jointure au forçage climatique n'existe pas	10
2.2.2 L'historique n'est pas consolidé, et la volumétrie est réelle	11
2.2.3 La donnée brute recèle des pièges qui ne s'annoncent pas	11
2.2.4 Aucun indicateur normalisé n'est fourni	11
2.3 Ce que l'apprentissage automatique exige en plus	11
2.4 Le coût collectif de l'absence d'infrastructure	12
3 Sourcing et entrepôt de données	13
3.1 Le principe retenu : une architecture médaillon	13
3.2 Bronze : ingérer sans interpréter	13
3.3 Silver : nettoyer en rendant compte	14
3.4 Gold : joindre, enrichir, exposer	14
3.5 Orchestration : planifier l'ingestion, déclencher la transformation	15
3.6 Ce que l'architecture garantit, et ce que l'exploitation a enseigné	15
3.6.1 La concurrence, éprouvée par un incident	15
3.6.2 Les défaillances silencieuses	16
3.7 Réalisation	16
4 Des mesures aux indicateurs : construction et validation	18
4.1 Pourquoi standardiser	18
4.2 Les indices par station	18
4.3 Les indices climatiques sur grille	19
4.4 Premier résultat : l'évapotranspiration de référence a dû être recalculée	19
4.5 Deuxième résultat : le choix de la loi statistique du SPEI	20
4.6 Troisième résultat : la validation des indices produits	20
4.7 Deux lectures à ne pas faire	21
4.8 Un contrat entre les deux dépôts	21
5 L'Observatoire : donner à voir	22
5.1 Une contrainte d'architecture posée d'emblée	22
5.2 Le besoin : explorer avant de modéliser	22
5.3 Organisation : deux compartiments	23
5.4 Une règle de conception qui a structuré l'interface	23

5.5	Trois choix techniques	23
5.6	Accès, sécurité et données personnelles	24
5.7	Environnements et déploiement	24
6	Modéliser : le laboratoire de modèles métier	26
6.1	Pourquoi commencer par le modèle métier	26
6.2	Les modèles à fonction de transfert et bruit	26
6.3	Calibration automatique et critères de qualité	26
6.4	L'apport hydrogéologique : des configurations par famille d'aquifère	27
6.5	Diagnostics et validation	28
6.6	Scénarios prospectifs	28
7	Apprendre : le laboratoire d'apprentissage automatique	30
7.1	Le problème posé	30
7.2	Un catalogue d'architectures sous interface unique	30
7.3	Le protocole expérimental	30
7.4	Optimisation d'hyperparamètres	31
7.5	Rendre l'outil utilisable par des non-spécialistes	31
7.6	Ce qui est établi, et ce qui ne l'est pas	31
8	Expliquer : le sujet initial, enfin abordable	33
8.1	Pourquoi l'explicabilité n'est pas une option ici	33
8.2	Sur quoi le modèle s'appuie-t-il : les méthodes d'attribution	33
8.3	Que se passerait-il si : les contrefactuels sous contrainte physique	34
8.3.1	Le problème du contrefactuel naïf	34
8.3.2	La solution retenue : contraindre l'espace de perturbation	34
8.3.3	Une comparaison honnête : la référence non contrainte	35
8.3.4	Une validation par un modèle indépendant	35
8.4	Cette chronique est-elle explicable par le climat ? La détection de prélèvements	35
9	Collaborations et réponses aux besoins	37
9.1	Le cadre de travail	37
9.2	Une réunion de cadrage qui a orienté les travaux	37
9.3	Ce que la collaboration métier a produit	38
9.4	Des besoins distincts, un outil commun	39
9.5	État de mise à disposition	39
10	Un socle pour l'IA en hydrologie	40
10.1	Pourquoi la plupart des développements de recherche ne se réutilisent pas	40
10.2	Les propriétés acquises	40
10.2.1	Un contrat d'interface qui découple l'amont de l'aval	40
10.2.2	Un cœur de calcul indépendant de toute interface	40
10.2.3	Des indicateurs validés une fois pour tous les usages	40
10.2.4	Des contrats exécutables entre composants	40
10.2.5	Une infrastructure reproductible	41
10.2.6	Une documentation écrite pour la reprise	41
10.3	Le patron généralisable	41
10.4	Extensions, par coût croissant	42

10.5 Ce qui est transmis aux travaux à venir	42
10.6 Ce qui manque pour un véritable environnement d'outils	43
10.7 Articulation avec le volet des jumeaux numériques	43
11 Bilan, limites et passation	45
11.1 Récapitulatif des réalisations	45
11.2 Bilan au regard de la mission initiale	45
11.3 Limites assumées	46
11.4 État de passation	46
11.5 Conclusion	47
A Annexes	48
A.1 Inventaire des réalisations logicielles	48
A.2 Sources de données et attributions	48
A.3 Volumétrie des indicateurs climatiques	49
A.4 Glossaire	50
Références	51

1 Contexte et positionnement

Dans quel dispositif de recherche ces travaux s'inscrivent-ils, et quelle mission leur avait été assignée au départ ?

1.1 Le programme JUNON

JUNON est l'un des programmes *Ambition Recherche & Développement* (ARD) financés par la Région Centre-Val de Loire. Coordonné par le BRGM, il mobilise sur cinq ans un budget supérieur à 12,3 M€, dont 6 M€ apportés par la Région, complétés par des financements CPER. Le consortium réunit dix-neuf partenaires et une vingtaine d'équipes de recherche : BRGM, universités d'Orléans et de Tours, CNRS, INRAE, INSA Centre-Val de Loire, le pôle de compétitivité DREAM Eau & Milieux, des collectivités et des entreprises du territoire [6, 7].

L'objectif du programme est de développer des **jumeaux numériques** appliqués aux milieux naturels continentaux — eau, sol, air — et de concevoir les services numériques associés. Un jumeau numérique ne se réduit pas à une visualisation : il vise à reproduire les structures et les processus réels tout au long de leur évolution, en s'appuyant notamment sur des approches d'apprentissage automatique. Cette ambition se décline en projets collaboratifs, dont trois portent sur des compartiments environnementaux — JUNEAU pour la quantité et la qualité des eaux souterraines, PREVIZO pour les eaux de surface, JANUSS pour la qualité de l'air et les zones humides — et trois structurent les moyens transversaux :

- **DATA** — la gestion des observations environnementales, des séries de mesures et des données satellitaires, leur partage et leur réutilisation au sein du programme ;
- **PREDICTION** — la modélisation et la prédiction à partir de ces données, pour représenter des systèmes naturels complexes ;
- **JUMEAUX NUMÉRIQUES** — l'assemblage des données, des modèles et des expertises en prototypes opérationnels.

Le LIFAT participe à ces trois volets transversaux sur la période 2022–2026 [23]. Le volet PREDICTION, sous la responsabilité de Nicolas Labroche, porte les questions de modélisation prédictive des séries temporelles environnementales : comment apprendre le comportement d'un système naturel à partir d'observations éparses, bruitées et déséquilibrées, et comment qualifier la confiance que l'on peut accorder à la prédiction obtenue.

C'est dans ce volet que s'inscrit le présent postdoctorat, mené sous la supervision de Nicolas Labroche du 15 septembre 2025 au 30 juin 2026.

1.2 La mission initiale : l'explicabilité

Le sujet assigné portait sur l'**explicabilité des modèles de prévision appliqués aux nappes d'eau souterraine**. La question est pertinente et bien posée. Un modèle d'apprentissage profond qui prévoit un niveau piézométrique produit un nombre ; ce nombre n'a de valeur opérationnelle que si l'on peut répondre à trois questions que tout hydrogéologue posera : sur quoi le modèle s'appuie-t-il, que se passerait-il dans d'autres conditions, et jusqu'où peut-on lui faire confiance hors du régime observé.

Ces questions ne sont pas académiques. Les niveaux de nappe conditionnent des décisions publiques — arrêtés de restriction d’usage, autorisations de prélèvement, planification de l’alimentation en eau potable. Une prédiction que l’on ne sait pas justifier ne sera pas mobilisée, et ne devrait pas l’être.

1.3 Le glissement de mission, et pourquoi il était nécessaire

L’explicabilité s’applique à un modèle ; un modèle s’entraîne sur des données. Or, au démarrage des travaux, **aucun jeu de données exploitable n’existait** pour les nappes françaises associées à leur forçage climatique. Ce constat, développé au chapitre 2, a déterminé la trajectoire de l’année.

Le travail a donc pris la forme d’une **ingénierie de recherche assumée** : identifier les sources, construire l’entrepôt, produire les indicateurs, vérifier leur validité, puis seulement outiller la modélisation et l’explicabilité. Cette réorientation n’a pas dilué le sujet initial, elle en a conditionné la possibilité — et, en pratique, elle a produit un résultat plus durable qu’une étude d’explicabilité menée sur un jeu de données jetable : **l’infrastructure survit à l’expérience**.

Ce n’est pas non plus une reconstruction a posteriori. La réunion de cadrage du 13 février 2026 entre le BRGM et l’Université de Tours inscrit parmi ses prochaines étapes la « mise en place d’une stack pérenne pour stocker et harmoniser les données communes », et en attribue nommément le pilotage à l’auteur de ce rapport [34].

Le fil conducteur de ce rapport

Ce rapport suit l’ordre dans lequel les obstacles se sont présentés — de la donnée dispersée jusqu’à la prévision explicable — plutôt que l’ordre des dépôts logiciels. Chaque chapitre s’ouvre sur la question à laquelle il répond et se referme sur ce qui est acquis et ce qui demeure ouvert.

1.4 Périmètre du rapport

Deux réalisations logicielles sont couvertes, développées intégralement au cours de la période :

Dépôt	Objet
hubeau_data_integration [35]	Entrepôt de données hydro-climatiques. Ingestion, transformation et exposition des données piézométriques, hydrométriques, climatiques et hydrogéologiques. Premier commit : 23 septembre 2025.
time-serie-explo [36]	Plateforme d’exploration, de modélisation et de prévision. Observatoire spatial, laboratoire de modèles métier, laboratoire d’apprentissage automatique, explicabilité. Premier commit : 6 novembre 2025.

Les deux dépôts totalisent environ 1 400 contributions. Le contrat postdoctoral s’est achevé le 30 juin 2026 ; les travaux de documentation, de neutralisation des éléments sensibles et de passation se sont poursuivis jusqu’au 24 août 2026, afin que les réalisations restent exploitables après le départ de leur auteur.

Acquis — Le positionnement est clair : ces travaux relèvent des volets DATA et PREDICTION du programme, et adressent le compartiment des eaux souterraines.

Ouvert — L’articulation avec le volet JUMEAUX NUMÉRIQUES reste à instruire ; le chapitre 10 propose une trajectoire.



2 Le verrou : une donnée ouverte mais inexploitable

La donnée hydrologique française est publique et accessible. Pourquoi faut-il malgré tout construire une infrastructure avant d'espérer entraîner le moindre modèle ?

2.1 Ce que la donnée ouverte offre réellement

Trois sources publiques couvrent, en principe, l'essentiel du besoin.

Hub'Eau est la plateforme d'accès aux données sur l'eau opérée dans le cadre du système d'information sur l'eau [30]. Elle expose par interfaces web les chroniques *piézométriques* — niveaux de nappe mesurés aux ouvrages de surveillance — et les données *hydrométriques* de débit des cours d'eau, organisées en sites, stations et observations élaborées. Le parc compte 23 333 ouvrages piézométriques et 6 468 stations hydrométriques réparties sur 9 283 sites.

ERA5-Land, produit par le Centre européen pour les prévisions météorologiques à moyen terme et diffusé par le *Climate Data Store* de Copernicus [12], fournit une réanalyse climatique sur grille d'environ 0,1°, continue depuis 1950 [18, 29]. C'est la source de forçage naturelle pour tout modèle hydrologique : précipitations, températures, évaporation.

BDLISA, le référentiel hydrogéologique du BRGM [10], décrit les entités aquifères du territoire — leur nature, leur géométrie, leur organisation. C'est ce qui permet de savoir si un piézomètre observe une nappe alluviale, un aquifère sédimentaire poreux, un système karstique ou un socle fracturé, distinction dont on verra au chapitre 6 qu'elle commande le comportement du signal.

Chacune de ces sources est ouverte, documentée et interrogeable. Le verrou n'est pas l'accessibilité.

Un arbitrage sur la source climatique

Une alternative existait. Le BRGM dispose d'une licence pour la réanalyse SAFRAN [28], mieux adaptée au territoire français qu'ERA5-Land. Elle a été écartée pour une raison qui n'est pas technique : les données SAFRAN ne sont pas redistribuables, ce qui interdisait de les verser dans un entrepôt destiné à être partagé entre équipes et documenté publiquement. ERA5-Land est libre, mondial et versionné. Le choix privilégie la reproductibilité et le partage sur la finesse de la source — arbitrage qu'il faut connaître pour interpréter les résultats.

2.2 Ce qui manque

2.2.1 La jointure au forçage climatique n'existe pas

Un niveau de nappe seul n'est pas modélisable. Il répond à la pluie efficace, c'est-à-dire à la différence entre précipitation et évapotranspiration, avec un retard et un amortissement propres à l'aquifère. Prédire une nappe suppose donc de disposer, *pour chaque station et chaque jour*, du signal climatique correspondant.

Or Hub'Eau ne fournit aucune variable météorologique, et ERA5 ignore l'existence des piézomètres. Rattacher les deux exige une jointure spatiale — associer chaque station à la maille climatique qui la contient ou l'approche le plus — puis une jointure temporelle sur un pas de temps commun. Ce travail n'est fourni par personne.

2.2.2 L'historique n'est pas consolidé, et la volumétrie est réelle

Les interfaces web sont paginées et conçues pour la consultation, non pour la constitution d'un corpus. Récupérer six décennies de chroniques sur l'ensemble du parc de stations, puis sept décennies de réanalyse climatique sur l'ensemble du territoire, représente des dizaines de gigaoctets et plusieurs jours de collecte. Ce n'est pas une opération que l'on relance à chaque expérience.

Le cas d'ERA5 illustre l'écart entre l'accès théorique et le coût pratique. Le produit dérivé de statistiques journalières proposé par le *Climate Data Store* est calculé côté serveur, sur une file d'attente saturée : environ **43 heures par année demandée**, soit près de six semaines pour reconstituer l'historique complet. La même information, recalculée localement à partir de l'archive horaire brute, demande environ **vingt-cinq minutes par année**. L'équivalence des deux voies a été vérifiée maille par maille et jour par jour, à 0,000 0 °C sur les extrêmes journaliers et 0,01 °C sur la moyenne.

2.2.3 La donnée brute recèle des pièges qui ne s'annoncent pas

Un exemple, parce qu'il a effectivement produit un diagnostic erroné avant d'être compris. Dans ERA5, les variables de précipitation et d'évaporation sont des *flux cumulés* : la valeur au pas de 0 h UTC constitue bien le total journalier. La température, elle, est une *grandeur instantanée* : prendre sa valeur à 0 h UTC comme moyenne journalière introduit un biais froid nocturne de l'ordre de 2 à 4 °C. Deux variables issues du même fichier, au même horodatage, dont l'une doit être lue telle quelle et l'autre reconstruite à partir des vingt-quatre pas horaires.

Rien dans la donnée ne signale cette différence. Elle se paie en résultats faux, silencieux et plausibles.

2.2.4 Aucun indicateur normalisé n'est fourni

Un hydrogéologue ne raisonne pas sur un niveau brut en mètres, qui n'a de sens que rapporté à l'historique de l'ouvrage. Il raisonne sur des **indicateurs standardisés** qui situent la mesure du jour par rapport à la distribution de référence du même mois : est-on dans la normale, en situation modérément sèche, en sécheresse sévère ? Ces indicateurs — indices standardisés de niveau, de débit, de précipitation, de bilan hydrique — ne sont fournis par aucune des trois sources. Ils doivent être calculés, ce qui suppose une période de référence, un ajustement statistique et une validation.

2.3 Ce que l'apprentissage automatique exige en plus

Les difficultés précédentes concernent tout usage de la donnée. L'apprentissage automatique en ajoute qui lui sont propres.

- **Une couverture temporelle continue.** Un modèle de séries temporelles supporte mal les lacunes ; encore faut-il savoir où elles sont, ce qui suppose une chronologie régulière et explicite plutôt qu'une liste d'observations.
- **Des covariables alignées.** Le forçage climatique doit être disponible sur exactement la même chronologie que la cible, sans décalage ni trou différentiel.
- **La reproductibilité.** Une expérience qui ne peut être rejouée sur les mêmes données n'est pas un résultat. Cela interdit l'extraction ponctuelle et impose un stockage versionné et interrogeable.
- **Le volume.** Comparer une douzaine d'architectures sur des centaines de stations suppose de lire les données des milliers de fois. Une chaîne d'extraction par interface web rend l'exercice impraticable ; une base de données ne le rend pas seulement possible, elle le rend rapide.

2.4 Le coût collectif de l'absence d'infrastructure

Le constat déterminant n'est pas technique mais organisationnel. En l'absence d'entrepôt, **chaque chercheur refait l'extraction**, avec ses propres conventions de nettoyage, sa propre gestion des lacunes, son propre rattachement climatique. Les résultats deviennent incomparables, non par divergence de méthode, mais par divergence de préparation des données. Le temps consacré à la collecte est prélevé sur le temps de recherche, et il est prélevé autant de fois qu'il y a de chercheurs.

La réunion de cadrage du 13 février 2026 dresse le même constat en termes opérationnels. Elle recense trois jeux de données candidats de provenances distinctes — un ensemble d'environ 220 piézomètres réputés peu influencés par les prélèvements, un ensemble d'environ 170 piézomètres annotés par des experts, et un jeu reconstitué dans le cadre de travaux de thèse — puis conclut à la nécessité de consolider et de qualifier ces jeux, et de centraliser données, modèles, expériences et scripts sur un espace commun [34].

C'est ce coût, réparti et invisible, que l'entrepôt décrit au chapitre 3 supprime.

Acquis — Le verrou est caractérisé : la donnée est ouverte, mais ni jointe, ni consolidée, ni normalisée, ni prête pour l'apprentissage. La question qui organise la suite est donc : *quelle infrastructure faut-il construire pour que la recherche en intelligence artificielle appliquée aux eaux souterraines devienne seulement possible ?*

Ouvert — Le périmètre retenu couvre la quantité (niveaux, débits). La qualité de l'eau, également visée par le programme, n'a pas été traitée.

3 Sourcing et entrepôt de données

Comment transformer quatre jeux de données hétérogènes, volumineux et piégeux en un ensemble interrogeable, reproductible et digne de confiance ?

Ce chapitre porte le résultat principal du travail. Il ne s'agit pas d'un choix d'outils, mais d'un ensemble de propriétés à garantir — celles dont dépend la possibilité même de comparer deux expériences.

3.1 Le principe retenu : une architecture médaille

La donnée traverse trois couches de qualité croissante, matérialisées par trois schémas distincts d'une même base PostgreSQL [32]. Ce patron, dit *médaille* et représenté sur la figure 3.1, répond à une exigence simple : **ne jamais perdre la donnée telle qu'elle a été reçue**, et rendre chaque transformation ultérieure explicite, versionnée et rejouable.




Figure 3.1 – Les trois couches de l'entrepôt. La donnée brute n'est jamais écrasée, et les lignes écartées au nettoyage sont conservées à part avec le motif de leur exclusion : le filtrage se vérifie par une requête au lieu d'être silencieux.

3.2 Bronze : ingérer sans interpréter

Chaque source est ingérée par une bibliothèque d'extraction déclarative [15] qui prend en charge la pagination des interfaces web, les tentatives successives avec temporisation exponentielle sur les erreurs serveur, l'inférence de schéma et la déduplication par fusion sur la clé primaire. Les séries temporelles sont partitionnées par année, ce qui rend chaque tranche rechargeable indépendamment.

Les partitions couvrent 1967 à aujourd’hui pour la piézométrie comme pour l’hydrométrie, la profondeur effectivement disponible variant d’une station à l’autre selon sa date de mise en service.

Le principe de la couche est de **ne rien décider** : les colonnes restent textuelles, les valeurs sont celles reçues. Toute interprétation appartient aux couches suivantes, où elle est lisible et modifiable.

Le cas d’ERA5 fait exception sur un point, imposé par la nature du produit : les fichiers NetCDF ne sont jamais archivés en base. Ils sont téléchargés en stockage temporaire, extraits en mémoire [21] et insérés directement. Deux chemins d’ingestion coexistent — l’un pour les séries issues du pas de 0 h UTC, l’autre pour les statistiques journalières de température agrégées localement sur les vingt-quatre pas horaires — pour la raison exposée au chapitre 2 : flux cumulés et grandeurs instantanées ne se lisent pas de la même manière.

Table 3.1 – Volumétrie de la couche brute, mesurée le 24 août 2026.

Table	Lignes
Statistiques journalières de température ERA5	≈ 320 000 000
Séries temporelles ERA5	≈ 300 000 000
Mesures piézométriques	≈ 23 000 000
Observations hydrométriques élaborées	≈ 15 000 000
Ouvrages piézométriques	23 333
Sites hydrométriques	9 283
Stations hydrométriques	6 468
Entités hydrogéologiques BDLISA	3 716
Total	≈ 658 000 000

3.3 Silver : nettoyer en rendant compte

Chaque modèle de cette couche [14] sélectionne les colonnes utiles, convertit les types, déduplique et écarte les lignes invalides. La caractéristique importante n’est pas le nettoyage lui-même, mais sa **traçabilité** : les lignes écartées ne disparaissent pas, elles sont écrites dans un schéma dédié, accompagnées du motif de leur exclusion — date de mesure absente, code de station manquant, station orpheline de son site.

Cette décision a un coût de stockage négligeable et une valeur méthodologique élevée. Un filtrage silencieux est invérifiable : rien ne distingue une station réellement absente d’une station éliminée par un critère trop strict. Ici, la question se tranche par une requête.

Huit modèles de nettoyage et trois modèles de rejets composent cette couche. Les modèles de séries temporelles sont incrémentaux, avec une fenêtre de recouvrement de sept jours qui absorbe les corrections tardives publiées par les producteurs de données.

3.4 Gold : joindre, enrichir, exposer

C’est dans cette couche que se résout le verrou central identifié au chapitre précédent.

Le rattachement climatique. Chaque station piézométrique ou hydrométrique est associée à sa maille ERA5 la plus proche par une jointure spatiale du plus proche voisin, exécutée par l’extension géospatiale de PostgreSQL [31]. Cette opération, effectuée une fois et matérialisée, transforme deux jeux de données étrangers l’un à l’autre en une chronique unique où le niveau et son forçage climatique figurent sur la même ligne, au même jour.

L'enrichissement hydrogéologique. Les entités du référentiel BDLISA sont rattachées aux stations, ce qui rend disponible la nature de l'aquifère observé — information que le chapitre 6 exploitera pour paramétrer les modèles métier.

Les tables analytiques. La couche expose des faits journaliers (chroniques piézométriques et hydrométriques enrichies du climat), des faits agrégés mensuels et annuels, des dimensions de description (calendrier, géographie, stations) et les grilles climatiques, soit dix-huit modèles de transformation complétés par des tables d'indicateurs calculées en Python. Les faits journaliers sont stockés en *hypertables* compressées [39], forme de partitionnement temporel qui maintient les performances d'interrogation sur plusieurs dizaines de millions de lignes.

L'ensemble est directement interrogeable en SQL. C'est le contrat d'interface : un consommateur n'a besoin de connaître ni la chaîne d'ingestion, ni les outils employés, seulement le schéma des tables finales.

3.5 Orchestration : planifier l'ingestion, déclencher la transformation

L'ingestion est **planifiée** [13] — mise à jour quotidienne des chroniques et du climat, rafraîchissement mensuel du référentiel, contrôle hebdomadaire de complétude, recalcul hebdomadaire des références statistiques. La transformation, elle, est **déclenchée par événement** : dès que de nouvelles données brutes sont disponibles, un capteur lance la chaîne de transformation, laquelle déclenche à son tour le recalcul des indicateurs et les contrôles qualité. L'ensemble compte huit traitements planifiés et trois capteurs.

Ce choix évite le défaut classique des chaînes entièrement planifiées, où la transformation s'exécute à heure fixe sur des données parfois absentes, et produit des résultats partiels sans que rien ne le signale.

Les contrôles qualité ne bloquent pas le rafraîchissement

Les tests de qualité s'exécutent en parallèle du recalcul des indicateurs, et non en amont. Un test en échec fait échouer sa propre exécution — donc alerte — mais n'empêche pas la donnée d'être mise à jour. L'arbitrage est délibéré : sur une chaîne de surveillance, une donnée imparfaite mais fraîche est préférable à une donnée absente, à condition que le défaut soit signalé.

3.6 Ce que l'architecture garantit, et ce que l'exploitation a enseigné

Trois propriétés ont été recherchées et vérifiées : l'**idempotence** — relancer une ingestion sur une période déjà chargée ne duplique rien —, la **reprise** — le chargement initial complet est interruptible et redémarrable, son avancement étant persisté en base — et la **maîtrise de la concurrence**.

Les incidents qui suivent sont rapportés parce qu'ils constituent le contenu concret du travail d'ingénierie : une architecture n'est pas correcte parce qu'elle est bien dessinée, elle le devient une fois ses modes de défaillance rencontrés et traités.

3.6.1 La concurrence, éprouvée par un incident

Les exécutions ne sont pas globalement sérialisées, ce qui serait simple mais inutilement lent ; elles sont contraintes par clés de concurrence, chaque clé plafonnant le nombre d'exécutions simultanées d'une même nature. Une de ces clés est partagée entre la mise à jour nocturne des températures et le rechargement historique. La table concernée ne porte pas de contrainte d'unicité et son

remplacement n'est pas atomique : lorsque la partition de l'année courante recouvrait la fenêtre nocturne, les deux traitements dupliquaient des lignes. L'incident s'est produit le 7 juillet 2026. Le partage de clé rend désormais ce recouvrement impossible, au prix d'un seul créneau d'exécution.

L'idempotence a également été mise en défaut par six modèles dont le prédicat de suppression incrémentale était ancré sur la date courante alors que leur sélection l'était sur le maximum de la table : sur un jeu plus ancien que la fenêtre, la suppression ne trouvait rien et l'insertion répétait des lignes déjà présentes, jusqu'à violation de contrainte d'unicité. Le prédicat, qui n'était qu'une optimisation d'élagage, a été retiré plutôt que réparé.

3.6.2 Les défaillances silencieuses

Trois situations produisent des résultats faux sans émettre la moindre erreur. Elles sont documentées dans le dépôt parce qu'elles sont invisibles à l'exécution et coûteuses à diagnostiquer.

- **Une colonne entièrement nulle.** Si les séries climatiques sont chargées avant les statistiques journalières de température pour la même période, la garde incrémentale du modèle intermédiaire ne trouve aucune ligne nouvelle, la jointure externe rend des valeurs nulles, et la température est absente de toutes les lignes. Aucun test n'échoue. Mesuré le 24 août 2026 : 0 % de lignes renseignées en température, contre 95,4 % après reconstruction complète du modèle intermédiaire.
- **Un rechargement historique qui n'atteint pas la couche intermédiaire.** Le modèle de nettoyage des températures fonctionne par ajout avec un filtre sur son propre maximum. Le traitement nocturne ayant déjà renseigné l'année courante, toute ligne rétrospective est silencieusement ignorée.
- **Un modèle incrémental qui ne produit rien.** Sur un jeu de données arrêté dans le passé, la fenêtre de recalcul glissante ne couvre aucune donnée. L'exécution est déclarée réussie et la table ne grandit pas.

Ce qu'il faut retenir de ces incidents

Une chaîne de données correcte en régime nominal peut être fausse en régime de recouvrement ou de rattrapage. Les garanties d'unicité doivent être portées par le schéma quand c'est possible, et par l'orchestration quand ce ne l'est pas — jamais par l'hypothèse implicite que deux traitements ne se croiseront pas. Surtout, une vérification qui ne peut pas échouer ne vérifie rien : les trois cas ci-dessus passent tous les tests existants.

3.7 Réalisation

Élément	État
Sources ingérées	Piézométrie et hydrométrie (partitions depuis 1967), ERA5-Land (1950→), référentiel BDLISA
Couche Silver	8 modèles de nettoyage, 3 modèles de rejets tracés
Couche Gold	18 modèles de transformation, complétés par des tables d'indicateurs calculées en Python
Orchestration	8 traitements planifiés, 3 capteurs événementiels
Infrastructure	7 services conteneurisés, séparation du code métier et de l'orchestrateur
Volume de code	≈ 7 000 lignes Python, ≈ 1 200 lignes SQL de transformation

Acquis — Une chaîne complète, automatisée, idempotente, documentée et éprouvée par l'exploitation, dont les tables finales sont consommables en SQL sans connaissance de l'amont. Le coût d'entrée à l'expérimentation passe de plusieurs semaines à une requête.

Ouvert — L'entrepôt couvre la quantité d'eau ; l'extension à la qualité supposerait de nouvelles sources et de nouveaux modèles, sans remettre en cause l'architecture. La restauration a été validée à l'échelle réelle, mais la supervision de production reste à instrumenter au-delà des contrôles existants.

4 Des mesures aux indicateurs : construction et validation

Une mesure brute ne dit rien de la situation qu'elle décrit. Comment produire des indicateurs normalisés, comparables entre stations et entre années, et comment établir qu'ils sont justes ?

4.1 Pourquoi standardiser

Un niveau piézométrique de 12,4 m n'est ni haut ni bas dans l'absolu : il l'est relativement à ce que l'ouvrage observe habituellement à cette période de l'année. La même remarque vaut pour un cumul de pluie ou une température. L'usage opérationnel — décider s'il faut restreindre les prélèvements, comparer deux bassins, situer un épisode dans l'histoire climatique — suppose donc de rapporter chaque mesure à sa **distribution de référence**.

C'est l'objet des indices standardisés. Leur principe est constant : ajuster une loi de probabilité sur la série de référence, puis transformer la valeur observée en un score exprimé en écarts-types d'une loi normale centrée réduite. Un score de -2 signifie alors la même chose partout : une situation dont la rareté correspond au seuil de sécheresse sévère.

Deux familles ont été produites : les indices *par station*, calculés sur les niveaux de nappe et les débits, et les indices *sur grille*, calculés sur les variables climatiques pour chaque maille du territoire.

4.2 Les indices par station

L'indicateur piézométrique standardisé et son équivalent pour les débits situent le mois courant par rapport à sa normale saisonnière. La méthode est centralisée dans un unique module, et l'application ne la recalcule pas : elle lit les tables produites par l'entrepôt.

Étape	Détail
Référence	Fenêtre fixe 1991–2020, normale climatique retenue par l'Organisation météorologique mondiale et par le BRGM. Ce n'est pas une fenêtre glissante.
Grille	Par mois calendaire, percentiles empiriques de 1 à 99 sur la fenêtre. Un mois comptant moins de dix observations est interpolé depuis son voisin circulaire.
Score	Rang percentile dans la grille, borné à $[0,001 ; 0,999]$, puis projeté sur la loi normale par sa fonction quantile.
Classes	Sept classes délimitées par les seuils $z \in \{-1,75 ; -1,28 ; -0,84 ; 0,84 ; 1,28 ; 1,75\}$.

Deux décisions de conception méritent d'être signalées.

Une référence qui se dégrade explicitement. Toutes les stations ne disposent pas de trente années d'historique. Plutôt que d'écarter les stations courtes ou de leur appliquer silencieusement une référence plus faible, la sélection de fenêtre se dégrade par paliers déclarés : la normale 1991–2020 si au moins quinze années sont disponibles, sinon la meilleure fenêtre trentenaire alignée sur les décennies, sinon l'historique complet. Le palier retenu est inscrit dans une colonne accompagnant chaque valeur, de sorte qu'un utilisateur sait toujours sur quelle base une station est classée.

Une grille n’est jamais fabriquée. Si aucun mois n’est exploitable, la grille reste nulle et l’indice prend la valeur *inconnu*. Produire une classe plutôt qu’un aveu d’ignorance reviendrait à inventer une information que l’utilisateur lirait comme une mesure.

La table de référence est recalculée *hebdomadairement*, et non chaque nuit ni une fois par décennie : la fenêtre est fixe, mais les grilles par station ne le sont pas — une station accumule de l’historique, de nouvelles stations apparaissent, et une station classée en référence provisoire peut franchir le seuil des quinze années.

4.3 Les indices climatiques sur grille

Trois indices sont calculés pour chaque maille de $0,1^\circ$, sur quatre fenêtres d’agrégation de 1, 3, 6 et 12 mois correspondant à des inerties différentes du système hydrologique. Tous emploient la période de référence 1991–2020 et l’échelle à sept classes de McKee [26], adoptée par l’Organisation météorologique mondiale.

Indice	Grandeur	Ajustement
SPI	Précipitation	Loi gamma, mélangée à la probabilité de cumul nul
STI	Température	Loi normale (score centré réduit)
SPEI	Précipitation moins évapotranspiration	Loi logistique généralisée

4.4 Premier résultat : l’évapotranspiration de référence a dû être recalculée

Le calcul du SPEI suppose un bilan hydrique, donc une évapotranspiration. ERA5-Land fournit directement une variable d’évaporation potentielle : l’employer semblait naturel, et c’est ce qui a été fait initialement.

Le résultat était aberrant. Comparé sur 30 888 couples maille-mois entre 2015 et 2025, sur les mêmes mailles :

	Hargreaves (FAO-56)	Évaporation potentielle ERA5-Land	Rapport
Évapotranspiration annuelle	818 mm	1 756 mm	$\times 2,15$
Bilan précipitation – ETP	146 mm an^{-1}	-793 mm an^{-1}	—

La seconde colonne place **l’intégralité du territoire français en déficit hydrique permanent**, y compris les années humides — ce qui est physiquement faux. La valeur de 818 mm an^{-1} se situe dans l’intervalle des références publiées pour la France (700 à 900 mm an^{-1}) ; celle de $1 756 \text{ mm an}^{-1}$ n’y est pas.

L’explication tient à la définition des grandeurs, et c’est le point à retenir : les deux portent des noms voisins et ne décrivent pas la même chose. L’évaporation potentielle d’ERA5 n’est pas une évapotranspiration de référence au sens de la FAO — c’est l’évaporation d’une surface non contrainte en eau, calculée avec la résistance aérodynamique du modèle atmosphérique, dont la littérature documente la surestimation substantielle. La formule de Hargreaves [17] est précisément le repli recommandé par la FAO-56 [2] lorsque le rayonnement, le vent et l’humidité ne sont pas disponibles ; elle ne requiert que les températures extrêmes journalières et le rayonnement

extraterrestre, dérivable analytiquement de la latitude et du jour de l'année. Elle est implémentée directement en SQL, avec le calcul complet du rayonnement extraterrestre.

Décision

L'évapotranspiration de référence est recalculée par la formule de Hargreaves à partir des températures journalières vraies. La variable ERA5 d'origine reste exposée pour la traçabilité, avec une consigne explicite de non-consommation.

4.5 Deuxième résultat : le choix de la loi statistique du SPEI

La formulation de référence du SPEI [40] ajuste une loi log-logistique à trois paramètres. Appliquée à la grille française, elle ne converge que sur 74,6 % des triplets maille $\times$ mois $\times$ fenêtre. Un quart du domaine restait sans valeur, ce qui est inacceptable pour une couche cartographique nationale.

Plutôt que de constater le taux d'échec, les rejets ont été instrumentés pour en identifier la cause. Le résultat est net : **la totalité des rejets** provient de la garde sur le paramètre de forme, et **aucun** d'une insuffisance de données.

L'explication tient en trois phrases. L'ajustement passe par la méthode des L-moments [20], qui résume la distribution par un coefficient d'asymétrie noté τ_3 . La loi log-logistique exige une asymétrie positive. Or environ 27 % des mailles présentent une asymétrie négative — une distribution du bilan hydrique dont la queue s'étend vers les valeurs basses — et aucune taille d'échantillon ne corrige cela : la loi ne peut structurellement pas représenter cette forme.

La logistique généralisée lève la limite : son paramètre de forme vaut $k = -\tau_3$ et accepte donc les deux signes. C'est également la loi retenue par l'implémentation de référence du SPEI [4]. La couverture atteint 100 %.

Un changement additif, non destructif

La log-logistique est exactement la logistique généralisée reparamétrée. Le remplacement laisse donc les valeurs inchangées partout où la loi d'origine convergait — vérifié à un écart maximal de 0,000 sur 35 614 mailles — et ne fait qu'ajouter les valeurs manquantes.

4.6 Troisième résultat : la validation des indices produits

Un indice standardisé doit, par construction, suivre approximativement une loi normale centrée réduite *sur sa propre période de référence*. C'est une propriété vérifiable, et elle a été vérifiée.

Protocole. Le critère d'acceptation a été fixé **avant** la mesure : moyenne voisine de zéro à $\pm 0,05$, écart-type voisin de un à $\pm 0,05$, et taux de saturation aux bornes inférieur à 1 %. Fixer le critère avant de mesurer évite l'ajustement rétrospectif du seuil au résultat obtenu.

Mesure. Effectuée sur 41 960 400 valeurs couvrant 11 496 mailles.

Indice	Fenêtres	Moyenne	Écart-type	Médiane	Saturation
SPI	1/3/6/12	-0,008 à +0,002	0,985 à 1,031	0,00 à 0,04	0,05 à 0,51 %
STI	1/3/6/12	0,000	0,983	-0,09 à -0,02	0,00 à 0,04 %
SPEI	1/3/6/12	+0,004 à +0,006	0,999 à 1,013	0,01 à 0,03	0,012 à 0,035 %

Conclusion

Les trois indices satisfont le critère d'acceptation sur les quatre fenêtres. La couverture du SPEI est uniforme à 100 %, ce qui signifie que la calibration n'est pas seulement préservée mais mesurée sur l'ensemble du domaine.

4.7 Deux lectures à ne pas faire

La validation ci-dessus autorise l'usage des indices ; elle n'autorise pas toutes les interprétations. Deux mises en garde ont été consignées, parce que l'erreur correspondante est naturelle.

La classe « normale » ne couvre pas la proportion théorique. Elle représente 54,8 % des valeurs au lieu des 59,9 % attendus d'une gaussienne, alors même que l'écart-type vaut 1,008. La distribution conserve des épaules légèrement plus lourdes. Cet écart est une propriété de la transformation au voisinage des bornes de classe. Il n'a pas de conséquence opérationnelle — les seuils employés sont ceux, communs, des autres indices — et il ne doit surtout **pas** être lu comme une anomalie de sécheresse.

Une décroissance décennale est un signal climatique, non une dérive de méthode. La moyenne du SPEI sur fenêtre d'un mois décroît de manière monotone d'une décennie à l'autre : +0,038 dans les années 1990, +0,007 dans les années 2000, -0,016 dans les années 2010, -0,117 depuis 2020. Cette évolution avait été anticipée avant d'être mesurée, ce qui la distingue d'un artefact d'ajustement : elle traduit un assèchement, non un biais.

4.8 Un contrat entre les deux dépôts

La classification en sept classes existe en deux endroits : dans l'entrepôt, qui produit les indicateurs, et dans la plateforme, qui les affiche et les compare aux prévisions. Cette duplication est délibérée — elle évite un couplage fort entre deux systèmes déployés séparément — mais elle crée un risque de divergence silencieuse.

Le risque est traité par un **contrat testé** : chaque dépôt possède une table de référence associant des valeurs d'entrée aux classes attendues, et ces deux tables sont identiques par construction. Toute modification de l'une sans l'autre fait échouer une suite de tests. Le mécanisme est simple, et c'est sa vertu : il rend la contrainte exécutable plutôt que documentaire.

Acquis — Une famille d'indicateurs normalisés, produite à l'échelle nationale, validée selon un protocole à critère pré-établi, et dont deux décisions méthodologiques structurantes sont documentées avec leurs mesures. Ces indicateurs sont directement utilisables par les hydrogéologues et constituent des variables candidates pour la modélisation.

Ouvert — Une incohérence connue subsiste entre la chaîne « grille » et la chaîne « station » sur l'évapotranspiration : la seconde expose encore la variable d'origine, car elle constitue l'entrée de forçage des modèles métier déjà calibrés et sa modification les invaliderait. Cet arbitrage est explicite et documenté ; sa résolution suppose une recalibration d'ensemble.

5 L'Observatoire : donner à voir

Un entrepôt ne se consulte pas. Comment rendre la donnée consolidée immédiatement lisible par ceux qui en ont l'usage, sans enfermer les méthodes développées dans l'application qui les héberge ?

5.1 Une contrainte d'architecture posée d'emblée

La plateforme comporte trois couches : une interface web [27], un service applicatif [33], et une bibliothèque métier en Python. La contrainte structurante porte sur la troisième : **la bibliothèque métier ne comporte aucune dépendance à l'interface**.

Cette règle a une conséquence pratique déterminante pour un travail de recherche. Le code de préparation des données, de calibration des modèles métier, d'entraînement, d'explicabilité et de génération de contrefactuels s'exécute indifféremment depuis le service web, depuis un script ou depuis un carnet de calcul. Les méthodes développées ne sont donc pas prisonnières de l'application : si l'interface était abandonnée, elles resteraient utilisables.




Figure 5.1 – Architecture de la plateforme. La bibliothèque métier est appellable depuis le service web, un script ou un carnet de calcul, sans modification. C'est cette propriété qui rend les développements réutilisables au-delà de l'application.

5.2 Le besoin : explorer avant de modéliser

Un entrepôt bien construit reste inerte tant qu'il n'est pas regardé. Deux publics le demandaient, pour des raisons différentes.

Les **hydrogéologues** ont besoin de situer une station dans son contexte : quelle nappe observe-t-elle, comment se comporte-t-elle par rapport à ses voisines, où en est-elle dans son historique, et que faisait le climat pendant ce temps. Ce travail de mise en regard, fait manuellement, mobilise plusieurs sources et plusieurs outils.

Les **modélisateurs** ont besoin de choisir leurs cas d'étude en connaissance de cause : une station dont la chronique est trop courte, trop lacunaire ou visiblement perturbée par un pompage ne fera

pas un bon cas d'apprentissage. Repérer ces situations avant d'entraîner un modèle évite d'attribuer à la méthode ce qui relève de la donnée.

L'Observatoire répond aux deux.

5.3 Organisation : deux compartiments

L'interface s'organise en deux volets correspondant aux deux compartiments du cycle observé.

Nappes et rivières. Exploration spatiale des stations piézométriques et hydrométriques sur fond cartographique, avec superposition des entités aquifères du référentiel BDLISA et d'un découpage en secteurs hydrogéologiques. Les indicateurs de situation y sont portés directement par les stations, ce qui donne une lecture immédiate de l'état du territoire. La comparaison entre stations est possible, avec conservation de la sélection d'une vue à l'autre.

Climat. Exploration de la grille nationale de 0,1° selon trois vues : une vue de situation cartographique à l'échelle du pays, une vue par point ou par zone donnant l'historique d'une maille depuis 1950 — pluie comparée à la normale, indices sur plusieurs fenêtres, table des épisodes de sécheresse, export tabulaire — et une vue de comparaison inter-annuelle.

Les deux volets communiquent : depuis la carte des nappes, un lien contextuel ouvre le climat de la maille correspondante ; depuis la fiche d'une station, on accède à son contexte climatique local.

5.4 Une règle de conception qui a structuré l'interface

Les couches cartographiques disponibles obéissent à une règle explicite, adoptée après discussion et maintenue depuis :

La règle

Soit un indicateur réellement standardisé, soit une valeur réelle affichée comme telle — jamais un intermédiaire inventé.

Concrètement, les indices standardisés (précipitation, température, bilan hydrique) sont cartographiés sur l'échelle à sept classes, et les grandeurs journalières brutes (températures extrêmes, pluie du jour) le sont sur une échelle absolue. En revanche, les cumuls mensuels absolus de pluie, de température ou d'évapotranspiration ne sont **pas** proposés comme couches cartographiques : ils apparaissent comme chiffres exacts dans le panneau de détail d'une maille.

La raison est méthodologique. Cartographier une grandeur absolue sur une palette de couleurs suppose un seuillage, donc une norme implicite — et cette norme, n'étant pas une référence statistique établie, serait une invention de l'outil. L'utilisateur lirait une carte de sécheresse là où il n'y a qu'un choix de bornes. Refuser cette couche coûte une fonctionnalité apparente et évite une erreur d'interprétation systématique.

5.5 Trois choix techniques

L'Observatoire ne recalcule rien. Ses points d'accès sont des lectures directes des tables analytiques de l'entrepôt. Aucune statistique n'est calculée à la volée. La conséquence est double : les temps de réponse sont ceux d'une base de données correctement indexée, et surtout **la valeur affichée est exactement celle qui a été validée** au chapitre 4 — il n'existe pas de second calcul susceptible de diverger.

Les réponses sont mises en cache. Les vues cartographiques nationales portent sur des volumes importants et changent peu ; leur mise en cache pour vingt-quatre heures réduit la charge sans affecter la fraîcheur perçue. Cette optimisation a un corollaire opérationnel documenté : tout déploiement qui modifie la forme ou la valeur des réponses doit purger le cache, sous peine de servir des valeurs périmées pendant une journée.

Le point d'entrée est unique. Le service qui sert l'interface assure également le relais vers l'API, les en-têtes de sécurité et la limitation de débit. Une architecture antérieure comportait un second relais, redondant, qui n'était jamais démarré en production — de sorte que les protections qu'il portait n'étaient, en pratique, jamais appliquées. Sa suppression au profit d'une configuration unique a supprimé cet écart entre l'intention et le déploiement réel.

Une leçon d'architecture

Une protection configurée dans un composant qui ne tourne pas est une protection absente, avec en plus la croyance qu'elle existe. La consolidation en un point d'entrée unique vaut moins pour sa simplicité que pour la disparition de cet écart.

5.6 Accès, sécurité et données personnelles

La plateforme héberge des comptes nominatifs et les travaux de leurs titulaires, ce qui impose des exigences distinctes de celles de l'entrepôt.

L'accès est provisionné par un administrateur : il n'existe ni inscription libre ni authentification déléguée. Les mots de passe sont hachés par un algorithme à coût mémoire paramétrable et ne sont détenus en clair par personne, administrateur compris. La session repose sur un jeton en cookie non accessible au script, révocable côté serveur par désactivation du compte ou incrément d'un compteur de version relu à chaque requête. Deux rôles existent, l'administration et l'usage courant, ce dernier ne donnant accès qu'aux objets dont l'utilisateur est propriétaire.

Un garde-fou mérite mention : la suppression du dernier administrateur actif est refusée. En l'absence d'inscription libre, elle rendrait l'application définitivement inaccessible par l'interface. La contrainte est portée par le code plutôt que par une consigne.

Enfin, les journaux d'authentification sont conservés trois cent soixante-cinq jours puis supprimés automatiquement, et l'utilisateur peut effacer son compte et les données associées depuis son espace personnel.

5.7 Environnements et déploiement

Deux environnements complètement séparés coexistent sur le serveur de calcul, l'un suivant la branche principale, l'autre la branche de développement, avec des volumes, des bases, des ports et des artefacts distincts. Un modèle entraîné ou un compte créé dans l'un n'affecte jamais l'autre. Cette séparation est ce qui autorise à expérimenter sur une chaîne en évolution sans compromettre l'instance servant aux utilisateurs.

La production est répartie : l'interface est déployée sur l'infrastructure mutualisée de l'établissement, le calcul et les bases restent sur le serveur équipé d'un processeur graphique. Une seule exigence réseau conditionne l'ensemble, l'ouverture de la route entre les deux.

Acquis — Une interface d'exploration opérationnelle couvrant les nappes, les rivières et le climat, alimentée directement par les indicateurs validés, gouvernée par une règle d'affichage qui protège l'utilisateur des lectures abusives, et bâtie sur un cœur métier indépendant de l'interface.

Ouvert — L'Observatoire dépend entièrement de l'entrepôt et ne se dégrade pas gracieusement en son absence : il répond en erreur plutôt que d'afficher un état partiel. Ce comportement est assumé pour un outil scientifique, mais serait à revoir pour une diffusion large.

6 Modéliser : le laboratoire de modèles métier

Avant d'invoquer l'apprentissage profond, que sait déjà faire la modélisation hydrogéologique établie, et comment l'outiller pour qu'elle serve de référence ?

6.1 Pourquoi commencer par le modèle métier

Il aurait été possible d'aller directement à l'apprentissage profond. Ce choix aurait été méthodologiquement fautif, pour trois raisons.

D'abord, **sans référence, une performance ne signifie rien**. Annoncer qu'un réseau de neurones prévoit un niveau de nappe avec une certaine erreur n'a de sens que comparé à ce qu'obtient la méthode que les hydrogéologues emploient déjà. Une architecture profonde qui n'égale pas un modèle à quelques paramètres ne mérite pas d'être déployée.

Ensuite, **le modèle métier est interprétable par construction**, et fournit donc un point d'ancrage à tout le travail d'explicabilité qui suivra. On sait ce qu'il représente ; on peut confronter les explications produites sur un modèle appris à ce que le modèle physique affirme.

Enfin, **c'est le langage des interlocuteurs**. Le BRGM développe et emploie sa propre famille de modèles à réservoirs — GARDÉNIA [9] pour la simulation des niveaux et des débits d'un bassin, EROS [8] pour les relations entre bassins — fédérés par une interface Python commune. Un outil qui ignorerait cette pratique ne serait pas adopté, quelles que soient ses performances.

6.2 Les modèles à fonction de transfert et bruit

L'approche retenue est celle des modèles *transfer function-noise*, mise en œuvre par la bibliothèque Pastas [11]. Son principe : le niveau piézométrique simulé est la somme des contributions de plusieurs facteurs de forçage — au minimum la recharge, dérivée de la précipitation et de l'évapotranspiration — chaque contribution étant obtenue par convolution du forçage avec une *fonction de réponse impulsionnelle* dont la forme et les paramètres sont calibrés. Un modèle de bruit rend compte de la structure résiduelle.

L'intérêt pour la question posée est direct : la fonction de réponse **est** l'objet d'intérêt hydrogéologique. Sa forme dit comment l'aquifère amortit et retarde le signal climatique ; son intégrale dit de combien le niveau varie pour une sollicitation donnée. Ce ne sont pas des paramètres opaques, ce sont des grandeurs qui s'interprètent.

La plateforme donne accès à quatre modèles de recharge, six formes de réponse impulsionnelle, deux modèles de bruit et deux solveurs, combinables librement.

6.3 Calibration automatique et critères de qualité

Choisir la bonne combinaison relève de l'expertise et de l'essai. Pour rendre cet essai systématique, un mécanisme de **calibration automatique** construit une grille de configurations candidates, calibre chacune, l'évalue et les classe.

L'évaluation ne repose pas sur un unique indicateur d'erreur, mais sur les quatre critères d'acceptation STOWA [37], standard néerlandais d'évaluation des modèles TFN pour la gestion des eaux souterraines :

1. **La variance expliquée** dépasse un seuil (70 % par défaut) ;
2. **les résidus sont aléatoires**, vérifié par un test de séquences ;

3. **le temps de réponse** à 95 % de la réponse indicielle reste inférieur à la moitié de la période de calibration — un modèle dont la mémoire excède ses données n'est pas identifiable ;
4. **le gain est statistiquement significatif**, son rapport à son erreur type dépassant le seuil usuel.

Le troisième critère mérite d'être souligné, car il capture une erreur fréquente et discrète : un modèle peut afficher une excellente variance expliquée tout en ayant ajusté une dynamique lente que la période d'observation ne permet pas de contraindre. Le critère l'écarte.

6.4 L'apport hydrogéologique : des configurations par famille d'aquifère

La grille de calibration automatique n'explore pas l'espace des configurations à l'aveugle. Elle est amorcée par des **configurations recommandées selon la nature de l'aquifère observé**, lue dans le référentiel BDLISA rattaché à la station par l'entrepôt (chapitre 3).

Cette table est le produit direct des échanges avec l'expertise hydrogéologique du BRGM. Elle traduit en choix de modélisation ce qu'un spécialiste sait du comportement de chaque milieu.

Famille	Réponse	Bruit	Justification hydrogéologique
Alluvial	Exponentielle	AR	Réponse rapide, temps de réponse court, système simple
Sédimentaire poreux	Gamma	AR	Réponse intermédiaire
Sédimentaire, double porosité (craie)	Gamma	AR	Forte inertie, temps de réponse long
Sédimentaire fracturé	Gamma	AR	Recharge complexe, modèle de recharge flexible
Karstique	Double exponentielle	ARMA	Deux temps de réponse : conduits et matrice
Socle, montagne	Gamma	AR	Fracturé, recharge non linéaire
Volcanique	Gamma	AR	Système hétérogène
Composite	Quatre paramètres	ARMA	Milieu hétérogène, modèle flexible

Le cas karstique est le plus parlant. Un système karstique se comporte comme deux réservoirs couplés : des conduits qui réagissent en quelques heures et une matrice qui réagit en mois. Une réponse impulsionnelle à un seul temps caractéristique ne peut pas représenter cette dualité — d'où la double exponentielle, et un modèle de bruit plus riche pour absorber ce que la structure ne capte pas.

Cette table recoupe la typologie discutée lors de la réunion de cadrage avec les hydrogéologues, qui distinguait les nappes inertielles à cycles longs, les nappes réactives à effets de seuil et les nappes influencées par une rivière ou des prélèvements [34].

Ce que cette table représente réellement

Elle est le point de contact entre deux disciplines : elle encode une connaissance qui ne s'obtient pas par validation croisée, et la rend disponible à un utilisateur qui ne la possède pas. C'est une forme concrète de transfert d'expertise, et elle réduit le coût d'entrée à la modélisation pour un non-spécialiste.

Ces configurations amorcent la recherche ; elles ne la contraignent pas. Une grille de référence est systématiquement évaluée en parallèle, de sorte qu'une station atypique n'est jamais enfermée dans la recommandation de sa famille.

6.5 Diagnostics et validation

La calibration est accompagnée d'un dispositif de vérification qui va au-delà de l'ajustement.

Séparation calibration/validation. Le modèle est calibré sur une période et évalué sur une période distincte, avec les indicateurs usuels en hydrologie — efficacité de Nash-Sutcliffe, critère de Kling-Gupta, erreur quadratique moyenne — complétés par l'examen de l'autocorrélation et de la normalité des résidus.

Diagnostics préalables. Avant même la calibration, la chronique est examinée : qualité et continuité des entrées, valeurs aberrantes, corrélations croisées avec le forçage, décomposition du signal, analyse spectrale, analyse des tarissements. Ce faisceau permet de détecter en amont les situations où la modélisation est vouée à l'échec, plutôt que de le découvrir dans un mauvais ajustement.

Analyse multi-stations. Les résidus peuvent être examinés conjointement sur plusieurs stations, ce qui fait apparaître les structures communes — donc d'origine régionale ou climatique — et les distingue des particularités locales.

6.6 Scénarios prospectifs

Le modèle calibré n'est pas seulement descriptif : il permet de répondre à des questions de la forme « *que se passerait-il si* », qui sont précisément celles des gestionnaires.

Trois familles de scénarios sont outillées : l'**ajout d'un prélèvement** selon des profils réalistes par type d'usage — alimentation en eau potable, irrigation, industrie — chacun ayant sa saisonnalité propre ; l'**application d'une tendance climatique** ; et la **modulation de l'intensité** d'un forçage existant.

Un mécanisme mérite d'être détaillé : les **bornes adaptatives**. Lorsqu'un utilisateur simule un prélèvement, la question « quel débit est plausible ici ? » n'a pas de réponse universelle — elle dépend de la transmissivité de l'aquifère, donc de la réponse calibrée. Le rabattement attendu est estimé à partir de la réponse indiciaire du modèle lui-même, et des bornes physiquement plausibles en sont dérivées pour guider la saisie. L'utilisateur n'est pas laissé libre de simuler un pompage qui viderait la nappe en un mois, ni contraint par une borne arbitraire identique partout.

Acquis — Un laboratoire de modélisation métier complet : calibration automatisée guidée par l'expertise hydrogéologique, évaluation selon un standard reconnu, diagnostics préalables et postérieurs, scénarisation prospective bornée par la physique du système. Il constitue la référence à laquelle comparer toute approche apprise.

Ouvert — La comparaison systématique modèle métier / modèle appris, sur un large échantillon de stations, reste à conduire : l'outillage des deux côtés est en place, la campagne d'évaluation ne l'est pas. Un rapprochement avec les modèles à réservoirs du BRGM constitue une seconde voie de comparaison, identifiée mais non explorée.

7 Apprendre : le laboratoire d'apprentissage automatique

Quel dispositif faut-il pour que des expériences d'apprentissage profond sur des séries hydrologiques soient comparables, reproductibles, et conduites par des chercheurs qui ne sont pas tous spécialistes de l'apprentissage ?

7.1 Le problème posé

Prévoir un niveau de nappe est un problème de série temporelle multivariée avec covariables exogènes : la cible est le niveau, les entrées sont la précipitation, la température et l'évapotranspiration. Les difficultés propres au domaine sont connues — inertie très variable d'un aquifère à l'autre, non-stationnarité liée aux prélèvements, lacunes d'observation, événements extrêmes rares donc sous-représentés dans l'apprentissage.

La littérature propose de nombreuses architectures ; aucune ne s'impose a priori. La question pratique n'est donc pas « quel modèle choisir » mais « comment mettre en place un dispositif qui permette de trancher, et de rejouer la comparaison quand les données changent ».

7.2 Un catalogue d'architectures sous interface unique

La plateforme donne accès à une douzaine d'architectures de prévision profonde issues de la bibliothèque Darts [19], couvrant les grandes familles de l'état de l'art :

- **à mécanisme d'attention** — *temporal fusion transformer* [24], transformeur classique ;
- **à décomposition par blocs** — N-BEATS, N-HiTS ;
- **récurrentes** — LSTM, GRU, réseaux récurrents par blocs ;
- **convolutives** — réseaux convolutifs temporels ;
- **récentes à faible coût** — TiDE, TSMixer, DLinear, NLinear.

L'inclusion des dernières est délibérée : les modèles linéaires ou quasi linéaires constituent des références exigeantes sur les séries temporelles, et une architecture lourde qui ne les dépasse pas doit être écartée. Disposer de la référence faible dans le même outil que le modèle sophistiqué évite la comparaison biaisée par des conditions expérimentales différentes.

Une fabrique de modèles instancie dynamiquement l'architecture demandée en validant ses hyperparamètres, ce qui permet d'ajouter une architecture sans modifier l'interface ni l'API.

7.3 Le protocole expérimental

Le dispositif vise trois propriétés, dans cet ordre de priorité.

La traçabilité. Chaque exécution d'entraînement est enregistrée dans un registre d'expériences [43] : paramètres, métriques, artefacts, modèle produit. Les jeux de données préparés et les modèles entraînés font l'objet de registres distincts, de sorte qu'un résultat puisse être rattaché sans ambiguïté au couple exact qui l'a produit. Sans ce mécanisme, une comparaison entre deux expériences menées à quelques semaines d'intervalle n'est pas défendable.

La séparation entre l'entraînement et l'interface. Le code d'entraînement n'a aucune connaissance de l'interface qui l'observe : il écrit son avancement dans un fichier d'état, que la couche de présentation lit indépendamment et retransmet au navigateur par un flux d'événements. Cette séparation, visible sur la figure 5.1, a une conséquence pratique importante : **le même code d'entraînement s'exécute depuis l'application, depuis un script ou depuis un carnet de calcul**, sans modification.

La conduite d'expériences longues. L'entraînement s'effectue sur processeur graphique lorsque disponible [16], avec arrêt anticipé et suivi de l'évolution des pertes en apprentissage et en validation. L'utilisateur voit progresser son entraînement au lieu d'attendre un résultat opaque, et peut l'interrompre s'il diverge.

7.4 Optimisation d'hyperparamètres

La comparaison d'architectures n'a de sens que si chacune est évaluée dans une configuration raisonnable ; comparer un modèle réglé à un modèle laissé aux valeurs par défaut ne renseigne que sur le réglage. Une recherche automatisée d'hyperparamètres [1] est donc intégrée, avec élagage des essais non prometteurs pour concentrer le budget de calcul sur les configurations viables.

7.5 Rendre l'outil utilisable par des non-spécialistes

Un dispositif d'expérimentation complet est, par nature, exigeant : longueur de fenêtre d'entrée, taille de lot, nombre d'époques, patience d'arrêt anticipé. Ces réglages sont un obstacle réel pour un hydrogéologue qui souhaite simplement obtenir une prévision.

Des **configurations prêtes à l'emploi** ont donc été définies par cas d'usage métier plutôt que par architecture : prévision piézométrique à court terme (sept jours), à moyen terme (trente jours), à long terme (quatre-vingt-dix jours), et prévision de débit à quatorze jours. Chacune fixe une architecture et un jeu d'hyperparamètres cohérents, choisis à partir des recommandations de la bibliothèque et des références publiées sur séries piézométriques.

Une distinction assumée

Ces configurations sont des *points de départ raisonnables*, non des réglages optimisés pour une station donnée. La documentation le dit explicitement, et oriente vers la recherche automatisée d'hyperparamètres pour aller plus loin. Il aurait été facile — et trompeur — de les présenter comme optimales.

7.6 Ce qui est établi, et ce qui ne l'est pas

Il importe d'être précis sur le statut de ce chapitre.

Ce qui est acquis est le dispositif : un banc d'expérimentation instrumenté, traçable, qui rend les comparaisons possibles et rejouables, accessible à des utilisateurs de niveaux d'expertise différents, et dont le cœur est réutilisable hors de l'application.

Ce qui n'est pas établi dans ce rapport est le classement des architectures sur le cas hydrogéologique. Les campagnes d'entraînement conduites au cours des travaux ont servi à valider le dispositif et à orienter les développements ; les jeux de données préparés et les points de sauvegarde ont été purgés des dépôts lors de la passation. Reconstituer a posteriori un tableau de performances à partir de souvenirs ne serait pas un résultat scientifique. La campagne d'évaluation comparative — modèles appris contre modèles métier du chapitre 6, sur un échantillon représentatif de stations

et de familles d'aquifères — reste donc à conduire, et l'outillage nécessaire est en place pour la mener.

Une limite d'ingénierie à corriger

La suite de tests de la plateforme compte 552 tests, dont 547 passent (mesuré le 24 août 2026). Aucun ne s'exécute automatiquement : le dépôt est hébergé sur une forge dont la chaîne d'intégration continue ne comporte qu'une étape de construction d'image, tandis que la définition de tests existante cible une autre forge. Parmi les quatre échecs, deux exigent un entrepôt peuplé et relèvent en réalité de l'intégration, un lit un fichier absent de tout autre poste, et le dernier est mis en défaut par la base en mémoire employée pour les tests, qui ne conserve pas le fuseau horaire. Aucun ne signale un défaut applicatif, mais la purge des journaux se trouve de fait non testée. C'est le premier correctif à apporter par toute personne reprenant ces travaux.

Acquis — Un laboratoire d'expérimentation opérationnel, traçable et accessible, dont le cœur de calcul est indépendant de l'interface et donc réutilisable.

Ouvert — L'évaluation comparative systématique, et l'automatisation de la suite de tests.

8 Expliquer : le sujet initial, enfin abordable

Une prévision de niveau de nappe n'est mobilisable que si l'on peut dire sur quoi elle repose et ce qu'elle deviendrait dans d'autres conditions. Comment produire de telles explications sans qu'elles soient elles-mêmes trompeuses ?

8.1 Pourquoi l'explicabilité n'est pas une option ici

Le sujet initial du postdoctorat retrouve ici sa place, une fois construit le terrain qui le rendait abordable.

L'exigence d'explication ne relève pas, dans ce domaine, d'une préférence méthodologique. Les niveaux de nappe conditionnent des décisions administratives contraignantes : restrictions d'usage, autorisations de prélèvement, dimensionnement d'ouvrages d'alimentation. Une décision publique doit pouvoir être motivée. Un modèle dont on ne sait pas dire pourquoi il annonce une baisse ne sera pas — et ne devrait pas être — invoqué à l'appui d'un arrêté.

S'y ajoute une condition d'adoption. L'interlocuteur d'un modèle de nappe est un hydrogéologue qui possède une compréhension physique du système. Il n'accordera sa confiance qu'à un modèle dont les explications sont compatibles avec ce qu'il sait — et, réciproquement, une explication qui contredit sa compréhension est une information précieuse : soit le modèle a capté quelque chose, soit il s'est trompé, et dans les deux cas il faut le savoir.

Trois questions organisent le dispositif : *sur quoi le modèle s'appuie-t-il ?*, *que se passerait-il dans d'autres conditions ?*, et *cette chronique est-elle seulement explicable par le climat ?*

8.2 Sur quoi le modèle s'appuie-t-il : les méthodes d'attribution

Le premier volet mobilise et adapte les familles usuelles d'attribution, chacune répondant à une facette différente de la question.

Famille	Ce qu'elle apporte
Importance par perturbation	Mesure la dégradation de la prévision quand une entrée est brouillée : lecture directe, sans hypothèse sur le modèle
Valeurs de Shapley [25]	Répartition de la contribution entre entrées sur des bases axiomatiques, avec une variante adaptée aux séries temporelles qui attribue aussi dans le temps [5]
Attributions par gradients [38, 22]	Saillance temporelle et gradients intégrés : quels pas de temps de la fenêtre d'entrée pèsent sur la sortie
Poids d'attention	Pour les architectures qui en possèdent, lecture directe de ce que le modèle regarde
Décomposition du signal	Sépare tendance, saisonnalité et résidu, et rapporte la prévision à ces composantes

L'intérêt de disposer de plusieurs familles dans un même outil n'est pas l'exhaustivité mais la **confrontation** : des méthodes qui reposent sur des principes différents et convergent donnent une explication crédible ; des méthodes qui divergent signalent que l'explication est fragile, ce qui est en soi une information utile — et qu'une méthode unique aurait masquée.

8.3 Que se passerait-il si : les contrefactuels sous contrainte physique

C'est l'apport le plus original de ces travaux, et il répond à un problème formulé avec les hydrogéologues avant d'être traité.

8.3.1 Le problème du contrefactuel naïf

Une explication contrefactuelle [41] répond à : *quelle modification minimale des entrées changerait la prévision de telle manière ?* Appliquée à une nappe : quel régime climatique aurait évité l'étiage annoncé ?

Les approches existantes pour les séries temporelles [3, 42] optimisent directement la perturbation des entrées sous contrainte de proximité. Sur des données climatiques, elles produisent des réponses correctes au sens de l'optimisation et **physiquement absurdes** : elles peuvent augmenter la température sans modifier l'évapotranspiration, faire varier la pluie d'un jour à l'autre de manière incohérente, ou construire un régime saisonnier qui n'existe nulle part. Une telle explication est inutilisable : on ne peut pas dire à un gestionnaire que l'étiage aurait été évité dans un climat qui ne peut pas exister.

La réunion de cadrage de février 2026 énonce ce constat dans les termes du métier. Elle relève que les métriques standard — validité, proximité, compacité — ne captent pas la physique, que le risque est de « générer des scénarios mathématiquement valides mais physiquement absurdes », et elle propose deux critères spécifiques : la plausibilité du bilan de masse et la cohérence temporelle avec les échelles de réponse des aquifères [34].

8.3.2 La solution retenue : contraindre l'espace de perturbation

L'approche développée renonce à perturber librement les entrées. Elle optimise à la place un petit nombre de paramètres interprétables, dont chacun a un sens physique et une plage de validité :

Paramètre	Plage	Neutre	Interprétation
Facteur de pluie (par saison, 4)	0,3 à 2,0	1,0	Régime pluviométrique saisonnier, de -70% à $\times 2$
Décalage de température	-5 à 5°C	0	Réchauffement ou refroidissement global
Résidu d'évapotranspiration	$-0,03$ à $0,03$	0	Écart fractionnaire résiduel
Décalage temporel	-30 à 30 d	0	Avance ou retard de la saison

Surtout, ces paramètres ne sont pas indépendants. L'évapotranspiration est **couplée à la température** par la relation de Clausius-Clapeyron, au taux d'environ 7% par degré qui gouverne la capacité de l'air à contenir de la vapeur d'eau. Élever la température dans le scénario contrefactuel élève donc mécaniquement la demande évaporative : le scénario reste thermodynamiquement cohérent *par construction*, non par pénalisation après coup. C'est la traduction du premier critère demandé, la plausibilité du bilan de masse ; la structure saisonnière des facteurs de pluie et le décalage temporel traduisent le second.

L'ensemble reste différentiable, donc optimisable par descente de gradient à travers le modèle de prévision, quel que soit ce modèle — une couche d'adaptation permet d'appliquer la méthode aux architectures du catalogue du chapitre 7. Une variante par optimisation bayésienne est également disponible pour les cas où le gradient n'est pas exploitable.

8.3.3 Une comparaison honnête : la référence non contrainte

Contraindre l'espace de recherche améliore l'interprétabilité ; encore faut-il montrer que cela ne se paie pas d'une perte de qualité rédhibitoire. Une méthode de référence inspirée des contrefactuels pour séries temporelles multivariées [3] a donc été implémentée pour la comparaison : elle optimise directement la perturbation brute, avec contraintes souples, sans couplage physique — soit un nombre de paramètres libres égal à trois fois la longueur de la fenêtre, contre sept pour l'approche contrainte.

Ce que cette comparaison met à l'épreuve

Avec deux à trois ordres de grandeur de paramètres libres en plus, la référence non contrainte atteindra presque toujours la cible plus facilement. La question n'est donc pas laquelle des deux optimise mieux — c'est réglé d'avance — mais si **davantage de degrés de liberté produit une meilleure explication**. C'est précisément ce que le dispositif permet de discuter, plutôt que de le supposer.

8.3.4 Une validation par un modèle indépendant

Un contrefactuel produit par optimisation à travers un modèle appris peut n'être valide que pour ce modèle : il exploiterait alors une particularité de l'approximation plutôt qu'une propriété du système. Pour écarter cette possibilité, le scénario contrefactuel est rejoué dans un modèle métier calibré indépendamment — le modèle à fonction de transfert du chapitre 6 — et l'on vérifie que l'effet annoncé s'y retrouve.

Cette validation croisée n'était possible que parce que les deux familles de modèles cohabitent dans le même outil, sur les mêmes données. C'est un bénéfice direct de l'architecture retenue, et une raison supplémentaire d'avoir commencé par le modèle métier.

8.4 Cette chronique est-elle explicable par le climat ? La détection de prélèvements

La troisième question renverse la perspective. Une chronique piézométrique qu'aucun modèle climatique ne parvient à reproduire n'est pas nécessairement le signe d'un mauvais modèle : elle peut porter la trace d'une **influence anthropique** — un pompage — que le forçage climatique ne contient pas.

L'enjeu est double, et il a été formulé comme tel lors du cadrage. Il s'agit d'abord d'écarter les stations impropres à l'apprentissage, préoccupation qui rejoint directement la constitution d'un jeu de piézomètres peu influencés. Il s'agit ensuite de produire une information utile en elle-même : l'annotation automatique des piézomètres selon leur caractère inertiel, réactif ou influencé figure parmi les cas d'usage identifiés avec le BRGM.

Le problème est difficile car **non supervisé** : on ne dispose pas d'un historique étiqueté des prélèvements. La démarche retenue croise trois regards indépendants — l'analyse des résidus d'un modèle métier calibré, une détection de ruptures et une analyse d'écart par apprentissage, une lecture par représentation apprise —, puis fusionne leurs verdicts. La couche d'explicabilité y joue un rôle inhabituel : elle ne sert pas à justifier une prédiction mais à détecter une **dérive dans les attributions**, un changement de ce sur quoi le modèle s'appuie, qui signale que le régime du système a changé.

Le résultat est confronté, quand elle existe, à l'information publique sur les ouvrages de prélèvement déclarés.

Acquis — Un dispositif d’explicabilité complet et confrontable, articulant attribution, contrefactuels et détection d’influence. La contribution originale porte sur les **contrefactuels sous contrainte physique** : en réduisant l’espace de perturbation à sept paramètres interprétables couplés par une relation thermodynamique, la méthode ne produit que des scénarios formulables dans le langage du domaine — « un hiver 20 % plus sec et 1 °C plus chaud » — au lieu de perturbations sans signification physique. Elle met en œuvre les deux critères demandés par les hydrogéologues, sa validité est éprouvée par un modèle indépendant et sa qualité mise en regard d’une référence non contrainte.

Ouvert — L’évaluation quantitative comparée des deux approches contrefactuelles, sur un échantillon large et selon des métriques de qualité d’explication établies, reste à conduire. C’est la suite naturelle et immédiate de ces travaux, et probablement leur débouché publiable.

9 Collaborations et réponses aux besoins

À quels besoins, exprimés par qui, ces développements répondent-ils effectivement ?

9.1 Le cadre de travail

Les développements présentés dans ce rapport ont été conçus et réalisés dans leur intégralité au cours du postdoctorat, dans un dialogue continu avec trois interlocuteurs aux apports distincts.

Supervision scientifique — Nicolas Labroche (LIFAT). Responsable du volet PREDICTION du programme, il a encadré l'orientation scientifique des travaux, en particulier l'arbitrage initial : accepter que le sujet d'explicabilité impose d'abord la construction de son terrain expérimental, plutôt que de le traiter sur un jeu de données de circonstance. Cet arbitrage détermine tout ce qui précède.

Collaboration technique — Hugo Breuillard (BRGM). Data scientist en charge du projet côté BRGM, il constitue le point de contact sur les questions de chaîne de données et de stratégie de prévision. Les échanges ont porté sur l'articulation entre l'entrepôt développé ici et les besoins de modélisation du programme, et sur la cohérence des indicateurs produits avec ceux employés par ailleurs.

Expertise métier — Augustin Thomas (BRGM). Hydrogéologue, il a été l'interlocuteur sur l'ensemble des questions de domaine. C'est de ces échanges que procèdent les décisions qui ancrent la plateforme dans la pratique hydrogéologique plutôt que dans une transposition générique de méthodes d'apprentissage.

9.2 Une réunion de cadrage qui a orienté les travaux

La rencontre du 13 février 2026 entre le BRGM et l'Université de Tours mérite d'être décrite, car elle a produit des effets identifiables dans le code [34].

Sa préparation consistait à formuler, à l'intention des hydrogéologues, les questions dont la réponse conditionnait les choix techniques : existe-t-il une typologie des nappes déjà employée, quels cas résistent aux modèles physiques, quels facteurs déterminent le paramétrage d'un modèle de prévision, l'explicabilité statistique suffit-elle ou faut-il des garanties physiques explicites, et qu'est-ce qu'une variation de niveau physiquement impossible.

Quatre orientations en sont issues.

Orientation	Traduction dans les développements
Typologie des nappes	La distinction entre nappes inertielles, réactives et influencées structure les configurations par famille d'aquifère du chapitre 6
Garanties physiques dans l'explication	Les critères de plausibilité du bilan de masse et de cohérence temporelle sont mis en œuvre par la méthode contrefactuelle de la section 8.3
Annotation des piézomètres	Le pipeline de détection d'influence anthropique du chapitre 8 répond au besoin d'identifier les ouvrages influencés
Consolidation des données	La mise en place de l'entrepôt, dont la réunion attribue le pilotage à l'auteur, répond au besoin d'un espace commun de données harmonisées

Cette réunion recense également les jeux de données existants et leurs limites : un ensemble d'environ 220 piézomètres réputés peu influencés dont la qualification restait à établir, un ensemble d'environ 170 piézomètres annotés par des experts et jugé représentatif de la métropole, et un jeu reconstitué dans le cadre de travaux de thèse. Le besoin exprimé était de les consolider et de les qualifier, ce que l'entrepôt rend possible en fournissant une base commune sur laquelle chacun peut être resitué.

9.3 Ce que la collaboration métier a produit

L'apport d'expertise n'est pas resté au stade de la discussion : il est inscrit dans le code, et identifiable. Quatre exemples le montrent.

Les configurations de modélisation par famille d'aquifère. La table présentée au chapitre 6 associe à chaque nature de milieu une combinaison de fonction de réponse et de modèle de bruit. Cette connaissance ne s'obtient pas par validation croisée : elle procède de la compréhension du comportement hydrodynamique de chaque milieu. Le cas karstique, traité par une double exponentielle pour représenter les deux temps de réponse des conduits et de la matrice, en est l'illustration la plus nette.

L'adoption d'un standard d'évaluation reconnu. Le choix d'évaluer les modèles selon les quatre critères STOWA plutôt que par un indicateur d'erreur unique relève du même registre. Il introduit notamment le critère de temps de réponse rapporté à la période de calibration, qui écarte des modèles apparemment excellents mais non identifiables — subtilité que la seule pratique de l'apprentissage automatique ne fait pas apparaître.

La règle d'affichage cartographique. La règle énoncée au chapitre 5 — un indicateur réellement standardisé ou une valeur réelle, jamais un intermédiaire — procède d'une préoccupation d'interprétation propre au domaine. Un outil qui colorie une carte de France selon des seuils choisis par son auteur fabrique une norme que l'utilisateur lira comme une référence établie.

L'arbitrage sur l'évapotranspiration. La décision documentée en section 4.4 est exemplaire du bénéfice de la confrontation disciplinaire. La variable fournie par la réanalyse était disponible, correctement nommée et directement utilisable ; seule la confrontation de ses valeurs aux ordres

de grandeur connus pour la France a révélé qu'elle ne désignait pas la grandeur attendue. Aucune vérification interne au code ne pouvait détecter cette erreur, car il ne s'agissait pas d'une erreur de calcul.

9.4 Des besoins distincts, un outil commun

Les deux communautés visées n'attendent pas la même chose, et l'architecture a dû accommoder les deux sans se scinder.

	Hydrogéologues du BRGM	Chercheurs en apprentissage
Question posée	Où en est la ressource, et que se passe-t-il si l'on prélève ?	Quelle méthode prédit le mieux, et pourquoi ?
Attente principale	Des indicateurs conformes aux pratiques, une scénarisation crédible	Un jeu de données consolidé, un protocole reproductible
Obstacle levé	L'agrégation manuelle de sources hétérogènes	Le coût d'entrée à l'expérimentation
Ce qui a été livré	Observatoire, indicateurs validés, laboratoire de modèles métier, scénarios bornés	Entrepôt interrogeable, catalogue d'architectures, traçabilité des expériences, outillage d'explicabilité

Le point de rencontre est l'entrepôt. Parce que les indicateurs métier et les jeux d'apprentissage sont produits par la même chaîne et validés une seule fois, une comparaison entre un modèle appris et un modèle métier porte réellement sur les modèles, et non sur des préparations de données divergentes. Cette propriété, invisible dans l'interface, est ce qui rend la plateforme utilisable comme instrument de recherche et non seulement comme outil de consultation.

9.5 État de mise à disposition

La plateforme est déployée — l'interface sur l'infrastructure mutualisée de l'établissement, le calcul et les bases sur un serveur équipé d'un processeur graphique — et son usage demeure à ce jour circonscrit au cercle du projet. L'accès est nominatif : il n'existe ni inscription libre ni authentification déléguée, les comptes étant créés par un administrateur. Ce choix, adapté à un outil scientifique manipulant une chaîne de traitement en évolution, constitue le principal frein à une diffusion plus large — et le premier levier à actionner pour l'obtenir.

Acquis — Une collaboration qui a effectivement transformé les développements : les décisions métier structurantes sont inscrites dans le code et documentées, et les deux communautés disposent d'un socle commun de données.

Ouvert — Plusieurs pistes identifiées lors du cadrage n'ont pas été explorées, notamment le rapprochement avec les modèles à réservoirs du BRGM et l'accès à leurs travaux de comparaison de modèles. L'élargissement des usages au-delà du cercle projet suppose une politique d'accès et un accompagnement, davantage que des développements supplémentaires.

10 Un socle pour l'IA en hydrologie

Ces développements survivront-ils au projet qui les a financés, et à quelles conditions peuvent-ils fonder un environnement d'outils plus vaste ?

10.1 Pourquoi la plupart des développements de recherche ne se réutilisent pas

La question mérite d'être posée franchement, parce que la réponse par défaut est négative. Un logiciel de recherche est ordinairement écrit pour produire un résultat, puis abandonné : il suppose un environnement particulier, mêle le traitement et son affichage, dépend de fichiers qui ne sont plus là, et sa reprise coûte plus cher que sa réécriture.

Affirmer qu'un développement constitue un « socle » n'a donc de valeur que si l'on peut désigner les propriétés qui le rendent réutilisable et montrer qu'elles sont effectivement acquises. C'est l'objet de ce chapitre.

10.2 Les propriétés acquises

10.2.1 Un contrat d'interface qui découple l'amont de l'aval

La couche analytique de l'entrepôt est consommée en SQL. Cette interface est stable, universelle et documentée : un utilisateur n'a besoin de connaître ni les outils d'ingestion, ni les bibliothèques de transformation, ni l'orchestrateur. Un carnet de calcul, un tableur connecté, un outil de visualisation décisionnelle ou une application tierce s'y branchent également.

La conséquence est structurante : **l'amont peut être remplacé sans que l'aval s'en aperçoive**. Si un outil d'ingestion devient obsolète, il est substituable sans que les consommateurs soient affectés. Peu de logiciels de recherche offrent cette propriété, et c'est elle qui distingue une infrastructure d'un script.

10.2.2 Un cœur de calcul indépendant de toute interface

Le cœur métier de la plateforme — préparation des données, modèles métier, entraînement, explicabilité, contrefactuels — ne comporte aucune dépendance à l'interface graphique. Le même code est appelé depuis l'API web, depuis un script ou depuis un carnet de calcul.

Cette contrainte, tenue depuis l'origine et vérifiée, a un effet direct sur la valeur résiduelle des travaux : **même si l'application web était abandonnée, les méthodes resteraient utilisables**. La contribution scientifique n'est pas prisonnière de son emballage.

10.2.3 Des indicateurs validés une fois pour tous les usages

Les indicateurs du chapitre 4 sont calculés dans l'entrepôt, validés selon un protocole documenté, et lus tels quels par tous les consommateurs. Il n'existe pas de second calcul susceptible de diverger.

Cette centralisation vaut au-delà de la performance. Elle garantit que deux études conduites à deux dates différentes, ou par deux équipes, parlent de la même chose. C'est une condition de comparabilité que l'on ne peut pas rattraper après coup.

10.2.4 Des contrats exécutables entre composants

Là où une duplication était nécessaire — la classification en classes de sévérité, présente dans les deux dépôts —, elle est gardée par des tables de référence identiques et des tests qui échouent en

cas de divergence. La contrainte n'est pas documentaire mais exécutable : elle résiste à l'oubli, ce qu'aucune note ne fait.

10.2.5 Une infrastructure reproductible

L'ensemble est conteneurisé, les volumes de données sont déclarés en dehors du cycle de vie des conteneurs — une commande d'arrêt ne peut pas les détruire —, et le chargement initial complet est interruptible et redémarrable, son avancement étant persisté en base. Les procédures de sauvegarde et de restauration ont été vérifiées à l'échelle réelle. Une réinstallation complète est une procédure documentée, éprouvée, et non une reconstitution.

10.2.6 Une documentation écrite pour la reprise

La documentation des deux dépôts a été refondue en fin de période dans une perspective explicite de passation : cartographie des documents, procédures vérifiées par exécution réelle, et consignation des pièges rencontrés — y compris ceux qui produisent des résultats faux sans émettre d'erreur. Ce dernier point est le plus utile à un successeur, et le plus rarement écrit.

10.3 Le patron généralisable

Au-delà des deux dépôts, ces travauxinstancient un enchaînement (figure 10.1) qui n'a rien de spécifique aux eaux souterraines.




Figure 10.1 – L'enchaînement mis en œuvre. Chaque étape suppose la précédente ; escamoter l'une d'elles produit des résultats incomparables ou inutilisables.

L'enseignement principal de l'année tient dans la lecture de gauche à droite de cette figure : **on ne peut pas commencer par la droite**. C'est pourtant ce que fait le plus grand nombre de projets d'intelligence artificielle appliquée à l'environnement, qui investissent dans le modèle et découvrent ensuite que la donnée ne permet pas de conclure.

10.4 Extensions, par coût croissant

Extension	Ce qu'elle suppose	Coût
Nouvelles stations, autre territoire	Rien : la couverture est déjà nationale et la chaîne est paramétrée par configuration	nul
Nouveaux indicateurs standardisés	Un ajustement statistique et sa validation, selon le protocole existant	faible
Nouvelles architectures de prévision	Une entrée au catalogue ; la fabrique de modèles et la traçabilité sont génériques	faible
Qualité des eaux souterraines	De nouvelles sources et de nouveaux modèles de transformation ; l'architecture est inchangée	moyen
Eaux de surface	La chaîne hydrométrique existe déjà ; l'extension porte sur la modélisation	moyen
Autre compartiment (air, sol)	Les sources et les indicateurs diffèrent, le patron tient	moyen
Couplage à un modèle hydrogéologique distribué	Une interface avec un simulateur physique externe et l'assimilation de ses sorties	élevé

Le tableau appelle une lecture précise : ce qui est peu coûteux l'est *parce que* l'infrastructure existe. Le coût élevé de l'année écoulée a été payé une fois ; il ne se représente pas à chaque extension. C'est la définition même d'un socle.

10.5 Ce qui est transmis aux travaux à venir

Les travaux d'explicabilité se poursuivront au-delà de cette période. Le tableau suivant confronte ce qu'ils supposent à ce qui leur est effectivement transmis.

Besoin	Disponible
Un jeu de données consolidé, joint au forçage climatique	Entrepôt national, partitions depuis 1967 pour les stations et 1950 pour le climat, rattachement spatial matérialisé
Des modèles à expliquer	Douze architectures de prévision profonde sous interface unique, avec traçabilité des expériences
Une référence interprétable à laquelle confronter les explications	Modèles à fonction de transfert calibrés, dont les paramètres ont un sens hydrogéologique
Des méthodes d'attribution	Cinq familles complémentaires, confrontables entre elles
Des explications actionnables	Contrefactuels sous contrainte physique, mettant en œuvre les critères formulés par les hydrogéologues
Un moyen de valider une explication	Rejeu du scénario dans un modèle métier indépendant
Des cas d'étude qualifiés	Détection non supervisée d'influence anthropique, permettant d'écarter les chroniques impropres

Ce qui n'est pas transmis doit être dit avec la même netteté : aucun résultat de performance comparée, aucune évaluation quantitative des méthodes contrefactuelles, et aucune campagne d'expériences consolidée. Le socle rend ces travaux possibles ; il ne les a pas menés.

10.6 Ce qui manque pour un véritable environnement d'outils

L'honnêteté commande de distinguer ce qui est acquis de ce qui reste à faire. Cinq chantiers séparent l'état actuel d'un environnement d'outils partagé. Aucun n'est un verrou de recherche ; tous sont des décisions d'investissement.

1. **L'automatisation des vérifications.** La suite de tests de la plateforme n'est pas exécutée automatiquement (chapitre 7). Tant que les vérifications dépendent d'une initiative humaine, la confiance dans les évolutions décroît avec le temps. C'est le chantier le moins coûteux et le plus rentable.
2. **Un accès élargi et gouverné.** L'accès nominatif convient à un outil de projet, non à un environnement partagé. Une politique d'accès — qui, pour quels usages, avec quelle responsabilité sur les données — conditionne tout élargissement.
3. **Un catalogue de données.** L'entrepôt est documenté pour qui sait où chercher. Un environnement d'outils suppose un catalogue décrivant les jeux disponibles, leur origine, leur fraîcheur et leurs conditions d'usage.
4. **Le calcul mutualisé.** L'entraînement s'appuie aujourd'hui sur un serveur unique. Un usage partagé suppose une file d'attente et un partage de ressources.
5. **La campagne d'évaluation comparative.** Le socle sera d'autant plus crédible qu'il aura servi à établir un résultat : la comparaison systématique modèles métier / modèles appris, et l'évaluation des méthodes contrefactuelles. L'outillage est prêt de part et d'autre.

10.7 Articulation avec le volet des jumeaux numériques

Un jumeau numérique de la ressource en eau suppose trois choses : une représentation de l'état courant du système, une capacité à le projeter, et une capacité à expliquer la projection. Les travaux présentés apportent une contribution à chacune.

Fonction attendue	Contribution disponible
État courant du système	Entrepôt actualisé quotidiennement, indicateurs standardisés validés, observatoire spatial
Projection	Modèles métier calibrés avec scénarisation bornée physiquement, catalogue de modèles appris
Explication de la projection	Attribution multi-méthodes, contrefactuels sous contrainte physique, détection d'influence anthropique
Confiance	Protocole de validation documenté, traçabilité des expériences, limites consignées

La contribution la plus spécifique est la troisième ligne. Un jumeau numérique qui projette sans expliquer n'est qu'un simulateur ; ce qui en fait un instrument de décision est la capacité à répondre « pourquoi » et « que se passerait-il si » dans les termes du métier. Les contrefactuels sous contrainte physique décrits en section 8.3 sont directement conçus pour cet usage : ils produisent des scénarios

énonçables — « un hiver plus sec et plus chaud d'un degré » — plutôt que des perturbations numériques.

Acquis — Les propriétés qui distinguent une infrastructure d'un prototype sont identifiées et effectivement tenues : interface stable, cœur indépendant, indicateurs centralisés, contrats exécutables, reproductibilité, documentation de reprise. Le patron mis en œuvre est transposable à d'autres compartiments environnementaux.

Ouvert — Cinq chantiers séparent ce socle d'un environnement d'outils partagé, et la démonstration par un résultat scientifique reste à produire.

11 Bilan, limites et passation

Que reste-t-il, une fois le contrat achevé, et dans quel état ?

11.1 Récapitulatif des réalisations

Domaine	Réalisation
Données	Chaîne d'ingestion automatisée de quatre jeux de données issus de trois fournisseurs publics ; entrepôt en architecture médaillon sur base relationnelle avec extensions temporelle et géospatiale ; rattachement spatial des stations à leur maille climatique ; enrichissement par le référentiel hydrogéologique ; environ 658 millions de lignes en couche brute
Fiabilité	Idempotence des traitements, traçabilité des lignes écartées, contraintes de concurrence par clés, reprise après interruption, sauvegarde et restauration vérifiées à l'échelle réelle
Indicateurs	Indices standardisés de niveau, de débit, de précipitation, de température et de bilan hydrique ; production à l'échelle nationale sur quatre fenêtres ; protocole de validation à critère pré-établi ; deux décisions méthodologiques établies par la mesure
Exploration	Observatoire spatial des nappes et des rivières ; module climatique national avec historique depuis 1950, épisodes de sécheresse et export
Modélisation métier	Laboratoire de modèles à fonction de transfert ; calibration automatique guidée par la nature de l'aquifère ; évaluation selon quatre critères normalisés ; diagnostics préalables et postérieurs ; scénarios prospectifs à bornes physiquement dérivées
Apprentissage	Catalogue d'une douzaine d'architectures de prévision profonde ; optimisation d'hyperparamètres ; traçabilité des expériences ; suivi d'entraînement en temps réel ; configurations prêtes à l'emploi par cas d'usage métier
Explicabilité	Attribution multi-méthodes ; contrefactuels sous contrainte physique avec couplage thermodynamique et validation par modèle indépendant ; détection non supervisée d'influence anthropique
Ingénierie	Deux dépôts conteneurisés, reproductibles et documentés pour la reprise ; environ 1 400 contributions ; environnements de développement et de production séparés

11.2 Bilan au regard de la mission initiale

La mission portait sur l'explicabilité des modèles de prévision appliqués aux eaux souterraines. Elle a été remplie, mais par un chemin plus long que prévu.

Ce qui a été atteint : un dispositif d'explicabilité complet et opérationnel, dont la contribution la plus originale — les contrefactuels sous contrainte physique — répond précisément à la difficulté qui rend l'explicabilité délicate dans ce domaine, à savoir qu'une explication physiquement incohérente n'est pas une explication.

Ce qui a été ajouté par nécessité : l'ensemble de l'infrastructure amont, sans laquelle le sujet initial n'aurait pu être traité que sur un jeu de données de circonstance, aux conclusions non généralisables.

Ce qui n'a pas été atteint : l'évaluation quantitative comparée des méthodes, faute de temps une fois l'infrastructure construite. C'est le regret principal de la période, et c'est aussi le travail le plus immédiatement accessible à qui reprendra ces développements — parce que tout ce qu'il suppose existe désormais.

Un arbitrage à assumer

Consacrer l'essentiel d'un postdoctorat à construire l'infrastructure d'un sujet plutôt qu'à publier sur ce sujet est un arbitrage défavorable à court terme et favorable à long terme. Le jeu de données, les indicateurs validés et les outils demeurent ; ils rendent possibles des travaux qui ne l'étaient pas. La question posée en introduction du chapitre 2 — *quelle infrastructure faut-il pour que la recherche en IA sur les eaux souterraines soit possible ?* — a reçu une réponse construite plutôt qu'argumentée.

11.3 Limites assumées

Elles sont énumérées ici sans atténuation, parce qu'un successeur doit les connaître et qu'un rapport qui n'en comporterait aucune ne serait pas crédible.

1. **Aucun résultat de performance comparée n'est établi.** Les campagnes d'entraînement ont validé le dispositif, non classé les méthodes. Les jeux préparés et les points de sauvegarde ont été purgés lors de la passation.
2. **Une incohérence connue subsiste sur l'évapotranspiration** entre la chaîne « grille » et la chaîne « station ». La seconde conserve la variable d'origine parce qu'elle constitue l'entrée de forçage des modèles métier déjà calibrés, et que sa modification les invaliderait. L'arbitrage est explicite, documenté, et sa résolution suppose une recalibration d'ensemble.
3. **Les tests ne sont pas exécutés automatiquement** sur la plateforme, la chaîne d'intégration de la forge hébergeante ne comportant qu'une étape de construction. Quatre des 552 tests échouent, pour des raisons documentées et sans rapport avec un défaut applicatif, mais la purge des journaux se trouve de fait non testée.
4. **Certaines températures agrégées au niveau des stations** sont des extrêmes de moyennes journalières et non de véritables extrêmes journaliers ; l'exposition de ces derniers supposerait de modifier une table partitionnée.
5. **La source climatique retenue est un compromis.** ERA5-Land a été préféré à une réanalyse plus fine mais non redistribuable, au bénéfice de la reproductibilité et du partage.
6. **L'usage reste circonscrit au cercle du projet**, faute d'une politique d'accès élargie.
7. **Le périmètre couvre la quantité, non la qualité** des eaux, également visée par le programme.

11.4 État de passation

Le contrat s'est achevé le 30 juin 2026. Les travaux se sont poursuivis jusqu'au 24 août 2026 dans le seul but de rendre les réalisations exploitables sans leur auteur :

- refonte complète de la documentation des deux dépôts, organisée autour d'une cartographie des documents et vérifiée par exécution réelle des procédures décrites ;

- consignation des pièges susceptibles de produire des résultats faux sans émettre d'erreur, développés au chapitre 3 ;
- retrait des éléments sensibles : identifiants, clés d'interface, topologie interne, adresses personnelles ; restriction par défaut de l'écoute des services à l'interface locale ;
- suppression du code mort et des scripts devenus inopérants ;
- vérification à l'échelle réelle des procédures de sauvegarde et de restauration ;
- explicitation du couplage entre les deux dépôts et de ses conditions de démarrage.

11.5 Conclusion

Ces travaux répondent à une question qui n'était pas celle posée au départ, mais qui la conditionnait : *comment rendre possible la recherche en intelligence artificielle sur les eaux souterraines françaises ?*

La réponse tient en une chaîne complète — de quatre jeux de données publics et dispersés jusqu'à des scénarios contrefactuels énonçables dans le langage des hydrogéologues — dont chaque maillon est documenté, vérifié et réutilisable indépendamment des autres. Le coût d'entrée à l'expérimentation, qui se comptait en semaines et se payait autant de fois qu'il y avait de chercheurs, se réduit désormais à une requête.

Ce qui a été construit dépasse le périmètre des eaux souterraines : l'enchaînement sources → entrepôt → indicateurs validés → modèles → explication est transposable aux autres compartiments environnementaux visés par le programme. C'est en ce sens que ces développements constituent moins un aboutissement qu'un point de départ.

A Annexes

A.1 Inventaire des réalisations logicielles

Entrepôt de données hydro-climatiques

Période	23 septembre 2025 — 24 août 2026
Volume	≈ 7 000 lignes Python, ≈ 1 200 lignes SQL de transformation
Ingestion	Bibliothèque d'extraction déclarative : pagination, reprise sur erreur, déduplication par fusion, partitionnement annuel de 1967 à aujourd'hui
Transformation	8 modèles de nettoyage, 3 modèles de rejets tracés, 18 modèles analytiques, complétés par des tables d'indicateurs calculées en Python
Orchestration	8 traitements planifiés, 3 capteurs événementiels, clés de concurrence par nature de traitement
Stockage	Base relationnelle avec extension de séries temporelles (partitionnement, compression) et extension géospatiale (jointures spatiales indexées)
Infrastructure	7 services conteneurisés, séparation du code métier et de l'orchestrateur, volumes de données déclarés hors du cycle de vie des conteneurs

Plateforme d'exploration, de modélisation et de prévision

Période	6 novembre 2025 — 24 août 2026
Volume	≈ 40 000 lignes Python, ≈ 29 000 lignes TypeScript
Interface	Application monopage : cartographie, graphiques interactifs, suivi d'entraînement en temps réel
Service	API avec flux d'événements, authentification nominative, journal d'audit, limitation de débit
Cœur métier	Bibliothèque Python sans dépendance d'interface : préparation, modèles métier, entraînement, explicabilité, contrefactuels, détection d'influence
Vérification	552 tests, dont 547 passent (mesuré le 24 août 2026)
Déploiement	Interface sur infrastructure mutualisée, calcul et bases sur serveur équipé d'un processeur graphique ; environnements de développement et de production séparés

A.2 Sources de données et attributions

Source	Contenu	Couverture
Hub'Eau — piézométrie	Niveaux de nappe aux ouvrages de surveillance	partitions depuis 1967
Hub'Eau — hydrométrie	Débits des cours d'eau (sites, stations, observations)	partitions depuis 1967
Copernicus — ERA5-Land	Réanalyse climatique sur grille 0,1°	depuis 1950
BDLISA	Référentiel hydrogéologique (entités aquifères)	référentiel

La profondeur effectivement disponible varie d'une station à l'autre : les partitions d'ingestion couvrent la période complète, les données retournées par les services web dépendent de la date de mise en service et de l'exploitation de chaque ouvrage.

Mentions obligatoires

Generated using Copernicus Climate Change Service information, 2026. Neither the European Commission nor ECMWF is responsible for any use that may be made of the Copernicus information or data it contains.

Source : Hub'Eau — eaufrance.fr • Source : BDLISA — BRGM / Sandre.

Les licences des développements couvrent le code produit, non les données consultées : chaque source conserve ses propres conditions d'usage.

A.3 Volumétrie des indicateurs climatiques

Mailles de la grille nationale	11 496
Valeurs d'indices produites	41 960 400
Fenêtres d'agrégation	1, 3, 6 et 12 mois
Période de référence	1991–2020
Échelle de classement	7 classes
Couples maille-mois de la comparaison d'évapotranspiration	30 888
Mailles de vérification de l'équivalence des lois	35 614

A.4 Glossaire

Terme	Définition
Architecture médaillon	Organisation d'un entrepôt en couches de qualité croissante : données brutes, données nettoyées, données analytiques
BDLISA	Référentiel hydrogéologique français décrivant les entités aquifères
Contrefactuel	Explication de la forme « quelle modification minimale des entrées changerait la sortie de telle manière »
ETP / ET0	Évapotranspiration potentielle ; évapotranspiration de référence au sens de la FAO-56
Hypertable	Table partitionnée dans le temps, permettant compression et interrogation efficace sur de grands volumes de séries
Idempotence	Propriété d'un traitement dont la réexécution ne modifie pas le résultat
IPS	Indicateur piézométrique standardisé, position du mois courant par rapport à sa normale saisonnière
L-moments	Statistiques d'ordre linéaires servant à ajuster une loi de probabilité, dont τ_3 mesure l'asymétrie
McKee (classes de)	Échelle à sept classes de sévérité associée aux indices standardisés
Modèle TFN	Modèle à fonction de transfert et bruit : le niveau simulé est la somme de convolutions des forçages par des réponses impulsionnelles calibrées
Piézométrie	Mesure du niveau des nappes d'eau souterraine
SPI / STI / SPEI	Indices standardisés de précipitation, de température et de bilan hydrique
SSFI	Indice standardisé de débit, équivalent de l'IPS pour les cours d'eau
STOWA	Standard néerlandais d'évaluation de la qualité des modèles TFN, en quatre critères
Valeurs de Shapley	Méthode d'attribution répartissant la contribution des entrées à une prédiction sur des bases axiomatiques

Références

- [1] T. AKIBA, S. SANO, T. YANASE, T. OHTA et M. KOYAMA. « Optuna : a next-generation hyperparameter optimization framework ». In : *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2019, p. 2623-2631.
- [2] R. G. ALLEN, L. S. PEREIRA, D. RAES et M. SMITH. *Crop evapotranspiration : guidelines for computing crop water requirements*. FAO Irrigation and Drainage Paper 56. Rome : Organisation des Nations unies pour l'alimentation et l'agriculture, 1998.
- [3] E. ATES, B. AKSAR, V. J. LEUNG et A. K. COSKUN. « Counterfactual explanations for multivariate time series ». In : *International Conference on Applied Artificial Intelligence (ICAPAI)*. 2021.
- [4] S. BEGUERÍA et S. M. VICENTE-SERRANO. *SPEI : calculation of the standardised precipitation-evapotranspiration index*. Paquet R, fonction `parglo` d'ajustement de la logistique généralisée. 2023. URL : <https://cran.r-project.org/package=SPEI>.
- [5] J. BENTO, P. SALEIRO, A. F. CRUZ, M. A. T. FIGUEIREDO et P. BIZARRO. « TimeSHAP : explaining recurrent models through sequence perturbations ». In : *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 2021, p. 2565-2573.
- [6] BRGM. *JUNON : des jumeaux numériques au service des ressources naturelles*. Programme scientifique, Bureau de recherches géologiques et minières. 2023. URL : <https://www.brgm.fr/fr/programme/junon-jumeaux-numeriques-service-ressources-naturelles>.
- [7] BRGM. *Lancement du programme JUNON en région Centre-Val de Loire*. Communiqué de presse. 2023. URL : <https://www.brgm.fr/fr/actualite/communiqu%C3%A9-presse/lancement-programme-junon-region-centre-val-loire>.
- [8] BRGM. *EROS : modèle hydrologique global multi-bassins*. Logiciel, Bureau de recherches géologiques et minières. 2026. URL : <https://www.brgm.fr/fr/logiciel/eros-logiciel-modelisation-hydrologique-bassins>.
- [9] BRGM. *GARDÉNIA : modèle global à réservoirs pour la simulation des débits et des niveaux de nappe*. Logiciel, Bureau de recherches géologiques et minières. 2026. URL : <https://www.brgm.fr/fr/logiciel/gardenia-logiciel-modelisation-hydrologique>.
- [10] BRGM et SANDRE. *BDLISA : base de données des limites des systèmes aquifères*. Référentiel hydrogéologique français. 2026. URL : <https://bdlisa.eaufrance.fr/>.
- [11] R. A. COLLENTUR, M. BAKKER, R. CALJÉ, S. A. KLOP et F. SCHAARS. « Pastas : open source software for the analysis of groundwater time series ». In : *Groundwater* 57.6 (2019), p. 877-885.
- [12] COPERNICUS CLIMATE CHANGE SERVICE. *Climate Data Store : ERA5-Land hourly data from 1950 to present*. Centre européen pour les prévisions météorologiques à moyen terme. 2026. URL : <https://cds.climate.copernicus.eu/>.
- [13] DAGSTER LABS. *Dagster : an orchestrator for data assets*. Logiciel, version 1.11. 2026. URL : <https://dagster.io/>.
- [14] DBT LABS. *dbt : data build tool*. Logiciel, version 1.7. 2026. URL : <https://www.getdbt.com/>.

- [15] DLTHUB. *dlt : data load tool, a Python library for declarative data ingestion*. Logiciel, version 0.4. 2026. URL : <https://dlthub.com/>.
- [16] W. FALCON et THE PYTORCH LIGHTNING TEAM. *PyTorch Lightning*. Logiciel. 2019. URL : <https://www.pytorchlightning.ai/>.
- [17] G. H. HARGREAVES et Z. A. SAMANI. « Reference crop evapotranspiration from temperature ». In : *Applied Engineering in Agriculture* 1.2 (1985), p. 96-99.
- [18] H. HERSBACH et al. « The ERA5 global reanalysis ». In : *Quarterly Journal of the Royal Meteorological Society* 146.730 (2020), p. 1999-2049.
- [19] J. HERZEN et al. « Darts : user-friendly modern machine learning for time series ». In : *Journal of Machine Learning Research* 23.124 (2022), p. 1-6.
- [20] J. R. M. HOSKING. « L-moments : analysis and estimation of distributions using linear combinations of order statistics ». In : *Journal of the Royal Statistical Society, Series B* 52.1 (1990), p. 105-124.
- [21] S. HOYER et J. HAMMAN. *xarray : N-D labeled arrays and datasets in Python*. Journal of Open Research Software, 5(1), 10. 2017. URL : <https://xarray.dev/>.
- [22] N. KOKHLIKYAN et al. *Captum : a unified and generic model interpretability library for PyTorch*. arXiv :2009.07896. 2020. URL : <https://captum.ai/>.
- [23] LIFAT. *Projet JUNON (2022–2026), volets DATA, PREDICTION et jumeaux numériques*. Laboratoire d’informatique fondamentale et appliquée de Tours, université de Tours. 2022. URL : <https://lifat.univ-tours.fr/projects/regional/recent/bdtin/2022-2026-junon-project>.
- [24] B. LIM, S. Ö. ARIK, N. LOEFF et T. PFISTER. « Temporal fusion transformers for interpretable multi-horizon time series forecasting ». In : *International Journal of Forecasting* 37.4 (2021), p. 1748-1764.
- [25] S. M. LUNDBERG et S.-I. LEE. « A unified approach to interpreting model predictions ». In : *Advances in Neural Information Processing Systems* 30. 2017, p. 4765-4774.
- [26] T. B. MCKEE, N. J. DOESKEN et J. KLEIST. « The relationship of drought frequency and duration to time scales ». In : *Proceedings of the 8th Conference on Applied Climatology*. Anaheim, Californie, 1993, p. 179-183.
- [27] META OPEN SOURCE. *React 19 : a JavaScript library for building user interfaces*. Logiciel. 2026. URL : <https://react.dev/>.
- [28] MÉTÉO-FRANCE. *SAFRAN : système d’analyse atmosphérique à méso-échelle sur la France*. Réanalyse météorologique sous licence, non redistribuable. 2026.
- [29] J. MUÑOZ-SABATER et al. « ERA5-Land : a state-of-the-art global reanalysis dataset for land applications ». In : *Earth System Science Data* 13.9 (2021), p. 4349-4383.
- [30] OFFICE FRANÇAIS DE LA BIODIVERSITÉ. *Hub’Eau : les API du système d’information sur l’eau*. Services web *niveaux_nappes* et *hydrometrie*. 2026. URL : <https://hubeau.eaufrance.fr/>.
- [31] POSTGIS PROJECT. *PostGIS : spatial and geographic objects for PostgreSQL*. Logiciel. 2026. URL : <https://postgis.net/>.
- [32] POSTGRESQL GLOBAL DEVELOPMENT GROUP. *PostgreSQL 16*. Système de gestion de base de données relationnelle. 2026. URL : <https://www.postgresql.org/>.
- [33] S. RAMÍREZ. *FastAPI : a modern, fast web framework for building APIs with Python*. Logiciel. 2026. URL : <https://fastapi.tiangolo.com/>.

- [34] N. RINGUET. *Échange hydrogéologie et intelligence artificielle : compte rendu de réunion BRGM et université de Tours*. Document de travail interne, programme JUNON. Réunion du 13 février 2026. 2026.
- [35] N. RINGUET. *hubeau_data_integration : entrepôt de données hydro-climatiques*. Dépôt logiciel, forge de l'université de Tours. 2026. URL : https://scm.univ-tours.fr/ringuet/hubeau_data_integration.
- [36] N. RINGUET. *time-serie-explo : plateforme d'exploration, de modélisation et de prévision piézométrique*. Dépôt logiciel, forge de l'université de Tours. 2026. URL : <https://scm.univ-tours.fr/ringuet/time-serie-explo>.
- [37] STOWA. *Beoordeling van tijdreeksmodellen voor grondwaterbeheer*. Rapp. tech. Critères d'acceptation des modèles à fonction de transfert et bruit. Amersfoort, Pays-Bas : Stichting Toegepast Onderzoek Waterbeheer, 2012.
- [38] M. SUNDARARAJAN, A. TALY et Q. YAN. « Axiomatic attribution for deep networks ». In : *Proceedings of the 34th International Conference on Machine Learning*. 2017, p. 3319-3328.
- [39] TIMESCALE. *TimescaleDB : time-series extension for PostgreSQL*. Logiciel. 2026. URL : <https://www.timescale.com/>.
- [40] S. M. VICENTE-SERRANO, S. BEGUERÍA et J. I. LÓPEZ-MORENO. « A multiscalar drought index sensitive to global warming : the standardized precipitation evapotranspiration index ». In : *Journal of Climate* 23.7 (2010), p. 1696-1718.
- [41] S. WACHTER, B. MITTELSTADT et C. RUSSELL. « Counterfactual explanations without opening the black box : automated decisions and the GDPR ». In : *Harvard Journal of Law and Technology* 31.2 (2018), p. 841-887.
- [42] Z. WANG, I. SAMSTEN, I. MILIOU, R. MOCHAOURAB et P. PAPAPETROU. « Counterfactual explanations for time series forecasting ». In : *IEEE International Conference on Data Mining (ICDM)*. 2023.
- [43] M. ZAHARIA et al. « Accelerating the machine learning lifecycle with MLflow ». In : *IEEE Data Engineering Bulletin* 41.4 (2018), p. 39-45.