

Programme JUNON
Ambition Recherche & Développement
Région Centre-Val de Loire

Rapport de clôture

De la donnée hydrologique dispersée à la prévision explicable

Construction d'un entrepôt de données et d'une plateforme
d'expérimentation en apprentissage automatique
pour les eaux souterraines

Nicolas Ringuet

Postdoctorant
Laboratoire d'Informatique Fondamentale et Appliquée de Tours (LIFAT)
Université de Tours

Supervision scientifique : Nicolas Labroche (LIFAT)
Collaboration : Hugo Breuillard, Augustin Thomas (BRGM)

Période couverte : 15 septembre 2025 au 30 juin 2026
Travaux de documentation et de passation prolongés jusqu'au 24 août 2026

Août 2026

Synthèse

Le programme JUNON construit des jumeaux numériques des milieux naturels, dont les eaux souterraines. Prévoir l'évolution d'une nappe par apprentissage automatique est aujourd'hui possible. S'en servir pour décider ne l'est pas : une prévision qu'on ne sait pas justifier ne sera pas retenue à l'appui d'un arrêté de restriction d'usage. C'est à cette difficulté, l'**explicabilité des prévisions**, que ce postdoctorat était consacré, au LIFAT de l'Université de Tours, du 15 septembre 2025 au 30 juin 2026.

Il s'est heurté d'emblée à un obstacle matériel. La donnée hydrologique française est publique, mais elle est éparpillée entre des services qui s'ignorent : les niveaux de nappe d'un côté, les débits des rivières d'un autre, le climat ailleurs encore, sans lien entre eux et sans indicateurs comparables d'une station à l'autre. On ne peut pas expliquer un modèle qu'on n'a pas pu entraîner.

J'aurais pu contourner l'obstacle par un jeu de données de circonstance. J'ai choisi d'en faire l'objet du travail. J'ai porté le constat auprès des équipes du BRGM, qui l'ont confirmé : le besoin d'un entrepôt consolidé et d'outils d'analyse ne concernait pas seulement ce postdoctorat, il était partagé par leurs propres équipes comme par d'autres projets, chacun butant sur la même difficulté de son côté. Construire ce socle est devenu le premier travail, non par défaut mais par décision assumée.

L'entrepôt de données sur l'eau et le climat rassemble automatiquement quatre sources publiques : les niveaux de nappe et les débits de rivière relevés par le réseau national, la reconstitution du climat français depuis 1950, et le référentiel qui décrit les aquifères. Il les met en cohérence, rattache chaque station de mesure au climat de son secteur, et se met à jour chaque jour. Il en tire des indicateurs de sécheresse normalisés, calculés de la même manière sur tout le territoire, dont la conformité a été vérifiée sur près de 42 millions de valeurs. Ce qui demandait plusieurs semaines de préparation à chaque équipe s'obtient désormais par une requête.

La plateforme d'exploration et de prévision donne accès à trois usages. Un observatoire cartographique montre l'état des nappes, des rivières et du climat sur tout le territoire. Un laboratoire de modélisation permet de caler les modèles qu'emploient les hydrogéologues et de simuler des scénarios, l'effet d'un nouveau prélèvement agricole par exemple. Un laboratoire d'intelligence artificielle donne accès à une douzaine de méthodes de prévision et, surtout, aux outils qui permettent d'examiner sur quoi leurs prévisions reposent.

Chaque public y trouve autre chose. Les hydrogéologues, des indicateurs conformes à leurs pratiques et de quoi simuler l'effet d'un prélèvement sur une nappe donnée. Les chercheurs, un jeu de données prêt à l'emploi et un banc d'expérimentation, qui suppriment le travail de préparation que chaque équipe refaisait pour son compte, avec ses propres conventions. Le programme, une chaîne complète, de la donnée publique jusqu'au service explicable, mobilisable pour les jumeaux numériques de la ressource en eau.

Les briques de modélisation et d'explication sont **préliminaires**, et c'est leur objet. Elles ne portent aucune conclusion scientifique : elles fournissent un point de départ à ceux qui voudront y greffer leurs propres modèles, protocoles ou questions de recherche, sans avoir à reconstruire l'amont. L'une d'elles répond à une exigence que les hydrogéologues ont formulée eux-mêmes : lorsqu'on demande à un modèle ce qu'il aurait fallu pour qu'une nappe ne descende pas si bas, la réponse doit rester physiquement possible. Une implémentation contraint la réponse en ce sens et l'exprime dans les termes du métier, un hiver plus sec et plus chaud de tant. Son évaluation reste à conduire.

L'ensemble constitue un socle réutilisable, national et documenté. Il a été présenté aux équipes du projet ANR AIDA, dont le périmètre est voisin, pour que celles qui en auraient l'usage n'aient pas à le reconstruire. La chaîne traite plusieurs centaines de millions de mesures, se relance sans rien dupliquer et reprend après interruption, ce qui décide si un jeu de données peut servir de référence commune à plusieurs équipes ou seulement à l'expérience qui l'a produit. Son architecture n'est pas propre aux eaux souterraines : le même enchaînement s'applique aux autres compartiments environnementaux visés par le programme. Il est surtout destiné à servir de base aux travaux d'explicabilité qui prendront la suite, auxquels il transmet à la fois les données, les modèles et les outils d'analyse.

Reste ce que ce rapport n'établit pas. Aucune comparaison chiffrée des méthodes de prévision n'y figure : le temps consacré à l'infrastructure ne l'a pas permis, et je n'ai rien reconstitué de mémoire. Et l'usage de la plateforme demeure circonscrit au cercle du projet ; son élargissement relève d'une décision d'accès plus que de développements supplémentaires.

Table des matières

Synthèse	2
1 Contexte et positionnement	7
1.1 Le programme JUNON	7
1.2 La mission initiale : l'explicabilité	7
1.3 Le glissement de mission, et pourquoi il était nécessaire	7
1.4 Périmètre du rapport	8
2 Le verrou : une donnée ouverte mais inexploitable	9
2.1 Ce que la donnée ouverte offre réellement	9
2.2 Ce qui manque	9
2.2.1 La jointure au forçage climatique n'existe pas	9
2.2.2 L'historique n'est pas consolidé, et la volumétrie est réelle	10
2.2.3 La donnée brute recèle des pièges qui ne s'annoncent pas	10
2.2.4 Des sources publiques, mais pas des sources stables	10
2.2.5 Aucun indicateur normalisé n'est fourni	11
2.3 Ce que l'apprentissage automatique exige en plus	11
2.4 Le coût collectif de l'absence d'infrastructure	11
3 Sourcing et entrepôt de données	12
3.1 Le principe retenu : une architecture médaillon	12
3.2 Le choix de la pile technique	12
3.3 Déploiement, packaging et reproductibilité	13
3.4 Bronze : ingérer sans interpréter	13
3.5 Silver : nettoyer en rendant compte	14
3.6 Gold : joindre, enrichir, exposer	14
3.6.1 Aligner les stations sur la grille climatique	15
3.7 Orchestration : planifier l'ingestion, déclencher la transformation	15
3.8 Les garanties de la chaîne, et comment elles ont été éprouvées	16
3.8.1 Deux règles contre les défaillances qui ne s'annoncent pas	16
4 Des mesures aux indicateurs : construction et validation	17
4.1 Pourquoi standardiser	17
4.2 Les indices par station	17
4.3 Les indices climatiques sur grille	18
4.4 Premier arbitrage : quelle évapotranspiration employer	18
4.4.1 De quoi il est question	18
4.4.2 Ce qui s'est passé	18
4.4.3 Pourquoi	19
4.4.4 Ce que cela change	19
4.4.5 Une incohérence connue, et ce qu'elle coûte	19
4.5 Deuxième arbitrage : quelle loi ajuster pour le SPEI	20
4.6 La vérification des indices produits	21

4.7	Deux lectures à ne pas faire	21
4.8	Un contrat entre les deux dépôts	21
5	L'Observatoire : donner à voir	23
5.1	Une contrainte d'architecture posée d'emblée	23
5.2	Le besoin : explorer avant de modéliser	23
5.3	Organisation : deux compartiments	24
5.4	Une règle de conception qui a structuré l'interface	24
5.5	Trois choix techniques	24
5.6	Environnements et déploiement	25
6	Modéliser : le laboratoire de modèles métier	26
6.1	Pourquoi commencer par le modèle métier	26
6.2	Les modèles à fonction de transfert et bruit	26
6.3	Calibration automatique et critères de qualité	26
6.4	L'apport hydrogéologique : des configurations par famille d'aquifère	27
6.5	Diagnostics et validation	28
6.6	Scénarios prospectifs	28
7	Apprendre : le laboratoire d'apprentissage automatique	29
7.1	Le problème posé	29
7.2	Un catalogue d'architectures sous interface unique	29
7.3	Le protocole expérimental	29
7.4	Optimisation d'hyperparamètres	30
7.5	Rendre l'outil utilisable par des non-spécialistes	30
7.6	Ce qui est établi, et ce qui ne l'est pas	30
8	Expliquer : le sujet initial, enfin abordable	32
8.1	Pourquoi l'explicabilité n'est pas une option ici	32
8.2	Le rôle de ce chapitre dans une recherche en cours	32
8.3	Sur quoi le modèle s'appuie-t-il : les méthodes d'attribution	32
8.4	Que se passerait-il si : les contrefactuels sous contrainte physique	33
8.4.1	Le problème du contrefactuel naïf	33
8.4.2	La solution retenue : contraindre l'espace de perturbation	33
8.4.3	Une comparaison honnête : la référence non contrainte	34
8.4.4	Une validation par un modèle indépendant	34
8.5	Cette chronique est-elle explicable par le climat ? La détection de prélèvements	34
9	Ce que la collaboration a produit	36
9.1	Le cadre de travail	36
9.2	L'expertise métier inscrite dans le code	36
9.3	Les cas d'usage identifiés avec le BRGM	36
9.4	L'articulation avec les travaux de recherche en cours	38
9.5	Des besoins distincts, un outil commun	38
9.6	État de mise à disposition	38
10	Un socle pour l'IA en hydrologie	40
10.1	Pourquoi la plupart des développements de recherche ne se réutilisent pas	40

10.2 Les propriétés acquises	40
10.3 Le patron généralisable	40
10.4 Extensions, par coût croissant	41
10.5 Ce qui est transmis aux travaux à venir	41
10.6 Ce qui manque pour un véritable environnement d'outils	42
10.7 Articulation avec le volet des jumeaux numériques	43
11 Bilan, limites et passation	44
11.1 Récapitulatif des réalisations	44
11.2 Bilan au regard de la mission initiale	44
11.3 Limites assumées	45
11.4 État de passation	45
11.5 Conclusion	46
A Annexes	47
A.1 Inventaire des réalisations logicielles	47
A.2 Sources de données et attributions	47
A.3 Le cheminement de l'évapotranspiration dans l'entrepôt	48
A.4 Volumétrie des indicateurs climatiques	49
A.5 Glossaire	49
B Revue des outils retenus	50
B.1 Ingestion : dlt	50
B.2 Transformation : dbt	50
B.3 Orchestration : Dagster	50
B.4 Stockage : PostgreSQL, TimescaleDB et PostGIS	51
B.5 Synthèse des choix	51
Références	52

1 Contexte et positionnement

Dans quel dispositif de recherche ces travaux s'inscrivent-ils, et quelle mission leur avait été assignée au départ ?

1.1 Le programme JUNON

JUNON est un programme *Ambition Recherche & Développement* de la Région Centre-Val de Loire, coordonné par le BRGM et réunissant une vingtaine d'équipes de recherche du territoire [6, 7]. Son objectif est de développer des **jumeaux numériques** des milieux naturels continentaux, l'eau, le sol et l'air, et les services numériques qui les accompagnent. Un jumeau numérique ne se réduit pas à une visualisation : il vise à reproduire les structures et les processus réels tout au long de leur évolution, en s'appuyant notamment sur l'apprentissage automatique.

À côté des projets consacrés à chaque compartiment environnemental, le programme comporte des volets transversaux qui fournissent les moyens communs, notamment la gestion des observations et la modélisation prédictive. Le LIFAT participe à ces volets transversaux sur la période 2022–2026 [22], sur les questions de prédiction à partir de séries temporelles environnementales : comment apprendre le comportement d'un système naturel à partir d'observations éparses, bruitées et déséquilibrées, et comment qualifier la confiance que l'on peut accorder à la prédiction obtenue.

C'est dans ce cadre que s'inscrivent les présents travaux, menés du 15 septembre 2025 au 30 juin 2026 sous la supervision de Nicolas Labroche.

1.2 La mission initiale : l'explicabilité

Le sujet assigné portait sur **l'explicabilité des modèles de prévision appliqués aux nappes d'eau souterraine**. Un modèle d'apprentissage profond qui prévoit un niveau piézométrique produit un nombre ; ce nombre n'a de valeur opérationnelle que si l'on peut répondre à trois questions que tout hydrogéologue posera : sur quoi le modèle s'appuie-t-il, que se passerait-il dans d'autres conditions, et jusqu'où peut-on lui faire confiance hors du régime observé.

Ces questions ne sont pas académiques. Les niveaux de nappe conditionnent des décisions publiques : arrêtés de restriction d'usage, autorisations de prélèvement, planification de l'alimentation en eau potable. Une prédiction que l'on ne sait pas justifier ne sera pas mobilisée, et ne devrait pas l'être.

1.3 Le glissement de mission, et pourquoi il était nécessaire

L'explicabilité s'applique à un modèle ; un modèle s'entraîne sur des données. Or, au démarrage des travaux, **aucun jeu de données exploitable n'existait** pour les nappes françaises associées à leur forçage climatique. Ce constat, développé au chapitre 2, a déterminé la trajectoire de l'année.

Le travail a donc pris la forme d'une **ingénierie de recherche assumée** : identifier les sources, construire l'entrepôt, produire les indicateurs, vérifier leur validité, puis seulement outiller la modélisation et l'explicabilité. Cette réorientation n'a pas dilué le sujet initial, elle en a conditionné la possibilité. En pratique, elle a produit un résultat plus durable qu'une étude d'explicabilité menée sur un jeu de données jetable : **l'infrastructure survit à l'expérience**.

Cette réorientation n'a pas été décidée seul. Elle procède d'un recadrage mené avec le BRGM au début de l'année 2026, associant les interlocuteurs techniques et les experts métier. Les échanges ont établi que le manque constaté n'était pas propre à ce postdoctorat : le besoin d'un entrepôt

consolidé, d'outils d'analyse et d'un environnement d'entraînement de modèles était partagé par les équipes du BRGM comme par d'autres projets du programme, chacun butant sur le même obstacle de son côté. C'est cette vérification qui a rendu légitime l'investissement de plusieurs mois que représente un entrepôt de données.

1.4 Périmètre du rapport

Deux réalisations logicielles sont couvertes, développées intégralement au cours de la période :

Dépôt	Objet
<code>hubeau_data_integration</code> [33]	Entrepôt de données hydro-climatiques. Ingestion, transformation et exposition des données piézométriques, hydrométriques, climatiques et hydrogéologiques. Premier commit : 23 septembre 2025.
<code>time-serie-explo</code> [34]	Plateforme d'exploration, de modélisation et de prévision. Observatoire spatial, laboratoire de modèles métier, laboratoire d'apprentissage automatique, explicabilité. Premier commit : 6 novembre 2025.

Le contrat postdoctoral s'est achevé le 30 juin 2026. Les travaux de documentation, de neutralisation des éléments sensibles et de passation se sont poursuivis jusqu'au 24 août 2026, afin que ces réalisations restent exploitables après le départ de leur auteur.

2 Le verrou : une donnée ouverte mais inexploitable

La donnée hydrologique française est publique et accessible. Pourquoi faut-il malgré tout construire une infrastructure avant d'espérer entraîner le moindre modèle ?

2.1 Ce que la donnée ouverte offre réellement

Trois sources publiques couvrent, en principe, l'essentiel du besoin.

Hub'Eau est la plateforme d'accès aux données sur l'eau opérée dans le cadre du système d'information sur l'eau [29]. Elle expose par interfaces web les chroniques *piézométriques*, c'est-à-dire les niveaux de nappe mesurés aux ouvrages de surveillance, et les données *hydrométriques* de débit des cours d'eau, organisées en sites, stations et observations élaborées. Le parc compte 23 333 ouvrages piézométriques, 6 468 stations hydrométriques et 9 283 sites de référence, ces derniers ne portant pas tous une station en service.

ERA5-Land, produit par le Centre européen pour les prévisions météorologiques à moyen terme et diffusé par le *Climate Data Store* de Copernicus [12], fournit une réanalyse climatique sur grille d'environ 0,1°, continue depuis 1950 [18, 28]. C'est la source de forçage naturelle pour tout modèle hydrologique : précipitations, températures, évaporation.

BDLISA, le référentiel hydrogéologique du BRGM [10], décrit les entités aquifères du territoire : leur nature, leur géométrie, leur organisation. C'est ce qui permet de savoir si un piézomètre observe une nappe alluviale, un aquifère sédimentaire poreux, un système karstique ou un socle fracturé, distinction dont on verra au chapitre 6 qu'elle commande le comportement du signal.

Chacune de ces sources est ouverte, documentée et interrogeable. Le verrou n'est pas l'accessibilité.

Une alternative existait. Le BRGM dispose d'une licence pour la réanalyse SAFRAN [27], mieux adaptée au territoire français. Elle a été écartée pour une raison qui n'est pas technique : les données SAFRAN ne sont pas redistribuables, ce qui interdisait de les verser dans un entrepôt destiné à être partagé entre équipes et documenté publiquement. ERA5-Land est libre, mondial et versionné. Le choix privilégie donc la reproductibilité et le partage sur la finesse de la source, arbitrage qu'il faut connaître pour interpréter les résultats.

2.2 Ce qui manque

2.2.1 La jointure au forçage climatique n'existe pas

Un niveau de nappe seul n'est pas modélisable. Il répond à la pluie efficace, c'est-à-dire à la différence entre précipitation et évapotranspiration, avec un retard et un amortissement propres à l'aquifère. Prédire une nappe suppose donc de disposer, *pour chaque station et chaque jour*, du signal climatique correspondant.

Or Hub'Eau ne fournit aucune variable météorologique, et ERA5 ignore l'existence des piézomètres. Rattacher les deux exige une jointure spatiale, qui associe chaque station à la maille climatique la plus proche, puis une jointure temporelle sur un pas de temps commun. Ce travail n'est fourni par personne.

2.2.2 L'historique n'est pas consolidé, et la volumétrie est réelle

Les interfaces web sont paginées et conçues pour la consultation, non pour la constitution d'un corpus. Récupérer six décennies de chroniques sur l'ensemble du parc de stations, puis sept décennies de réanalyse climatique sur l'ensemble du territoire, représente des dizaines de gigaoctets et plusieurs jours de collecte. Ce n'est pas une opération que l'on relance à chaque expérience.

Le cas d'ERA5 illustre l'écart entre l'accès théorique et le coût pratique. Le produit dérivé de statistiques journalières proposé par le *Climate Data Store* est calculé côté serveur, sur une file d'attente saturée : environ **43 heures par année demandée**. À ce rythme, reconstituer sept décennies se compte en mois. La même information, recalculée localement à partir de l'archive horaire brute, demande environ **vingt-cinq minutes par année**. L'équivalence des deux voies a été vérifiée maille par maille et jour par jour, à 0,000 0 °C sur les extrêmes journaliers et 0,01 °C sur la moyenne.

2.2.3 La donnée brute recèle des pièges qui ne s'annoncent pas

Un exemple suffit. Dans ERA5, les variables de précipitation et d'évaporation sont des *flux cumulés* : la valeur au pas de 0 h UTC constitue bien le total journalier. La température, elle, est une *grandeur instantanée* : prendre sa valeur à 0 h UTC comme moyenne journalière introduit un biais froid nocturne de l'ordre de 2 à 4 °C. Deux variables issues du même fichier, au même horodatage, dont l'une doit être lue telle quelle et l'autre reconstruite à partir des vingt-quatre pas horaires.

Rien dans la donnée ne signale cette différence. Elle se paie en résultats faux, silencieux et plausibles.

2.2.4 Des sources publiques, mais pas des sources stables

Les interfaces publiques sont ouvertes, elles ne sont pas pour autant fiables. Ce point a coûté un temps considérable et n'apparaît dans aucune documentation officielle. Il a fallu composer avec leurs défauts plutôt que les supposer absents.

La disponibilité, d'abord, n'est pas garantie : les services répondent en erreur lorsqu'ils sont sollicités intensément, ce qui est précisément le régime d'une collecte historique. Toute ingestion doit donc intégrer des tentatives successives avec temporisation croissante, et être capable de reprendre là où elle s'est arrêtée. Une extraction naïve échoue au bout de quelques heures et laisse un jeu de données incomplet sans le signaler.

Les conventions, ensuite, varient d'un point d'accès à l'autre au sein d'une même source. Le paramètre qui identifie une station n'est pas le même selon l'interface interrogée. Employer le mauvais ne provoque pas d'erreur explicite, mais un résultat vide. S'y ajoutent des plafonds de pagination qui diffèrent d'une interface à l'autre et ne sont documentés nulle part : chacun a été découvert à l'usage.

Les données elles-mêmes, enfin, présentent des incohérences. Le service d'observations hydrométriques retourne des mesures rattachées à des stations *absentes de son propre référentiel* : la source se contredit, et une jointure naïve échoue sur une violation de clé étrangère.

Ces défauts ont une conséquence directe sur l'architecture décrite au chapitre 3. Le nettoyage ne peut pas être une formalité que l'on expédie : il devient une fonction de premier plan, et surtout il doit **rendre compte de ce qu'il écarte**. C'est la raison d'être des tables de rejets, qui conservent chaque ligne exclue avec le motif de son exclusion. Sans elles, il serait impossible de distinguer une station réellement absente du terrain d'une station perdue en route par un défaut de la source ou par un critère de filtrage trop strict.

2.2.5 Aucun indicateur normalisé n'est fourni

Un hydrogéologue ne raisonne pas sur un niveau brut en mètres, qui n'a de sens que rapporté à l'historique de l'ouvrage. Il raisonne sur des **indicateurs standardisés** qui situent la mesure du jour par rapport à la distribution de référence du même mois : est-on dans la normale, en situation modérément sèche, en sécheresse sévère ? Ces indicateurs, qu'il s'agisse des indices standardisés de niveau, de débit, de précipitation ou de bilan hydrique, ne sont fournis par aucune des trois sources. Ils doivent être calculés, ce qui suppose une période de référence, un ajustement statistique et une validation.

2.3 Ce que l'apprentissage automatique exige en plus

Les difficultés précédentes concernent tout usage de la donnée. L'apprentissage automatique en ajoute qui lui sont propres.

- **Une couverture temporelle continue.** Un modèle de séries temporelles supporte mal les lacunes ; encore faut-il savoir où elles sont, ce qui suppose une chronologie régulière et explicite plutôt qu'une liste d'observations.
- **Des covariables alignées.** Le forçage climatique doit être disponible sur exactement la même chronologie que la cible, sans décalage ni trou différentiel.
- **La reproductibilité.** Une expérience qui ne peut être rejouée sur les mêmes données n'est pas un résultat. Cela interdit l'extraction ponctuelle et impose un stockage versionné et interrogeable.
- **Le volume.** Comparer une douzaine d'architectures sur des centaines de stations suppose de lire les données des milliers de fois. Une chaîne d'extraction par interface web rend l'exercice impraticable ; une base de données ne le rend pas seulement possible, elle le rend rapide.

2.4 Le coût collectif de l'absence d'infrastructure

Le constat déterminant n'est pas technique mais organisationnel. En l'absence d'entrepôt, **chaque chercheur refait l'extraction**, avec ses propres conventions de nettoyage, sa propre gestion des lacunes, son propre rattachement climatique. Les résultats deviennent incomparables, non par divergence de méthode, mais par divergence de préparation des données. Le temps consacré à la collecte est prélevé sur le temps de recherche, et il est prélevé autant de fois qu'il y a de chercheurs.

Les équipes du BRGM faisaient le même constat, dans leurs termes : plusieurs jeux de données coexistaient, de provenances et de qualités différentes, sans base commune permettant de les comparer.

C'est ce coût, réparti et invisible, que l'entrepôt décrit au chapitre 3 supprime.

Le verrou est donc caractérisé : la donnée est ouverte, mais ni jointe, ni consolidée, ni normalisée, ni prête pour l'apprentissage. La question qui organise la suite de ce rapport découle de ce constat. Quelle infrastructure faut-il construire pour que la recherche en intelligence artificielle appliquée aux eaux souterraines devienne seulement possible ? Une précision de périmètre s'impose avant d'y répondre : les travaux portent sur la quantité d'eau, niveaux et débits. La qualité, également visée par le programme, n'a pas été abordée.

3 Sourcing et entrepôt de données

Comment transformer quatre jeux de données hétérogènes, volumineux et piégeux en un ensemble interrogeable, reproductible et digne de confiance ?

Ce chapitre porte le résultat principal du travail. Il ne s'agit pas d'un choix d'outils, mais d'un ensemble de propriétés à garantir, celles dont dépend la possibilité même de comparer deux expériences.

3.1 Le principe retenu : une architecture médaille

La donnée traverse trois couches de qualité croissante, matérialisées par trois schémas distincts d'une même base PostgreSQL [31]. Ce patron, dit *médaille* et représenté sur la figure 3.1, répond à une exigence simple : **ne jamais perdre la donnée telle qu'elle a été reçue**, et rendre chaque transformation ultérieure explicite, versionnée et rejouable.




Figure 3.1 – Les trois couches de l'entrepôt. La donnée brute n'est jamais écrasée, et les lignes écartées au nettoyage sont conservées à part avec le motif de leur exclusion : le filtrage se vérifie par une requête au lieu d'être silencieux.

3.2 Le choix de la pile technique

Aucun outil n'était imposé. Chacun a été retenu après une revue des solutions disponibles, selon trois critères explicites, et c'est le troisième qui a le plus pesé.

1. **Ce que l'outil évite d'écrire.** Tout mécanisme fourni par une bibliothèque éprouvée est du code que je n'ai pas à produire, à tester ni à documenter, et qui n'apporte aucun résultat scientifique propre.

2. **L'adéquation au besoin réel**, en particulier la combinaison rare de séries temporelles longues et de traitement géospatial.
3. **La pérennité et la transférabilité**. Ces travaux sont destinés à être repris. Un outil de niche, si élégant soit-il, condamne le successeur à une documentation absente, à des forums vides et à une compétence introuvable. Le critère décisif n'est donc pas la supériorité technique d'un outil, mais son **adoption** : la taille de sa communauté, la vivacité de sa maintenance, l'abondance de sa documentation et la probabilité qu'un nouvel arrivant le connaisse déjà.

Ce dernier point est la raison pour laquelle la pile retenue est délibérément **conventionnelle**. L'enchaînement ingestion, transformation, orchestration correspond à un patron d'architecture largement diffusé dans l'industrie de la donnée, et chacun de ses composants est un choix courant dans ce patron plutôt qu'une préférence personnelle.

La pile retenue est donc dlt pour l'ingestion, dbt pour la transformation, Dagster pour l'orchestration, et PostgreSQL équipé de TimescaleDB et de PostGIS pour le stockage. Chacun de ces choix a été instruit contre ses alternatives : le détail figure en annexe B, avec ce qui a été écarté et pourquoi. Le reste de ce chapitre porte sur ce que la chaîne fait, non sur les outils qui la composent.

3.3 Déploiement, packaging et reproductibilité

Ce point a fait l'objet d'un travail délibéré, et non d'une finition de dernière minute. Un socle destiné à être repris ne vaut que s'il se réinstalle : une chaîne qui ne fonctionne que sur la machine de son auteur meurt avec son départ.

Tout est conteneurisé. Les deux dépôts se déploient par Docker Compose, rien n'est installé sur l'hôte, aucune dépendance système n'est supposée présente, et les versions sont figées dans les images. Une orchestration plus élaborée, de type Kubernetes, aurait été surdimensionnée pour un serveur unique et aurait ajouté une compétence à transmettre sans bénéfice opérationnel. L'entrepôt dispose d'une configuration de production et d'une configuration de bac à sable, la plateforme en compte trois, production, accélération sur processeur graphique et développement complètement séparé, avec ses propres volumes, bases et ports, de sorte qu'un modèle entraîné ou un compte créé d'un côté n'atteint jamais l'autre. Le profil se choisit par une variable d'environnement, sans modifier de fichier.

Les volumes de données, eux, sont déclarés en dehors du cycle de vie de la pile, ce qui rend impossible leur destruction par une commande d'arrêt, même assortie de l'option qui supprime les volumes. Un script dédié les crée une fois, avant le premier démarrage. D'autres scripts couvrent les gestes que le successeur devra poser : sauvegarde et restauration de l'entrepôt, export à plat des tables analytiques pour un usage hors base, création d'un compte en lecture seule pour un consommateur tiers, déploiement sur le serveur. La procédure de restauration a été vérifiée à l'échelle réelle, et non sur un échantillon.

La documentation d'installation n'a pas davantage été rédigée de mémoire. Elle a été éprouvée en repartant d'une machine vierge, ce qui fait apparaître les écarts qu'une machine déjà configurée masque. Chaque dépôt fournit par ailleurs un exemple de fichier d'environnement recensant toutes les variables attendues, avec leur rôle. Les secrets n'y figurent pas, et les services n'écoutent par défaut que sur l'interface locale, ce qui évite qu'une installation de test se retrouve exposée par inadvertance.

3.4 Bronze : ingérer sans interpréter

Chaque source est ingérée par dlt, assisté du client dédié décrit plus haut pour la pagination et la reprise sur erreur. dlt infère le schéma, crée les tables et charge par lots. Les séries temporelles

sont partitionnées par année, ce qui rend chaque tranche rechargeable indépendamment. Les partitions couvrent 1967 à aujourd’hui pour la piézométrie comme pour l’hydrométrie, la profondeur effectivement disponible variant d’une station à l’autre selon sa date de mise en service.

Le principe de la couche est de **ne rien décider** : les colonnes restent textuelles, les valeurs sont celles reçues. Toute interprétation appartient aux couches suivantes, où elle est lisible et modifiable.

Le cas d’ERA5 fait exception sur un point, imposé par la nature du produit : les fichiers NetCDF ne sont jamais archivés en base. Ils sont téléchargés en stockage temporaire, extraits en mémoire avec xarray [20] et insérés directement. Deux chemins d’ingestion coexistent, l’un pour les séries issues du pas de 0 h UTC, l’autre pour les statistiques journalières de température agrégées localement sur les vingt-quatre pas horaires, pour la raison exposée au chapitre 2 : flux cumulés et grandeurs instantanées ne se lisent pas de la même manière.

Table 3.1 – Volumétrie de la couche brute, mesurée le 24 août 2026.

Table	Lignes
Statistiques journalières de température ERA5	≈ 320 000 000
Séries temporelles ERA5	≈ 300 000 000
Mesures piézométriques	≈ 23 000 000
Observations hydrométriques élaborées	≈ 15 000 000
Ouvrages piézométriques	23 333
Sites hydrométriques	9 283
Stations hydrométriques	6 468
Entités hydrogéologiques BDLISA	3 716
Total	≈ 658 000 000

3.5 Silver : nettoyer en rendant compte

Chaque modèle dbt de cette couche sélectionne les colonnes utiles, convertit les types, déduplique et écarte les lignes invalides. La caractéristique importante n’est pas le nettoyage lui-même, mais sa **traçabilité** : les lignes écartées ne disparaissent pas, elles sont écrites dans un schéma dédié, accompagnées du motif de leur exclusion : date de mesure absente, code de station manquant, station orpheline de son site.

Cette décision a un coût de stockage négligeable et une valeur méthodologique élevée. Un filtrage silencieux est invérifiable : rien ne distingue une station réellement absente d’une station éliminée par un critère trop strict. Ici, la question se tranche par une requête.

Huit modèles de nettoyage et trois modèles de rejets composent cette couche. Les modèles de séries temporelles sont incrémentaux, avec une fenêtre de recouvrement de sept jours qui absorbe les corrections tardives publiées par les producteurs de données.

3.6 Gold : joindre, enrichir, exposer

C’est dans cette couche que se résout le verrou central identifié au chapitre précédent.

Le premier travail de cette couche est le rattachement climatique. Chaque station piézométrique ou hydrométrique est associée à sa maille ERA5 la plus proche par une jointure spatiale du plus proche voisin, exécutée par PostGIS. Cette opération, effectuée une fois et matérialisée, transforme deux jeux de données étrangers l’un à l’autre en une chronique unique où le niveau et son forçage climatique figurent sur la même ligne, au même jour.

Deux précautions s'y attachent.

3.6.1 Aligner les stations sur la grille climatique

La première tient à l'emprise. La grille climatique ingérée couvre un rectangle allant de 41° à 51,5° de latitude et de -5,5° à 10° de longitude, soit la France métropolitaine et la Corse. Les départements et territoires d'outre-mer en sont exclus. Ce choix n'est pas de principe : il tient au volume, puisque étendre l'emprise multiplie d'autant la quantité de données à télécharger, à stocker et à indexer, pour des territoires que le programme ne visait pas.

La conséquence doit être connue de quiconque exploite l'entrepôt. Les stations ultramarines présentes dans les référentiels nationaux sont bien ingérées, avec leurs mesures de niveau ou de débit, mais elles n'ont **aucun forçage climatique associé**. Elles restent donc inutilisables pour toute modélisation supposant la pluie et la température, et il faut les écarter explicitement plutôt que de les laisser produire des séries incomplètes. Elles constituent l'essentiel des lignes sans météo constatées dans les tables analytiques.

La seconde porte sur les coordonnées elles-mêmes, puisqu'elles servent de clé de jointure. Une même maille écrite avec deux précisions flottantes différentes, 48,1° d'un côté et 48,099 999 999 999 95 de l'autre, fait deux points distincts pour la base, et la grille se dédouble sans que rien ne le signale. Les coordonnées sont donc arrondies au pas natif de la grille, 0,1°, ce qui est sans perte puisque c'est la résolution réelle du produit, et l'arrondi s'applique partout où elles servent de clé : au nettoyage, à la construction des points de grille, et à chaque lecture qui rapproche une station de sa maille. Un test automatique garde l'invariant.

Vient enfin l'enrichissement hydrogéologique. Les entités du référentiel BDLISA sont rattachées aux stations, ce qui rend disponible la nature de l'aquifère observé, information que le chapitre 6 exploitera pour paramétrer les modèles métier.

Ce rattachement appelle une réserve. Le référentiel décrit les entités hydrogéologiques et leur ordre de superposition, mais ne porte pas leur profondeur. Déterminer laquelle un piézomètre capte réellement reste donc approximatif, difficulté que les hydrogéologues rencontrés signalent comme ouverte de leur côté également. L'enrichissement fourni est une indication utile, pas une caractérisation certaine de l'ouvrage.

La couche expose au bout du compte des faits journaliers (chroniques piézométriques et hydro-métriques enrichies du climat), des faits agrégés mensuels et annuels, des dimensions de description (calendrier, géographie, stations) et les grilles climatiques, soit dix-huit modèles de transformation complétés par des tables d'indicateurs calculées en Python. Les faits journaliers sont stockés en *hypertables* TimescaleDB compressées, forme de partitionnement temporel qui maintient les performances d'interrogation sur plusieurs dizaines de millions de lignes.

L'ensemble est directement interrogeable en SQL. C'est le contrat d'interface : un consommateur n'a besoin de connaître ni la chaîne d'ingestion, ni les outils employés, seulement le schéma des tables finales.

3.7 Orchestration : planifier l'ingestion, déclencher la transformation

L'ingestion est **planifiée** par Dagster : mise à jour quotidienne des chroniques et du climat, rafraîchissement mensuel du référentiel, contrôle hebdomadaire de complétude, recalcul hebdomadaire des références statistiques. La transformation, elle, est **déclenchée par événement** : dès que de nouvelles données brutes sont disponibles, un capteur lance la chaîne de transformation, laquelle déclenche à son tour le recalcul des indicateurs et les contrôles qualité. L'ensemble compte huit traitements planifiés et trois capteurs.

Ce choix évite le défaut classique des chaînes entièrement planifiées, où la transformation s'exécute à heure fixe sur des données parfois absentes, et produit des résultats partiels sans que rien ne le signale.

Les contrôles, enfin, ne bloquent pas le rafraîchissement : les tests de qualité s'exécutent en parallèle du recalcul des indicateurs, et non en amont. Un test en échec fait échouer sa propre exécution, donc alerte, mais n'empêche pas la donnée d'être mise à jour. L'arbitrage est délibéré : sur une chaîne de surveillance, une donnée imparfaite mais fraîche est préférable à une donnée absente, à condition que le défaut soit signalé.

3.8 Les garanties de la chaîne, et comment elles ont été éprouvées

Trois propriétés décident de la confiance que l'on peut accorder à un jeu de données partagé.

- **L'idempotence** : relancer une ingestion sur une période déjà chargée ne duplique rien. Le mécanisme est explicite plutôt que délégué. Avant chaque chargement, les lignes de la plage visée sont supprimées, puis les nouvelles sont ajoutées. Ce choix, plus verbeux qu'une fusion sur clé, fonctionne sur des tables dont les colonnes sont encore textuelles à ce stade, et rend la suppression visible dans le code plutôt qu'implicite dans une configuration.
- **La reprise** : le chargement initial complet, qui se compte en jours, est interruptible et redémarrable, son avancement étant persisté en base.
- **La maîtrise de la concurrence** : les exécutions ne sont pas globalement sérialisées, ce qui serait simple mais lent. Elles sont contraintes par clés, chaque clé plafonnant le nombre d'exécutions simultanées d'une même nature, de sorte qu'un rechargement historique n'affame jamais la mise à jour quotidienne.

Ces propriétés ne se vérifient pas sur le papier. Elles ont été éprouvées en exploitation réelle, et le manuel d'exploitation du dépôt en conserve le détail.

3.8.1 Deux règles contre les défaillances qui ne s'annoncent pas

Une chaîne de données peut s'exécuter, se déclarer réussie et livrer un résultat faux. Aucun test unitaire ne détecte ce cas, puisque le code fait exactement ce qu'on lui demande. Deux règles en découlent, appliquées ici :

- les garanties d'unicité sont portées par le schéma de la base quand c'est possible, et par l'orchestration quand ce ne l'est pas, jamais par l'hypothèse implicite que deux traitements ne se croiseront pas ;
- la surveillance porte sur la **fraîcheur des données** et non sur le succès des exécutions. Comparer la date maximale présente en base à celle réellement disponible chez le fournisseur est la seule vérification qui détecte une ingestion figée sur une réponse périmée.

Ce que cette chaîne change se mesure à une chose : obtenir soixante ans de niveaux de nappe joints à leur climat demandait plusieurs semaines de préparation. C'est aujourd'hui une requête.

4 Des mesures aux indicateurs : construction et validation

Une mesure brute ne dit rien de la situation qu'elle décrit. Comment produire des indicateurs normalisés, comparables entre stations et entre années, et comment établir qu'ils sont justes ?

4.1 Pourquoi standardiser

Un niveau piézométrique de 12,4 m n'est ni haut ni bas dans l'absolu : il l'est relativement à ce que l'ouvrage observe habituellement à cette période de l'année. La même remarque vaut pour un cumul de pluie ou une température. L'usage opérationnel suppose donc de rapporter chaque mesure à sa **distribution de référence** : décider s'il faut restreindre les prélèvements, comparer deux bassins, situer un épisode dans l'histoire climatique.

C'est l'objet des indices standardisés. Leur principe est constant : ajuster une loi de probabilité sur la série de référence, puis transformer la valeur observée en un score exprimé en écarts-types d'une loi normale centrée réduite. Un score de -2 signifie alors la même chose partout : une situation d'une rareté que les échelles usuelles rangent parmi les sécheresses les plus marquées.

Deux familles ont été produites : les indices *par station*, calculés sur les niveaux de nappe et les débits, et les indices *sur grille*, calculés sur les variables climatiques pour chaque maille du territoire.

4.2 Les indices par station

L'indicateur piézométrique standardisé et son équivalent pour les débits situent le mois courant par rapport à sa normale saisonnière. La méthode est centralisée dans un unique module, et l'application ne la recalcule pas : elle lit les tables produites par l'entrepôt.

Étape	Détail
Référence	Fenêtre fixe 1991–2020, normale climatique retenue par l'Organisation météorologique mondiale et par le BRGM. Ce n'est pas une fenêtre glissante.
Grille	Par mois calendaire, percentiles empiriques de 1 à 99 sur la fenêtre. Un mois comptant moins de dix observations est interpolé depuis son voisin circulaire.
Score	Rang percentile dans la grille, borné à $[0,001 ; 0,999]$, puis projeté sur la loi normale par sa fonction quantile.
Classes	Sept classes délimitées par les seuils $z \in \{-1,75 ; -1,28 ; -0,84 ; 0,84 ; 1,28 ; 1,75\}$.

Toutes les stations ne disposent pas de trente années d'historique. Plutôt que d'écarter les stations courtes ou de leur appliquer silencieusement une référence plus faible, la sélection de fenêtre se dégrade par paliers déclarés : la normale 1991–2020 si au moins quinze années sont disponibles, sinon la meilleure fenêtre trentenaire alignée sur les décennies, sinon l'historique complet. Le palier retenu est inscrit dans une colonne accompagnant chaque valeur, de sorte qu'un utilisateur sait toujours sur quelle base une station est classée.

Une limite de portée doit être connue. L'indicateur piézométrique standardisé a été conçu pour les nappes libres, dont le niveau suit une cyclicité annuelle marquée. Il est ici calculé pour toutes

les stations sans distinction, faute d’une information fiable permettant d’identifier les ouvrages captant une nappe captive. Les échanges avec les hydrogéologues ont confirmé qu’aucun indicateur équivalent n’existe aujourd’hui pour ces nappes, et que le sujet fait l’objet de travaux dédiés. La valeur produite pour une station captive doit donc être lue avec prudence : elle est calculée correctement, mais l’indicateur n’a pas été pensé pour ce cas.

Une grille n’est jamais fabriquée pour autant. Si aucun mois n’est exploitable, elle reste nulle et l’indice prend la valeur *inconnu*. Produire une classe plutôt qu’un aveu d’ignorance reviendrait à inventer une information que l’utilisateur lirait comme une mesure.

La table de référence est recalculée *hebdomadairement*, et non chaque nuit ni une fois par décennie. La fenêtre est fixe, mais les grilles par station ne le sont pas : une station accumule de l’historique, de nouvelles stations apparaissent, et une station classée en référence provisoire peut franchir le seuil des quinze années.

4.3 Les indices climatiques sur grille

Trois indices sont calculés pour chaque maille de $0,1^\circ$, sur quatre fenêtres d’agrégation de 1, 3, 6 et 12 mois correspondant à des inerties différentes du système hydrologique. Tous emploient la période de référence 1991–2020 et l’échelle à sept classes de McKee [25], adoptée par l’Organisation météorologique mondiale.

Indice	Grandeur	Ajustement
SPI	Précipitation	Loi gamma, mélangée à la probabilité de cumul nul
STI	Température	Loi normale (score centré réduit)
SPEI	Précipitation moins évapotranspiration	Loi logistique généralisée

4.4 Premier arbitrage : quelle évapotranspiration employer

4.4.1 De quoi il est question

L’indice de bilan hydrique, le SPEI, compare ce que le ciel apporte à ce que l’atmosphère reprend. L’apport, c’est la pluie, et elle se mesure. Le prélèvement, c’est l’**évapotranspiration** : l’eau qui repart vers l’atmosphère, à la fois par évaporation directe du sol et par transpiration des plantes. Cette seconde grandeur ne se mesure pas partout, il faut donc la calculer.

Or « calculer l’évapotranspiration » n’a pas de sens tant qu’on n’a pas dit *de quelle surface*. Un lac, une forêt et un champ de blé n’évaporent pas la même quantité d’eau sous le même ciel. Pour rendre les chiffres comparables d’un pays à l’autre, l’Organisation des Nations unies pour l’alimentation et l’agriculture, la **FAO**, a fixé une convention dans un document de référence appelé FAO-56 [2] : on calcule ce qu’évaporerait une surface conventionnelle, un gazon ras et bien alimenté en eau. C’est l’**évapotranspiration de référence**, et c’est elle qu’emploient les hydrologues, les agronomes et les indices de sécheresse publiés.

4.4.2 Ce qui s’est passé

ERA5-Land fournit directement une variable nommée « évaporation potentielle », et son emploi paraît naturel. Ses valeurs sont pourtant incompatibles avec ce que l’on sait du climat français. Comparée sur 30 888 couples maille-mois entre 2015 et 2025, sur les mêmes mailles :

	Hargreaves (référence FAO-56)	Variable ERA5-Land (« évaporation potentielle »)	Rapport
Évapotranspiration annuelle	818 mm	1 756 mm	$\times 2,15$
Bilan précipitation moins ETP	146 mm an ⁻¹	-793 mm an ⁻¹	

La seconde colonne place **l'intégralité du territoire français en déficit hydrique permanent**, y compris les années humides, ce qui est physiquement faux. La valeur de 818 mm an⁻¹ se situe dans l'intervalle des références publiées pour la France (700 à 900 mm an⁻¹) ; celle de 1 756 mm an⁻¹ n'y est pas.

4.4.3 Pourquoi

Les deux grandeurs portent des noms voisins et ne décrivent pas la même chose. Il n'y a d'erreur nulle part : la variable d'ERA5 est conforme à ce qu'elle annonce, elle ne correspond simplement pas à la grandeur dont le SPEI a besoin. Le travail n'était donc pas de corriger un défaut, mais d'identifier la bonne grandeur et de la produire.

Elle répond à la question : *combien cette surface pourrait-elle évaporer si l'eau ne manquait jamais*, dans les conditions du modèle atmosphérique qui l'a produite. C'est une borne haute théorique, et la littérature documente qu'elle dépasse largement la demande réelle d'un couvert végétal. La grandeur de la FAO répond à une autre question : *combien évapore la surface conventionnelle de référence*.

Pour obtenir la seconde, la FAO-56 prévoit une méthode complète, qui exige le rayonnement, le vent et l'humidité. Ces variables n'étaient pas ingérées. Le même document recommande alors une méthode de repli, la formule de Hargreaves [17], qui n'a besoin que des températures journalières minimale, maximale et moyenne, plus le rayonnement reçu au sommet de l'atmosphère, lequel se calcule à partir de la seule latitude et du jour de l'année. C'est cette formule qui a été implémentée, directement en SQL.

4.4.4 Ce que cela change

Le choix de la grandeur décide de la justesse de tout ce qui en découle. Avec la variable brute, les indices de bilan hydrique auraient reposé sur un déficit d'eau surestimé de plus du double, et la carte nationale aurait affiché une France en sécheresse quasi permanente, y compris pendant les années pluvieuses. L'anomalie aurait été lue comme un signal climatique alors qu'elle n'aurait tenu qu'à une confusion entre deux définitions.

C'est le genre de piège qu'aucun test logiciel ne détecte, et c'est ce qui le rend coûteux : le calcul était juste, le code sans faute, seule la grandeur employée n'était pas la bonne. Seule la confrontation des valeurs obtenues aux ordres de grandeur connus pour la France pouvait le révéler.

Les deux grandeurs coexistent dans l'entrepôt et suivent des trajectoires distinctes : la variable brute est ingérée telle quelle, l'évapotranspiration de référence est calculée en couche analytique à partir des températures journalières. Elles figurent côte à côte dans la table finale, ce qui a rendu possible la mesure comparative ci-dessus. L'annexe A.3 donne le détail des colonnes, couche par couche.

4.4.5 Une incohérence connue, et ce qu'elle coûte

Cet arbitrage ne vaut que pour la chaîne climatique sur grille. La chaîne des stations expose encore, sous le nom `potential_evaporation`, la variable brute d'origine. C'est elle qui alimente les modèles métier du chapitre 6, et il faut le dire sans détour : **les modèles calibrés sur les stations ne reçoivent pas l'évapotranspiration de référence**, mais une grandeur environ deux fois

plus élevée. Mesuré sur les données en base, le forçage station vaut $1\,839\text{ mm an}^{-1}$ là où l'ET0 de référence se situe autour de 818 mm an^{-1} .

L'effet de cet écart a été mesuré plutôt que supposé. Sur une station de contrôle, un même modèle a été calibré deux fois, avec la variable brute puis avec une évaporation ramenée à l'ordre de grandeur de référence. Deux enseignements en ressortent.

D'abord, **le modèle n'absorbe pas l'erreur d'échelle**. On pouvait espérer que le paramètre qui pondère l'évaporation dans la recharge s'ajuste et compense, laissant la prévision inchangée. Il n'en est rien : ce paramètre est borné, et la calibration le pousse à sa borne dans les deux cas. Il ne lui reste aucune marge pour corriger quoi que ce soit.

Ensuite, l'ajustement en dépend réellement : la variance expliquée passe de 72,2 % à 68,5 % entre les deux jeux de forçage. Le fait que la variable brute donne le meilleur ajustement ne signifie pas qu'elle soit la bonne. Un paramètre collé à sa borne indique au contraire un modèle qui réclame davantage d'évaporation que son forçage ne lui en fournit, c'est-à-dire le symptôme d'une entrée mal dimensionnée.

La portée de cette mesure doit être précisée : elle porte sur une seule station et sur une période de 385 jours, seule profondeur disponible dans la base au moment de la vérification. Le protocole et les valeurs obtenues sont consignés dans le dépôt de la plateforme, afin que la mesure puisse être rejouée plutôt que crue sur parole. Elle établit que l'écart a un effet, non son ampleur générale. Une évaluation sur un historique long et un échantillon de stations reste à conduire.

Pourquoi cette incohérence n'a-t-elle pas été corrigée ? Parce que la correction n'est pas un changement de colonne. La chaîne station ne transporte que la température moyenne, alors que la formule de Hargreaves exige aussi les extrêmes journaliers. Il faudrait donc les ajouter, y calculer l'évapotranspiration au pas journalier, puis propager le résultat dans deux tables partitionnées, ce qui impose une reconstruction complète, et enfin recalibrer les modèles existants. Engager cette chaîne d'opérations sans pouvoir la valider sur un historique complet aurait remplacé une incohérence documentée par une incertitude non mesurée.

C'est donc le premier chantier que ces travaux laissent à leur suite, et il est prioritaire sur toute campagne de calibration : tant qu'il n'est pas traité, les paramètres des modèles métier n'ont pas d'interprétation physique directe, même si leur pouvoir prédictif reste utilisable.

4.5 Deuxième arbitrage : quelle loi ajuster pour le SPEI

Un indice standardisé transforme une valeur en score de rareté, ce qui suppose d'ajuster une loi de probabilité sur la série de référence. Le choix de cette loi détermine sur quelles mailles l'indice pourra être calculé.

L'article fondateur du SPEI [37] emploie une loi log-logistique. Appliquée à la grille française, elle ne s'ajuste que sur 74,6 % des combinaisons de maille, de mois et de fenêtre. Le manque n'est pas uniforme : selon la fenêtre d'agrégation, la couverture va d'environ deux tiers à un peu moins de neuf dixièmes, ce qui laisse des trous mouvants dans la carte nationale. L'instrumentation des rejets a montré que la cause était unique et structurelle : cette loi ne représente qu'un sens d'asymétrie, et environ 27 % des mailles françaises présentent l'autre. Aucune quantité de données supplémentaire n'y aurait changé quoi que ce soit.

L'implémentation de référence du SPEI [4], distribuée par les auteurs de la méthode, emploie quant à elle la logistique généralisée, qui accepte les deux sens. C'est elle qui a été retenue. Le choix n'a donc rien d'original : il consiste à suivre la pratique établie plutôt que la seule formulation de l'article. La couverture passe à 100 %.

Le remplacement est par ailleurs sans effet sur l'existant. Les deux lois étant équivalentes par

reparamétrage, les valeurs restent inchangées partout où la première fonctionnait, ce qui a été vérifié à un écart maximal de 0,000 sur 35 614 ajustements. La carte se complète là où elle était trouée, sans que rien d'autre ne bouge.

4.6 La vérification des indices produits

Un indice standardisé doit, par construction, suivre approximativement une loi normale centrée réduite *sur sa propre période de référence*. C'est une propriété vérifiable, et elle a été vérifiée.

Le critère d'acceptation a été fixé **avant** la mesure : moyenne voisine de zéro à $\pm 0,05$, écart-type voisin de un à $\pm 0,05$, et taux de saturation aux bornes inférieur à 1 %. Fixer le critère avant de mesurer évite l'ajustement rétrospectif du seuil au résultat obtenu.

La mesure porte sur 41 960 400 valeurs couvrant 11 496 mailles.

Indice	Fenêtres	Moyenne	Écart-type	Médiane	Saturation
SPI	1/3/6/12	-0,008 à +0,002	0,985 à 1,031	0,00 à 0,04	0,05 à 0,51 %
STI	1/3/6/12	0,000	0,983	-0,09 à -0,02	0,00 à 0,04 %
SPEI	1/3/6/12	+0,004 à +0,006	0,999 à 1,013	0,01 à 0,03	0,012 à 0,035 %

Les trois indices satisfont le critère d'acceptation sur les quatre fenêtres. La couverture du SPEI est uniforme à 100 %, ce qui signifie que la calibration n'est pas seulement préservée mais mesurée sur l'ensemble du domaine.

4.7 Deux lectures à ne pas faire

La validation ci-dessus autorise l'usage des indices ; elle n'autorise pas toutes les interprétations. Deux mises en garde ont été consignées, parce que l'erreur correspondante est naturelle.

La première porte sur la classe « normale », qui ne couvre pas la proportion théorique. Elle représente 54,8 % des valeurs au lieu des 59,9 % attendus d'une gaussienne, alors même que l'écart-type vaut 1,008. La distribution conserve des épaules légèrement plus lourdes. Cet écart est une propriété de la transformation au voisinage des bornes de classe. Il n'a pas de conséquence opérationnelle, les seuils employés étant ceux, communs, des autres indices, et il ne doit surtout **pas** être lu comme une anomalie de sécheresse.

La seconde porte sur la décroissance décennale du SPEI, qui est un signal climatique et non une dérive de méthode. La moyenne sur fenêtre d'un mois décroît de manière monotone d'une décennie à l'autre : +0,038 dans les années 1990, +0,007 dans les années 2000, -0,016 dans les années 2010, -0,117 depuis 2020. Cette évolution avait été anticipée avant d'être mesurée, ce qui la distingue d'un artefact d'ajustement : elle traduit un assèchement, non un biais.

4.8 Un contrat entre les deux dépôts

La classification en sept classes existe en deux endroits : dans l'entrepôt, qui produit les indicateurs, et dans la plateforme, qui les affiche et les compare aux prévisions. Cette duplication est délibérée, car elle évite un couplage fort entre deux systèmes déployés séparément, mais elle crée un risque de divergence silencieuse.

Le risque est traité par un **contrat testé** : chaque dépôt possède une table de référence associant des valeurs d'entrée aux classes attendues, et ces deux tables sont identiques par construction. Toute modification de l'une sans l'autre fait échouer une suite de tests. Le mécanisme est simple, et c'est sa vertu : il rend la contrainte exécutable plutôt que documentaire.

L'entrepôt produit désormais une famille d'indicateurs normalisés à l'échelle nationale, utilisables tels quels par les hydrogéologues et candidats comme variables de modélisation. Le critère de leur validation avait été fixé avant la mesure, et les deux décisions méthodologiques structurantes sont documentées avec les chiffres qui les établissent.

5 L'Observatoire : donner à voir

Un entrepôt ne se consulte pas. Comment rendre la donnée consolidée immédiatement lisible par ceux qui en ont l'usage, sans enfermer les méthodes développées dans l'application qui les héberge ?

5.1 Une contrainte d'architecture posée d'emblée

La plateforme comporte trois couches : une interface web en React [26], un service applicatif FastAPI [32], et une bibliothèque métier en Python. La contrainte structurante porte sur la troisième : **la bibliothèque métier ne comporte aucune dépendance à l'interface**.

Cette règle a une conséquence pratique déterminante pour un travail de recherche. Le code de préparation des données, de calibration des modèles métier, d'entraînement, d'explicabilité et de génération de contrefactuels s'exécute indifféremment depuis le service web, depuis un script ou depuis un carnet de calcul. Les méthodes développées ne sont donc pas prisonnières de l'application : si l'interface était abandonnée, elles resteraient utilisables.




Figure 5.1 – Architecture de la plateforme. La bibliothèque métier est appellable depuis le service web, un script ou un carnet de calcul, sans modification. C'est cette propriété qui rend les développements réutilisables au-delà de l'application.

5.2 Le besoin : explorer avant de modéliser

Un entrepôt bien construit reste inerte tant qu'il n'est pas regardé. Deux publics le demandaient, pour des raisons différentes.

Les **hydrogéologues** ont besoin de situer une station dans son contexte : quelle nappe observe-t-elle, comment se comporte-t-elle par rapport à ses voisines, où en est-elle dans son historique, et que faisait le climat pendant ce temps. Ce travail de mise en regard, fait manuellement, mobilise plusieurs sources et plusieurs outils.

Les **modélisateurs** ont besoin de choisir leurs cas d'étude en connaissance de cause : une station dont la chronique est trop courte, trop lacunaire ou visiblement perturbée par un pompage ne fera

pas un bon cas d'apprentissage. Repérer ces situations avant d'entraîner un modèle évite d'attribuer à la méthode ce qui relève de la donnée.

L'Observatoire répond aux deux.

5.3 Organisation : deux compartiments

L'interface s'organise en deux volets correspondant aux deux compartiments du cycle observé.

Le premier volet, nappes et rivières, donne l'exploration spatiale des stations piézométriques et hydrométriques sur fond cartographique, avec superposition des entités aquifères du référentiel BDLISA et d'un découpage en secteurs hydrogéologiques. Les indicateurs de situation y sont portés directement par les stations, ce qui donne une lecture immédiate de l'état du territoire. La comparaison entre stations est possible, avec conservation de la sélection d'une vue à l'autre.

Le second, le climat, donne l'exploration de la grille nationale de 0,1° selon trois vues : une vue de situation cartographique à l'échelle du pays, une vue par point ou par zone donnant l'historique d'une maille depuis 1950 (pluie comparée à la normale, indices sur plusieurs fenêtres, table des épisodes de sécheresse, export tabulaire), et une vue de comparaison inter-annuelle.

Les deux volets communiquent : depuis la carte des nappes, un lien contextuel ouvre le climat de la maille correspondante ; depuis la fiche d'une station, on accède à son contexte climatique local.

5.4 Une règle de conception qui a structuré l'interface

Les couches cartographiques disponibles obéissent à une règle explicite, adoptée après discussion et maintenue depuis :

*Soit un indicateur réellement standardisé, soit une valeur réelle affichée comme telle.
Jamais un intermédiaire inventé.*

Concrètement, les indices standardisés (précipitation, température, bilan hydrique) sont cartographiés sur l'échelle à sept classes, et les grandeurs journalières brutes (températures extrêmes, pluie du jour) le sont sur une échelle absolue. En revanche, les cumuls mensuels absolus de pluie, de température ou d'évapotranspiration ne sont **pas** proposés comme couches cartographiques : ils apparaissent comme chiffres exacts dans le panneau de détail d'une maille.

La raison est méthodologique. Cartographier une grandeur absolue sur une palette de couleurs suppose un seuillage, donc une norme implicite. Or cette norme, n'étant pas une référence statistique établie, serait une invention de l'outil. L'utilisateur lirait une carte de sécheresse là où il n'y a qu'un choix de bornes. Refuser cette couche coûte une fonctionnalité apparente et évite une erreur d'interprétation systématique.

5.5 Trois choix techniques

L'Observatoire recalcule le moins possible : ses points d'accès lisent les tables analytiques de l'entrepôt plutôt que de refaire le calcul. La carte, la situation courante et les exports lisent ainsi les indicateurs déjà produits, de sorte que **la valeur affichée est exactement celle qui a été validée** au chapitre 4. Deux points d'accès font exception, ceux qui servent la série historique d'une station : ils lisent la grille de référence dans l'entrepôt, mais appliquent la standardisation à la requête. Le calcul reste le même, et un test croisé garde la cohérence des classes entre les deux dépôts.

Les réponses sont mises en cache, ensuite. Les vues cartographiques nationales portent sur des volumes importants et changent peu ; leur mise en cache pour vingt-quatre heures réduit la charge sans affecter la fraîcheur perçue. Les couches qui bougent plus vite ont des durées plus courtes, de

quelques heures pour le fond de carte des stations à une heure pour les alertes. Cette optimisation a un corollaire opérationnel documenté : tout déploiement qui modifie la forme ou la valeur des réponses doit purger le cache, sous peine de servir des valeurs périmées pendant une journée.

Le point d'entrée, enfin, est unique. Le service qui sert l'interface assure également le relais vers l'API, les en-têtes de sécurité et la limitation de débit. Regrouper ces fonctions dans un seul composant vaut moins pour la simplicité que pour ce que cela écarte : une protection configurée dans un composant qui ne tourne pas est une protection absente, avec en plus la croyance qu'elle existe.

5.6 Environnements et déploiement

La séparation des environnements décrite au chapitre 3 prend ici tout son sens : elle autorise à expérimenter sur une chaîne en évolution sans compromettre l'instance qui sert les utilisateurs. La production est répartie : l'interface est déployée sur l'infrastructure mutualisée de l'établissement, le calcul et les bases restent sur le serveur équipé d'un processeur graphique. Une seule exigence réseau conditionne l'ensemble, l'ouverture de la route entre les deux.

L'Observatoire dépend entièrement de l'entrepôt, et ne se dégrade pas gracieusement en son absence : il répond en erreur plutôt que d'afficher un état partiel. Le choix est assumé pour un outil scientifique, où une valeur absente vaut mieux qu'une valeur douteuse. Il serait à revoir pour une diffusion large.

6 Modéliser : le laboratoire de modèles métier

Avant d'invoquer l'apprentissage profond, que sait déjà faire la modélisation hydrogéologique établie, et comment l'outiller pour qu'elle serve de référence ?

6.1 Pourquoi commencer par le modèle métier

Il aurait été possible d'aller directement à l'apprentissage profond. Ce choix aurait été méthodologiquement fautif, pour trois raisons.

D'abord, **sans référence, une performance ne signifie rien**. Annoncer qu'un réseau de neurones prévoit un niveau de nappe avec une certaine erreur n'a de sens que comparé à ce qu'obtient la méthode que les hydrogéologues emploient déjà. Une architecture profonde qui n'égale pas un modèle à quelques paramètres ne mérite pas d'être déployée.

Ensuite, **le modèle métier est interprétable par construction**, et fournit donc un point d'ancrage à tout le travail d'explicabilité qui suivra. On sait ce qu'il représente ; on peut confronter les explications produites sur un modèle appris à ce que le modèle physique affirme.

Enfin, **c'est le langage des interlocuteurs**. Le BRGM développe et emploie sa propre famille de modèles à réservoirs : GARDÉNIA [9] pour la simulation des niveaux et des débits d'un bassin, EROS [8] pour les relations entre bassins, fédérés par une interface Python commune. Un outil qui ignorerait cette pratique ne serait pas adopté, quelles que soient ses performances.

6.2 Les modèles à fonction de transfert et bruit

L'approche retenue est celle des modèles *transfer function-noise*, mise en œuvre par la bibliothèque Pastas [11]. Son principe : le niveau piézométrique simulé est la somme des contributions de plusieurs facteurs de forçage, au minimum la recharge dérivée de la précipitation et de l'évapotranspiration. Chaque contribution est obtenue par convolution du forçage avec une *fonction de réponse impulsionnelle* dont la forme et les paramètres sont calibrés. Un modèle de bruit rend compte de la structure résiduelle.

L'intérêt pour la question posée est direct : la fonction de réponse **est** l'objet d'intérêt hydrogéologique. Sa forme dit comment l'aquifère amortit et retarde le signal climatique ; son intégrale dit de combien le niveau varie pour une sollicitation donnée. Ce ne sont pas des paramètres opaques, ce sont des grandeurs qui s'interprètent.

La plateforme donne accès à quatre modèles de recharge, cinq formes de réponse impulsionnelle proposées à la sélection, deux modèles de bruit et deux solveurs, combinables librement.

6.3 Calibration automatique et critères de qualité

Choisir la bonne combinaison relève de l'expertise et de l'essai. Pour rendre cet essai systématique, un mécanisme de **calibration automatique** construit une grille de configurations candidates, calibre chacune, l'évalue et les classe.

L'évaluation ne repose pas sur un unique indicateur d'erreur, mais sur les quatre critères d'acceptation STOWA [38], standard néerlandais d'évaluation des modèles TFN pour la gestion des eaux souterraines :

1. **La variance expliquée** dépasse un seuil (70 % par défaut) ;
2. **les résidus sont aléatoires**, vérifié par un test de séquences ;

3. **le temps de réponse** à 95 % de la réponse indicielle reste inférieur à la moitié de la période de calibration, car un modèle dont la mémoire excède ses données n'est pas identifiable ;
4. **le gain est statistiquement significatif**, son rapport à son erreur type dépassant le seuil usuel.

Cette démarche recoupe la méthode de travail des hydrogéologues telle qu'ils l'ont décrite : partir du modèle le plus simple, examiner les résidus pour identifier ce qu'il ne capte pas, puis enrichir la structure en conséquence. La calibration automatique outille cet enchaînement, et les diagnostics de résidus présentés plus loin en fournissent la seconde étape.

Le troisième critère capture une erreur fréquente et discrète : un modèle peut afficher une excellente variance expliquée tout en ayant ajusté une dynamique lente que la période d'observation ne permet pas de contraindre. Le critère l'écarte.

6.4 L'apport hydrogéologique : des configurations par famille d'aquifère

La grille de calibration automatique n'explore pas l'espace des configurations à l'aveugle. Elle est amorcée par des **configurations recommandées selon la nature de l'aquifère observé**, lue dans le référentiel BDLISA rattaché à la station par l'entrepôt (chapitre 3).

Cette table est le produit direct des échanges avec l'expertise hydrogéologique du BRGM. Elle traduit en choix de modélisation ce qu'un spécialiste sait du comportement de chaque milieu.

Famille	Réponse	Bruit	Justification hydro-géologique
Alluvial	Exponentielle	AR	Réponse rapide, temps de réponse court, système simple
Sédimentaire poreux	Gamma	AR	Réponse intermédiaire
Sédimentaire, double porosité (craie)	Gamma	AR	Forte inertie, temps de réponse long
Sédimentaire fracturé	Gamma	AR	Recharge complexe, modèle de recharge flexible
Karstique	Double exponentielle	ARMA	Deux temps de réponse : conduits et matrice
Socle, montagne	Gamma	AR	Fracturé, recharge non linéaire
Volcanique	Gamma	AR	Système hétérogène
Composite	Quatre paramètres	ARMA	Milieu hétérogène, modèle flexible

Le cas karstique est le plus parlant. Un système karstique se comporte comme deux réservoirs couplés : des conduits qui réagissent en quelques heures et une matrice qui réagit en mois. Une réponse impulsionnelle à un seul temps caractéristique ne peut pas représenter cette dualité. D'où la double exponentielle, et un modèle de bruit plus riche pour absorber ce que la structure ne capte pas.

Elle recoupe la typologie que les hydrogéologues emploient eux-mêmes, qui distingue les nappes inertielles à cycles longs, les nappes réactives à effets de seuil et les nappes influencées par une

rivière ou des prélèvements. Elle encode ainsi une connaissance qui ne s'obtient pas par validation croisée, et la rend disponible à un utilisateur qui ne la possède pas.

Ces configurations amorcent la recherche ; elles ne la contraignent pas. Une grille de référence est systématiquement évaluée en parallèle, de sorte qu'une station atypique n'est jamais enfermée dans la recommandation de sa famille.

6.5 Diagnostics et validation

La calibration est accompagnée d'un dispositif de vérification qui va au-delà de l'ajustement.

Le modèle est calibré sur une période et évalué sur une période distincte, avec les indicateurs usuels en hydrologie (efficience de Nash-Sutcliffe, critère de Kling-Gupta, erreur quadratique moyenne), complétés par l'examen de l'autocorrélation et de la normalité des résidus.

Avant même la calibration, la chronique est examinée : qualité et continuité des entrées, valeurs aberrantes, corrélations croisées avec le forçage, décomposition du signal, analyse spectrale, analyse des tarissements. Ce faisceau permet de détecter en amont les situations où la modélisation est vouée à l'échec, plutôt que de le découvrir dans un mauvais ajustement.

Les résidus peuvent enfin être examinés conjointement sur plusieurs stations, ce qui fait apparaître les structures communes, donc d'origine régionale ou climatique, et les distingue des particularités locales.

6.6 Scénarios prospectifs

Le modèle calibré n'est pas seulement descriptif : il permet de répondre à des questions de la forme « *que se passerait-il si* », qui sont précisément celles des gestionnaires.

Quatre types de modification sont outillés. L'**ajout d'un prélèvement synthétique** suit des profils réalistes par type d'usage, alimentation en eau potable, irrigation ou industrie, chacun avec sa saisonnalité propre. L'**import d'une chronique de prélèvement réelle** permet de rejouer un pompage documenté plutôt que simulé. Enfin, une **tendance climatique** et une **mise à l'échelle** d'un forçage existant complètent la panoplie.

Reste le mécanisme des **bornes adaptatives**. Lorsqu'un utilisateur simule un prélèvement, la question « quel débit est plausible ici ? » n'a pas de réponse universelle : elle dépend de la transmissivité de l'aquifère, donc de la réponse calibrée. Le rabattement attendu est estimé à partir de la réponse indicielle du modèle lui-même, et des bornes physiquement plausibles en sont dérivées pour guider la saisie. L'utilisateur n'est pas laissé libre de simuler un pompage qui viderait la nappe en un mois, ni contraint par une borne arbitraire identique partout.

Ce chapitre décrit un instrument, non des résultats. Aucune campagne de calibration sur un large échantillon n'a été conduite, et la comparaison avec les approches apprises reste à faire. Ce que le laboratoire apporte, c'est la possibilité de mener ces travaux sans les préparer.

Une réserve accompagne tout usage : les modèles y sont calibrés sur l'évapotranspiration transportée par la chaîne des stations, qui vaut environ le double de la grandeur de référence (section 4.4). Les calibrations restent exploitables pour la prévision, mais leurs paramètres ne s'interprètent pas physiquement tant que ce forçage n'a pas été corrigé.

7 Apprendre : le laboratoire d'apprentissage automatique

Quel dispositif faut-il pour que des expériences d'apprentissage profond sur des séries hydrologiques soient comparables, reproductibles, et conduites par des chercheurs qui ne sont pas tous spécialistes de l'apprentissage ?

7.1 Le problème posé

Prévoir un niveau de nappe est un problème de série temporelle multivariée avec covariables exogènes : la cible est le niveau, les entrées sont la précipitation, la température et l'évapotranspiration. Les difficultés propres au domaine sont connues : inertie très variable d'un aquifère à l'autre, non-stationnarité liée aux prélèvements, lacunes d'observation, événements extrêmes rares donc sous-représentés dans l'apprentissage.

La littérature propose de nombreuses architectures ; aucune ne s'impose a priori. La question pratique n'est donc pas « quel modèle choisir » mais « comment mettre en place un dispositif qui permette de trancher, et de rejouer la comparaison quand les données changent ».

7.2 Un catalogue d'architectures sous interface unique

La plateforme donne accès à une douzaine d'architectures de prévision profonde issues de la bibliothèque Darts [19], couvrant les grandes familles de l'état de l'art :

- **à mécanisme d'attention** : *temporal fusion transformer* [23], transformeur classique ;
- **à décomposition par blocs** : N-BEATS, N-HITS ;
- **récurrentes** : LSTM, GRU, réseaux récurrents par blocs ;
- **convolutives** : réseaux convolutifs temporels ;
- **récentes à faible coût** : TiDE, TSMixer, DLinear, NLinear.

L'inclusion des dernières est délibérée : les modèles linéaires ou quasi linéaires constituent des références exigeantes sur les séries temporelles, et une architecture lourde qui ne les dépasse pas doit être écartée. Disposer de la référence faible dans le même outil que le modèle sophistiqué évite la comparaison biaisée par des conditions expérimentales différentes.

Une fabrique de modèles instancie dynamiquement l'architecture demandée en validant ses hyperparamètres, ce qui permet d'ajouter une architecture sans modifier l'interface ni l'API.

7.3 Le protocole expérimental

Le dispositif vise trois propriétés.

La traçabilité, d'abord. Chaque exécution d'entraînement est enregistrée dans MLflow [41] : paramètres, métriques, artefacts, modèle produit. Les jeux de données préparés et les modèles entraînés font l'objet de registres distincts, de sorte qu'un résultat puisse être rattaché sans ambiguïté au couple exact qui l'a produit. Sans ce mécanisme, une comparaison entre deux expériences menées à quelques semaines d'intervalle n'est pas défendable.

La séparation entre l'entraînement et l'interface, ensuite. Le code d'entraînement n'a aucune connaissance de l'interface qui l'observe : il écrit son avancement dans un fichier d'état, que la

couche de présentation lit indépendamment et retransmet au navigateur par un flux d'événements. Cette séparation, visible sur la figure 5.1, a une conséquence pratique importante : un entraînement lancé depuis un script se suit dans l'interface, et réciproquement.

La conduite d'expériences longues, enfin. L'entraînement s'appuie sur PyTorch Lightning [16] et s'effectue sur processeur graphique lorsque celui-ci est disponible, avec arrêt anticipé et suivi de l'évolution des pertes en apprentissage et en validation. L'utilisateur voit progresser son entraînement au lieu d'attendre un résultat opaque, et peut l'interrompre s'il diverge.

7.4 Optimisation d'hyperparamètres

La comparaison d'architectures n'a de sens que si chacune est évaluée dans une configuration raisonnable ; comparer un modèle réglé à un modèle laissé aux valeurs par défaut ne renseigne que sur le réglage. Optuna [1] est donc intégré pour la recherche automatisée d'hyperparamètres, avec un échantillonnage guidé par les essais déjà évalués. Chaque essai est par ailleurs interrompu dès que sa perte de validation cesse de progresser. L'élagage entre essais, qui abandonnerait une configuration en cours au vu des premières époques, n'est pas activé : ce serait le premier réglage à ajouter pour réduire le coût d'une campagne.

7.5 Rendre l'outil utilisable par des non-spécialistes

Un dispositif d'expérimentation complet est, par nature, exigeant : longueur de fenêtre d'entrée, taille de lot, nombre d'époques, patience d'arrêt anticipé. Ces réglages sont un obstacle réel pour un hydrogéologue qui souhaite simplement obtenir une prévision.

Des **configurations prêtes à l'emploi** ont donc été définies par cas d'usage métier plutôt que par architecture : prévision piézométrique à court terme (sept jours), à moyen terme (trente jours), à long terme (quatre-vingt-dix jours), et prévision de débit à quatorze jours. Chacune fixe une architecture et un jeu d'hyperparamètres cohérents, choisis à partir des recommandations de la bibliothèque et des références publiées sur séries piézométriques.

Ces configurations sont des points de départ raisonnables, non des réglages optimisés pour une station donnée. La documentation le dit explicitement et oriente vers la recherche automatisée d'hyperparamètres pour aller plus loin. Il aurait été facile, et trompeur, de les présenter comme optimales.

Les échanges avec les hydrogéologues ont d'ailleurs montré que cette réserve n'est pas de pure forme. La réponse d'un aquifère à la pluie varie fortement selon sa nature : certains systèmes sont inertiels et réagissent avec une forte latence, d'autres se rechargent presque directement. Les cycles observés vont de l'annuel au pluriannuel. La profondeur d'historique à fournir en entrée, l'horizon de prévision pertinent et le pas d'agrégation devraient donc être choisis selon le type de nappe, comme le sont déjà les configurations de modèles métier du chapitre 6. Cette adaptation par famille d'aquifère n'a pas été faite pour les modèles appris : elle constitue une piste identifiée, et vraisemblablement le premier gain à aller chercher.

7.6 Ce qui est établi, et ce qui ne l'est pas

Ce qui est acquis est le dispositif : un banc d'expérimentation instrumenté, traçable, qui rend les comparaisons possibles et rejouables, accessible à des utilisateurs de niveaux d'expertise différents, et dont le cœur est réutilisable hors de l'application.

Ce qui n'est pas établi dans ce rapport est le classement des architectures sur le cas hydrogéologique. Les campagnes d'entraînement conduites au cours des travaux ont servi à valider le dispositif et à orienter les développements ; les jeux de données préparés et les points de sauvegarde

ont été purgés des dépôts lors de la passation. Reconstituer a posteriori un tableau de performances à partir de souvenirs ne serait pas un résultat scientifique. La campagne d'évaluation comparative, qui opposerait les modèles appris aux modèles métier du chapitre 6 sur un échantillon représentatif de stations et de familles d'aquifères, reste donc à conduire, et l'outillage nécessaire est en place pour la mener.

Une limite d'ingénierie reste à corriger. La suite de tests de la plateforme compte 552 tests, dont 547 passent (mesuré le 24 août 2026). Aucun ne s'exécute automatiquement, faute d'une étape de test dans la chaîne d'intégration de la forge qui héberge le dépôt. Les cinq cas non passants, quatre échecs et un test ignoré, sont documentés et aucun ne signale un défaut applicatif, mais la purge des journaux se trouve de fait non testée. C'est le premier correctif à apporter par toute personne reprenant ces travaux.

8 Expliquer : le sujet initial, enfin abordable

Une prévision de niveau de nappe n'est mobilisable que si l'on peut dire sur quoi elle repose et ce qu'elle deviendrait dans d'autres conditions. Comment produire de telles explications sans qu'elles soient elles-mêmes trompeuses ?

8.1 Pourquoi l'explicabilité n'est pas une option ici

Le sujet initial du postdoctorat retrouve ici sa place, une fois construit le terrain qui le rendait abordable.

L'exigence d'explication ne relève pas, dans ce domaine, d'une préférence méthodologique : les décisions publiques rappelées au chapitre 1 doivent pouvoir être motivées.

S'y ajoute une condition d'adoption, moins souvent formulée. L'interlocuteur d'un modèle de nappe est un hydrogéologue qui possède une compréhension physique du système. Il n'accordera sa confiance qu'à un modèle dont les explications sont compatibles avec ce qu'il sait. Réciproquement, une explication qui contredit sa compréhension est une information précieuse : soit le modèle a capté quelque chose, soit il s'est trompé, et dans les deux cas il faut le savoir.

Trois questions organisent le dispositif : *sur quoi le modèle s'appuie-t-il ?*, *que se passerait-il dans d'autres conditions ?*, et *cette chronique est-elle seulement explicable par le climat ?*

8.2 Le rôle de ce chapitre dans une recherche en cours

Ces développements n'ont pas l'ambition qu'on pourrait leur prêter.

La deuxième question, celle des explications contrefactuelles et de leur qualité, fait l'objet de travaux de recherche menés au LIFAT sous la direction de Nicolas Labroche. Ces travaux portent sur ce qui constitue une bonne explication et sur la manière de le mesurer, question ouverte : les critères habituellement employés, validité de la sortie obtenue, proximité à l'observation d'origine, compacité de la modification proposée, décrivent la mécanique de l'optimisation plus qu'ils ne renseignent sur la valeur explicative du résultat.

Ce chapitre n'apporte pas de réponse à cette question. Il en construit les conditions matérielles. Étudier la qualité d'une explication contrefactuelle suppose d'avoir des modèles à expliquer, des données sur lesquelles ils ont été entraînés, au moins deux méthodes à comparer, un moyen de vérifier qu'un contrefactuel n'est pas un artefact du modèle qui l'a produit, et des cas d'étude qui ne soient pas pollués par des influences non climatiques. Rien de tout cela n'existait au démarrage. La suite de ce chapitre décrit ce qui a été mis en place pour que ces travaux puissent porter sur le domaine hydrogéologique, avec des données réelles, plutôt que sur des jeux d'essai génériques.

L'implémentation contrainte par la physique décrite en section 8.4 relève de la même logique : elle donne corps à une exigence formulée par les hydrogéologues, pour que l'évaluation puisse ensuite porter sur quelque chose de concret. Elle constitue une hypothèse outillée, pas un résultat.

8.3 Sur quoi le modèle s'appuie-t-il : les méthodes d'attribution

Le premier volet mobilise et adapte les familles usuelles d'attribution, chacune répondant à une facette différente de la question.

Famille	Ce qu'elle apporte
Importance par perturbation	Mesure la dégradation de la prévision quand une entrée est brouillée : lecture directe, sans hypothèse sur le modèle
Valeurs de Shapley [24]	Répartition de la contribution entre entrées sur des bases axiomatiques, avec une variante adaptée aux séries temporelles qui attribue aussi dans le temps [5]
Attributions par gradients [35, 21]	Saillance temporelle et gradients intégrés : quels pas de temps de la fenêtre d'entrée pèsent sur la sortie
Poids d'attention	Pour les architectures qui en possèdent, lecture directe de ce que le modèle regarde
Décomposition du signal	Sépare tendance, saisonnalité et résidu, et rapporte la prévision à ces composantes

L'intérêt de disposer de plusieurs familles dans un même outil n'est pas l'exhaustivité mais la **confrontation** : des méthodes qui reposent sur des principes différents et convergent donnent une explication crédible ; des méthodes qui divergent signalent que l'explication est fragile, ce qui est en soi une information utile, et qu'une méthode unique aurait masquée.

8.4 Que se passerait-il si : les contrefactuels sous contrainte physique

C'est le développement le plus spécifique de ce chapitre, et celui qui alimente le plus directement les travaux évoqués ci-dessus. Il répond à une exigence formulée par les hydrogéologues avant d'être traité.

8.4.1 Le problème du contrefactuel naïf

Une explication contrefactuelle [39] répond à : *quelle modification minimale des entrées changerait la prévision de telle manière ?* Appliquée à une nappe : quel régime climatique aurait évité l'étiage annoncé ?

Les approches existantes pour les séries temporelles [3, 40] optimisent directement la perturbation des entrées sous contrainte de proximité. Sur des données climatiques, elles produisent des réponses correctes au sens de l'optimisation et **physiquement absurdes** : elles peuvent augmenter la température sans modifier l'évapotranspiration, faire varier la pluie d'un jour à l'autre de manière incohérente, ou construire un régime saisonnier qui n'existe nulle part. Une telle explication est inutilisable : on ne peut pas dire à un gestionnaire que l'étiage aurait été évité dans un climat qui ne peut pas exister.

Les hydrogéologues y substituent deux exigences, et ce sont elles que la méthode décrite plus loin met en œuvre : le respect du bilan de masse, et la cohérence avec les échelles de temps auxquelles un aquifère réagit réellement.

8.4.2 La solution retenue : contraindre l'espace de perturbation

L'approche développée renonce à perturber librement les entrées. Elle optimise à la place un petit nombre de paramètres interprétables, dont chacun a un sens physique et une plage de validité :

Paramètre	Plage	Neutre	Interprétation
Facteur de pluie (par saison, 4)	0,3 à 2,0	1,0	Régime pluviométrique saisonnier, de -70% à $\times 2$
Décalage de température	-5 à 5°C	0	Réchauffement ou refroidissement global
Résidu d'évapotranspiration	$-0,03$ à $0,03$	0	Écart fractionnaire résiduel
Décalage temporel	-30 à 30 d	0	Avance ou retard de la saison

Surtout, ces paramètres ne sont pas indépendants. L'évapotranspiration est **couplée à la température** par la relation de Clausius-Clapeyron, au taux d'environ 7% par degré qui gouverne la capacité de l'air à contenir de la vapeur d'eau. Élever la température dans le scénario contrefactuel élève donc mécaniquement la demande évaporative : le scénario reste thermodynamiquement cohérent *par construction*, non par pénalisation après coup. C'est la traduction du premier critère demandé, la plausibilité du bilan de masse ; la structure saisonnière des facteurs de pluie et le décalage temporel traduisent le second.

L'ensemble reste différentiable, donc optimisable par descente de gradient à travers le modèle de prévision, quel que soit ce modèle : une couche d'adaptation permet d'appliquer la méthode aux architectures du catalogue du chapitre 7. Une variante par optimisation bayésienne est également disponible pour les cas où le gradient n'est pas exploitable.

8.4.3 Une comparaison honnête : la référence non contrainte

Contraindre l'espace de recherche améliore l'interprétabilité ; encore faut-il montrer que cela ne se paie pas d'une perte de qualité rédhibitoire. Une méthode de référence inspirée des contrefactuels pour séries temporelles multivariées [3] a donc été implémentée pour la comparaison : elle optimise directement la perturbation brute, avec contraintes souples, sans couplage physique, soit un nombre de paramètres libres égal à trois fois la longueur de la fenêtre, contre sept pour l'approche contrainte.

Cette comparaison met à l'épreuve une hypothèse précise. Avec plusieurs dizaines à quelques centaines de fois plus de paramètres libres, la référence non contrainte atteindra presque toujours la cible plus facilement. La question n'est donc pas laquelle des deux optimise mieux, ce qui est réglé d'avance, mais si **davantage de degrés de liberté produit une meilleure explication**. Le dispositif permet d'en discuter sur pièces plutôt que de le supposer.

8.4.4 Une validation par un modèle indépendant

Un contrefactuel produit par optimisation à travers un modèle appris peut n'être valide que pour ce modèle : il exploiterait alors une particularité de l'approximation plutôt qu'une propriété du système. Pour écarter cette possibilité, le scénario contrefactuel est rejoué dans un modèle métier calibré indépendamment, celui du chapitre 6, et l'on vérifie que l'effet annoncé s'y retrouve.

Cette validation croisée n'était possible que parce que les deux familles de modèles cohabitent dans le même outil, sur les mêmes données. C'est un bénéfice direct de l'architecture retenue, et une raison supplémentaire d'avoir commencé par le modèle métier.

8.5 Cette chronique est-elle explicable par le climat ? La détection de prélèvements

La troisième question renverse la perspective. Une chronique piézométrique qu'aucun modèle climatique ne parvient à reproduire n'est pas nécessairement le signe d'un mauvais modèle : elle

peut porter la trace d'une **influence anthropique**, un pompage, que le forçage climatique ne contient pas.

L'enjeu est double, et il a été formulé comme tel lors du cadrage. Il s'agit d'abord d'écarter les stations impropres à l'apprentissage, préoccupation qui rejoint directement la constitution d'un jeu de piézomètres peu influencés. Il s'agit ensuite de produire une information utile en elle-même : l'annotation automatique des piézomètres selon leur caractère inertiel, réactif ou influencé figure parmi les cas d'usage identifiés avec le BRGM.

Le problème est difficile car **non supervisé** : on ne dispose pas d'un historique étiqueté des prélèvements. La démarche procède en deux temps. Un modèle métier calibré fournit d'abord ses résidus et une détection de ruptures, dont on tire les périodes que l'on peut tenir pour non perturbées. Deux lectures indépendantes l'une de l'autre s'appuient ensuite sur cette base, l'une par analyse d'écart après apprentissage, l'autre par représentation apprise, et leurs verdicts sont fusionnés. La couche d'explicabilité y joue un rôle inhabituel : elle ne sert pas à justifier une prédiction mais à détecter une **dérive dans les attributions**, un changement de ce sur quoi le modèle s'appuie, qui signale que le régime du système a changé.

Le résultat est confronté, quand elle existe, à l'information publique sur les ouvrages de prélèvement déclarés.

Attribution, contrefactuels et détection d'influence sont ainsi outillés, et surtout organisés pour que leurs verdicts puissent être confrontés entre eux. Aucune évaluation quantitative n'a été conduite pour autant, sur aucun échantillon, selon aucune métrique de qualité d'explication établie. Ce qui est livré, c'est un banc complet, des données réelles, deux méthodes comparables, un moyen de validation indépendant, et une hypothèse formulée dans les termes du domaine. Tout ce qu'il faut pour que la question de la qualité des explications se traite sur un cas hydrogéologique, et rien de plus.

9 Ce que la collaboration a produit

À quels besoins, exprimés par qui, ces développements répondent-ils effectivement ?

9.1 Le cadre de travail

Les développements présentés dans ce rapport ont été conçus et réalisés dans leur intégralité au cours du postdoctorat, dans un dialogue continu avec trois interlocuteurs aux apports distincts.

Nicolas Labroche (LIFAT) a assuré la supervision scientifique et encadré l'orientation des travaux, en particulier l'arbitrage initial : accepter que le sujet d'explicabilité impose d'abord la construction de son terrain expérimental, plutôt que de le traiter sur un jeu de données de circonstance.

Hugo Breuillard, data scientist en charge du projet côté BRGM, a été le point de contact sur les questions de chaîne de données et de stratégie de prévision. Les échanges ont porté sur l'articulation entre l'entrepôt développé ici et les besoins de modélisation du programme, et sur la cohérence des indicateurs produits avec ceux employés par ailleurs.

Augustin Thomas, hydrogéologue au BRGM, a été l'interlocuteur sur l'ensemble des questions de domaine. C'est de ces échanges que procèdent les décisions qui ancrent la plateforme dans la pratique hydrogéologique plutôt que dans une transposition générique de méthodes d'apprentissage.

9.2 L'expertise métier inscrite dans le code

L'apport d'expertise n'est pas resté au stade de la discussion : il est inscrit dans le code, et identifiable. Quatre exemples le montrent.

La table présentée au chapitre 6 traduit en choix de modélisation ce qu'un hydrogéologue sait du comportement de chaque milieu. Aucune procédure automatique ne l'aurait produite.

L'adoption d'un standard d'évaluation reconnu relève du même registre. Le choix d'évaluer les modèles selon les quatre critères STOWA plutôt que par un indicateur d'erreur unique relève du même registre. Il introduit notamment le critère de temps de réponse rapporté à la période de calibration, qui écarte des modèles apparemment excellents mais non identifiables, subtilité que la seule pratique de l'apprentissage automatique ne fait pas apparaître.

La règle d'affichage cartographique énoncée au chapitre 5, un indicateur réellement standardisé ou une valeur réelle et jamais un intermédiaire, procède d'une préoccupation d'interprétation propre au domaine. Un outil qui colorie une carte de France selon des seuils choisis par son auteur fabrique une norme que l'utilisateur lira comme une référence établie.

L'arbitrage sur l'évapotranspiration, enfin. La décision documentée en section 4.4 est exemplaire du bénéfice de la confrontation disciplinaire. La variable fournie par la réanalyse était disponible, correctement nommée et directement utilisable ; seule la confrontation de ses valeurs aux ordres de grandeur connus pour la France a révélé qu'elle ne désignait pas la grandeur attendue. Aucune vérification interne au code ne pouvait détecter cette erreur, car il ne s'agissait pas d'une erreur de calcul.

9.3 Les cas d'usage identifiés avec le BRGM

Les échanges n'ont pas seulement produit des décisions techniques. Ils ont fait émerger une liste de besoins concrets, qui a servi à orienter les développements et qui reste disponible pour la suite.

Cette liste est un livrable à elle seule : un socle sans usage identifié n'est qu'une infrastructure en attente.

Besoin exprimé	Ce qu'il recouvre	État
Qualifier les piézomètres	Distinguer automatiquement les ouvrages inertiels, réactifs et influencés par des prélèvements, pour savoir lesquels sont exploitables	outillé
Prévoir les niveaux	Anticiper l'évolution d'une nappe à partir du climat	outillé
Expliquer les prévisions	Identifier les facteurs déterminants d'une prévision donnée	outillé
Comparer les approches	Confronter méthodes statistiques, modèles métier et apprentissage profond sur les mêmes données	possible, non fait
Explorer les données	Permettre aux experts de parcourir et de comparer les chroniques sans écrire de requête	outillé
Scénariser la sécheresse	Répondre à des questions du type « quelle pluie faudrait-il pour sortir de cet état ? », en appui des comités sécheresse	outillé, non éprouvé
Étudier les échanges nappe-rivière	Détecter et caractériser les relations entre une nappe et le cours d'eau voisin, notamment le soutien d'étiage	non traité
Caractériser la double porosité	Distinguer, au sein d'une même formation, les écoulements rapides des écoulements lents, que les méthodes actuelles peinent à séparer	non traité
Couvrir les nappes captives	Disposer d'un indicateur de situation pour les nappes qui n'en ont pas, l'indicateur existant ne valant que pour les nappes libres	non traité

La colonne d'état est délibérément sévère : « outillé » signifie que les moyens existent, pas qu'un résultat a été produit. Et les trois dernières lignes sont assumées comme telles : ce sont des sujets à part entière, identifiés comme prometteurs au cours des échanges, mais qui dépassaient le périmètre et le temps disponibles. Ils sont consignés ici parce qu'ils constituent des points d'entrée pour la suite, et parce qu'ils viennent des experts du domaine plutôt que d'une projection d'informaticien.

Un mot sur la scénarisation. Les équipes du BRGM travaillant sur la situation des nappes emploient déjà les indicateurs standardisés que produit désormais l'entrepôt. Coupler ces indicateurs à des scénarios prospectifs, c'est-à-dire répondre non seulement « où en est-on » mais « que faudrait-il pour en sortir », est le prolongement naturel de leur pratique actuelle. C'est cette continuité qui rend le socle mobilisable par eux sans changement de méthode.

9.4 L'articulation avec les travaux de recherche en cours

Les développements présentés au chapitre 8 ne sont pas isolés. Des travaux menés au LIFAT sous la direction de Nicolas Labroche portent sur les explications contrefactuelles et sur la mesure de leur qualité en tant qu'explications, question ouverte que les métriques usuelles ne tranchent pas.

La contribution de ce postdoctorat à cette thématique est **d'ordre technique**, et c'est délibéré : fournir les données, les modèles, les méthodes comparables et les moyens de validation sans lesquels cette recherche resterait cantonnée à des jeux d'essai génériques. La répartition est claire, et il vaut mieux l'écrire que la laisser deviner.

Relève de ces travaux	Le socle de données, les modèles à expliquer, l'implémentation des méthodes, la référence de comparaison, le moyen de validation indépendant, et la qualification des cas d'étude
Relève des travaux en cours	La définition de ce qu'est une bonne explication, les métriques qui la mesurent, et l'évaluation comparative des approches

C'est aussi ce qui explique qu'aucune conclusion méthodologique ne figure dans ce rapport sur la qualité des contrefactuels produits. Elle n'aurait pas eu de sens : la question relève d'un travail en cours, et l'anticiper reviendrait à préjuger de son résultat.

9.5 Des besoins distincts, un outil commun

Les deux communautés visées n'attendent pas la même chose, et l'architecture a dû accommoder les deux sans se scinder.

	Hydrogéologues du BRGM	Chercheurs en apprentissage
Question posée	Où en est la ressource, et que se passe-t-il si l'on prélève ?	Quelle méthode prédit le mieux, et pourquoi ?
Attente principale	Des indicateurs conformes aux pratiques, une scénarisation crédible	Un jeu de données consolidé, un protocole reproductible
Obstacle levé	L'agrégation manuelle de sources hétérogènes	Le coût d'entrée à l'expérimentation
Ce qui a été livré	Observatoire, indicateurs validés, laboratoire de modèles métier, scénarios bornés	Entrepôt interrogeable, catalogue d'architectures, traçabilité des expériences, outillage d'explicabilité

Le point de rencontre est l'entrepôt. Parce que les indicateurs métier et les jeux d'apprentissage sont produits par la même chaîne et validés une seule fois, une comparaison entre un modèle appris et un modèle métier porte réellement sur les modèles, et non sur des préparations de données divergentes. Cette propriété, invisible dans l'interface, est ce qui rend la plateforme utilisable comme instrument de recherche et non seulement comme outil de consultation.

9.6 État de mise à disposition

La plateforme est déployée (chapitre 5), mais son usage demeure à ce jour circonscrit au cercle du projet. L'accès est nominatif : il n'existe ni inscription libre ni authentification déléguée, les comptes étant créés par un administrateur. Ce choix, adapté à un outil scientifique manipulant une chaîne de traitement en évolution, constitue le principal frein à une diffusion plus large, et le premier levier à actionner pour l'obtenir.

Le socle a par ailleurs été présenté aux équipes du projet ANR AIDA, dont le domaine d'expérimentation recouvre en partie celui traité ici, afin que celles qui en auraient l'usage n'aient pas à le reconstruire.

Plusieurs pistes ouvertes au cours de ces échanges n'ont pas été suivies. Le rapprochement avec les modèles à réservoirs du BRGM en est la principale : elle donnerait une seconde référence de comparaison, indépendante de celle construite ici. Quant à l'élargissement des usages, il tient à une politique d'accès et à un accompagnement, non à des développements supplémentaires.

10 Un socle pour l'IA en hydrologie

Ces développements survivront-ils au projet qui les a financés, et à quelles conditions peuvent-ils fonder un environnement d'outils plus vaste ?

10.1 Pourquoi la plupart des développements de recherche ne se réutilisent pas

La réponse par défaut est négative. Un logiciel de recherche est ordinairement écrit pour produire un résultat, puis abandonné : il suppose un environnement particulier, mêle le traitement et son affichage, dépend de fichiers qui ne sont plus là, et sa reprise coûte plus cher que sa réécriture.

Affirmer qu'un développement constitue un « socle » n'a donc de valeur que si l'on peut désigner les propriétés qui le rendent réutilisable et montrer qu'elles sont effectivement acquises.

10.2 Les propriétés acquises

La couche analytique de l'entrepôt se consomme en SQL, et rien d'autre. Un utilisateur n'a besoin de connaître ni l'outil d'ingestion, ni la bibliothèque de transformation, ni l'orchestrateur : un carnet de calcul, un tableur connecté ou une application tierce s'y branchent également. La conséquence est structurante : **l'amont peut être remplacé sans que l'aval s'en aperçoive**. Un outil d'ingestion devenu obsolète se remplace sans toucher aux consommateurs. Peu de logiciels de recherche offrent cette propriété, et c'est elle qui distingue une infrastructure d'un script.

Le cœur de calcul de la plateforme, lui, ne dépend d'aucune interface. La contrainte a été posée dès l'origine, au chapitre 5, et son effet sur la valeur résiduelle des travaux est direct : **même si l'application web était abandonnée, les méthodes resteraient utilisables**. La contribution n'est pas prisonnière de son emballage.

Le reste a été acquis en chemin. Des indicateurs calculés une fois pour tous les consommateurs, sans second calcul susceptible de diverger, et gardés par des tests qui échouent si les deux dépôts cessent de s'accorder (chapitre 4). Une pile conteneurisée dont les volumes de données survivent à l'arrêt des conteneurs, et dont la restauration a été vérifiée à l'échelle réelle (chapitre 3). Une documentation refondue en fin de période pour la reprise, jusqu'aux pièges qui produisent des résultats faux sans émettre d'erreur (chapitre 11).

10.3 Le patron généralisable

Au-delà des deux dépôts, ces travaux instancient un enchaînement (figure 10.1) qui n'a rien de spécifique aux eaux souterraines.




Figure 10.1 – L'enchaînement mis en œuvre. Chaque étape suppose la précédente; escamoter l'une d'elles produit des résultats incomparables ou inutilisables.

L'enseignement principal de l'année tient dans la lecture de gauche à droite de cette figure : **on ne peut pas commencer par la droite**. C'est pourtant ce que fait le plus grand nombre de projets d'intelligence artificielle appliquée à l'environnement, qui investissent dans le modèle et découvrent ensuite que la donnée ne permet pas de conclure.

10.4 Extensions, par coût croissant

Extension	Ce qu'elle suppose	Coût
Nouvelles stations, autre territoire	Rien : la couverture est déjà nationale et la chaîne est paramétrée par configuration	nul
Nouveaux indicateurs standardisés	Un ajustement statistique et sa validation, selon le protocole existant	faible
Nouvelles architectures de prévision	Une entrée au catalogue ; la fabrique de modèles et la traçabilité sont génériques	faible
Qualité des eaux souterraines	De nouvelles sources et de nouveaux modèles de transformation ; l'architecture est inchangée	moyen
Eaux de surface	La chaîne hydrométrique existe déjà ; l'extension porte sur la modélisation	moyen
Autre compartiment (air, sol)	Les sources et les indicateurs diffèrent, le patron tient	moyen
Couplage à un modèle hydrogéologique distribué	Une interface avec un simulateur physique externe et l'assimilation de ses sorties	élevé

Ce qui est peu coûteux l'est *parce que* l'infrastructure existe. Le coût élevé de l'année écoulée a été payé une fois ; il ne se représente pas à chaque extension. C'est la définition même d'un socle.

10.5 Ce qui est transmis aux travaux à venir

Les travaux d'explicabilité se poursuivront au-delà de cette période. Le tableau suivant confronte ce qu'ils supposent à ce qui leur est effectivement transmis.

Besoin	Disponible
Un jeu de données consolidé, joint au forçage climatique	Entrepôt national, partitions depuis 1967 pour les stations et 1950 pour le climat, rattachement spatial matérialisé
Des modèles à expliquer	Douze architectures de prévision profonde sous interface unique, avec traçabilité des expériences
Une référence interprétable à laquelle confronter les explications	Modèles à fonction de transfert calibrés, dont les paramètres ont un sens hydrogéologique
Des méthodes d'attribution	Cinq familles complémentaires, confrontables entre elles
Des explications actionnables	Contrefactuels sous contrainte physique, mettant en œuvre les critères formulés par les hydrogéologues
Un moyen de valider une explication	Rejeu du scénario dans un modèle métier indépendant
Des cas d'étude qualifiés	Détection non supervisée d'influence anthropique, permettant d'écarter les chroniques impropres

Ce qui n'est pas transmis doit être dit avec la même netteté : aucun résultat de performance comparée, aucune évaluation quantitative des méthodes contrefactuelles, et aucune campagne d'expériences consolidée. Le socle rend ces travaux possibles ; il ne les a pas menés.

10.6 Ce qui manque pour un véritable environnement d'outils

Six chantiers séparent l'état actuel d'un environnement d'outils partagé. Aucun n'est un verrou de recherche ; tous sont des décisions d'investissement.

1. **L'alignement de l'évapotranspiration sur la chaîne des stations** (chapitre 4). C'est le seul chantier de la liste qui conditionne la validité de résultats à venir, et non seulement le confort de travail.
2. **L'automatisation des vérifications.** La suite de tests de la plateforme n'est pas exécutée automatiquement (chapitre 7). Tant que les vérifications dépendent d'une initiative humaine, la confiance dans les évolutions décroît avec le temps. C'est le chantier le moins coûteux et le plus rentable.
3. **Un accès élargi et gouverné.** L'accès nominatif convient à un outil de projet, non à un environnement partagé. Une politique d'accès, précisant qui accède, pour quels usages et avec quelle responsabilité sur les données, conditionne tout élargissement.
4. **Un catalogue de données.** L'entrepôt est documenté pour qui sait où chercher. Un environnement d'outils suppose un catalogue décrivant les jeux disponibles, leur origine, leur fraîcheur et leurs conditions d'usage.
5. **Le calcul mutualisé.** L'entraînement s'appuie aujourd'hui sur un serveur unique. Un usage partagé suppose une file d'attente et un partage de ressources.
6. **La campagne d'évaluation comparative.** Le socle sera d'autant plus crédible qu'il aura servi à établir un résultat : la comparaison systématique modèles métier / modèles appris, et l'évaluation des méthodes contrefactuelles. L'outillage est prêt de part et d'autre.

10.7 Articulation avec le volet des jumeaux numériques

Un jumeau numérique de la ressource en eau suppose trois choses : une représentation de l'état courant du système, une capacité à le projeter, et une capacité à expliquer la projection. Le tableau précédent couvre les deux premières, l'entrepôt et l'observatoire pour l'état, les modèles métier et appris pour la projection.

La contribution la plus spécifique porte sur la troisième. Un jumeau numérique qui projette sans expliquer n'est qu'un simulateur ; ce qui en fait un instrument de décision est la capacité à répondre « pourquoi » et « que se passerait-il si » dans les termes du métier. Les contrefactuels sous contrainte physique décrits en section 8.4 sont directement conçus pour cet usage : ils produisent des scénarios énonçables, du type « un hiver plus sec et plus chaud d'un degré », plutôt que des perturbations numériques.

La démonstration la plus convaincante resterait que ce socle ait servi à établir un résultat scientifique. Elle n'a pas encore eu lieu.

11 Bilan, limites et passation

Que reste-t-il, une fois le contrat achevé, et dans quel état ?

11.1 Récapitulatif des réalisations

Domaine	Réalisation
Données	Chaîne d'ingestion automatisée de quatre jeux de données issus de trois fournisseurs publics ; entrepôt en architecture médaillon sur base relationnelle avec extensions temporelle et géospatiale ; rattachement spatial des stations à leur maille climatique ; enrichissement par le référentiel hydrogéologique ; environ 658 millions de lignes en couche brute
Fiabilité	Idempotence des traitements, traçabilité des lignes écartées, contraintes de concurrence par clés, reprise après interruption, sauvegarde et restauration vérifiées à l'échelle réelle
Indicateurs	Indices standardisés de niveau, de débit, de précipitation, de température et de bilan hydrique ; production à l'échelle nationale sur quatre fenêtres ; protocole de validation à critère pré-établi ; deux décisions méthodologiques établies par la mesure
Exploration	Observatoire spatial des nappes et des rivières ; module climatique national avec historique depuis 1950, épisodes de sécheresse et export
Modélisation métier	Laboratoire de modèles à fonction de transfert ; calibration automatique guidée par la nature de l'aquifère ; évaluation selon quatre critères normalisés ; diagnostics préalables et postérieurs ; scénarios prospectifs à bornes physiquement dérivées
Apprentissage	Catalogue d'une douzaine d'architectures de prévision profonde ; optimisation d'hyperparamètres ; traçabilité des expériences ; suivi d'entraînement en temps réel ; configurations prêtes à l'emploi par cas d'usage métier
Explicabilité	Attribution multi-méthodes ; contrefactuels sous contrainte physique avec couplage thermodynamique et validation par modèle indépendant ; détection non supervisée d'influence anthropique
Ingénierie	Deux dépôts conteneurisés, reproductibles et documentés pour la reprise ; environnements de développement et de production séparés

11.2 Bilan au regard de la mission initiale

La mission portait sur l'explicabilité des modèles de prévision appliqués aux eaux souterraines. Elle a été remplie, mais par un chemin plus long que prévu.

Ce qui a été atteint : l'outillage complet que le sujet supposait, jusqu'aux méthodes d'explication elles-mêmes. Parmi elles, les contrefactuels sous contrainte physique s'attaquent directement à ce qui rend l'explicabilité délicate dans ce domaine, à savoir qu'une explication physiquement incohérente n'est pas une explication. Ces développements restent préliminaires : ils sont opérationnels et prêts à être éprouvés, ils ne sont pas validés.

Ce qui a été ajouté par nécessité : l'ensemble de l'infrastructure amont, sans laquelle le sujet initial n'aurait pu être traité que sur un jeu de données de circonstance, aux conclusions non généralisables.

Ce qui n'a pas été atteint : l'évaluation quantitative comparée des méthodes, faute de temps une fois l'infrastructure construite. C'est le regret principal de la période, et c'est aussi le travail le plus immédiatement accessible à qui reprendra ces développements, parce que tout ce qu'il suppose existe désormais.

C'est un arbitrage qu'il faut assumer. Consacrer l'essentiel d'un postdoctorat à construire l'infrastructure d'un sujet plutôt qu'à publier sur ce sujet est défavorable à court terme et favorable à long terme. Le jeu de données, les indicateurs validés et les outils demeurent, et ils rendent possibles des travaux qui ne l'étaient pas. La question posée en introduction du chapitre 2 a reçu une réponse construite plutôt qu'argumentée.

11.3 Limites assumées

Un successeur doit les connaître.

1. **Aucun résultat de performance comparée n'est établi.** Les campagnes d'entraînement ont validé le dispositif, non classé les méthodes. Les jeux préparés et les points de sauvegarde ont été purgés lors de la passation.
2. **Les modèles métier sont calibrés sur une évapotranspiration inadaptée.** La chaîne des stations transporte encore la variable brute, environ deux fois supérieure à l'évapotranspiration de référence employée par la chaîne climatique. La mesure présentée au chapitre 4 montre que le modèle n'absorbe pas cet écart : le paramètre qui pondère l'évaporation sature à sa borne, et l'ajustement en dépend. Les prévisions restent exploitables, mais les paramètres calibrés n'ont pas d'interprétation physique directe. C'est le premier chantier à reprendre, avant toute campagne de calibration.
3. **Les tests ne sont pas exécutés automatiquement** sur la plateforme, la chaîne d'intégration de la forge hébergeante ne comportant qu'une étape de construction. Quatre des 552 tests échouent, pour des raisons documentées et sans rapport avec un défaut applicatif, mais la purge des journaux se trouve de fait non testée.
4. **Certaines températures agrégées au niveau des stations** sont des extrêmes de moyennes journalières et non de véritables extrêmes journaliers ; l'exposition de ces derniers supposerait de modifier une table partitionnée.
5. **La source climatique retenue est un compromis.** ERA5-Land a été préféré à une réanalyse plus fine mais non redistribuable, au bénéfice de la reproductibilité et du partage.
6. **L'usage reste circonscrit au cercle du projet**, faute d'une politique d'accès élargie.
7. **La couverture climatique s'arrête à la métropole.** La grille ingérée couvre la France métropolitaine et la Corse. Les stations ultramarines sont présentes dans l'entrepôt mais sans forçage climatique, ce qui les rend inutilisables pour la modélisation.
8. **Le périmètre couvre la quantité, non la qualité** des eaux, également visée par le programme.

11.4 État de passation

Le contrat s'est achevé le 30 juin 2026. Les travaux se sont poursuivis jusqu'au 24 août 2026 dans le seul but de rendre les réalisations exploitables sans leur auteur :

- refonte complète de la documentation des deux dépôts, organisée autour d'une cartographie des documents et vérifiée par exécution réelle des procédures décrites ;
- consignation des pièges susceptibles de produire des résultats faux sans émettre d'erreur, développés au chapitre 3 ;
- retrait des éléments sensibles : identifiants, clés d'interface, topologie interne, adresses personnelles ; restriction par défaut de l'écoute des services à l'interface locale ;
- suppression du code mort et des scripts devenus inopérants ;
- vérification à l'échelle réelle des procédures de sauvegarde et de restauration ;
- explicitation du couplage entre les deux dépôts et de ses conditions de démarrage.

11.5 Conclusion

Ces travaux répondent à une question qui n'était pas celle posée au départ, mais qui la conditionnait : *comment rendre possible la recherche en intelligence artificielle sur les eaux souterraines françaises ?*

La réponse tient en une chaîne complète, allant de quatre jeux de données publics et dispersés jusqu'à des scénarios contrefactuels énonçables dans le langage des hydrogéologues, dont chaque maillon est documenté, vérifié et réutilisable indépendamment des autres.

Ce qui a été construit dépasse le périmètre des eaux souterraines : l'enchaînement sources → entrepôt → indicateurs validés → modèles → explication est transposable aux autres compartiments environnementaux visés par le programme. C'est en ce sens que ces développements constituent moins un aboutissement qu'un point de départ.

A Annexes

A.1 Inventaire des réalisations logicielles

Entrepôt de données hydro-climatiques

Période	23 septembre 2025 au 24 août 2026
Volume	≈ 7 000 lignes Python, ≈ 1 200 lignes SQL de transformation
Ingestion	Bibliothèque d'extraction déclarative : pagination, reprise sur erreur, déduplication par fusion, partitionnement annuel de 1967 à aujourd'hui
Transformation	8 modèles de nettoyage, 3 modèles de rejets tracés, 18 modèles analytiques, complétés par des tables d'indicateurs calculées en Python
Orchestration	8 traitements planifiés, 3 capteurs événementiels, clés de concurrence par nature de traitement
Stockage	Base relationnelle avec extension de séries temporelles (partitionnement, compression) et extension géospatiale (jointures spatiales indexées)
Infrastructure	7 services conteneurisés, séparation du code métier et de l'orchestrateur, volumes de données déclarés hors du cycle de vie des conteneurs

Plateforme d'exploration, de modélisation et de prévision

Période	6 novembre 2025 au 24 août 2026
Volume	≈ 40 000 lignes Python, ≈ 29 000 lignes TypeScript
Interface	Application monopage : cartographie, graphiques interactifs, suivi d'entraînement en temps réel
Service	API avec flux d'événements, authentification nominative, journal d'audit, limitation de débit
Cœur métier	Bibliothèque Python sans dépendance d'interface : préparation, modèles métier, entraînement, explicabilité, contrefactuels, détection d'influence
Vérification	552 tests, dont 547 passent (mesuré le 24 août 2026)
Déploiement	Interface sur infrastructure mutualisée, calcul et bases sur serveur équipé d'un processeur graphique ; environnements de développement et de production séparés

A.2 Sources de données et attributions

Source	Contenu	Couverture
Hub'Eau, piézométrie	Niveaux de nappe aux ouvrages de surveillance	partitions depuis 1967
Hub'Eau, hydrométrie	Débits des cours d'eau (sites, stations, observations)	partitions depuis 1967
Copernicus ERA5-Land	Réanalyse climatique sur grille 0,1°, France métropolitaine et Corse	depuis 1950
BDLISA	Référentiel hydrogéologique (entités aquifères)	référentiel

La profondeur effectivement disponible varie d'une station à l'autre : les partitions d'ingestion

couvrent la période complète, les données retournées par les services web dépendent de la date de mise en service et de l'exploitation de chaque ouvrage.

Mentions obligatoires

Generated using Copernicus Climate Change Service information, 2026. Neither the European Commission nor ECMWF is responsible for any use that may be made of the Copernicus information or data it contains.

Source : Hub'Eau, eaufrance.fr • Source : BDLISA, BRGM et Sandre.

Les licences des développements couvrent le code produit, non les données consultées : chaque source conserve ses propres conditions d'usage.

A.3 Le cheminement de l'évapotranspiration dans l'entrepôt

Une précision s'impose, car la correction ne consiste pas à remplacer une valeur en cours de route. Les deux grandeurs coexistent, et leurs trajectoires diffèrent.

La variable brute d'ERA5 est **ingérée telle quelle** en couche Bronze, avec pour seule opération la conversion des mètres en millimètres. La couche Silver se contente de la typer : aucun calcul n'y est fait, conformément au principe énoncé au chapitre 3.

C'est en couche Gold, dans le modèle de grille mensuelle, que tout se joue. L'évapotranspiration de référence n'y est pas dérivée de la variable brute : elle est **calculée à partir d'une autre source**, les statistiques journalières de température issues du second chemin d'ingestion. La formule de Hargreaves est appliquée jour par jour, puis cumulée sur le mois. La variable brute, elle, est conservée dans une colonne distincte de la même table.

Couche	Colonne	Contenu
Bronze	potential_evaporation	Variable ERA5 brute, convertie en millimètres. Aucune interprétation.
Silver	potential_evaporation	La même, typée. Toujours aucun calcul.
Gold	etp_totale	Évapotranspiration de référence , calculée par Hargreaves depuis les températures journalières. C'est cette colonne qui est consommée.
Gold	bilan_hydrique	Précipitation moins etp_totale. Le SPEI en découle.
Gold	etp_pev_era5	La variable brute cumulée, conservée pour la traçabilité et la comparaison. À ne pas consommer.

Conserver les deux colonnes côte à côte a un intérêt qui dépasse la traçabilité : c'est ce qui a rendu la mesure possible. Les valeurs de 818 et 1 756 millimètres par an comparées plus haut sont issues d'une simple requête sur cette table, et non d'un calcul externe. Elle se rejoue telle quelle, à condition que la période sur laquelle la mesure a porté, de 2015 à 2025, soit chargée : la profondeur de la grille climatique est un paramètre d'ingestion, pas une propriété de la table.

A.4 Volumétrie des indicateurs climatiques

Mailles de la grille nationale	11 496
Valeurs d'indices produites	41 960 400
Fenêtres d'agrégation	1, 3, 6 et 12 mois
Période de référence	1991–2020
Échelle de classement	7 classes
Couples maille-mois de la comparaison d'évapotranspiration	30 888
Ajustements comparés lors du changement de loi	35 614

A.5 Glossaire

Terme	Définition
Architecture médaillon	Organisation d'un entrepôt en couches de qualité croissante : données brutes, données nettoyées, données analytiques
BDLISA	Référentiel hydrogéologique français décrivant les entités aquifères
Contrefactuel	Explication de la forme « quelle modification minimale des entrées changerait la sortie de telle manière »
ETP / ET0	Évapotranspiration potentielle ; évapotranspiration de référence au sens de la FAO-56
Hypertable	Table partitionnée dans le temps, permettant compression et interrogation efficace sur de grands volumes de séries
Idempotence	Propriété d'un traitement dont la réexécution ne modifie pas le résultat
IPS	Indicateur piézométrique standardisé, position du mois courant par rapport à sa normale saisonnière
L-moments	Statistiques d'ordre linéaires servant à ajuster une loi de probabilité, dont τ_3 mesure l'asymétrie
McKee (classes de)	Échelle à sept classes de sévérité associée aux indices standardisés
Modèle TFN	Modèle à fonction de transfert et bruit : le niveau simulé est la somme de convolutions des forçages par des réponses impulsionnelles calibrées
Piézométrie	Mesure du niveau des nappes d'eau souterraine
SPI / STI / SPEI	Indices standardisés de précipitation, de température et de bilan hydrique
SSFI	Indice standardisé de débit, équivalent de l'IPS pour les cours d'eau
STOWA	Standard néerlandais d'évaluation de la qualité des modèles TFN, en quatre critères
Valeurs de Shapley	Méthode d'attribution répartissant la contribution des entrées à une prédiction sur des bases axiomatiques

B Revue des outils retenus

Les trois critères de sélection sont exposés au chapitre 3. Cette annexe en donne l'application, outil par outil, avec ce qui a été écarté dans chaque cas.

B.1 Ingestion : dlt

Interroger une interface web publique paraît trivial jusqu'à ce qu'on le fasse sérieusement. Il faut paginer, réessayer sur erreur serveur avec une temporisation croissante, découvrir le schéma des colonnes, créer les tables, insérer par lots et suivre l'état des chargements. **dlt** [15] prend en charge la seconde moitié de cette liste : on déclare une ressource, la bibliothèque crée et fait évoluer les tables, charge par lots et tient l'historique des chargements.

La première moitié a dû être écrite. Les particularités des interfaces Hub'Eau décrites au chapitre 2, pagination par en-tête de lien, plafonds non documentés, conventions qui changent d'un point d'accès à l'autre, ne se laissent pas absorber par un mécanisme générique. Un client dédié d'environ quatre cents lignes porte donc la pagination, les tentatives successives avec temporisation exponentielle et bruitage, et les garde-fous contre les boucles infinies. C'est un enseignement en soi : l'outil a économisé le travail répétitif de chargement, pas l'adaptation aux caprices de la source.

Deux familles d'alternatives ont été écartées. Tout écrire, chargement et gestion des schémas compris, aurait doublé ce volume sans intérêt propre. Déployer une plateforme d'intégration complète, du type de celles qui s'administrent par interface graphique, aurait imposé un service supplémentaire à maintenir et une configuration hors du dépôt, donc non versionnée, pour quatre sources seulement. **dlt** occupe l'espace intermédiaire : une bibliothèque, dans le code, versionnée avec lui.

B.2 Transformation : dbt

Le choix déterminant est ici de transformer **dans la base** plutôt qu'en mémoire. Avec des centaines de millions de lignes, charger les données dans un tableau Python n'est pas une option, alors que le moteur de base de données sait le faire sur place.

dbt [14] est le standard de fait de cette approche, au point d'avoir donné son nom à un métier, l'*analytics engineering*. Sa maturité et sa diffusion sont précisément ce qu'on recherche pour un socle destiné à durer. Il apporte quatre mécanismes : chaque transformation est un fichier SQL versionné, l'ordre d'exécution se déduit automatiquement des références entre modèles, les tests de qualité se déclarent à côté du modèle qu'ils vérifient, et la documentation se génère. Un bénéfice secondaire compte autant que les autres : les transformations restent lisibles par un hydrogéologue ou un analyste, ce qu'un script Python de plusieurs centaines de lignes n'aurait pas été.

B.3 Orchestration : Dagster

Un ordonnanceur classique raisonne en tâches : exécuter A, puis B, à trois heures du matin. **Dagster** [13] raisonne en *actifs* : on déclare qu'une table doit exister et être à jour, et l'outil détermine ce qu'il faut exécuter pour cela.

La différence est concrète sur cette chaîne. Elle permet de partitionner l'ingestion par année et de rejouer une seule année, de déclencher la transformation quand la donnée arrive plutôt qu'à heure fixe, et de voir d'un coup d'œil quelles tables sont fraîches et lesquelles ne le sont pas. Airflow, l'ordonnanceur historique du domaine, aurait imposé de décrire ces dépendances à la main et de

maintenir un second graphe en parallèle de celui de dbt, alors que l'intégration est ici native. Un simple ordonnanceur système, quant à lui, n'offre ni reprise partielle, ni traçabilité, ni limitation de concurrence, trois besoins dont la suite de ce chapitre montre qu'ils se sont révélés indispensables.

B.4 Stockage : PostgreSQL, TimescaleDB et PostGIS

Le besoin dictait le choix. Ce travail exige simultanément deux capacités : interroger efficacement des séries temporelles longues, et effectuer des jointures spatiales pour rattacher chaque station à sa maille climatique. **PostgreSQL** [31] est le seul moteur courant qui réunisse les deux dans un même produit, grâce à **TimescaleDB** [36] pour le partitionnement temporel et la compression, et à **PostGIS** [30] pour les index et opérateurs géospatiaux. PostGIS est d'ailleurs la référence du géospatial libre, employée bien au-delà du monde de la recherche.

S'y ajoutent trois propriétés qui pesaient lourd dans un contexte de recherche publique : aucun coût de licence, un déploiement sur le serveur du laboratoire donc aucune dépendance à un fournisseur ni facturation à la requête, et une interface SQL que tout le monde sait déjà interroger. Un entrepôt hébergé dans le nuage aurait apporté une élasticité inutile à cette échelle, en échange d'un budget récurrent et d'une adhérence contractuelle. Un stockage en fichiers colonnaires, plus léger, ne fournissait ni les jointures spatiales indexées ni la mise à jour incrémentale dont la chaîne a besoin.

B.5 Synthèse des choix

Rôle	Retenu	Écarté, et pourquoi
Ingestion	dlt	Tout écrire, chargement et schémas compris ; plateforme d'intégration administrée (service en plus, configuration hors dépôt)
Transformation	dbt	Scripts Python (ne passent pas à l'échelle, illisibles pour les métiers)
Orchestration	Dagster	Airflow (dépendances à décrire à la main, second graphe à maintenir) ; ordonnanceur système (ni reprise, ni traçabilité)
Stockage	PostgreSQL	Entrepôt hébergé (coût récurrent, adhérence) ; fichiers colonnaires (pas de jointure spatiale indexée)
Séries temporelles	TimescaleDB	Partitionnement manuel (à écrire et à maintenir)
Géospatial	PostGIS	Calculs de distance en Python (lents, non indexés)
Déploiement	Docker Compose	Kubernetes (surdimensionné pour un serveur)

Le même raisonnement a présidé aux choix de la plateforme, présentés aux chapitres 6 et 7 : Pastas est la référence de la communauté hydrogéologique pour les modèles à fonction de transfert, Darts unifie sous une seule interface des architectures de prévision qu'il aurait fallu intégrer une à une, MLflow et Optuna sont les outils les plus répandus pour, respectivement, tracer des expériences et optimiser des hyperparamètres. Dans chaque cas, le critère est le même : un successeur doit pouvoir reprendre le travail sans apprendre un outil que personne n'utilise.

Références

- [1] T. AKIBA, S. SANO, T. YANASE, T. OHTA et M. KOYAMA. « Optuna : a next-generation hyperparameter optimization framework ». In : *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2019, p. 2623-2631.
- [2] R. G. ALLEN, L. S. PEREIRA, D. RAES et M. SMITH. *Crop evapotranspiration : guidelines for computing crop water requirements*. FAO Irrigation and Drainage Paper 56. Rome : Organisation des Nations unies pour l'alimentation et l'agriculture, 1998.
- [3] E. ATES, B. AKSAR, V. J. LEUNG et A. K. COSKUN. « Counterfactual explanations for multivariate time series ». In : *International Conference on Applied Artificial Intelligence (ICAPAI)*. IEEE, 2021, p. 1-8.
- [4] S. BEGUERÍA et S. M. VICENTE-SERRANO. *SPEI : calculation of the standardised precipitation-evapotranspiration index*. Paquet R, fonction `parglo` d'ajustement de la logistique généralisée. 2023. URL : <https://cran.r-project.org/package=SPEI>.
- [5] J. BENTO, P. SALEIRO, A. F. CRUZ, M. A. T. FIGUEIREDO et P. BIZARRO. « TimeSHAP : explaining recurrent models through sequence perturbations ». In : *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 2021, p. 2565-2573.
- [6] BRGM. *JUNON : des jumeaux numériques au service des ressources naturelles*. Programme scientifique, Bureau de recherches géologiques et minières. 2023. URL : <https://www.brgm.fr/fr/programme-scientifique/junon-jumeaux-numeriques-au-service-ressources-naturelles>.
- [7] BRGM. *Lancement du programme JUNON en région Centre-Val de Loire*. Communiqué de presse. 2023. URL : <https://www.brgm.fr/fr/actualite/communiqu%C3%A9-presse/lancement-programme-junon-centre-val-loire>.
- [8] BRGM. *EROS : modèle hydrologique global multi-bassins*. Logiciel, Bureau de recherches géologiques et minières. 2026. URL : <https://www.brgm.fr/fr/logiciel/eros-logiciel-modelisation-hydrologique-semi-globale-bassin-versant-decoupe-sous-bassins>.
- [9] BRGM. *GARDÉNIA : modèle global à réservoirs pour la simulation des débits et des niveaux de nappe*. Logiciel, Bureau de recherches géologiques et minières. 2026. URL : <https://www.brgm.fr/fr/logiciel/gardenia-logiciel-modelisation-hydrologique-globale-bassin-versant>.
- [10] BRGM et SANDRE. *BDLISA : base de données des limites des systèmes aquifères*. Référentiel hydrogéologique français. 2026. URL : <https://bdlisa.eaufrance.fr/>.
- [11] R. A. COLLENTUR, M. BAKKER, R. CALJÉ, S. A. KLOP et F. SCHAARS. « Pastas : open source software for the analysis of groundwater time series ». In : *Groundwater* 57.6 (2019), p. 877-885.
- [12] COPERNICUS CLIMATE CHANGE SERVICE. *Climate Data Store : ERA5-Land hourly data from 1950 to present*. Centre européen pour les prévisions météorologiques à moyen terme. 2026. URL : <https://cds.climate.copernicus.eu/>.
- [13] DAGSTER LABS. *Dagster : an orchestrator for data assets*. Logiciel, version 1.11. 2026. URL : <https://dagster.io/>.
- [14] DBT LABS. *dbt : data build tool*. Logiciel, version 1.7. 2026. URL : <https://www.getdbt.com/>.

- [15] DLTHUB. *dlt : data load tool, a Python library for declarative data ingestion*. Logiciel, version 0.4. 2026. URL : <https://dlthub.com/>.
- [16] W. FALCON et THE PYTORCH LIGHTNING TEAM. *PyTorch Lightning*. Logiciel. 2019. URL : <https://www.pytorchlightning.ai/>.
- [17] G. H. HARGREAVES et Z. A. SAMANI. « Reference crop evapotranspiration from temperature ». In : *Applied Engineering in Agriculture* 1.2 (1985), p. 96-99.
- [18] H. HERSBACH et al. « The ERA5 global reanalysis ». In : *Quarterly Journal of the Royal Meteorological Society* 146.730 (2020), p. 1999-2049.
- [19] J. HERZEN et al. « Darts : user-friendly modern machine learning for time series ». In : *Journal of Machine Learning Research* 23.124 (2022), p. 1-6.
- [20] S. HOYER et J. HAMMAN. *xarray : N-D labeled arrays and datasets in Python*. Journal of Open Research Software, 5(1), 10. 2017. URL : <https://xarray.dev/>.
- [21] N. KOKHLIKYAN et al. *Captum : a unified and generic model interpretability library for PyTorch*. arXiv :2009.07896. 2020. URL : <https://captum.ai/>.
- [22] LIFAT. *Projet JUNON (2022–2026), volets DATA, PREDICTION et jumeaux numériques*. Laboratoire d’informatique fondamentale et appliquée de Tours, université de Tours. 2022. URL : <https://lifat.univ-tours.fr/projects/regional/recent/bdtin/2022-2026-junon-project>.
- [23] B. LIM, S. Ö. ARIK, N. LOEFF et T. PFISTER. « Temporal fusion transformers for interpretable multi-horizon time series forecasting ». In : *International Journal of Forecasting* 37.4 (2021), p. 1748-1764.
- [24] S. M. LUNDBERG et S.-I. LEE. « A unified approach to interpreting model predictions ». In : *Advances in Neural Information Processing Systems* 30. 2017, p. 4765-4774.
- [25] T. B. MCKEE, N. J. DOESKEN et J. KLEIST. « The relationship of drought frequency and duration to time scales ». In : *Proceedings of the 8th Conference on Applied Climatology*. Anaheim, Californie, 1993, p. 179-184.
- [26] META OPEN SOURCE. *React 19 : a JavaScript library for building user interfaces*. Logiciel. 2026. URL : <https://react.dev/>.
- [27] MÉTÉO-FRANCE. *SAFRAN : système d’analyse atmosphérique à méso-échelle sur la France*. Réanalyse météorologique sous licence, non redistribuable. 2026.
- [28] J. MUÑOZ-SABATER et al. « ERA5-Land : a state-of-the-art global reanalysis dataset for land applications ». In : *Earth System Science Data* 13.9 (2021), p. 4349-4383.
- [29] OFFICE FRANÇAIS DE LA BIODIVERSITÉ. *Hub’Eau : les API du système d’information sur l’eau*. Services web *niveaux_nappes* et *hydrometrie*. 2026. URL : <https://hubeau.eaufrance.fr/>.
- [30] POSTGIS PROJECT. *PostGIS : spatial and geographic objects for PostgreSQL*. Logiciel. 2026. URL : <https://postgis.net/>.
- [31] POSTGRESQL GLOBAL DEVELOPMENT GROUP. *PostgreSQL 16*. Système de gestion de base de données relationnelle. 2026. URL : <https://www.postgresql.org/>.
- [32] S. RAMÍREZ. *FastAPI : a modern, fast web framework for building APIs with Python*. Logiciel. 2026. URL : <https://fastapi.tiangolo.com/>.
- [33] N. RINGUET. *hubeau_data_integration : entrepôt de données hydro-climatiques*. Dépôt logiciel, forge de l’université de Tours. 2026. URL : https://scm.univ-tours.fr/ringuet/hubeau_data_integration.

- [34] N. RINGUET. *time-serie-explo : plateforme d'exploration, de modélisation et de prévision piézométrique*. Dépôt logiciel, forge de l'université de Tours. 2026. URL : <https://scm.univ-tours.fr/ringuet/time-serie-explo>.
- [35] M. SUNDARARAJAN, A. TALY et Q. YAN. « Axiomatic attribution for deep networks ». In : *Proceedings of the 34th International Conference on Machine Learning*. 2017, p. 3319-3328.
- [36] TIMESCALE. *TimescaleDB : time-series extension for PostgreSQL*. Logiciel. 2026. URL : <https://www.timescale.com/>.
- [37] S. M. VICENTE-SERRANO, S. BEGUERÍA et J. I. LÓPEZ-MORENO. « A multiscalar drought index sensitive to global warming : the standardized precipitation evapotranspiration index ». In : *Journal of Climate* 23.7 (2010), p. 1696-1718.
- [38] J. VON ASMUTH et al. *Handleiding tijdreeksanalyse*. Rapp. tech. 2021-32. Manuel de référence de l'analyse de séries temporelles pour la gestion des eaux souterraines, et critères d'acceptation des modèles. Amersfoort, Pays-Bas : Stichting Toegepast Onderzoek Waterbeheer (STOWA), 2021.
- [39] S. WACHTER, B. MITTELSTADT et C. RUSSELL. « Counterfactual explanations without opening the black box : automated decisions and the GDPR ». In : *Harvard Journal of Law and Technology* 31.2 (2018), p. 841-887.
- [40] Z. WANG, I. MILIOU, I. SAMSTEN et P. PAPAPETROU. « Counterfactual explanations for time series forecasting ». In : *IEEE International Conference on Data Mining (ICDM)*. 2023, p. 1391-1396.
- [41] M. ZAHARIA et al. « Accelerating the machine learning lifecycle with MLflow ». In : *IEEE Data Engineering Bulletin* 41.4 (2018), p. 39-45.