



Programme JUNON
Ambition Recherche & Développement
Région Centre-Val de Loire

Rapport de clôture

De la donnée hydrologique dispersée à la prévision explicable

Construction d'un entrepôt de données et d'une plateforme
d'expérimentation en apprentissage automatique
pour les eaux souterraines

Nicolas Ringuet

Postdoctorant
Laboratoire d'Informatique Fondamentale et Appliquée de Tours (LIFAT)
Université de Tours

Supervision scientifique : Nicolas Labroche (LIFAT)
Collaboration : Hugo Breuillard, Augustin Thomas (BRGM)

Période couverte : 15 septembre 2025 au 30 juin 2026
Travaux de documentation et de passation prolongés jusqu'au 26 août 2026

Projet PRÉDICTION – ARD CVL JUNON
Texte de référence : Convention d'Application N°2021 00146736 / N°2022 00151803
Document technique de référence du livrable ST3.2

Août 2026

Avec le soutien de la
Région Centre-Val de Loire



Synthèse

Le programme JUNON construit des jumeaux numériques des milieux naturels, dont les eaux souterraines. Prévoir l'évolution d'une nappe par apprentissage automatique est aujourd'hui possible. S'en servir pour décider ne l'est pas : une prévision qu'on ne sait pas justifier ne sera pas retenue à l'appui d'un arrêté de restriction d'usage. C'est à cette difficulté, l'**explicabilité des prévisions**, que ce postdoctorat était consacré, au LIFAT de l'Université de Tours, du 15 septembre 2025 au 30 juin 2026.

Il s'est heurté d'emblée à un obstacle matériel. La donnée hydrologique française est publique, mais elle est éparpillée entre des services qui s'ignorent : les niveaux de nappe d'un côté, les débits des rivières d'un autre, le climat ailleurs encore, sans lien entre eux et sans indicateurs comparables d'une station à l'autre. On ne peut pas expliquer un modèle qu'on n'a pas pu entraîner.

J'aurais pu contourner l'obstacle par un jeu de données de circonstance. J'ai choisi d'en faire l'objet du travail. J'ai porté le constat auprès des équipes du BRGM, qui l'ont confirmé : le besoin d'un entrepôt consolidé et d'outils d'analyse ne concernait pas seulement ce postdoctorat, il était partagé par leurs propres équipes comme par d'autres projets, chacun butant sur la même difficulté de son côté. Construire ce socle est devenu le premier travail, non par défaut mais par décision assumée.

L'entrepôt de données sur l'eau et le climat rassemble automatiquement quatre jeux de données issus de trois sources publiques : les niveaux de nappe et les débits de rivière relevés par le réseau national, la reconstitution du climat français depuis 1950, et le référentiel qui décrit les aquifères. Il les met en cohérence, rattache chaque station de mesure au climat de son secteur, et se met à jour chaque jour. Il en tire des indicateurs de sécheresse normalisés, calculés de la même manière sur tout le territoire, dont la conformité a été vérifiée sur près de 42 millions de valeurs. Ce qui demandait plusieurs semaines de préparation à chaque équipe s'obtient désormais par une requête.

La plateforme d'exploration et de prévision donne accès à trois usages. Un observatoire cartographique montre l'état des nappes, des rivières et du climat sur tout le territoire. Un laboratoire de modélisation permet de caler les modèles qu'emploient les hydrogéologues et de simuler des scénarios, l'effet d'un nouveau prélèvement agricole par exemple. Un laboratoire d'intelligence artificielle donne accès à une douzaine de méthodes de prévision et, surtout, aux outils qui permettent d'examiner sur quoi leurs prévisions reposent.

Chaque public y trouve autre chose. Les hydrogéologues, des indicateurs conformes à leurs pratiques et de quoi simuler l'effet d'un prélèvement sur une nappe donnée. Les chercheurs, un jeu de données prêt à l'emploi et un environnement d'expérimentation, qui suppriment le travail de préparation que chaque équipe refaisait pour son compte, avec ses propres conventions. Le programme, une chaîne complète, de la donnée publique jusqu'au service explicable, mobilisable pour les jumeaux numériques de la ressource en eau.

Les briques de modélisation et d'explication sont **préliminaires**, et c'est leur objet. Elles ne portent aucune conclusion scientifique : elles fournissent un point de départ à ceux qui voudront y greffer leurs propres modèles, protocoles ou questions de recherche, sans avoir à reconstruire l'amont. L'une d'elles répond à une exigence que les hydrogéologues ont formulée eux-mêmes : lorsqu'on demande à un modèle ce qu'il aurait fallu pour qu'une nappe ne descende pas si bas, la réponse doit rester physiquement possible. Une implémentation contraint la réponse en ce sens et l'exprime dans les termes du métier : il aurait fallu des hivers plus humides et un climat plus frais

de tant. Son évaluation reste à conduire.

L'ensemble constitue un socle réutilisable, national et documenté. Il a été présenté aux équipes du projet ANR AIDA, dont le périmètre est voisin, pour que celles qui en auraient l'usage n'aient pas à le reconstruire. La chaîne traite plusieurs centaines de millions de mesures, se relance sans rien dupliquer et reprend après interruption, ce qui décide si un jeu de données peut servir de référence commune à plusieurs équipes ou seulement à l'expérience qui l'a produit. Son architecture n'est pas propre aux eaux souterraines : le même enchaînement s'applique aux autres compartiments environnementaux visés par le programme. Il est surtout destiné à servir de base aux travaux d'explicabilité qui prendront la suite, auxquels il transmet à la fois les données, les modèles et les outils d'analyse.

Ce rapport a une seconde fonction, qu'il vaut mieux énoncer que laisser deviner. Le projet PRÉDICTION de JUNON comporte une tâche 3.2, consacrée à l'explicabilité et à l'interprétabilité des modèles prédictifs profonds de séries temporelles, dont le livrable est signé conjointement par le LIFAT et le BRGM. Ce livrable expose les questions de recherche, l'état de l'art des méthodes contrefactuelles et le protocole selon lequel elles doivent être comparées ; il décrit le socle en une section, à la mesure de ce que son propos exige. Le présent document est le **rapport technique de ce socle** : il donne la chaîne source par source, les décisions qui engagent la validité des résultats, les procédures d'exploitation et l'inventaire des limites. Les deux se lisent séparément, et le second répond aux questions que le premier laisse ouvertes sur la construction.

Reste ce que ce rapport n'établit pas. Aucune comparaison chiffrée des méthodes de prévision n'y figure : le temps consacré à l'infrastructure ne l'a pas permis, et je n'ai rien reconstitué de mémoire. Et l'usage de la plateforme demeure circonscrit au cercle du projet ; son élargissement relève d'une décision d'accès plus que de développements supplémentaires.

Table des matières

Synthèse	2
1 Contexte et positionnement	7
1.1 Le programme JUNON	7
1.2 La mission initiale : l'explicabilité	7
1.3 Le glissement de mission, et pourquoi il était nécessaire	7
1.4 Périmètre du rapport	8
2 Le verrou : une donnée ouverte mais inexploitable	9
2.1 Ce que la donnée ouverte offre réellement	9
2.2 Ce qui manque	9
2.2.1 La jointure au forçage climatique n'existe pas	9
2.2.2 L'historique n'est pas consolidé, et la volumétrie est réelle	10
2.2.3 Lire la donnée brute suppose d'en connaître les conventions	10
2.2.4 Des sources publiques, mais pas des sources stables	10
2.2.5 Aucun indicateur normalisé n'est fourni	11
2.3 Ce que l'apprentissage automatique exige en plus	11
2.4 Le coût collectif de l'absence d'infrastructure	11
3 Sourcing et entrepôt de données	12
3.1 Le principe retenu : une architecture médaillon	12
3.2 Le choix de la pile technique	12
3.3 Déploiement, packaging et reproductibilité	13
3.4 Bronze : ingérer sans interpréter	14
3.5 Silver : nettoyer en rendant compte	15
3.6 Gold : joindre, enrichir, exposer	15
3.6.1 Aligner les stations sur la grille climatique	15
3.7 Orchestration : planifier l'ingestion, déclencher la transformation	16
3.8 Les garanties de la chaîne, et comment elles ont été éprouvées	16
3.8.1 Deux règles contre les défaillances qui ne s'annoncent pas	17
4 Des mesures aux indicateurs : construction et validation	18
4.1 Pourquoi standardiser	18
4.2 Les indices par station	18
4.3 Les indices climatiques sur grille	19
4.4 Premier arbitrage : quelle évapotranspiration employer	21
4.4.1 De quoi il est question	21
4.4.2 Ce qui s'est passé	21
4.4.3 Pourquoi	21
4.4.4 Ce que cela change	22
4.4.5 Une incohérence connue, et ce qu'elle coûte	23
4.5 Deuxième arbitrage : quelle loi ajuster pour le SPEI	23
4.6 La vérification des indices produits	24

4.7	Deux lectures à ne pas faire	24
4.8	Un contrat entre les deux dépôts	24
5	L'Observatoire : donner à voir	26
5.1	Une contrainte d'architecture posée d'emblée	26
5.2	Le besoin : explorer avant de modéliser	26
5.3	Organisation : deux compartiments	27
5.4	Une règle de conception qui a structuré l'interface	28
5.5	Trois choix techniques	28
5.6	Environnements et déploiement	30
6	Modéliser : le laboratoire de modèles métier	31
6.1	Pourquoi commencer par le modèle métier	31
6.2	Les modèles à fonction de transfert et bruit	31
6.3	Calibration automatique et critères de qualité	31
6.4	L'apport hydrogéologique : des configurations par famille d'aquifère	33
6.5	Diagnostics et validation	35
6.6	Scénarios prospectifs	36
7	Apprendre et expliquer : le laboratoire d'intelligence artificielle	38
7.1	Le problème posé	38
7.2	Un catalogue d'architectures sous interface unique	38
7.3	Le protocole expérimental	38
7.4	Optimisation d'hyperparamètres	39
7.5	Rendre l'outil utilisable par des non-spécialistes	40
7.6	Lire une prévision avant de l'expliquer	40
7.7	Analyser les prévisions produites	41
7.7.1	Contrefactuels sous contrainte physique	42
7.8	Deux travaux personnels conduits en marge	43
7.8.1	Éprouver la méthode contrefactuelle hors de l'application	43
7.8.2	Un banc d'essai des représentations de chroniques piézométriques	43
7.9	Ce qui est établi, et ce qui ne l'est pas	45
8	Ce que la collaboration a produit	46
8.1	Le cadre de travail	46
8.2	Les cas d'usage identifiés avec le BRGM	46
8.3	L'articulation avec les travaux de recherche en cours	47
8.4	Des besoins distincts, un outil commun	48
8.5	État de mise à disposition	48
9	Bilan : le socle, ses limites, sa reprise	50
9.1	Récapitulatif des réalisations	50
9.2	Bilan au regard de la mission initiale	51
9.3	Ce qui rend ce socle réutilisable	51
9.4	Ce qui est transmis aux travaux à venir	52
9.5	Limites et chantiers à reprendre	52
9.6	Extensions, par coût croissant	54
9.7	Articulation avec le volet des jumeaux numériques	55

9.8	État de passation	55
9.9	Conclusion	55
A	Annexes	56
A.1	Inventaire des réalisations logicielles	56
A.1.1	Entrepôt de données hydro-climatiques	56
A.1.2	Plateforme d'exploration, de modélisation et de prévision	56
A.2	Sources de données et attributions	57
A.3	Le cheminement de l'évapotranspiration dans l'entrepôt	57
A.4	Volumétrie des indicateurs climatiques	58
A.5	Glossaire	59
B	Revue des outils retenus	60
B.1	Ingestion : dlt	60
B.2	Transformation : dbt	60
B.3	Orchestration : Dagster	60
B.4	Stockage : PostgreSQL, TimescaleDB et PostGIS	61
B.5	Synthèse des choix	61
	Références	62

1 Contexte et positionnement

Dans quel dispositif de recherche ces travaux s'inscrivent-ils, et quelle mission leur avait été assignée au départ ?

1.1 Le programme Junon

JUNON est un programme *Ambition Recherche & Développement* de la Région Centre-Val de Loire, coordonné par le BRGM et réunissant une vingtaine d'équipes de recherche du territoire [6, 7]. Son objectif est de développer des **jumeaux numériques** des milieux naturels continentaux, l'eau, le sol et l'air, et les services numériques qui les accompagnent. Un jumeau numérique ne se réduit pas à une visualisation : il vise à reproduire les structures et les processus réels tout au long de leur évolution, en s'appuyant notamment sur l'apprentissage automatique.

À côté des projets consacrés à chaque compartiment environnemental, le programme comporte des volets transversaux qui fournissent les moyens communs, notamment la gestion des observations et la modélisation prédictive. Le LIFAT participe à ces volets transversaux sur la période 2022–2026 [25], sur les questions de prédiction à partir de séries temporelles environnementales : comment apprendre le comportement d'un système naturel à partir d'observations éparses, bruitées et déséquilibrées, et comment qualifier la confiance que l'on peut accorder à la prédiction obtenue.

C'est dans ce cadre que s'inscrivent les présents travaux, menés du 15 septembre 2025 au 30 juin 2026 sous la supervision de Nicolas Labroche.

1.2 La mission initiale : l'explicabilité

Le sujet assigné portait sur **l'explicabilité des modèles de prévision appliqués aux nappes d'eau souterraine**. Un modèle d'apprentissage profond qui prévoit un niveau piézométrique produit un nombre ; ce nombre n'a de valeur opérationnelle que si l'on peut répondre à trois questions que tout hydrogéologue posera : sur quoi le modèle s'appuie-t-il, que se passerait-il dans d'autres conditions, et jusqu'où peut-on lui faire confiance hors du régime observé.

Ces questions ne sont pas académiques. Les niveaux de nappe conditionnent des décisions publiques : arrêtés de restriction d'usage, autorisations de prélèvement, planification de l'alimentation en eau potable. Une prédiction que l'on ne sait pas justifier ne sera pas mobilisée, et ne devrait pas l'être.

1.3 Le glissement de mission, et pourquoi il était nécessaire

L'explicabilité s'applique à un modèle ; un modèle s'entraîne sur des données. Or, au démarrage des travaux, **aucun jeu de données exploitable n'existait** pour les nappes françaises associées à leur forçage climatique. Ce constat, développé au chapitre 2, a déterminé la trajectoire de l'année.

Le travail a donc pris la forme d'une **ingénierie de recherche assumée** : identifier les sources, construire l'entrepôt, produire les indicateurs, vérifier leur validité, puis seulement outiller la modélisation et l'explicabilité. Cette réorientation n'a pas dilué le sujet initial, elle en a conditionné la possibilité. En pratique, elle a produit un résultat plus durable qu'une étude d'explicabilité menée sur un jeu de données jetable : **l'infrastructure survit à l'expérience**.

Cette réorientation n'a pas été décidée seul. Elle procède d'un recadrage mené avec le BRGM au début de l'année 2026, associant les interlocuteurs techniques et les experts métier. Les échanges ont établi que le manque constaté n'était pas propre à ce postdoctorat : le besoin d'un entrepôt

consolidé, d'outils d'analyse et d'un environnement d'entraînement de modèles était partagé par les équipes du BRGM comme par d'autres projets du programme, chacun butant sur le même obstacle de son côté. C'est cette vérification qui a rendu légitime l'investissement de plusieurs mois que représente un entrepôt de données.

1.4 Périmètre du rapport

Deux réalisations logicielles sont couvertes, développées intégralement au cours de la période :

Table 1.1 – Les deux réalisations logicielles couvertes par ce rapport.

Dépôt	Objet
<code>hubeau_data_integration</code> [36]	Entrepôt de données hydro-climatiques. Ingestion, transformation et exposition des données piézométriques, hydrométriques, climatiques et hydrogéologiques. Premier commit : 23 septembre 2025.
<code>time-serie-explo</code> [37]	Plateforme d'exploration, de modélisation et de prévision. Observatoire spatial, laboratoire de modèles métier, laboratoire d'apprentissage automatique, explicabilité. Premier commit : 6 novembre 2025.

Le contrat postdoctoral s'est achevé le 30 juin 2026. Les travaux de documentation, de neutralisation des éléments sensibles et de passation se sont poursuivis jusqu'au 26 août 2026, afin que ces réalisations restent exploitables après le départ de leur auteur.

2 Le verrou : une donnée ouverte mais inexploitable

La donnée hydrologique française est publique et accessible. Pourquoi faut-il malgré tout construire une infrastructure avant d'espérer entraîner le moindre modèle ?

2.1 Ce que la donnée ouverte offre réellement

Trois sources publiques couvrent, en principe, l'essentiel du besoin.

Hub'Eau est la plateforme d'accès aux données sur l'eau opérée dans le cadre du système d'information sur l'eau [32]. Elle expose par interfaces web les chroniques *piézométriques*, c'est-à-dire les niveaux de nappe mesurés aux ouvrages de surveillance, et les données *hydrométriques* de débit des cours d'eau, organisées en sites, stations et observations élaborées. Le parc compte 23 333 ouvrages piézométriques, 6 468 stations hydrométriques et 9 283 sites de référence, ces derniers ne portant pas tous une station en service.

ERA5-Land, produit par le Centre européen pour les prévisions météorologiques à moyen terme et diffusé par le *Climate Data Store* de Copernicus [12], fournit une réanalyse climatique sur grille d'environ 0,1°, continue depuis 1950 [19, 31]. C'est la source de forçage naturelle pour tout modèle hydrologique : précipitations, températures, évaporation.

BDLISA, le référentiel hydrogéologique du BRGM [10], décrit les entités aquifères du territoire : leur nature, leur géométrie, leur organisation. C'est ce qui permet de savoir si un piézomètre observe une nappe alluviale, un aquifère sédimentaire poreux, un système karstique ou un socle fracturé, distinction dont on verra au chapitre 6 qu'elle commande le comportement du signal.

Chacune de ces sources est ouverte, documentée et interrogeable. Le verrou n'est pas l'accessibilité.

Une alternative existait. Le BRGM dispose d'une licence pour la réanalyse SAFRAN [30], mieux adaptée au territoire français. Elle a été écartée pour une raison qui n'est pas technique : les données SAFRAN ne sont pas redistribuables, ce qui interdisait de les verser dans un entrepôt destiné à être partagé entre équipes et documenté publiquement. ERA5-Land est libre, mondial et versionné. Le choix privilégie donc la reproductibilité et le partage sur la finesse de la source, arbitrage qu'il faut connaître pour interpréter les résultats.

2.2 Ce qui manque

2.2.1 La jointure au forçage climatique n'existe pas

Un niveau de nappe seul n'est pas modélisable. Il répond à la pluie efficace, c'est-à-dire à la différence entre précipitation et évapotranspiration, avec un retard et un amortissement propres à l'aquifère. Prédire une nappe suppose donc de disposer, *pour chaque station et chaque jour*, du signal climatique correspondant.

Or Hub'Eau ne fournit aucune variable météorologique, et ERA5 ignore l'existence des piézomètres. Rattacher les deux exige une jointure spatiale, qui associe chaque station à la maille climatique la plus proche, puis une jointure temporelle sur un pas de temps commun. Ce travail n'est fourni par personne.

2.2.2 L'historique n'est pas consolidé, et la volumétrie est réelle

Les interfaces web sont paginées et conçues pour la consultation, non pour la constitution d'un corpus. Récupérer six décennies de chroniques sur l'ensemble du parc de stations, puis sept décennies de réanalyse climatique sur l'ensemble du territoire, représente des dizaines de gigaoctets et plusieurs jours de collecte. Ce n'est pas une opération que l'on relance à chaque expérience.

Le cas d'ERA5 illustre l'écart entre l'accès théorique et le coût pratique. Le produit dérivé de statistiques journalières proposé par le *Climate Data Store* est calculé côté serveur, sur une file d'attente saturée : environ **43 heures par année demandée**. À ce rythme, reconstituer sept décennies se compte en mois. La même information, recalculée localement à partir de l'archive horaire brute, demande environ **vingt-cinq minutes par année**. L'équivalence des deux voies a été vérifiée maille par maille et jour par jour, à 0,0000 °C sur les extrêmes journaliers et 0,01 °C sur la moyenne.

2.2.3 Lire la donnée brute suppose d'en connaître les conventions

Dans ERA5, les variables de précipitation et d'évaporation sont des *flux cumulés* : la valeur au pas de 00 h UTC constitue le total du jour écoulé. La température est une *grandeur instantanée* : la même valeur, au même horodatage, n'est qu'un relevé de minuit. Deux variables issues du même fichier, à la même heure, dont l'une se lit telle quelle et l'autre doit être reconstruite à partir des vingt-quatre pas horaires.

Le fournisseur documente cette convention et distingue explicitement les paramètres cumulés des paramètres instantanés [31]. Rien dans les valeurs ni dans les horodatages ne l'exprime pour autant, et se tromper ne produit aucun signal : la série obtenue reste plausible, simplement trop froide. Mesuré sur les 11 496 mailles du territoire, du 1^{er} janvier 2025 au 19 août 2026, sur les 935 040 couples maille-jour où les deux chemins d'ingestion se recouvrent, l'écart entre le relevé de minuit et la vraie moyenne journalière vaut $-2,90^{\circ}\text{C}$ en moyenne et atteint $-3,4^{\circ}\text{C}$ en juin. C'est ce qui impose le second chemin d'ingestion décrit au chapitre 3.

2.2.4 Des sources publiques, mais pas des sources stables

Les interfaces publiques sont ouvertes, elles ne sont pas pour autant fiables. Ce point a coûté un temps considérable. Il a fallu composer avec leurs défauts plutôt que les supposer absents.

La disponibilité, d'abord, n'est pas garantie : les services répondent en erreur lorsqu'ils sont sollicités intensément, ce qui est précisément le régime d'une collecte historique. Toute ingestion doit donc intégrer des tentatives successives avec temporisation croissante, et être capable de reprendre là où elle s'est arrêtée. Une extraction naïve échoue au bout de quelques heures et laisse un jeu de données incomplet sans le signaler.

Les conventions, ensuite, varient d'un point d'accès à l'autre au sein d'une même source. Le paramètre qui identifie une station n'est pas le même selon l'interface interrogée. Employer le mauvais ne provoque pas d'erreur explicite, mais un résultat vide. S'y ajoute que la version 1 de l'interface n'accepte pas le paramètre de taille de page, ni dans la requête initiale ni dans les liens de pagination qu'elle retourne, ce qui oblige à le retirer des deux.

Les données elles-mêmes, enfin, présentent des incohérences. Le service d'observations hydrométriques retourne des mesures rattachées à des stations *absentes de son propre référentiel* : la source se contredit, et une jointure naïve échoue sur une violation de clé étrangère.

Ces défauts ont une conséquence directe sur l'architecture décrite au chapitre 3. Le nettoyage ne peut pas être une formalité que l'on expédie : il devient une fonction de premier plan, et surtout il doit **rendre compte de ce qu'il écarte**. C'est la raison d'être des tables de rejets, qui conservent chaque ligne exclue avec le motif de son exclusion. Sans elles, il serait impossible de distinguer une

station réellement absente du terrain d'une station perdue en route par un défaut de la source ou par un critère de filtrage trop strict.

2.2.5 Aucun indicateur normalisé n'est fourni

Un hydrogéologue ne raisonne pas sur un niveau brut en mètres, qui n'a de sens que rapporté à l'historique de l'ouvrage. Il raisonne sur des **indicateurs standardisés** qui situent la mesure du jour par rapport à la distribution de référence du même mois : est-on dans la normale, en situation modérément sèche, en sécheresse sévère ? Ces indicateurs, qu'il s'agisse des indices standardisés de niveau, de débit, de précipitation ou de bilan hydrique, ne sont exposés par aucune des interfaces exploitées ici. Ils doivent être calculés, ce qui suppose une période de référence, un ajustement statistique et une validation.

2.3 Ce que l'apprentissage automatique exige en plus

Les difficultés précédentes concernent tout usage de la donnée. L'apprentissage automatique en ajoute qui lui sont propres.

- **Une couverture temporelle continue.** Un modèle de séries temporelles supporte mal les lacunes ; encore faut-il savoir où elles sont, ce qui suppose une chronologie régulière et explicite plutôt qu'une liste d'observations.
- **Des covariables alignées.** Le forçage climatique doit être disponible sur exactement la même chronologie que la cible, sans décalage ni trou différentiel.
- **La reproductibilité.** Une expérience qui ne peut être rejouée sur les mêmes données n'est pas un résultat. Cela interdit l'extraction ponctuelle et impose un stockage versionné et interrogeable.
- **Le volume.** Comparer une douzaine d'architectures sur des centaines de stations suppose de lire les données des milliers de fois. Une chaîne d'extraction par interface web rend l'exercice impraticable ; une base de données ne le rend pas seulement possible, elle le rend rapide.

2.4 Le coût collectif de l'absence d'infrastructure

Le constat déterminant n'est pas technique mais organisationnel. En l'absence d'entrepôt, **chaque chercheur refait l'extraction**, avec ses propres conventions de nettoyage, sa propre gestion des lacunes, son propre rattachement climatique. Les résultats deviennent incomparables, non par divergence de méthode, mais par divergence de préparation des données. Le temps consacré à la collecte est prélevé sur le temps de recherche, et il est prélevé autant de fois qu'il y a de chercheurs.

Les équipes du BRGM faisaient le même constat, dans leurs termes : plusieurs jeux de données coexistaient, de provenances et de qualités différentes, sans base commune permettant de les comparer.

C'est ce coût, réparti et invisible, que l'entrepôt décrit au chapitre 3 supprime.

Le verrou est donc caractérisé : la donnée est ouverte, mais ni jointe, ni consolidée, ni normalisée, ni prête pour l'apprentissage. La question qui organise la suite de ce rapport découle de ce constat. Quelle infrastructure faut-il construire pour que la recherche en intelligence artificielle appliquée aux eaux souterraines devienne seulement possible ? Une précision de périmètre s'impose avant d'y répondre : les travaux portent sur la quantité d'eau, niveaux et débits. La qualité, également visée par le programme, n'a pas été abordée.

3 Sourcing et entrepôt de données

Comment transformer quatre jeux de données hétérogènes, volumineux et piégeux en un ensemble interrogeable, reproductible et digne de confiance ?

Ce chapitre porte le résultat principal du travail. Il ne s'agit pas d'un choix d'outils, mais d'un ensemble de propriétés à garantir, celles dont dépend la possibilité même de comparer deux expériences.

3.1 Le principe retenu : une architecture médaille

La donnée traverse trois couches de qualité croissante, matérialisées par trois schémas distincts d'une même base PostgreSQL [34]. Ce patron, dit *médaille* et représenté sur la figure 3.1, répond à une exigence simple : **ne jamais perdre la donnée telle qu'elle a été reçue**, et rendre chaque transformation ultérieure explicite, versionnée et rejouable.




Figure 3.1 – Les trois couches de l'entrepôt. La donnée brute n'est jamais écrasée, et les lignes écartées au nettoyage sont conservées à part avec le motif de leur exclusion : le filtrage se vérifie par une requête au lieu d'être silencieux.

3.2 Le choix de la pile technique


Aucun outil n'était imposé. Chacun a été retenu après une revue des solutions disponibles, selon trois critères explicites, et c'est le troisième qui a le plus pesé.

1. **Ce que l'outil évite d'écrire.** Tout mécanisme fourni par une bibliothèque éprouvée est du code que je n'ai pas à produire, à tester ni à documenter, et qui n'apporte aucun résultat scientifique propre.

2. **L'adéquation au besoin réel**, en particulier la combinaison rare de séries temporelles longues et de traitement géospatial.
3. **La pérennité et la transférabilité**. Ces travaux sont destinés à être repris. Un outil de niche, si élégant soit-il, condamne le successeur à une documentation absente, à des forums vides et à une compétence introuvable. Le critère décisif n'est donc pas la supériorité technique d'un outil, mais son **adoption** : la taille de sa communauté, la vivacité de sa maintenance, l'abondance de sa documentation et la probabilité qu'un nouvel arrivant le connaisse déjà.

Ce dernier point est la raison pour laquelle la pile retenue est délibérément **conventionnelle**. L'enchaînement ingestion, transformation, orchestration correspond à un patron d'architecture largement diffusé dans l'industrie de la donnée, et chacun de ses composants est un choix courant dans ce patron plutôt qu'une préférence personnelle.

La figure 3.2 donne la pile complète, celle de l'entrepôt comme celle de la plateforme construite au-dessus. Chacun de ces choix a été instruit contre ses alternatives : le détail figure en annexe B, avec ce qui a été écarté et pourquoi. Le reste de ce chapitre porte sur ce que la chaîne fait, non sur les outils qui la composent.



Les deux dépôts se déploient par Docker Compose, versions figées dans les images.

Figure 3.2 – La pile technique, de la source publique jusqu'à l'interface. Aucun outil n'était imposé ; chacun est un choix courant de son emplacement, retenu pour son adoption plutôt que pour sa supériorité technique.

3.3 Déploiement, packaging et reproductibilité

Ce point a fait l'objet d'un travail délibéré, et non d'une finition de dernière minute. Un socle destiné à être repris ne vaut que s'il se réinstalle : une chaîne qui ne fonctionne que sur la machine de son auteur meurt avec son départ.

Tout est conteneurisé. Les deux dépôts se déploient par Docker Compose, rien n'est installé sur l'hôte, aucune dépendance système n'est supposée présente, et les versions sont figées dans les images. Une orchestration plus élaborée, de type Kubernetes, aurait été surdimensionnée pour un serveur unique et aurait ajouté une compétence à transmettre sans bénéfice opérationnel. L'entrepôt dispose d'une configuration de production et d'une configuration de bac à sable, la plateforme en compte trois, production, accélération sur processeur graphique et développement complètement séparé, avec ses propres volumes, bases et ports, de sorte qu'un modèle entraîné ou un compte créé d'un côté n'atteint jamais l'autre. Le profil se choisit par une variable d'environnement, sans modifier de fichier.

Les volumes de données, eux, sont déclarés en dehors du cycle de vie de la pile, ce qui rend impossible leur destruction par une commande d'arrêt, même assortie de l'option qui supprime les volumes. Un script dédié les crée une fois, avant le premier démarrage. D'autres scripts couvrent les gestes que le successeur devra poser : sauvegarde et restauration de l'entrepôt, export à plat des tables analytiques pour un usage hors base, création d'un compte en lecture seule pour un consommateur tiers, déploiement sur le serveur. La procédure de restauration a été vérifiée de bout en bout sur un entrepôt représentatif, 4,5 GB et quinze tables dont six hypertables à chunks compressés, et non sur une table jouet.

La documentation d'installation n'a pas davantage été rédigée de mémoire. Elle a été éprouvée en repartant d'une machine vierge, ce qui fait apparaître les écarts qu'une machine déjà configurée masque. Chaque dépôt fournit par ailleurs un exemple de fichier d'environnement recensant toutes les variables attendues, avec leur rôle. Les secrets n'y figurent pas, et les services n'écoutent par défaut que sur l'interface locale, ce qui évite qu'une installation de test se retrouve exposée par inadvertance.

3.4 Bronze : ingérer sans interpréter

Chaque source est ingérée par dlt, assisté du client dédié décrit plus haut pour la pagination et la reprise sur erreur. dlt infère le schéma, crée les tables et charge par lots. Les séries temporelles sont partitionnées par année, ce qui rend chaque tranche rechargeable indépendamment. Les partitions couvrent 1967 à aujourd'hui pour la piézométrie comme pour l'hydrométrie, la profondeur effectivement disponible variant d'une station à l'autre selon sa date de mise en service.

Le principe de la couche est de **ne rien décider** : les colonnes restent textuelles, les valeurs sont celles reçues. Toute interprétation appartient aux couches suivantes, où elle est lisible et modifiable.

Le cas d'ERA5 fait exception sur un point, imposé par la nature du produit : les fichiers NetCDF ne sont jamais archivés en base. Ils sont téléchargés en stockage temporaire, extraits en mémoire avec xarray [22] et insérés directement. Deux chemins d'ingestion coexistent, l'un pour les séries issues du pas de 00 h UTC, l'autre pour les statistiques journalières de température agrégées localement sur les vingt-quatre pas horaires, pour la raison exposée au chapitre 2 : flux cumulés et grandeurs instantanées ne se lisent pas de la même manière.

Table 3.1 – Volumétrie de la couche brute, mesurée le 24 août 2026.

Table	Lignes
Statistiques journalières de température ERA5	≈ 320 000 000
Séries temporelles ERA5	≈ 300 000 000
Mesures piézométriques	≈ 23 000 000
Observations hydrométriques élaborées	≈ 15 000 000
Ouvrages piézométriques	23 333
Sites hydrométriques	9 283
Stations hydrométriques	6 468
Entités hydrogéologiques BDLISA	3 716
Total	≈ 658 000 000

3.5 Silver : nettoyer en rendant compte

Chaque modèle dbt de cette couche sélectionne les colonnes utiles, convertit les types, déduplique et écarte les lignes invalides. La caractéristique importante n'est pas le nettoyage lui-même, mais sa **traçabilité** : les lignes écartées ne disparaissent pas, elles sont écrites dans un schéma dédié, accompagnées du motif de leur exclusion : date de mesure absente, code de station manquant, station orpheline de son site.

Cette décision a un coût de stockage négligeable et une valeur méthodologique élevée : la question posée au chapitre 2, distinguer une station réellement absente d'une station éliminée par un critère trop strict, se tranche ici par une requête.

Huit modèles de nettoyage et trois modèles de rejets composent cette couche. Les modèles de séries temporelles sont incrémentaux, avec une fenêtre de recouvrement de sept jours qui absorbe les corrections tardives publiées par les producteurs de données.

3.6 Gold : joindre, enrichir, exposer

C'est dans cette couche que se résout le verrou central identifié au chapitre précédent.

Le premier travail de cette couche est le rattachement climatique. Chaque station piézométrique ou hydrométrique est associée à sa maille ERA5 la plus proche par une jointure spatiale du plus proche voisin, exécutée par PostGIS. Cette opération, effectuée une fois et matérialisée, transforme deux jeux de données étrangers l'un à l'autre en une chronique unique où le niveau et son forçage climatique figurent sur la même ligne, au même jour.

Deux précautions s'y attachent.

3.6.1 Aligner les stations sur la grille climatique

La première tient à l'emprise. La grille climatique ingérée couvre un rectangle allant de 41° à 51,5° de latitude et de -5,5° à 10° de longitude, soit la France métropolitaine et la Corse. Les départements et territoires d'outre-mer en sont exclus. Ce choix n'est pas de principe : il tient au volume, puisque étendre l'emprise multiplie d'autant la quantité de données à télécharger, à stocker et à indexer, pour des territoires que le programme ne visait pas.

La conséquence doit être connue de quiconque exploite l'entrepôt. Les stations ultramarines présentes dans les référentiels nationaux sont bien ingérées, avec leurs mesures de niveau ou de débit, mais elles n'ont **aucun forçage climatique associé**. Elles restent donc inutilisables pour

toute modélisation supposant la pluie et la température, et il faut les écarter explicitement plutôt que de les laisser produire des séries incomplètes. Elles constituent l'essentiel des lignes sans météo constatées dans les tables analytiques.

La seconde porte sur les coordonnées elles-mêmes, puisqu'elles servent de clé de jointure. Une même maille écrite avec deux précisions flottantes différentes, 48,1° d'un côté et 48,099 999 999 999 95 de l'autre, fait deux points distincts pour la base, et la grille se dédouble sans que rien ne le signale. Les coordonnées sont donc arrondies au pas natif de la grille, 0,1°, ce qui est sans perte puisque c'est la résolution réelle du produit, et l'arrondi s'applique partout où elles servent de clé : au nettoyage, à la construction des points de grille, et à chaque lecture qui rapproche une station de sa maille. Un test automatique garde l'invariant.

Vient enfin l'enrichissement hydrogéologique. Les entités du référentiel BDLISA sont rattachées aux stations, ce qui rend disponible la nature de l'aquifère observé, information que le chapitre 6 exploitera pour paramétrer les modèles métier.

Ce rattachement appelle une réserve. Le référentiel décrit les entités hydrogéologiques et leur ordre de superposition, mais ne porte pas leur profondeur. Déterminer laquelle un piézomètre capte réellement reste donc approximatif, difficulté que les hydrogéologues rencontrés signalent comme ouverte de leur côté également. L'enrichissement fourni est une indication utile, pas une caractérisation certaine de l'ouvrage.

La couche expose au bout du compte des faits journaliers (chroniques piézométriques et hydrométriques enrichies du climat), des faits agrégés mensuels et annuels, des dimensions de description (calendrier, géographie, stations) et les grilles climatiques, soit dix-huit modèles de transformation complétés par des tables d'indicateurs calculées en Python. Les faits journaliers sont stockés en *hypertables* TimescaleDB compressées, forme de partitionnement temporel qui maintient les performances d'interrogation sur plusieurs dizaines de millions de lignes.

L'ensemble est directement interrogeable en SQL. C'est le contrat d'interface : un consommateur n'a besoin de connaître ni la chaîne d'ingestion, ni les outils employés, seulement le schéma des tables finales.

3.7 Orchestration : planifier l'ingestion, déclencher la transformation

L'ingestion est **planifiée** par Dagster : mise à jour quotidienne des chroniques et du climat, rafraîchissement mensuel du référentiel, contrôle hebdomadaire de complétude, recalcul hebdomadaire des références statistiques. La transformation, elle, est **déclenchée par événement** : dès que de nouvelles données brutes sont disponibles, un capteur lance la chaîne de transformation, laquelle déclenche à son tour le recalcul des indicateurs et les contrôles qualité. L'ensemble compte huit traitements planifiés et trois capteurs.

Ce choix évite le défaut classique des chaînes entièrement planifiées, où la transformation s'exécute à heure fixe sur des données parfois absentes, et produit des résultats partiels sans que rien ne le signale.

Les contrôles, enfin, ne bloquent pas le rafraîchissement : les tests de qualité s'exécutent en parallèle du recalcul des indicateurs, et non en amont. Un test en échec fait échouer sa propre exécution, donc alerte, mais n'empêche pas la donnée d'être mise à jour. L'arbitrage est délibéré : sur une chaîne de surveillance, une donnée imparfaite mais fraîche est préférable à une donnée absente, à condition que le défaut soit signalé.

3.8 Les garanties de la chaîne, et comment elles ont été éprouvées

Trois propriétés décident de la confiance que l'on peut accorder à un jeu de données partagé.

- **L'idempotence** : relancer une ingestion sur une période déjà chargée ne duplique rien. Le mécanisme est explicite plutôt que délégué. Avant chaque chargement, les lignes de la plage visée sont supprimées, puis les nouvelles sont ajoutées. Ce choix, plus verbeux qu'une fusion sur clé, fonctionne sur des tables dont les colonnes sont encore textuelles à ce stade, et rend la suppression visible dans le code plutôt qu'implicite dans une configuration.
- **La reprise** : le chargement initial complet, qui se compte en jours, est interruptible et redémarrable, son avancement étant persisté en base.
- **La maîtrise de la concurrence** : les exécutions ne sont pas globalement sérialisées, ce qui serait simple mais lent. Elles sont contraintes par clés, chaque clé plafonnant le nombre d'exécutions simultanées d'une même nature, de sorte qu'un rechargement historique n'affame jamais la mise à jour quotidienne.

Ces propriétés ne se vérifient pas sur le papier. Elles ont été éprouvées en exploitation réelle, et le manuel d'exploitation du dépôt en conserve le détail.

3.8.1 Deux règles contre les défaillances qui ne s'annoncent pas

Une chaîne de données peut s'exécuter, se déclarer réussie et livrer un résultat faux. Aucun test unitaire ne détecte ce cas, puisque le code fait exactement ce qu'on lui demande. Deux règles en découlent, appliquées ici :

- les garanties d'unicité sont portées par le schéma de la base quand c'est possible, et par l'orchestration quand ce ne l'est pas, jamais par l'hypothèse implicite que deux traitements ne se croiseront pas ;
- la surveillance porte sur la **fraîcheur des données** et non sur le succès des exécutions. Comparer la date maximale présente en base à celle réellement disponible chez le fournisseur est la seule vérification qui détecte une ingestion figée sur une réponse périmée.

Ce que cette chaîne change se mesure à une chose : obtenir soixante ans de niveaux de nappe joints à leur climat demandait plusieurs semaines de préparation. C'est aujourd'hui une requête.

4 Des mesures aux indicateurs : construction et validation

Une mesure brute ne dit rien de la situation qu'elle décrit. Comment produire des indicateurs normalisés, comparables entre stations et entre années, et comment établir qu'ils sont justes ?

4.1 Pourquoi standardiser

Un niveau piézométrique de 12,4 m n'est ni haut ni bas dans l'absolu : il l'est relativement à ce que l'ouvrage observe habituellement à cette période de l'année. La même remarque vaut pour un cumul de pluie ou une température. L'usage opérationnel suppose donc de rapporter chaque mesure à sa **distribution de référence** : décider s'il faut restreindre les prélèvements, comparer deux bassins, situer un épisode dans l'histoire climatique.

C'est l'objet des indices standardisés. Leur principe est constant : ajuster une loi de probabilité sur la série de référence, puis transformer la valeur observée en un score exprimé en écarts-types d'une loi normale centrée réduite. Un score de -2 signifie alors la même chose partout : une situation d'une rareté que les échelles usuelles rangent parmi les sécheresses les plus marquées.

Deux familles ont été produites : les indices *par station*, calculés sur les niveaux de nappe et les débits, et les indices *sur grille*, calculés sur les variables climatiques pour chaque maille du territoire.

4.2 Les indices par station

L'indicateur piézométrique standardisé et son équivalent pour les débits situent le mois courant par rapport à sa normale saisonnière. La méthode n'a pas été inventée ici : elle suit celle que le BRGM a proposée pour le Bulletin de situation hydrologique [38], précisée ensuite par une note d'utilisation [23] et éprouvée par une comparaison avec l'indicateur qu'elle remplaçait [39]. Ce choix est délibéré. Il aurait été possible de définir un indice maison, mieux ajusté à nos données ; il aurait été inutilisable pour les équipes qui publient déjà l'IPS, et incomparable aux valeurs qu'elles diffusent. Reprendre la méthode publiée place le socle dans le vocabulaire de ses destinataires et rattache la chaîne à une famille d'indices standardisés établie, celle du SPI de McKee [28] dont l'IPS transpose le principe aux niveaux de nappe.

Trois points de la méthode BRGM sont repris tels quels : le caractère mensuel de l'indicateur, l'exigence d'un minimum de quinze années d'observation pour un mois donné, et la classification en sept classes. Deux points s'en écartent, et ils sont signalés parce qu'ils changent les valeurs. La période de référence retenue est 1991–2020 plutôt que 1981–2010, pour s'aligner sur la normale en vigueur à l'Organisation météorologique mondiale et sur celle qu'emploie la chaîne climatique de l'entrepôt, ce qui rend les deux familles d'indices comparables entre elles. Et le passage au score suit un rang percentile empirique plutôt qu'un ajustement paramétrique, choix dont l'effet est discuté plus loin. La méthode est par ailleurs centralisée dans un unique module, et l'application ne la recalcule pas : elle lit les tables produites par l'entrepôt.

Table 4.1 – Construction de l’indicateur standardisé par station, étape par étape.

Étape	Détail
Référence	Fenêtre fixe 1991–2020, normale climatique retenue par l’Organisation météorologique mondiale et par le BRGM. Ce n’est pas une fenêtre glissante.
Grille	Par mois calendaire, percentiles empiriques de 1 à 99 sur la fenêtre. Un mois comptant moins de dix observations est interpolé depuis son voisin circulaire.
Score	Rang percentile dans la grille, borné à $[0,001 ; 0,999]$, puis projeté sur la loi normale par sa fonction quantile.
Classes	Sept classes délimitées par les seuils $z \in \{-1,75 ; -1,28 ; -0,84 ; 0,84 ; 1,28 ; 1,75\}$.

Toutes les stations ne disposent pas de trente années d’historique. Plutôt que d’écarter les stations courtes ou de leur appliquer silencieusement une référence plus faible, la sélection de fenêtre se dégrade par paliers déclarés : la normale 1991–2020 si au moins quinze années sont disponibles, sinon la meilleure fenêtre trentenaire alignée sur les décennies, sinon l’historique complet. Le palier retenu est inscrit dans une colonne accompagnant chaque valeur, de sorte qu’un utilisateur sait toujours sur quelle base une station est classée.

Une limite de portée doit être connue. L’indicateur piézométrique standardisé a été conçu pour les nappes libres, dont le niveau suit une cyclicité annuelle marquée. Il est ici calculé pour toutes les stations sans distinction, faute d’une information fiable permettant d’identifier les ouvrages captant une nappe captive. Les échanges avec les hydrogéologues ont confirmé qu’aucun indicateur équivalent n’existe aujourd’hui pour ces nappes, et que le sujet fait l’objet de travaux dédiés. La valeur produite pour une station captive doit donc être lue avec prudence : elle est calculée correctement, mais l’indicateur n’a pas été pensé pour ce cas.

Une grille n’est jamais fabriquée pour autant. Si aucun mois n’est exploitable, elle reste nulle et l’indice prend la valeur *inconnu*. Produire une classe plutôt qu’un aveu d’ignorance reviendrait à inventer une information que l’utilisateur lirait comme une mesure.

La figure 4.1 montre à quoi ressemble la série produite pour une station, et la figure 4.2 la fiche à laquelle elle se rattache.

La table de référence est recalculée *hebdomadairement*, et non chaque nuit ni une fois par décennie. La fenêtre est fixe, mais les grilles par station ne le sont pas : une station accumule de l’historique, de nouvelles stations apparaissent, et une station classée en référence provisoire peut franchir le seuil des quinze années.

4.3 Les indices climatiques sur grille

Trois indices sont calculés pour chaque maille de $0,1^\circ$, sur quatre fenêtres d’agrégation de 1, 3, 6 et 12 mois correspondant à des inerties différentes du système hydrologique. Tous emploient la période de référence 1991–2020 et l’échelle à sept classes de McKee [28], adoptée par l’Organisation météorologique mondiale.



Figure 4.1 – La station de Mur-de-Sologne, en niveau puis en indicateur. En haut la chronique brute sur cinq ans, en mètres NGF : elle situe la mesure dans son unité, mais ne dit pas si le niveau est haut ou bas pour la saison. En bas le même ouvrage sur dix ans en indicateur standardisé mensuel, sur les sept classes. C’est le passage de l’une à l’autre qui rend deux ouvrages comparables, et c’est tout l’objet de ce chapitre.




Figure 4.2 – La fiche du même ouvrage, telle que l’entrepôt la constitue. Le code BSS et le code BDLISA y figurent côte à côte : c’est le rattachement décrit au chapitre 3 qui les réunit, aucune source ne les publiant ensemble. La durée et le nombre de mesures conditionnent directement le palier de référence retenu pour l’indicateur, ici trente et un ans donc la normale 1991–2020.

Table 4.2 – Les trois indices climatiques sur grille et la loi ajustée pour chacun.

Indice	Grandeur	Ajustement
SPI	Précipitation	Loi gamma, mélangée à la probabilité de cumul nul
STI	Température	Loi normale (score centré réduit)
SPEI	Précipitation moins évapotranspiration	Loi logistique généralisée

4.4 Premier arbitrage : quelle évapotranspiration employer

4.4.1 De quoi il est question

L'indice de bilan hydrique, le SPEI, compare ce que le ciel apporte à ce que l'atmosphère reprend. L'apport, c'est la pluie, et elle se mesure. Le prélèvement, c'est l'**évapotranspiration** : l'eau qui repart vers l'atmosphère, à la fois par évaporation directe du sol et par transpiration des plantes. Cette seconde grandeur ne se mesure pas partout, il faut donc la calculer.

Or « calculer l'évapotranspiration » n'a pas de sens tant qu'on n'a pas dit *de quelle surface*. Un lac, une forêt et un champ de blé n'évaporent pas la même quantité d'eau sous le même ciel. Pour rendre les chiffres comparables d'un pays à l'autre, l'Organisation des Nations unies pour l'alimentation et l'agriculture, la **FAO**, a fixé une convention dans un document de référence appelé FAO-56 [2] : on calcule ce qu'évaporerait une surface conventionnelle, un gazon ras et bien alimenté en eau. C'est l'**évapotranspiration de référence**, et c'est elle qu'emploient les hydrologues, les agronomes et les indices de sécheresse publiés.

4.4.2 Ce qui s'est passé

ERA5-Land fournit directement une variable nommée « évaporation potentielle », et son emploi paraît naturel. Ses valeurs sont pourtant incompatibles avec ce que l'on sait du climat français. Comparée sur 30 888 couples maille-mois entre 2015 et 2025, sur les mêmes mailles :

Table 4.3 – Évapotranspiration annuelle : la formule de Hargreaves comparée à la variable brute d'ERA5-Land, sur 30 888 couples maille-mois de 2015 à 2025.

	Hargreaves (référence FAO-56)	Variable ERA5-Land (« évaporation potentielle »)	Rapport
Évapotranspiration annuelle	818 mm	1 756 mm	$\times 2,15$
Bilan précipitation moins ETP	$+146 \text{ mm an}^{-1}$	-793 mm an^{-1}	

La seconde colonne place l'**intégralité du territoire français en déficit hydrique permanent**, y compris les années humides, ce qui est physiquement faux. La valeur de 818 mm an^{-1} se situe dans l'intervalle des références publiées pour la France (700 à 900 mm an^{-1}) ; celle de $1 756 \text{ mm an}^{-1}$ n'y est pas.

4.4.3 Pourquoi

Les deux grandeurs portent des noms voisins et ne décrivent pas la même chose. Il n'y a d'erreur nulle part : la variable d'ERA5 est conforme à ce qu'elle annonce, elle ne correspond simplement pas à la grandeur dont le SPEI a besoin. Le travail n'était donc pas de corriger un défaut, mais d'identifier la bonne grandeur et de la produire.

La documentation du produit est explicite sur ce point : dans ERA5-Land, cette variable est une **évaporation en nappe d'eau libre**, du type de celle qu'on mesure sur un bac d'évaporation [16]. Le même nom recouvre d'ailleurs deux calculs différents chez le même fournisseur, puisque dans ERA5 il désigne l'évaporation d'une terre agricole supposée sans stress hydrique. La grandeur de la FAO répond à une tout autre question : *combien évapore la surface conventionnelle de référence*, un gazon ras de 0,12 m.

L'écart d'un facteur deux s'explique alors physiquement, et non par une imprécision. Une nappe d'eau libre n'oppose aucune résistance de surface au passage de la vapeur et réfléchit peu le rayonnement, là où un couvert végétal ferme ses stomates et renvoie près du quart de l'énergie reçue. À ciel égal, un plan d'eau évapore environ le double d'une prairie. La variable d'ERA5-Land est donc juste pour ce qu'elle décrit, un lac ou un bac, et hors sujet pour un bilan hydrique de territoire. Le fournisseur invite du reste les utilisateurs à vérifier que la définition convient à leur application.

Reste à choisir par quelle route l'obtenir, et c'est une décision distincte de la précédente. La méthode de référence de la FAO-56 est celle de Penman-Monteith, qui demande trois grandeurs physiques : le rayonnement net, soit l'énergie disponible pour vaporiser l'eau ; le déficit de pression de vapeur, soit la capacité d'absorption de l'air ; et le vent à 2 m, soit la vitesse à laquelle cette vapeur est évacuée. ERA5-Land publie de quoi les construire toutes les trois, rayonnement solaire descendant, composantes du vent et point de rosée. Ces variables n'ont pas été ingérées, et il faut l'énoncer comme le choix de périmètre que c'est plutôt que comme une indisponibilité : les obtenir supposait un second flux horaire par variable, du même type que celui déjà en place pour les extrêmes de température, et un volume que le projet n'a pas engagé pour un gain de précision sur une grandeur d'entrée.

La FAO-56 prévoit précisément ce cas. Sa recommandation première est d'estimer les variables manquantes et d'appliquer quand même Penman-Monteith ; elle propose en alternative la formule de Hargreaves [18], son équation 52, qui n'a besoin que des températures journalières minimale, maximale et moyenne, plus le rayonnement reçu au sommet de l'atmosphère, lequel se calcule à partir de la seule latitude et du jour de l'année. C'est cette formule qui a été implémentée, directement en SQL. Elle ne produit pas une autre grandeur : elle produit la même évapotranspiration de référence, par une route moins exigeante en données. Elle la produit un peu moins bien, et la FAO-56 dit où : Hargreaves sous-estime au-delà de 3 m s^{-1} de vent et surestime en forte humidité relative, deux régimes présents sur le territoire français. Ce choix garde par ailleurs les indices comparables aux travaux publiés, la littérature employant couramment le couple ERA5 et Hargreaves.

4.4.4 Ce que cela change

Le choix de la grandeur décide de la justesse de tout ce qui en découle. Avec la variable brute, les indices de bilan hydrique auraient reposé sur un déficit d'eau surestimé de plus du double, et la carte nationale aurait affiché une France en sécheresse quasi permanente, y compris pendant les années pluvieuses. L'anomalie aurait été lue comme un signal climatique alors qu'elle n'aurait tenu qu'à une confusion entre deux définitions.

C'est le genre de piège qu'aucun test logiciel ne détecte, et c'est ce qui le rend coûteux : le calcul était juste, le code sans faute, seule la grandeur employée n'était pas la bonne. Seule la confrontation des valeurs obtenues aux ordres de grandeur connus pour la France pouvait le révéler.

Les deux grandeurs coexistent dans l'entrepôt et suivent des trajectoires distinctes : la variable brute est ingérée telle quelle, l'évapotranspiration de référence est calculée en couche analytique à partir des températures journalières. Elles figurent côte à côte dans la table finale, ce qui a rendu possible la mesure comparative ci-dessus. L'annexe A.3 donne le détail des colonnes, couche par

couche.

4.4.5 Une incohérence connue, et ce qu'elle coûte

Cet arbitrage ne vaut que pour la chaîne climatique sur grille. La chaîne des stations expose encore, sous le nom `potential_evaporation`, la variable brute d'origine. C'est elle qui alimente les modèles métier du chapitre 6, et il faut le dire sans détour : **les modèles calibrés sur les stations ne reçoivent pas l'évapotranspiration de référence**, mais une grandeur environ deux fois plus élevée. Mesuré sur les données en base, le forçage station vaut $1\,839\text{ mm an}^{-1}$ là où l'ET0 de référence se situe autour de 818 mm an^{-1} .

Ce que cet écart change pour les calibrations n'a pas été évalué. On pourrait espérer que le paramètre qui pondère l'évaporation dans la recharge s'ajuste et compense, laissant la prévision inchangée, mais rien ne l'établit : aucune campagne comparant les deux forçages sur un historique long et un échantillon de stations n'a été conduite. Tant qu'elle ne l'est pas, l'ampleur de l'effet reste inconnue, et c'est à ce titre que l'incohérence est signalée.

Pourquoi cette incohérence n'a-t-elle pas été corrigée ? Parce que la correction n'est pas un changement de colonne. La chaîne station ne transporte que la température moyenne, alors que la formule de Hargreaves exige aussi les extrêmes journaliers. Il faudrait donc les ajouter, y calculer l'évapotranspiration au pas journalier, puis propager le résultat dans deux tables partitionnées, ce qui impose une reconstruction complète, et enfin recalibrer les modèles existants. Engager cette chaîne d'opérations sans pouvoir la valider sur un historique complet aurait remplacé une incohérence documentée par une incertitude non mesurée.

C'est donc le premier chantier que ces travaux laissent à leur suite, et il est prioritaire sur toute campagne de calibration : tant qu'il n'est pas traité, les paramètres des modèles métier n'ont pas d'interprétation physique directe, même si leur pouvoir prédictif reste utilisable.

4.5 Deuxième arbitrage : quelle loi ajuster pour le SPEI

Un indice standardisé transforme une valeur en score de rareté, ce qui suppose d'ajuster une loi de probabilité sur la série de référence. Le choix de cette loi détermine sur quelles mailles l'indice pourra être calculé.

L'article fondateur du SPEI [42] emploie une loi log-logistique. Appliquée à la grille française, elle ne s'ajuste que sur 74,6 % des combinaisons de maille, de mois et de fenêtre. Le manque n'est pas uniforme : selon la fenêtre d'agrégation, la couverture va d'environ deux tiers à un peu moins de neuf dixièmes, ce qui laisse des trous mouvants dans la carte nationale. L'instrumentation des rejets a montré que la cause était unique et structurelle : cette loi ne représente qu'un sens d'asymétrie, mesuré ici par le rapport de L-moments τ_3 [21], et la totalité des rejets vient de là. Le quart restant du territoire, en combinant maille, mois et fenêtre, présente l'asymétrie inverse. Aucune quantité de données supplémentaire n'y aurait changé quoi que ce soit.

L'implémentation de référence du SPEI [4], distribuée par les auteurs de la méthode, emploie quant à elle la logistique généralisée, qui accepte les deux sens. C'est elle qui a été retenue. Le choix n'a donc rien d'original : il consiste à suivre la pratique établie plutôt que la seule formulation de l'article. La couverture passe à 100 %.

Le remplacement est par ailleurs sans effet sur l'existant. Les deux lois étant équivalentes par reparamétrage, les valeurs restent inchangées partout où la première fonctionnait, ce qui a été vérifié à un écart maximal de 0,000 sur 35 614 mailles. La carte se complète là où elle était trouée, sans que rien d'autre ne bouge.

4.6 La vérification des indices produits

Un indice standardisé doit, par construction, suivre approximativement une loi normale centrée réduite *sur sa propre période de référence*. C'est une propriété vérifiable, et elle a été vérifiée.

Le critère d'acceptation a été fixé **avant** la mesure : moyenne voisine de zéro à $\pm 0,05$, écart-type voisin de un à $\pm 0,05$, et taux de saturation aux bornes inférieur à 1 %. Fixer le critère avant de mesurer évite l'ajustement rétrospectif du seuil au résultat obtenu.

La mesure porte sur 41 960 400 valeurs couvrant 11 496 mailles.

Table 4.4 – Vérification des indices produits sur leur propre période de référence, 41 960 400 valeurs.

Indice	Fenêtres	Moyenne	Écart-type	Médiane	Saturation
SPI	1/3/6/12	-0,008 à +0,002	0,985 à 1,031	0,00 à 0,04	0,05 à 0,51 %
STI	1/3/6/12	0,000	0,983	-0,09 à -0,02	0,00 à 0,04 %
SPEI	1/3/6/12	+0,004 à +0,006	0,999 à 1,013	0,01 à 0,03	0,012 à 0,035 %

Les trois indices satisfont le critère d'acceptation sur les quatre fenêtres. La couverture du SPEI est uniforme à 100 %, ce qui signifie que la calibration n'est pas seulement préservée mais mesurée sur l'ensemble du domaine.

4.7 Deux lectures à ne pas faire

La validation ci-dessus autorise l'usage des indices ; elle n'autorise pas toutes les interprétations. Deux mises en garde ont été consignées, parce que l'erreur correspondante est naturelle.

La première porte sur la classe « normale », qui ne couvre pas la proportion théorique. Elle représente 54,8 % des valeurs au lieu des 59,9 % attendus d'une gaussienne, alors même que l'écart-type vaut 1,008. La distribution conserve des épaules légèrement plus lourdes. Cet écart est une propriété de la transformation au voisinage des bornes de classe. Il n'a pas de conséquence opérationnelle, les seuils employés étant ceux, communs, des autres indices, et il ne doit surtout **pas** être lu comme une anomalie de sécheresse.

La seconde porte sur la décroissance décennale du SPEI, qui est un signal climatique et non une dérive de méthode. La moyenne sur fenêtre d'un mois décroît de manière monotone d'une décennie à l'autre : +0,038 dans les années 1990, +0,007 dans les années 2000, -0,016 dans les années 2010, -0,117 depuis 2020. Cette évolution avait été anticipée avant d'être mesurée, ce qui la distingue d'un artefact d'ajustement : elle traduit un assèchement, non un biais.

4.8 Un contrat entre les deux dépôts

La classification en sept classes existe en deux endroits : dans l'entrepôt, qui produit les indicateurs, et dans la plateforme, qui les affiche et les compare aux prévisions. Cette duplication est délibérée, car elle évite un couplage fort entre deux systèmes déployés séparément, mais elle crée un risque de divergence silencieuse.

Le risque est traité par un **contrat exécutable** : chaque dépôt possède une table de référence associant des valeurs d'entrée aux classes attendues, ces deux tables sont identiques par construction, et chacun porte le test qui vérifie la sienne. Toute modification de l'une sans l'autre fait échouer ce test. Le mécanisme est simple, et c'est sa vertu : il rend la contrainte vérifiable plutôt que documentaire. Sa faiblesse est ailleurs, et elle est signalée au chapitre 9 : aucune chaîne d'intégration ne lance ces tests, de sorte que le contrat n'est garanti que par la discipline de celui qui les exécute.

L'entrepôt produit désormais une famille d'indicateurs normalisés à l'échelle nationale, utilisables tels quels par les hydrogéologues et candidats comme variables de modélisation. Le critère de leur validation avait été fixé avant la mesure, et les deux décisions méthodologiques structurantes sont documentées avec les chiffres qui les établissent.


5 L'Observatoire : donner à voir

Un entrepôt ne se consulte pas. Comment rendre la donnée consolidée immédiatement lisible par ceux qui en ont l'usage, sans enfermer les méthodes développées dans l'application qui les héberge ?

5.1 Une contrainte d'architecture posée d'emblée

La plateforme comporte trois couches : une interface web en React [29], un service applicatif FastAPI [35], et une bibliothèque métier en Python. La contrainte structurante porte sur la troisième : **la bibliothèque métier ne dépend ni du service applicatif ni de l'interface web**. Elle produit des figures, donc dépend d'une bibliothèque de tracé, mais rien dans son code ne suppose le navigateur ni le serveur.

Cette règle a une conséquence pratique déterminante pour un travail de recherche. Le code de préparation des données, de calibration des modèles métier, d'entraînement, d'explicabilité et de génération de contrefactuels s'exécute indifféremment depuis le service web, depuis un script ou depuis un carnet de calcul. Les méthodes développées ne sont donc pas prisonnières de l'application : si l'interface était abandonnée, elles resteraient utilisables.



dépôt de l'entrepôt, chapitre 3

Figure 5.1 – Architecture de la plateforme. La bibliothèque métier est appelable depuis le service web, un script ou un carnet de calcul, sans modification. C'est cette propriété qui rend les développements réutilisables au-delà de l'application.

5.2 Le besoin : explorer avant de modéliser

Un entrepôt bien construit reste inerte tant qu'il n'est pas regardé. Deux publics le demandaient, pour des raisons différentes.

Les **hydrogéologues** ont besoin de situer une station dans son contexte : quelle nappe observe-t-elle, comment se comporte-t-elle par rapport à ses voisines, où en est-elle dans son historique, et que faisait le climat pendant ce temps. Ce travail de mise en regard, fait manuellement, mobilise plusieurs sources et plusieurs outils.

Les **modélisateurs** ont besoin de choisir leurs cas d'étude en connaissance de cause : une station dont la chronique est trop courte, trop lacunaire ou visiblement perturbée par un pompage ne fera pas un bon cas d'apprentissage. Repérer ces situations avant d'entraîner un modèle évite d'attribuer à la méthode ce qui relève de la donnée.

L'Observatoire répond aux deux.

5.3 Organisation : deux compartiments

L'interface s'organise en deux volets correspondant aux deux compartiments du cycle observé.

Le premier volet, nappes et rivières, donne l'exploration spatiale des stations piézométriques et hydrométriques sur fond cartographique, avec superposition des entités aquifères du référentiel BDLISA et d'un découpage en secteurs hydrogéologiques. Les indicateurs de situation y sont portés directement par les stations, ce qui donne une lecture immédiate de l'état du territoire. La comparaison entre stations est possible, avec conservation de la sélection d'une vue à l'autre. La figure 5.2 en donne la vue d'ensemble, la figure 5.3 la lecture d'un ouvrage particulier.




Figure 5.2 – Le volet nappes et rivières à l'échelle du pays. Chaque pastille agrège les stations d'un groupe et porte la couleur de leur classe de situation ; le curseur du bas rejoue la période 2000–2026 saison par saison. Le compteur donne l'assiette réelle du classement, 2 610 piézomètres classés sur 22 407 recensés et 2 170 stations hydrométriques sur 6 253 : les stations non classées le sont faute d'historique suffisant pour standardiser, et l'écart est visible plutôt que masqué.

Le second, le climat, donne l'exploration de la grille nationale de 0,1° selon trois vues : une vue de situation cartographique à l'échelle du pays, une vue par point ou par zone donnant l'historique d'une maille depuis 1950 (pluie comparée à la normale, indices sur plusieurs fenêtres, table des épisodes de sécheresse, export tabulaire), et une vue de comparaison inter-annuelle.

Les deux volets communiquent : depuis la carte des nappes, un lien contextuel ouvre le climat de la maille correspondante ; depuis la fiche d'une station, on accède à son contexte climatique local.




Figure 5.3 – La même carte à l'échelle régionale, une station sélectionnée. Le panneau de gauche porte l'indicateur de situation, la position de la mesure du mois sur les sept classes de référence, la profondeur d'historique, et les stations de la même entité hydrogéologique BDLISA avec leur propre classe. C'est cette mise en regard, faite manuellement sur plusieurs sources, que le volet remplace par une sélection. *Valeurs lues sur la capture : elles illustrent l'instrument, elles ne constituent pas un résultat d'évaluation.*

La figure 5.4 montre ce croisement sur une station, la figure 5.5 la comparaison inter-annuelle.

5.4 Une règle de conception qui a structuré l'interface

Les couches cartographiques disponibles obéissent à une règle explicite, adoptée après discussion et maintenue depuis :

*Soit un indicateur réellement standardisé, soit une valeur réelle affichée comme telle.
Jamais un intermédiaire inventé.*

Concrètement, les indices standardisés (précipitation, température, bilan hydrique) sont cartographiés sur l'échelle à sept classes, et les grandeurs journalières brutes (températures extrêmes, pluie du jour) le sont sur une échelle absolue. En revanche, les cumuls mensuels absolus de pluie, de température ou d'évapotranspiration ne sont **pas** proposés comme couches cartographiques : ils apparaissent comme chiffres exacts dans le panneau de détail d'une maille.

La raison est méthodologique. Cartographier une grandeur absolue sur une palette de couleurs suppose un seuillage, donc une norme implicite. Or cette norme, n'étant pas une référence statistique établie, serait une invention de l'outil. L'utilisateur lirait une carte de sécheresse là où il n'y a qu'un choix de bornes. Refuser cette couche coûte une fonctionnalité apparente et évite une erreur d'interprétation systématique.

5.5 Trois choix techniques

L'Observatoire recalcule le moins possible : ses points d'accès lisent les tables analytiques de l'entrepôt plutôt que de refaire le calcul. La carte, la situation courante et les exports lisent ainsi



Figure 5.4 – Le contexte climatique d'une station, sur la même page que sa chronique : indice standardisé de précipitation sur trois mois depuis dix ans, coloré selon les sept classes, et cumuls glissants comparés à la normale 1991–2020. Les valeurs affichées sont celles produites et validées au chapitre 4, non un recalcul.




Figure 5.5 – La comparaison inter-annuelle : plusieurs années superposées mois par mois sur le même ouvrage, à sélectionner dans la liste des années disponibles. La lecture recherchée est qualitative, situer l'année courante parmi les années remarquables, et elle ne suppose aucun seuillage inventé.

les indicateurs déjà produits, de sorte que **la valeur affichée est exactement celle qui a été validée** au chapitre 4. Trois points d'accès font exception : les deux qui servent la série historique d'une station, et celui qui calcule l'antériorité portée par la carte de situation. Ils lisent la grille de référence dans l'entrepôt, mais appliquent la standardisation à la requête. Le calcul reste le même, et un test croisé garde la cohérence des classes entre les deux dépôts.

Les réponses sont mises en cache, ensuite. Les vues cartographiques nationales portent sur des volumes importants et changent peu ; leur mise en cache pour vingt-quatre heures réduit la charge sans affecter la fraîcheur perçue. Les couches qui bougent plus vite ont des durées plus courtes, de quelques heures pour le fond de carte des stations à une heure pour les alertes. Cette optimisation a un corollaire opérationnel documenté : tout déploiement qui modifie la forme ou la valeur des réponses doit purger le cache, sous peine de servir des valeurs périmées pendant une journée.

Le point d'entrée, enfin, est unique. Le service qui sert l'interface assure également le relais vers l'API, les en-têtes de sécurité et la limitation de débit. Regrouper ces fonctions dans un seul composant vaut moins pour la simplicité que pour ce que cela écarte : une protection configurée dans un composant qui ne tourne pas est une protection absente, avec en plus la croyance qu'elle existe.

5.6 Environnements et déploiement

La séparation des environnements décrite au chapitre 3 prend ici tout son sens : elle autorise à expérimenter sur une chaîne en évolution sans compromettre l'instance qui sert les utilisateurs. La production est répartie : l'interface est déployée sur l'infrastructure mutualisée de l'établissement, le calcul et les bases restent sur le serveur équipé d'un processeur graphique. Une seule exigence réseau conditionne l'ensemble, l'ouverture de la route entre les deux.

L'Observatoire dépend entièrement de l'entrepôt, et ne se dégrade pas gracieusement en son absence : il répond en erreur plutôt que d'afficher un état partiel. Le choix est assumé pour un outil scientifique, où une valeur absente vaut mieux qu'une valeur douteuse. Il serait à revoir pour une diffusion large.

6 Modéliser : le laboratoire de modèles métier

Avant d'invoquer l'apprentissage profond, que sait déjà faire la modélisation hydrogéologique établie, et comment l'outiller pour qu'elle serve de référence ?

6.1 Pourquoi commencer par le modèle métier

Il aurait été possible d'aller directement à l'apprentissage profond. Ce choix aurait été méthodologiquement fautif, pour trois raisons.

D'abord, **sans référence, une performance ne signifie rien**. Annoncer qu'un réseau de neurones prévoit un niveau de nappe avec une certaine erreur n'a de sens que comparé à ce qu'obtient la méthode que les hydrogéologues emploient déjà. Une architecture profonde qui n'égale pas un modèle à quelques paramètres ne mérite pas d'être déployée.

Ensuite, **le modèle métier est interprétable par construction**, et fournit donc un point d'ancrage à tout le travail d'explicabilité qui suivra. On sait ce qu'il représente ; on peut confronter les explications produites sur un modèle appris à ce que le modèle physique affirme.

Enfin, **c'est le langage des interlocuteurs**. Le BRGM développe et emploie sa propre famille de modèles à réservoirs : GARDÉNIA [9] pour la simulation des niveaux et des débits d'un bassin, EROS [8] pour les relations entre bassins, fédérés par une interface Python commune. Un outil qui ignorerait cette pratique ne serait pas adopté, quelles que soient ses performances.

6.2 Les modèles à fonction de transfert et bruit

L'approche retenue est celle des modèles *transfer function-noise*, mise en œuvre par la bibliothèque Pastas [11]. Son principe : le niveau piézométrique simulé est la somme des contributions de plusieurs facteurs de forçage, au minimum la recharge dérivée de la précipitation et de l'évapotranspiration. Chaque contribution est obtenue par convolution du forçage avec une *fonction de réponse impulsionnelle* dont la forme et les paramètres sont calibrés. Un modèle de bruit rend compte de la structure résiduelle.

L'intérêt pour la question posée est direct : la fonction de réponse **est** l'objet d'intérêt hydrogéologique. Sa forme dit comment l'aquifère amortit et retarde le signal climatique ; son intégrale dit de combien le niveau varie pour une sollicitation donnée. Ce ne sont pas des paramètres opaques, ce sont des grandeurs qui s'interprètent.

La plateforme donne accès à quatre modèles de recharge, cinq formes de réponse impulsionnelle proposées à la sélection, deux modèles de bruit et deux solveurs, combinables librement. La figure 6.1 montre l'écran où ces choix se posent, la figure 6.2 ce que la calibration en retourne.

6.3 Calibration automatique et critères de qualité

Choisir la bonne combinaison relève de l'expertise et de l'essai. Pour rendre cet essai systématique, un mécanisme de **calibration automatique** construit une grille de configurations candidates, calibre chacune, l'évalue et les classe.

L'évaluation ne repose pas sur un unique indicateur d'erreur, mais sur les quatre critères d'acceptation STOWA [43], standard néerlandais d'évaluation des modèles TFN pour la gestion des eaux souterraines :

1. **La variance expliquée** dépasse un seuil (70 % par défaut) ;

STATION
02645X0038/D601 Changer

Configuration

Recommandé : Sédimentaire poreux (sable/grès)

Modèle de recharge ⓘ
Linear

P – f-E : excès de précipitations linéaire (von Asmuth 2002)

Fonction de réponse ⓘ
Gamma

3 paramètres (A, a, n) — réponse retardée, la plus courante

Modèle de bruit ⓘ
ArNoiseModel

Solveur ⓘ
LeastSquares

AR(1) — corrige l'autocorrélation des résidus

Moindres carrés (scipy) — rapide, déterministe, par défaut

Début de calibration
jj / mm / aaaa

Fin de calibration
jj / mm / aaaa

Vide = début des données

Vide = fin des données

Validation ⓘ Activée

Calibration : 70% (premières années)

Test : 30% (dernières années)

Les métriques de test montrent la qualité du modèle sur une période réservée, non utilisée pour la calibration.

☐ Inclure la température ⓘ
Ajoute la température ERA5 comme stress supplémentaire.

Figure 6.1 — L'écran de calibration. Chaque choix porte sa justification en clair, parce que l'utilisateur visé n'est pas l'auteur de la bibliothèque : le modèle de recharge renvoie à sa référence, la forme de réponse à son nombre de paramètres, le modèle de bruit à ce qu'il corrige. La configuration proposée par défaut est celle que recommande la famille d'aquifère de la station, selon la table 6.1.

PARAMÈTRES DU MODÈLE		
Nom	Optimal	Erreur-type
recharge_A	1.633165	0.041376
recharge_n	0.844127	0.013584
recharge_a	146.982374	7.224866
recharge_f	-0.924230	0.028925
linear_trend_a	-0.000133	0.000006

Figure 6.2 — Les paramètres calés et leur erreur type. Ce sont les grandeurs qui s'interprètent : le gain, le temps caractéristique en jours, la forme de la réponse Gamma, le coefficient d'évapotranspiration. Une erreur type du même ordre que la valeur signale un paramètre que les données ne contraignent pas. *Valeurs lues sur la capture : elles illustrent l'instrument, elles ne constituent pas un résultat d'évaluation.*

2. **les résidus sont aléatoires**, vérifié par un test de séquences ;
3. **le temps de réponse** à 95 % de la réponse indicielle reste inférieur à la moitié de la période de calibration, car un modèle dont la mémoire excède ses données n'est pas identifiable ;
4. **le gain est statistiquement significatif**, son rapport à son erreur type dépassant le seuil usuel.

Cette démarche recoupe la méthode de travail des hydrogéologues telle qu'ils l'ont décrite : partir du modèle le plus simple, examiner les résidus pour identifier ce qu'il ne capte pas, puis enrichir la structure en conséquence. La calibration automatique outille cet enchaînement, et les diagnostics de résidus présentés plus loin en fournissent la seconde étape. Les modèles calés sont conservés (figure 6.4), sans quoi l'enchaînement demanderait de refaire à chaque itération ce qui a déjà été calculé.

Le troisième critère capture une erreur fréquente et discrète : un modèle peut afficher une excellente variance expliquée tout en ayant ajusté une dynamique lente que la période d'observation ne permet pas de contraindre. Le critère l'écarte. C'est pourquoi le verdict STOWA figure à part de l'erreur dans le classement, comme le montre la figure 6.3 : un bon critère de Nash-Sutcliffe ne suffit pas à rendre un modèle identifiable. Le classement place d'abord les configurations qui satisfont les quatre critères, puis les trie entre elles sur la variance expliquée.

Deux mécanismes distincts portent ici le nombre soixante-dix, et les confondre changerait la lecture du tableau. Le premier est le seuil du critère STOWA rappelé ci-dessus : la variance expliquée doit atteindre 70 %, c'est une exigence de qualité, et elle est évaluée **sur la période de calibration**. Le second est le partage optionnel entre une période d'apprentissage et une période réservée, réglable dans l'interface et laissé par défaut à 70 % contre 30 %, qui transpose aux modèles métier le protocole d'entraînement et de test des modèles appris (chapitre 7). Il sert à mesurer ce que vaut le modèle hors de ce sur quoi il a été ajusté ; il n'entre ni dans le calcul des critères STOWA, ni dans le tri des configurations.

Résultats de la calibration automatique
8 configurations testées en 31.2 s

Configuration	NSE	RMSE	KGE	STOWA	Temps
✓ Linear / Gamma	0.589	0.4744	0.717	Partiel	3.3 s
Linear / Gamma / ArMoiseModel	0.528	0.5085	0.639	Partiel	8.0 s
Linear / Gamma / ArMoiseModel	0.523	0.5113	0.588	Partiel	5.6 s
Linear / Exponential	0.491	0.5281	0.590	Partiel	2.0 s
Linear / Gamma	0.483	0.5325	0.787	Partiel	4.0 s
Linear / Exponential / ArMoiseModel	0.391	0.5777	0.644	Partiel	3.9 s
Linear / Exponential	0.310	0.6151	0.375	Partiel	1.6 s
Linear / Exponential / ArMoiseModel	0.017	0.7340	-0.151	Partiel	2.7 s

Figure 6.3 – Le classement produit par la calibration automatique sur une station. Les métriques affichées et le verdict STOWA portent sur la période de calibration ; les configurations qui satisfont les quatre critères passent en tête, puis sont triées entre elles sur la variance expliquée. Le verdict occupe sa propre colonne parce qu'il ne se déduit pas de l'erreur : ici aucune configuration ne le satisfait entièrement, alors que la meilleure atteint un critère de Nash-Sutcliffe de 0,589. Le temps par configuration rend le coût de l'exploration explicite, ce qui compte quand elle doit être répétée sur un échantillon de stations. *Valeurs lues sur la capture : elles illustrent l'instrument, elles ne constituent pas un résultat d'évaluation.*

6.4 L'apport hydrogéologique : des configurations par famille d'aquifère

La grille de calibration automatique n'explore pas l'espace des configurations à l'aveugle. Elle est amorcée par des **configurations recommandées selon la nature de l'aquifère observé**, lue dans le référentiel BDLISA rattaché à la station par l'entrepôt (chapitre 3).




Figure 6.4 – Les modèles calés restent en galerie, avec leur structure, leurs métriques de calibration et de validation et leur critère d'information. Comparer plusieurs structures sur une même station devient une lecture plutôt qu'une campagne à reconstituer, ce qui est la condition pratique de la démarche décrite plus haut : partir du modèle le plus simple, puis enrichir. *Valeurs lues sur la capture : elles illustrent l'instrument, elles ne constituent pas un résultat d'évaluation.*

Cette table est le produit direct des échanges avec l'expertise hydrogéologique du BRGM. Elle traduit en choix de modélisation ce qu'un spécialiste sait du comportement de chaque milieu.

Table 6.1 – Configurations de modélisation recommandées par famille d'aquifère.

Famille	Réponse	Bruit	Justification hydrogéologique
Alluvial	Exponentielle	AR	Réponse rapide, temps de réponse court, système simple
Sédimentaire poreux	Gamma	AR	Réponse intermédiaire
Sédimentaire, double porosité (craie)	Gamma	AR	Forte inertie, temps de réponse long
Sédimentaire fracturé	Gamma	AR	Recharge complexe, modèle de recharge flexible
Karstique	Double exponentielle	ARMA	Deux temps de réponse : conduits et matrice
Socle, montagne	Gamma	AR	Fracturé, recharge non linéaire
Volcanique	Gamma	AR	Système hétérogène
Composite	Quatre paramètres	ARMA	Milieu hétérogène, modèle flexible

Le cas karstique est le plus parlant. Un système karstique se comporte comme deux réservoirs couplés : des conduits qui réagissent en quelques heures et une matrice qui réagit en mois. Une réponse impulsionnelle à un seul temps caractéristique ne peut pas représenter cette dualité. D'où la double exponentielle, et un modèle de bruit plus riche pour absorber ce que la structure ne capte pas.

Elle recoupe la typologie que les hydrogéologues emploient eux-mêmes, qui distingue les nappes inertielles à cycles longs, les nappes réactives à effets de seuil et les nappes influencées par une rivière ou des prélèvements. Elle encode ainsi une connaissance qui ne s'obtient pas par validation croisée, et la rend disponible à un utilisateur qui ne la possède pas.

Ces configurations amorcent la recherche ; elles ne la contraignent pas. Une grille de référence est

systématiquement évaluée en parallèle, de sorte qu'une station atypique n'est jamais enfermée dans la recommandation de sa famille.

6.5 Diagnostics et validation

La calibration est accompagnée d'un dispositif de vérification qui va au-delà de l'ajustement.

Le modèle est calibré sur une période et évalué sur une période distincte, avec les indicateurs usuels en hydrologie (efficacité de Nash-Sutcliffe, critère de Kling-Gupta, erreur quadratique moyenne), complétés par l'examen de l'autocorrélation et de la normalité des résidus. Les figures 6.5 et 6.6 en donnent les deux lectures, celle de l'ajustement et celle des résidus.



Figure 6.5 – Un modèle calibré, sur une station. En haut les métriques des deux périodes, séparées plutôt que fondues, de sorte qu'une dégradation entre calibration et validation se voie. En bas l'ajustement sur trente ans, observé et simulé superposés, la contribution de la recharge en dessous, et le trait vertical marquant la bascule d'une période à l'autre. *Valeurs lues sur la capture : elles illustrent l'instrument, elles ne constituent pas un résultat d'évaluation.*



Figure 6.6 – Les diagnostics de résidus. Les tests sont affichés avec leur verdict, et le texte de chaque graphique dit ce qu'il faut y chercher plutôt que de supposer la statistique acquise. Un ajustement satisfaisant assorti d'une structure résiduelle marquée n'est pas un rejet : c'est l'indication de ce que la structure ne capte pas encore.

Avant même la calibration, la chronique est examinée : qualité et continuité des entrées, valeurs aberrantes, corrélations croisées avec le forçage, décomposition du signal, analyse spectrale, analyse des tarissements. Ce faisceau permet de détecter en amont les situations où la modélisation est vouée à l'échec, plutôt que de le découvrir dans un mauvais ajustement.

Une seconde lecture complète la première, celle des **signatures hydrologiques** (figure 6.7). Un modèle peut être juste en moyenne et faux sur la dynamique ; comparer l'observé au simulé sur la saisonnalité, les vitesses de montée et de descente ou les constantes de tarissement met en évidence ce qu'une métrique d'erreur agrège.

Les résidus peuvent enfin être examinés conjointement sur plusieurs stations, ce qui fait apparaître les structures communes, donc d'origine régionale ou climatique, et les distingue des particularités locales.




Figure 6.7 – Les signatures hydrologiques, observées (bleu) contre simulées (orange), rapportées à une échelle commune. Vingt-neuf signatures sont calculées, avec le rapport du simulé à l’observé pour chacune ; le radar n’en porte que les principales. Les grandeurs retenues sont celles que l’hydrogéologue nomme, non des statistiques génériques.

6.6 Scénarios prospectifs

Le modèle calibré n’est pas seulement descriptif : il permet de répondre à des questions de la forme « *que se passerait-il si* », qui sont précisément celles des gestionnaires.

Quatre types de modification sont outillés. L’**ajout d’un prélèvement synthétique** suit des profils réalistes par type d’usage, alimentation en eau potable, irrigation ou industrie, chacun avec sa saisonnalité propre. L’**import d’une chronique de prélèvement réelle** permet de rejouer un pompage documenté plutôt que simulé. Enfin, une **tendance climatique** et une **mise à l’échelle** d’un forçage existant complètent la panoplie.

La figure 6.8 montre la construction d’un de ces scénarios.




Figure 6.8 – La construction d’un scénario prospectif. En haut les scénarios préconfigurés, dont les débits sont proposés d’après la famille d’aquifère de la station. En bas la modification de stress elle-même : un type d’usage, un profil temporel, une durée et un débit, plutôt qu’une perturbation libre des entrées. La plage de débit annoncée sous le champ est dérivée de la réponse indicielle du modèle calibré, mécanisme décrit ci-dessous.

Reste le mécanisme des **bornes adaptatives**. Lorsqu’un utilisateur simule un prélèvement, la question « quel débit est plausible ici ? » n’a pas de réponse universelle : elle dépend de la transmissivité de l’aquifère, donc de la réponse calibrée. Le rabattement attendu est estimé à partir de la réponse indicielle du modèle lui-même, et des bornes physiquement plausibles en sont dérivées pour guider la saisie. L’utilisateur n’est pas laissé libre de simuler un pompage qui viderait la nappe

en un mois, ni contraint par une borne arbitraire identique partout.

Ce chapitre décrit un instrument, non des résultats. Aucune campagne de calibration sur un large échantillon n'a été conduite, et la comparaison avec les approches apprises reste à faire. Ce que le laboratoire apporte, c'est la possibilité de mener ces travaux sans les préparer.

Une réserve accompagne tout usage : les modèles y sont calibrés sur l'évapotranspiration transportée par la chaîne des stations, qui vaut environ le double de la grandeur de référence (section 4.4). Les calibrations restent exploitables pour la prévision, mais leurs paramètres ne s'interprètent pas physiquement tant que ce forçage n'a pas été corrigé.

7 Apprendre et expliquer : le laboratoire d'intelligence artificielle

Quel dispositif faut-il pour que des expériences d'apprentissage profond sur des séries hydrologiques soient comparables et reproductibles, et pour qu'on puisse dire ensuite sur quoi leurs prévisions reposent ?

7.1 Le problème posé

Prévoir un niveau de nappe est un problème de série temporelle multivariée avec covariables exogènes : la cible est le niveau, les entrées sont la précipitation, la température et l'évapotranspiration. Les difficultés propres au domaine sont connues : inertie très variable d'un aquifère à l'autre, non-stationnarité liée aux prélèvements, lacunes d'observation, événements extrêmes rares donc sous-représentés dans l'apprentissage.

La littérature propose de nombreuses architectures ; aucune ne s'impose a priori. La question pratique n'est donc pas « quel modèle choisir » mais « comment mettre en place un dispositif qui permette de trancher, et de rejouer la comparaison quand les données changent ».

7.2 Un catalogue d'architectures sous interface unique

La plateforme donne accès à une douzaine d'architectures de prévision profonde issues de la bibliothèque Darts [20], couvrant les grandes familles de l'état de l'art :

- **à mécanisme d'attention** : *temporal fusion transformer* [26], transformeur classique ;
- **à décomposition par blocs** : N-BEATS, N-HITS ;
- **récurrentes** : LSTM, GRU, réseaux récurrents par blocs ;
- **convolutives** : réseaux convolutifs temporels ;
- **récentes à faible coût** : TiDE, TSMixer, DLinear, NLinear.

L'inclusion des dernières est délibérée : les modèles linéaires ou quasi linéaires constituent des références exigeantes sur les séries temporelles, et une architecture lourde qui ne les dépasse pas doit être écartée. Disposer de la référence faible dans le même outil que le modèle sophistiqué évite la comparaison biaisée par des conditions expérimentales différentes.

Une fabrique de modèles instancie dynamiquement l'architecture demandée en validant ses hyperparamètres, ce qui permet d'ajouter une architecture sans modifier l'interface ni l'API. La figure 7.1 montre l'écran où une expérience se déclare.

7.3 Le protocole expérimental

Le dispositif vise trois propriétés.

La traçabilité, d'abord. Chaque exécution d'entraînement est enregistrée dans MLflow [46] : paramètres, métriques, artefacts, modèle produit. Les jeux de données préparés et les modèles entraînés font l'objet de registres distincts, de sorte qu'un résultat puisse être rattaché sans ambiguïté au couple exact qui l'a produit. Sans ce mécanisme, une comparaison entre deux expériences menées à quelques semaines d'intervalle n'est pas défendable.

Configuration du modèle

Préréglage métier (recommandé)
 — Configuration manuelle —
 Choisissez un préréglage pour entraîner avec des paramètres adaptés à votre cas d'usage, ou laissez sur « Configuration manuelle » pour tout définir vous-même.

Architecture
 TFT
Transformer with attention, interpretable, excellent for complex time series

Jeu de données
 04312X0039_F (10930 lignes)

INFORMATIONS DU JEU DE DONNÉES
 Cible : `niveau_nappe_eau` Lignes : 10,930
 Covariables : 4 Période : 1994-07-24 → 2026-05-09
 Stations : 1 station(s)
 profondeur_nappe, temperature_2m, total_precipitation, potential_evaporation

Station
 04312X0039/F

☒ Utiliser les covariables (4 variables)

Fonction de perte
 MAE (Mean Absolute Error)

Entrée (jours de contexte) 30 **Sortie (horizon de prévision)** 7

Part entraînement 0,7 **Part validation** 0,15

Époques maximum 100

Figure 7.1 – La déclaration d’un entraînement. L’écran expose ce qui doit rester explicite pour qu’une expérience soit rejouable : architecture, jeu de données horodaté avec sa période et son nombre de lignes, covariables retenues, fonction de perte, fenêtre d’entrée et horizon de sortie, partage entre entraînement et validation. Le préréglage métier, en tête, permet de ne rien régler du tout.

La séparation entre l’entraînement et l’interface, ensuite. Le code d’entraînement n’a aucune connaissance de l’interface qui l’observe : il écrit son avancement dans un fichier d’état, que la couche de présentation lit indépendamment et retransmet au navigateur par un flux d’événements. Cette séparation, visible sur la figure 5.1, a une conséquence pratique importante : un entraînement lancé depuis un script se suit dans l’interface, et réciproquement.

La conduite d’expériences longues, enfin. L’entraînement s’appuie sur PyTorch Lightning [17] et s’effectue sur processeur graphique lorsque celui-ci est disponible, avec arrêt anticipé et suivi de l’évolution des pertes en apprentissage et en validation. L’utilisateur voit progresser son entraînement au lieu d’attendre un résultat opaque, et peut l’interrompre s’il diverge.

Le modèle produit conserve ensuite ce qui l’a fait (figure 7.2), de sorte qu’une prévision se rattache sans ambiguïté au couple exact qui l’a produite.

7.4 Optimisation d’hyperparamètres

La comparaison d’architectures n’a de sens que si chacune est évaluée dans une configuration raisonnable ; comparer un modèle réglé à un modèle laissé aux valeurs par défaut ne renseigne que sur le réglage. Optuna [1] est donc intégré pour la recherche automatisée d’hyperparamètres, avec un échantillonnage guidé par les essais déjà évalués. Chaque essai est par ailleurs interrompu dès que sa perte de validation cesse de progresser. L’élagage entre essais, qui abandonnerait une configuration en cours au vu des premières époques, n’est pas activé : ce serait le premier réglage à ajouter pour réduire le coût d’une campagne.




Figure 7.2 – Un modèle entraîné, tel que la page de prévision le présente : architecture, station, jeu de données horodaté, variables employées, métriques de test, et la fenêtre d’entrée comme l’horizon avec lesquels il a été appris. Un modèle dont on ne saurait pas dire ces choses ne serait pas comparable à un autre. *Valeurs lues sur la capture : elles illustrent l’instrument, elles ne constituent pas un résultat d’évaluation.*

7.5 Rendre l’outil utilisable par des non-spécialistes

Un dispositif d’expérimentation complet est, par nature, exigeant : longueur de fenêtre d’entrée, taille de lot, nombre d’époques, patience d’arrêt anticipé. Ces réglages sont un obstacle réel pour un hydrogéologue qui souhaite simplement obtenir une prévision.

Des **configurations prêtes à l’emploi** ont donc été définies par cas d’usage métier plutôt que par architecture : prévision piézométrique à court terme (sept jours), à moyen terme (trente jours), à long terme (quatre-vingt-dix jours), et prévision de débit à quatorze jours. Chacune fixe une architecture et un jeu d’hyperparamètres cohérents, choisis à partir des recommandations de la bibliothèque et des références publiées sur séries piézométriques.

Ces configurations sont des points de départ raisonnables, non des réglages optimisés pour une station donnée. La documentation le dit explicitement et oriente vers la recherche automatisée d’hyperparamètres pour aller plus loin. Il aurait été facile, et trompeur, de les présenter comme optimales.

Les échanges avec les hydrogéologues ont d’ailleurs montré que cette réserve n’est pas de pure forme. La réponse d’un aquifère à la pluie varie fortement selon sa nature : certains systèmes sont inertiels et réagissent avec une forte latence, d’autres se rechargent presque directement. Les cycles observés vont de l’annuel au pluriannuel. La profondeur d’historique à fournir en entrée, l’horizon de prévision pertinent et le pas d’agrégation devraient donc être choisis selon le type de nappe, comme le sont déjà les configurations de modèles métier du chapitre 6. Cette adaptation par famille d’aquifère n’a pas été faite pour les modèles appris : elle constitue une piste identifiée, et vraisemblablement le premier gain à aller chercher.

7.6 Lire une prévision avant de l’expliquer

Le dispositif expose la prévision de deux manières complémentaires, dont la seconde conditionne ce qu’on peut dire de la première.

La première est la **fenêtre glissante** sur le jeu de test (figure 7.3). La fenêtre d’entrée et l’horizon se déplacent ensemble sur toute la période réservée, ce qui évite de conclure d’une fenêtre unique et bien choisie.

La seconde est la **fenêtre examinée de près**, avec ses écarts chiffrés (figure 7.4). L’erreur y est rapportée à l’amplitude de l’ouvrage, et non seulement exprimée en mètres : une erreur de quelques centimètres n’a pas le même sens sur une nappe dont le battement annuel est décimétrique et sur une nappe dont il dépasse le mètre. C’est cette mise en rapport, plus que l’erreur brute, qui permet




Figure 7.3 – Le jeu de test entier, que le modèle n’a pas vu à l’entraînement. La zone claire est la fenêtre d’entrée, la bande orange l’horizon de prévision, et les deux se positionnent n’importe où sur la période. La vue d’ensemble sert d’abord à situer la fenêtre examinée dans la dynamique de l’ouvrage, saison humide ou étiage.

à un hydrogéologue de dire si la prévision lui sert.



Figure 7.4 – Une fenêtre de prévision confrontée aux observations, et les écarts associés. La dernière ligne du panneau rapporte l’erreur absolue moyenne et l’erreur quadratique à l’écart interquartile de la série, ce qui les rend comparables d’un ouvrage à l’autre. La précision directionnelle indique par ailleurs la part des pas où le sens de variation est correct, qui est souvent ce qui intéresse un gestionnaire. *Valeurs lues sur la capture : elles illustrent l’instrument, elles ne constituent pas un résultat d’évaluation.*

7.7 Analyser les prévisions produites

Une prévision de niveau de nappe n’est mobilisable pour décider que si l’on peut dire sur quoi elle repose. Les décisions publiques rappelées au chapitre 1 doivent pouvoir être motivées, et l’interlocuteur d’un modèle de nappe est un hydrogéologue qui n’accordera sa confiance qu’à des explications compatibles avec sa compréhension du système. Le laboratoire outille donc trois questions : *sur quoi le modèle s’appuie-t-il*, *que se passerait-il dans d’autres conditions*, et *cette chronique est-elle seulement explicable par le climat*.

La première question mobilise cinq familles d’attribution complémentaires : l’importance par perturbation, les valeurs de Shapley [27] et leur variante pour séries temporelles [5], les attributions par gradients [40, 24], les poids d’attention pour les architectures qui en possèdent, et la décomposition du signal en tendance, saisonnalité et résidu. Les réunir dans un même outil ne vise pas l’exhaustivité mais la **confrontation** : des méthodes reposant sur des principes différents et qui convergent donnent une explication crédible, tandis que leur divergence signale une explication

fragile, information qu'une méthode unique aurait masquée.

Quatre de ces cinq familles sont atteignables depuis l'interface, dans le panneau d'explicabilité de la page de prévision : l'importance par perturbation, les valeurs de Shapley, les attributions par gradients et la décomposition du signal. Les poids d'attention font exception. Le calcul existe dans la bibliothèque, le point d'accès existe dans l'API et le client web sait l'appeler, mais aucun composant de l'interface ne le sollicite : ils ne sont donc pas accessibles à un utilisateur.

La deuxième question relève des explications contrefactuelles, formalisées par Wachter *et al.* [44] et transposées depuis peu à la prévision de séries temporelles [45]. Elle a demandé un développement propre, parce que la réponse directe ne vaut rien ici. Laisser un algorithme modifier librement les entrées jusqu'à ce que la prévision atteigne la cible produit des scénarios corrects au sens de l'optimisation et physiquement absurdes : de l'air réchauffé sans évaporation supplémentaire, une pluie incohérente d'un jour au suivant, une saison qui n'existe nulle part. Les hydrogéologues y ont substitué deux exigences, le respect du bilan de masse et la cohérence avec les échelles de temps auxquelles un aquifère réagit.

7.7.1 Contrefactuels sous contrainte physique

L'implémentation retenue, désignée PhysCF, a été conçue au cours de ces travaux ; un prototype séparé, décrit en section 7.8, sert à l'éprouver hors de l'application. Elle traduit ces exigences en renonçant à perturber les entrées valeur par valeur, et ne règle que sept paramètres décrivant un régime climatique : un facteur de pluie par saison, un décalage de température, un décalage du calendrier, et un résidu d'évaporation étroitement borné. L'évapotranspiration n'est pas libre, elle est calculée à partir de la température au taux d'environ 7 % par degré, ordre de grandeur tiré de la relation de Clausius-Clapeyron. Le scénario reste donc cohérent par construction plutôt que redressé après coup, et la réponse s'énonce dans les termes du métier : *il aurait fallu des hivers un cinquième plus humides et un climat plus frais d'un degré*. Une seconde méthode, adaptée de CoMTE [3], répond à la même question en allant chercher dans l'historique une période réellement observée plutôt qu'en construisant un climat, ce qui donne un point de comparaison de nature différente. Chaque scénario produit est enfin rejoué dans un modèle métier calibré indépendamment, celui du chapitre 6 : s'il fait diverger les deux modèles bien plus qu'ils ne divergeaient sur la situation observée, il est rejeté.

Ces deux méthodes et leur validation croisée sont livrées dans la bibliothèque métier et exposées par l'API, où elles disposent chacune de leur point d'accès. Le prototype de recherche dont PhysCF est issue vit dans un dépôt distinct, décrit plus loin. Elles ne sont en revanche **pas atteignables depuis l'interface**. La page qui les pilote existe dans le dépôt, avec son sélecteur de cible et sa vue de comparaison, mais elle n'est déclarée dans aucune route de l'application : le laboratoire d'intelligence artificielle propose quatre onglets, données, entraînement, prévision et modèles, et aucun d'eux ne mène aux contrefactuels. Un utilisateur ne peut donc en produire aucun sans passer par l'API ou par un carnet de calcul. Rebrancher cette page est un travail court, puisque tout ce qu'elle appelle fonctionne, mais il n'a pas été fait et il conditionne tout usage par un non-développeur.

La troisième question renverse la perspective. Une chronique qu'aucun modèle climatique ne reproduit n'est pas nécessairement mal modélisée : elle peut porter la trace d'un prélèvement, que le forçage climatique ne contient pas. Le problème est non supervisé, faute d'historique étiqueté. La démarche part des résidus d'un modèle métier calibré pour isoler des périodes tenues pour non perturbées, puis croise deux lectures indépendantes dont les verdicts sont fusionnés. L'explicabilité y joue un rôle inhabituel : elle ne justifie pas une prédiction, elle détecte une dérive de ce sur quoi le modèle s'appuie, signe que le régime du système a changé. L'annotation qui en résulte sert à écarter

les stations impropres à l'apprentissage, et figure parmi les cas d'usage identifiés avec le BRGM.

7.8 Deux travaux personnels conduits en marge

Deux questions soulevées par la plateforme ne pouvaient pas être traitées avec elle. Toutes deux demandaient de sortir de l'application pour isoler la question de l'outil qui la pose, et toutes deux ont donné lieu à un développement séparé, mené à titre personnel dans le cadre de ces travaux. Elles figurent ici parce qu'elles éclairent des choix décrits plus haut, et parce qu'un repreneur qui ignorerait la seconde referait une erreur qu'elle documente.

7.8.1 Éprouver la méthode contrefactuelle hors de l'application

La méthode décrite en section 7.7.1 devait être évaluée, et la plateforme ne s'y prête pas : elle mêle l'instrument et le cas, alors qu'une évaluation demande un petit nombre de sites choisis, des modèles entraînés pour eux et des mesures répétables. Le prototype PhysCF a donc été construit à part, autour de quatre stations couvrant le gradient qui va de l'aquifère le plus réactif au plus inertiel : un alluvial de Moselle, un karst du Val d'Orléans, une craie de la Somme et un calcaire de Beauce.

Le but est de vérifier une hypothèse précise : que le choix de *l'espace* de perturbation compte davantage que celui de l'algorithme d'optimisation. Une méthode de référence opérant en espace brut, sur un millier de dimensions avec des pénalités molles, est comparée à PhysCF, qui optimise quatre à sept paramètres dans un espace où la cohérence physique est vraie par construction. Chaque scénario est confronté à un modèle métier calibré indépendamment.

Ce qui est acquis est le dispositif complet : les opérateurs de perturbation, l'optimisation par gradient et par recherche bayésienne, la validation croisée par le modèle métier, les cibles définies sur les classes de l'indicateur piézométrique, et la suite de tests qui les couvre. Le protocole d'évaluation est écrit lui aussi, jusqu'aux mesures à relever et aux tableaux qui doivent les recevoir. Ces tableaux sont vides : la campagne n'a pas été conduite, et le chapitre 9 dit ce qu'elle demande d'abord.

7.8.2 Un banc d'essai des représentations de chroniques piézométriques

La détection des chroniques perturbées par un prélèvement, évoquée en section 7.7, prévoit un étage qui suit la dérive d'une représentation apprise de la chronique. Rien ne disait quel encodeur employer, et la littérature ne comparait aucune de ces méthodes sur des données hydrogéologiques. La question s'est révélée plus large que son motif : elle porte sur ce qu'une compression apprise retient d'une chronique piézométrique.

Sept encodeurs ont été comparés sur 5 116 stations, avec un partage de validation croisée qui tient chaque département entier du même côté : aucune station n'est ainsi évaluée par un modèle qui aurait appris sur ses voisines immédiates, dont la chronique lui ressemble par le seul effet de la proximité. Le protocole principal est **univarié** : chaque encodeur ne reçoit que le niveau. Une variante y ajoute les trois covariables climatiques, non comme un raffinement mais comme une expérience de contrôle.

Table 7.1 – Classification du milieu hydrogéologique à partir du seul niveau, précision équilibrée sous partage spatial. La dernière colonne mesure ce que la représentation retient de la latitude, quantité qui n'a aucune raison d'aider à reconnaître un aquifère.

Encodeur	Précision équilibrée	R^2 latitude	Nature
Signatures hydrologiques	0,303	−0,021	29 descripteurs métier
Catch22	0,259	0,117	statistiques génériques
MultiRocket	0,256	0,365	convolutions aléatoires
SoftCLT	0,241	0,222	contrastif appris
TS2Vec	0,233	0,174	contrastif appris
Analyse en composantes	0,170	0,003	référence linéaire
Bruit gaussien	0,148	−0,012	référence basse

Trois résultats en sortent. Le premier est que **vingt-neuf descripteurs écrits à la main devancent l'apprentissage contrastif** sur le signal endogène, avec un écart statistiquement significatif contre les deux encodeurs contrastifs et un écart non significatif contre les deux méthodes génériques restantes, Catch22 et MultiRocket. Une recherche d'hyperparamètres dédiée à l'un des encodeurs contrastifs n'en comble que 0,015 à 0,020, le reste étant structurel plutôt qu'un défaut de réglage. Les mêmes descripteurs prédisent les signatures physiques d'une chronique avec un coefficient de détermination proche de 0,89, contre 0,08 à 0,19 pour les représentations apprises. Cet avantage tient cependant à la tâche et ne se transporte pas : sur une régression de tendance longue, ce sont les descripteurs génériques qui l'emportent, tandis que les descripteurs métier retombent au niveau d'une prédiction faite à partir de la seule position géographique. Aucun encodeur ne domine partout, et le choix suit l'usage qu'on veut en faire.

Le deuxième porte sur la validation. Une validation croisée qui ignore la structure spatiale porte la valeur de 0,303 à 0,376 pour le même encodeur : l'autocorrélation géographique des étiquettes suffit à gonfler une performance sans qu'aucune erreur de calcul ne soit commise.

Le troisième est le plus utile ici, et le plus inattendu. **Ajouter les covariables climatiques brutes améliore la classification, et pour la mauvaise raison.** La précision équilibrée gagne de 0,059 à 0,146 selon l'encodeur, mais la latitude devient au même moment prédictible à partir de la représentation, avec un gain de 0,488 à 0,633 sur le même coefficient. Deux stations voisines partagent leur maille climatique ; le forçage écrit donc dans la représentation une structure géographiquement lisse, et l'essentiel du gain apparent est un transfert de cette structure, non un progrès de discrimination hydrogéologique.

Ce résultat conditionne l'interprétation des modèles multivariés de ce chapitre, qui consomment exactement ces trois covariables. Une réserve accompagne cependant sa transposition : le banc travaille sur une grille au quart de degré, alors que l'entrepôt en produit une au dixième de degré, dont la structure est moins lisse. Le mécanisme vaut, son ampleur reste à mesurer sur la chaîne décrite au chapitre 3. Le remède proposé, employer des anomalies ou une recharge dérivée du modèle métier plutôt que le forçage brut, figure parmi les chantiers du chapitre 9.

Le banc explique enfin pourquoi l'étage de dérive de représentation reste inerte dans la plateforme : les encodeurs qu'il attend ne se sont pas montrés supérieurs, sur le signal endogène, à des descripteurs que la bibliothèque métier calcule déjà.

Une précision s'impose sur l'état du dépôt, puisqu'il est public et que le tableau ci-dessus invite à s'y reporter. Les campagnes multivariées, la régression de tendance et les recherches

d'hyperparamètres y sont versionnées avec leurs métriques ; la campagne univariée dont ce tableau est tiré ne l'est pas, et les carnets de vérification n'ont pas été exécutés. Les valeurs rapportées ici ont été recoupées avec les artefacts disponibles, mais les rendre rejouables d'un bout à l'autre reste à faire, et figure au chapitre 9.

7.9 Ce qui est établi, et ce qui ne l'est pas

Ce qui est acquis est le dispositif : un environnement d'expérimentation instrumenté, traçable, qui rend les comparaisons possibles et rejouables, accessible à des utilisateurs de niveaux d'expertise différents, et dont le cœur est réutilisable hors de l'application.

Ce qui n'est pas établi dans ce rapport est le classement des architectures *de prévision* sur le cas hydrogéologique. La section précédente compare des encodeurs de représentation, question distincte traitée par un dispositif distinct ; sur la prévision elle-même, ce rapport ne produit aucun classement. Les campagnes d'entraînement conduites au cours des travaux ont servi à valider le dispositif et à orienter les développements ; les jeux de données préparés et les points de sauvegarde ont été purgés des dépôts lors de la passation. Reconstituer a posteriori un tableau de performances de prévision à partir de souvenirs ne serait pas un résultat scientifique. La campagne d'évaluation comparative, qui opposerait les modèles appris aux modèles métier du chapitre 6 sur un échantillon représentatif de stations et de familles d'aquifères, reste donc à conduire, et l'outillage nécessaire est en place pour la mener.

Cela vaut au même titre pour les outils d'analyse. Ils mettent en œuvre l'exigence formulée par les hydrogéologues, et le dispositif prévoit de quoi les comparer entre eux comme de quoi vérifier leurs résultats sur un modèle indépendant. Ils sont opérationnels au niveau de la bibliothèque et de l'API ; pour les contrefactuels, ils ne le sont pas au niveau de l'interface, faute du branchement signalé plus haut. Mais aucune évaluation quantitative n'a été conduite, sur aucun échantillon, selon aucune métrique de qualité d'explication établie. Ces développements sont **préliminaires**, et c'est leur objet : la question de ce qu'est une bonne explication relève des travaux en cours évoqués au chapitre 8, auxquels ce laboratoire fournit son terrain.

Une limite d'ingénierie reste à corriger. La suite de tests de la plateforme compte 552 tests, dont 547 passent (mesuré le 24 août 2026). Aucun ne s'exécute automatiquement : les chaînes d'intégration des deux dépôts ne comportent que des étapes de construction et de déploiement, sans étape de test. Les cinq cas non passants, quatre échecs et un test ignoré, sont documentés et aucun ne signale un défaut applicatif, mais la purge des journaux se trouve de fait non testée. C'est le premier correctif à apporter par toute personne reprenant ces travaux.

8 Ce que la collaboration a produit

À quels besoins, exprimés par qui, ces développements répondent-ils effectivement ?

8.1 Le cadre de travail

Les développements présentés dans ce rapport ont été conçus et réalisés dans leur intégralité au cours du postdoctorat, dans un dialogue continu avec trois interlocuteurs aux apports distincts.

Nicolas Labroche (LIFAT) a assuré la supervision scientifique et encadré l'orientation des travaux, à commencer par l'arbitrage exposé au chapitre 1, qui a fixé la trajectoire de l'année.

Hugo Breuillard, data scientist en charge du projet côté BRGM, a été le point de contact sur les questions de chaîne de données et de stratégie de prévision. Les échanges ont porté sur l'articulation entre l'entrepôt développé ici et les besoins de modélisation du programme, et sur la cohérence des indicateurs produits avec ceux employés par ailleurs.

Augustin Thomas, hydrogéologue au BRGM, a été l'interlocuteur sur l'ensemble des questions de domaine. C'est de ces échanges que procèdent les décisions qui ancrent la plateforme dans la pratique hydrogéologique plutôt que dans une transposition générique de méthodes d'apprentissage.

Cet apport n'est pas resté au stade de la discussion : il est inscrit dans le code, et identifiable ligne à ligne. Les configurations par famille d'aquifère (tableau 6.1) et les quatre critères d'acceptation STOWA (chapitre 6), la règle d'affichage cartographique (chapitre 5) et l'arbitrage sur l'évapotranspiration (section 4.4) en sont les quatre traces les plus nettes. Aucune ne procède d'une procédure automatique, et la dernière mérite d'être relevée pour ce qu'elle dit de la confrontation disciplinaire : la variable fournie par la réanalyse était disponible, correctement nommée et directement utilisable, et seule sa confrontation aux ordres de grandeur connus pour la France a révélé qu'elle ne désignait pas la grandeur attendue. Aucune vérification interne au code ne pouvait détecter cette erreur, puisqu'il ne s'agissait pas d'une erreur de calcul.

8.2 Les cas d'usage identifiés avec le BRGM

Les échanges n'ont pas seulement produit des décisions techniques. Ils ont fait émerger une liste de besoins concrets, qui a servi à orienter les développements et qui reste disponible pour la suite. Cette liste est un livrable à elle seule : un socle sans usage identifié n'est qu'une infrastructure en attente.

Table 8.1 – Les besoins exprimés par les équipes du BRGM, et l'état de leur prise en charge.

Besoin exprimé	Ce qu'il recouvre	État
Qualifier les piézomètres	Distinguer automatiquement les ouvrages inertiels, réactifs et influencés par des prélèvements, pour savoir lesquels sont exploitables	outillé
Prévoir les niveaux	Anticiper l'évolution d'une nappe à partir du climat	outillé
Expliquer les prévisions	Identifier les facteurs déterminants d'une prévision donnée	outillé
Comparer les approches	Confronter méthodes statistiques, modèles métier et apprentissage profond sur les mêmes données	possible, non fait
Explorer les données	Permettre aux experts de parcourir et de comparer les chroniques sans écrire de requête	outillé
Scénariser la sécheresse	Répondre à des questions du type « quelle pluie faudrait-il pour sortir de cet état ? », en appui des comités sécheresse	outillé hors interface
Étudier les échanges nappe-rivière	Détecter et caractériser les relations entre une nappe et le cours d'eau voisin, notamment le soutien d'étiage	non traité
Caractériser la double porosité	Distinguer, au sein d'une même formation, les écoulements rapides des écoulements lents, que les méthodes actuelles peinent à séparer	non traité
Couvrir les nappes captives	Disposer d'un indicateur de situation pour les nappes qui n'en ont pas, l'indicateur existant ne valant que pour les nappes libres	non traité

La colonne d'état est délibérément sévère : « outillé » signifie que les moyens existent, pas qu'un résultat a été produit, et « outillé hors interface » signale que la méthode s'exécute par l'API ou par un carnet de calcul mais reste inaccessible depuis l'application, pour la raison exposée au chapitre 7. Et les trois dernières lignes sont assumées comme telles : ce sont des sujets à part entière, identifiés comme prometteurs au cours des échanges, mais qui dépassaient le périmètre et le temps disponibles. Ils sont consignés ici parce qu'ils constituent des points d'entrée pour la suite, et parce qu'ils viennent des experts du domaine plutôt que d'une projection d'informaticien.

Un mot sur la scénarisation. Les équipes du BRGM travaillant sur la situation des nappes emploient déjà les indicateurs standardisés que produit désormais l'entrepôt. Coupler ces indicateurs à des scénarios prospectifs, c'est-à-dire répondre non seulement « où en est-on » mais « que faudrait-il pour en sortir », est le prolongement naturel de leur pratique actuelle. C'est cette continuité qui rend le socle mobilisable par eux sans changement de méthode.

8.3 L'articulation avec les travaux de recherche en cours

Les outils d'analyse présentés en section 7.7 ne sont pas isolés. Des travaux menés au LIFAT sous la direction de Nicolas Labroche portent sur les explications contrefactuelles et sur la mesure de leur qualité en tant qu'explications, question ouverte que les métriques usuelles ne tranchent pas.

La contribution de ce postdoctorat à cette thématique est **d'ordre technique**, et c'est délibéré : fournir les données, les modèles, les méthodes comparables et les moyens de validation sans lesquels

cette recherche resterait cantonnée à des jeux d'essai génériques. La répartition est claire, et il vaut mieux l'écrire que la laisser deviner.

Table 8.2 – Répartition entre ces travaux et la recherche en cours au LIFAT.

Relève de ces travaux	Le socle de données, les modèles à expliquer, l'implémentation des méthodes, la référence de comparaison, le moyen de validation indépendant, et la qualification des cas d'étude
Relève des travaux en cours	La définition de ce qu'est une bonne explication, les métriques qui la mesurent, et l'évaluation comparative des approches

C'est aussi ce qui explique qu'aucune conclusion méthodologique ne figure dans ce rapport sur la qualité des contrefactuels produits. Elle n'aurait pas eu de sens : la question relève d'un travail en cours, et l'anticiper reviendrait à préjuger de son résultat.

8.4 Des besoins distincts, un outil commun

Les deux communautés visées n'attendent pas la même chose, et l'architecture a dû accommoder les deux sans se scinder.

Table 8.3 – Deux communautés, deux attentes, un même socle.

	Hydrogéologues du BRGM	Chercheurs en apprentissage
Question posée	Où en est la ressource, et que se passe-t-il si l'on prélève ?	Quelle méthode prédit le mieux, et pourquoi ?
Attente principale	Des indicateurs conformes aux pratiques, une scénarisation crédible	Un jeu de données consolidé, un protocole reproductible
Obstacle levé	L'agrégation manuelle de sources hétérogènes	Le coût d'entrée à l'expérimentation
Ce qui a été livré	Observatoire, indicateurs validés, laboratoire de modèles métier, scénarios bornés	Entrepôt interrogeable, catalogue d'architectures, traçabilité des expériences, outillage d'explicabilité

Le point de rencontre est l'entrepôt. Parce que les indicateurs métier et les jeux d'apprentissage sont produits par la même chaîne et validés une seule fois, une comparaison entre un modèle appris et un modèle métier porte réellement sur les modèles, et non sur des préparations de données divergentes. Cette propriété, invisible dans l'interface, est ce qui rend la plateforme utilisable comme instrument de recherche et non seulement comme outil de consultation.

8.5 État de mise à disposition

Les deux dépôts sont publics, sous licence MIT, qui n'impose ni réciprocité ni autorisation préalable à la reprise :

- l'entrepôt, https://github.com/xairon/hubeau_data_integration ;
- la plateforme, <https://github.com/xairon/time-serie-explo>.

Chacun porte sa documentation d'installation, éprouvée depuis une machine vierge, et son manuel d'exploitation. Reprendre ces travaux ne suppose donc ni demande d'accès, ni contact préalable

avec leur auteur.

Deux dépôts complémentaires portent les travaux personnels décrits en section 7.8. Ils sont publiés séparément, sous licence Apache 2.0, dont la concession de brevet explicite convient à des méthodes originales :

- le prototype de contrefactuels sous contrainte physique :
<https://github.com/xairon/physcf>
- le banc d'essai des représentations de chroniques :
https://github.com/xairon/aida_embedding_benchmark

Ils ne sont pas nécessaires à la reprise du socle, qui n'en dépend pas. Le premier documente l'origine d'une méthode que la bibliothèque métier intègre ; le second porte un résultat qui conditionne l'interprétation des modèles multivariés.

La plateforme est déployée (chapitre 5), mais son usage demeure à ce jour circonscrit au cercle du projet. L'accès est nominatif : il n'existe ni inscription libre ni authentification déléguée, les comptes étant créés par un administrateur. Ce choix, adapté à un outil scientifique manipulant une chaîne de traitement en évolution, constitue le principal frein à une diffusion plus large, et le premier levier à actionner pour l'obtenir.

Le socle a par ailleurs été présenté aux équipes du projet ANR AIDA, dont le domaine d'expérimentation recouvre en partie celui traité ici, afin que celles qui en auraient l'usage n'aient pas à le reconstruire.

Plusieurs pistes ouvertes au cours de ces échanges n'ont pas été suivies. Le rapprochement avec les modèles à réservoirs du BRGM en est la principale : elle donnerait une seconde référence de comparaison, indépendante de celle construite ici. Quant à l'élargissement des usages, il tient à une politique d'accès et à un accompagnement, non à des développements supplémentaires.

9 Bilan : le socle, ses limites, sa reprise

Que reste-t-il une fois le contrat achevé, dans quel état, et à quelles conditions ces développements peuvent-ils servir au-delà du projet qui les a financés ?

9.1 Récapitulatif des réalisations

Table 9.1 – Les réalisations de la période, par domaine.

Domaine	Réalisation
Données	Chaîne d'ingestion automatisée de quatre jeux de données issus de trois fournisseurs publics ; entrepôt en architecture médaillon sur base relationnelle avec extensions temporelle et géospatiale ; rattachement spatial des stations à leur maille climatique ; enrichissement par le référentiel hydrogéologique ; environ 658 millions de lignes en couche brute
Fiabilité	Idempotence des traitements, traçabilité des lignes écartées, contraintes de concurrence par clés, reprise après interruption, sauvegarde et restauration vérifiées sur un entrepôt représentatif
Indicateurs	Indices standardisés de niveau, de débit, de précipitation, de température et de bilan hydrique ; production à l'échelle nationale sur quatre fenêtres ; protocole de validation à critère pré-établi ; deux décisions méthodologiques établies par la mesure
Exploration	Observatoire spatial des nappes et des rivières ; module climatique national avec historique depuis 1950, épisodes de sécheresse et export
Modélisation métier	Laboratoire de modèles à fonction de transfert ; calibration automatique guidée par la nature de l'aquifère ; évaluation selon quatre critères normalisés ; diagnostics préalables et postérieurs ; scénarios prospectifs à bornes physiquement dérivées
Apprentissage	Catalogue d'une douzaine d'architectures de prévision profonde ; optimisation d'hyperparamètres ; traçabilité des expériences ; suivi d'entraînement en temps réel ; configurations prêtes à l'emploi par cas d'usage métier
Explicabilité	Attribution multi-méthodes, dont quatre familles accessibles dans l'interface ; contrefactuels sous contrainte physique avec couplage thermodynamique et validation par modèle indépendant, livrés en bibliothèque et en API mais non branchés dans l'interface ; détection non supervisée d'influence anthropique
Ingénierie	Deux dépôts conteneurisés, reproductibles et documentés pour la reprise ; environnements de développement et de production séparés

9.2 Bilan au regard de la mission initiale

La mission portait sur l'explicabilité des modèles de prévision appliqués aux eaux souterraines. Elle a été instrumentée de bout en bout ; elle n'a pas été conclue.

Ce qui a été atteint : l'outillage complet que le sujet supposait, jusqu'aux méthodes d'explication elles-mêmes. Parmi elles, les contrefactuels sous contrainte physique s'attaquent directement à ce qui rend l'explicabilité délicate dans ce domaine, à savoir qu'une explication physiquement incohérente n'est pas une explication. Ces développements restent préliminaires à deux titres : ils ne sont pas validés, et la page d'interface qui devait les mettre à portée d'un hydrogéologue n'est pas branchée dans l'application, de sorte qu'ils ne s'exécutent aujourd'hui que par l'API ou par un carnet de calcul.

Ce qui n'a pas été atteint : l'évaluation quantitative comparée des méthodes, faute de temps une fois l'infrastructure construite. C'est le travail le plus immédiatement accessible à qui reprendra ces développements, parce que tout ce qu'il suppose existe désormais.

9.3 Ce qui rend ce socle réutilisable

Affirmer qu'un développement constitue un « socle » n'a de valeur que si l'on peut désigner les propriétés qui le rendent réutilisable et montrer qu'elles sont acquises. Elles sont au nombre de quatre.

La couche analytique de l'entrepôt se consomme en SQL, et rien d'autre. Un utilisateur n'a besoin de connaître ni l'outil d'ingestion, ni la bibliothèque de transformation, ni l'orchestrateur : un carnet de calcul, un tableur connecté ou une application tierce s'y branchent également. La conséquence est structurante : **l'amont peut être remplacé sans que l'aval s'en aperçoive**. Un outil d'ingestion devenu obsolète se remplace sans toucher aux consommateurs. C'est cette propriété qui distingue une infrastructure d'un script.

Le cœur de calcul de la plateforme, lui, ne dépend ni du service web ni de l'interface. La contrainte a été posée dès l'origine, au chapitre 5, et son effet sur la valeur résiduelle des travaux est direct : **même si l'application web était abandonnée, les méthodes resteraient utilisables**. La contribution n'est pas prisonnière de son emballage.

Les indicateurs sont calculés une fois pour tous les consommateurs, sans second calcul susceptible de diverger, et un test de contrat échoue si les deux dépôts cessent de s'accorder (chapitre 4), sous la réserve d'exécution rappelée plus bas. La pile, enfin, est conteneurisée, ses volumes de données survivent à l'arrêt des conteneurs, sa restauration a été vérifiée sur un entrepôt représentatif et non sur une table jouet (chapitre 3), et sa documentation a été refondue en fin de période pour la reprise, jusqu'aux pièges qui produisent des résultats faux sans émettre d'erreur.

Au-delà des deux dépôts, ces travauxinstancient un enchaînement (figure 9.1) qui n'a rien de spécifique aux eaux souterraines.




Figure 9.1 – L'enchaînement mis en œuvre. Chaque étape suppose la précédente ; escamoter l'une d'elles produit des résultats incomparables ou inutilisables.

L'enseignement principal de l'année tient dans la lecture de gauche à droite de cette figure : **on**

ne peut pas commencer par la droite. Investir dans le modèle avant de disposer d'une donnée exploitable conduit à découvrir ensuite qu'elle ne permet pas de conclure.

9.4 Ce qui est transmis aux travaux à venir

Les travaux d'explicabilité se poursuivront au-delà de cette période. Le tableau 9.2 confronte ce qu'ils supposent à ce qui leur est effectivement transmis.

Table 9.2 – Ce que supposent les travaux d'explicabilité à venir, et ce dont ils disposent.

Besoin	Disponible
Un jeu de données consolidé, joint au forçage climatique	Entrepôt national, partitions depuis 1967 pour les stations et 1950 pour le climat, rattachement spatial matérialisé
Des modèles à expliquer	Douze architectures de prévision profonde sous interface unique, avec traçabilité des expériences
Une référence interprétable à laquelle confronter les explications	Modèles à fonction de transfert calibrés, dont les paramètres ont un sens hydrogéologique
Des méthodes d'attribution	Cinq familles complémentaires, confrontables entre elles, dont quatre accessibles dans l'interface
Des explications actionnables	Contrefactuels sous contrainte physique, mettant en œuvre les critères formulés par les hydrogéologues, appelables par l'API et non par l'interface
Un moyen de valider une explication	Rejeu du scénario dans un modèle métier indépendant
Des cas d'étude qualifiés	Détection non supervisée d'influence anthropique, permettant d'écarter les chroniques impropres

Ce qui n'est pas transmis tient en une phrase : le socle rend ces travaux possibles, il ne les a pas menés. Le détail en est donné plus bas, aux points 3 et suivants.

9.5 Limites et chantiers à reprendre

Un successeur doit savoir ce que le socle ne fait pas, et ce qu'il faut engager pour qu'il le fasse. Les deux questions n'en font qu'une : une limite qui se corrige est un chantier. La liste suivante est ordonnée par priorité, la première ligne étant la seule qui conditionne la validité de résultats à venir.

- 1. Les modèles métier sont calibrés sur une évapotranspiration inadaptée.** La chaîne des stations transporte encore la variable brute, environ deux fois supérieure à l'évapotranspiration de référence employée par la chaîne climatique. Ce que cet écart change pour les calibrations n'a pas été évalué, aucune campagne comparant les deux forçages n'ayant été conduite. Les prévisions restent exploitables, mais les paramètres calibrés n'ont pas d'interprétation physique directe tant que ce point n'est pas tranché. Aligner la chaîne des stations est le premier chantier, et il précède toute campagne de calibration.
- 2. Aucun des deux dépôts n'exécute ses tests automatiquement.** Leurs chaînes d'intégration ne comportent que des étapes de construction et de déploiement. Sur la plateforme, cinq

des 552 tests ne passent pas, quatre échecs et un test ignoré, pour des raisons documentées et sans rapport avec un défaut applicatif, mais la purge des journaux se trouve de fait non testée. Surtout, le contrat de classification décrit au chapitre 4 n'est gardé par aucune exécution : les deux tables de référence sont bien identiques et le test qui les compare existe de part et d'autre, mais rien ne le lance. Tant que les vérifications dépendent d'une initiative humaine, la confiance dans les évolutions décroît avec le temps. C'est le chantier le moins coûteux et le plus rentable.

3. **Les contrefactuels ne sont pas atteignables depuis l'interface.** La page qui les pilote existe dans le dépôt, avec son sélecteur de cible, sa vue de comparaison et son appel à la validation par modèle indépendant, et tout ce qu'elle appelle fonctionne. Mais elle n'est déclarée dans aucune route de l'application, et le laboratoire d'intelligence artificielle n'expose que ses quatre onglets de données, d'entraînement, de prévision et de modèles. Les méthodes ne s'exécutent donc aujourd'hui que par l'API ou par un carnet de calcul. Le même constat vaut, plus modestement, pour les poids d'attention côté attribution. Rebrancher la route est court ; ne pas le faire prive de l'outil le public auquel il était destiné.
4. **Aucun résultat de performance comparée n'est établi.** Les campagnes d'entraînement ont validé le dispositif, non classé les méthodes ; les jeux préparés et les points de sauvegarde ont été purgés lors de la passation. La campagne d'évaluation comparative, qui opposerait modèles métier et modèles appris sur un échantillon représentatif de stations et de familles d'aquifères, reste donc à conduire. L'outillage est prêt de part et d'autre, et le socle sera d'autant plus crédible qu'il aura servi à établir un résultat.
5. **Le forçage climatique brut inscrit de la géographie dans les modèles multivariés.** Le banc d'essai décrit en section 7.8 montre qu'ajouter les covariables climatiques telles quelles à une représentation apprise améliore ses performances tout en y rendant la latitude prédictible, deux effets couplés : le gain vient pour l'essentiel de la structure géographiquement lisse du forçage, non d'une meilleure lecture du système hydrogéologique. Le remède est connu, employer des anomalies par rapport à la moyenne locale de longue période ou une recharge dérivée du modèle métier, ce qui conserve l'information temporelle du climat en retirant sa composante spatialement lisse. Deux réserves : la mesure a été faite sur une grille au quart de degré, quatre fois plus grossière que celle de l'entrepôt, et son effet sur la prévision, par opposition à la classification, n'a pas été évalué. Vérifier ce point sur la chaîne du chapitre 3 précède toute interprétation d'un modèle multivarié.
6. **Deux travaux personnels attendent leur campagne.** Le prototype de contrefactuels sous contrainte physique dispose de son cadre, de ses opérateurs, de ses quatre sites et de son protocole d'évaluation écrit ; ses tableaux de résultats sont vides, et la campagne demande d'abord que le forçage d'évapotranspiration de la chaîne des stations soit aligné, faute de quoi la validation par modèle métier hériterait du défaut signalé en première ligne de cette liste. Le banc d'essai des représentations, lui, a ses résultats, mais la campagne du protocole principal n'est pas versionnée et ses carnets de vérification n'ont jamais été exécutés : les rendre reproductibles est un travail court, sans calcul lourd, et c'est la condition pour que ces résultats soient opposables à un tiers.
7. **La couverture climatique s'arrête à la métropole.** La grille ingérée couvre la France métropolitaine et la Corse. Les stations ultramarines sont présentes dans l'entrepôt mais sans forçage climatique, ce qui les rend inutilisables pour la modélisation.
8. **Certaines températures agrégées au niveau des stations** sont des extrêmes de moyennes journalières et non de véritables extrêmes journaliers ; l'exposition de ces derniers supposerait

de modifier une table partitionnée.

9. **La source climatique retenue est un compromis.** ERA5-Land a été préféré à une réanalyse plus fine mais non redistribuable, au bénéfice de la reproductibilité et du partage.
10. **Le périmètre couvre la quantité, non la qualité** des eaux, également visée par le programme.

Trois autres chantiers ne corrigent aucune limite du livrable, mais conditionnent son usage au-delà du cercle actuel. Aucun n'est un verrou de recherche ; tous sont des décisions d'investissement.

- **Un accès élargi et gouverné.** L'accès nominatif convient à un outil de projet, non à un environnement partagé. Une politique d'accès, précisant qui accède, pour quels usages et avec quelle responsabilité sur les données, conditionne tout élargissement.
- **Un catalogue de données.** L'entrepôt est documenté pour qui sait où chercher. Un environnement d'outils suppose un catalogue décrivant les jeux disponibles, leur origine, leur fraîcheur et leurs conditions d'usage.
- **Le calcul mutualisé.** L'entraînement s'appuie aujourd'hui sur un serveur unique. Un usage partagé suppose une file d'attente et un partage de ressources.

9.6 Extensions, par coût croissant

Table 9.3 – Ce que coûterait chaque extension du socle, et ce qu'elle suppose.

Extension	Ce qu'elle suppose	Coût
Nouvelles stations, autre territoire	Rien : la couverture est déjà nationale et la chaîne est paramétrée par configuration	nul
Nouveaux indicateurs standardisés	Un ajustement statistique et sa validation, selon le protocole existant	faible
Nouvelles architectures de prévision	Une entrée au catalogue ; la fabrique de modèles et la traçabilité sont génériques	faible
Qualité des eaux souterraines	De nouvelles sources et de nouveaux modèles de transformation ; l'architecture est inchangée	moyen
Eaux de surface	La chaîne hydrométrique existe déjà ; l'extension porte sur la modélisation	moyen
Autre compartiment (air, sol)	Les sources et les indicateurs diffèrent, le patron tient	moyen
Couplage à un modèle hydrogéologique distribué	Une interface avec un simulateur physique externe et l'assimilation de ses sorties	élevé

Ce qui est peu coûteux l'est *parce que* l'infrastructure existe. Le coût élevé de l'année écoulée a été payé une fois ; il ne se représente pas à chaque extension. C'est la définition même d'un socle.

9.7 Articulation avec le volet des jumeaux numériques

Un jumeau numérique de la ressource en eau suppose trois choses : une représentation de l'état courant du système, une capacité à le projeter, et une capacité à expliquer la projection. L'entrepôt et l'observatoire couvrent l'état, les modèles métier et appris la projection.

La contribution la plus spécifique porte sur la troisième. Un jumeau numérique qui projette sans expliquer n'est qu'un simulateur ; ce qui en fait un instrument de décision est la capacité à répondre « pourquoi » et « que se passerait-il si » dans les termes du métier. Les contrefactuels sous contrainte physique décrits en section 7.7.1 sont directement conçus pour cet usage : ils produisent des scénarios énonçables, du type « il aurait fallu des hivers un cinquième plus humides et un climat plus frais d'un degré », plutôt que des perturbations numériques. Leur mise à portée effective d'un gestionnaire suppose toutefois le branchement de l'interface signalé au chapitre 7.

9.8 État de passation

Le contrat s'est achevé le 30 juin 2026. Les travaux se sont poursuivis jusqu'au 26 août 2026 dans le seul but de rendre les réalisations exploitables sans leur auteur :

- refonte complète de la documentation des deux dépôts, organisée autour d'une cartographie des documents et vérifiée par exécution réelle des procédures décrites ;
- consignation des pièges susceptibles de produire des résultats faux sans émettre d'erreur, développés au chapitre 3 ;
- retrait des éléments sensibles : identifiants, clés d'interface, topologie interne, adresses personnelles ; restriction par défaut de l'écoute des services à l'interface locale ;
- suppression du code mort et des scripts devenus inopérants ;
- vérification à l'échelle réelle des procédures de sauvegarde et de restauration ;
- explicitation du couplage entre les deux dépôts et de ses conditions de démarrage.

Aucun repreneur n'est désigné à la date de ce rapport. Ce qui précède ne prépare donc pas une transmission à une personne identifiée : il vise à ce que la reprise reste possible par quiconque en aura la charge, sans recours à son auteur.

9.9 Conclusion

Ces travaux répondent à une question qui n'était pas celle posée au départ, mais qui la conditionnait : *comment rendre possible la recherche en intelligence artificielle sur les eaux souterraines françaises ?*

La réponse tient en une chaîne complète, allant de quatre jeux de données publics et dispersés jusqu'à des scénarios contrefactuels énonçables dans le langage des hydrogéologues, dont chaque maillon est documenté, vérifié et réutilisable indépendamment des autres.

Ce qui a été construit dépasse le périmètre des eaux souterraines : l'enchaînement sources → entrepôt → indicateurs validés → modèles → explication est transposable aux autres compartiments environnementaux visés par le programme. C'est en ce sens que ces développements constituent moins un aboutissement qu'un point de départ.

A Annexes

A.1 Inventaire des réalisations logicielles

A.1.1 Entrepôt de données hydro-climatiques

Table A.1 – Inventaire de l’entrepôt de données hydro-climatiques.

Période	23 septembre 2025 au 26 août 2026
Volume	≈ 6 000 lignes Python, ≈ 2 600 lignes SQL de transformation (mesuré le 26 août 2026, hors tests)
Ingestion	Bibliothèque d’extraction déclarative : pagination, reprise sur erreur, déduplication avant chargement, partitionnement annuel de 1967 à aujourd’hui
Transformation	8 modèles de nettoyage, 3 modèles de rejets tracés, 18 modèles analytiques, complétés par des tables d’indicateurs calculées en Python
Orchestration	8 traitements planifiés, 3 capteurs événementiels, clés de concurrence par nature de traitement
Stockage	Base relationnelle avec extension de séries temporelles (partitionnement, compression) et extension géospatiale (jointures spatiales indexées)
Infrastructure	7 services conteneurisés, séparation du code métier et de l’orchestrateur, volumes de données déclarés hors du cycle de vie des conteneurs

A.1.2 Plateforme d’exploration, de modélisation et de prévision

Table A.2 – Inventaire de la plateforme d’exploration, de modélisation et de prévision.

Période	6 novembre 2025 au 26 août 2026
Volume	≈ 34 000 lignes Python, ≈ 26 000 lignes TypeScript (mesuré le 26 août 2026, hors tests)
Interface	Application monopage : cartographie, graphiques interactifs, suivi d’entraînement en temps réel
Service	API avec flux d’événements, authentification nominative, journal d’audit, limitation de débit
Cœur métier	Bibliothèque Python indépendante du service web et de l’interface : préparation, modèles métier, entraînement, explicabilité, contrefactuels, détection d’influence
Vérification	552 tests, dont 547 passent (mesuré le 24 août 2026)
Déploiement	Interface sur infrastructure mutualisée, calcul et bases sur serveur équipé d’un processeur graphique ; environnements de développement et de production séparés

A.2 Sources de données et attributions

Table A.3 – Les quatre jeux de données ingérés et leur couverture.

Source	Contenu	Couverture
Hub'Eau, piézométrie	Niveaux de nappe aux ouvrages de surveillance	partitions depuis 1967
Hub'Eau, hydrométrie	Débits des cours d'eau (sites, stations, observations)	partitions depuis 1967
Copernicus ERA5-Land	Réanalyse climatique sur grille 0,1°, France métropolitaine et Corse	depuis 1950
BDLISA	Référentiel hydrogéologique (entités aquifères)	référentiel

La profondeur effectivement disponible varie d'une station à l'autre : les partitions d'ingestion couvrent la période complète, les données retournées par les services web dépendent de la date de mise en service et de l'exploitation de chaque ouvrage.

Mentions obligatoires

Generated using Copernicus Climate Change Service information, 2026. Neither the European Commission nor ECMWF is responsible for any use that may be made of the Copernicus information or data it contains.

Source : Hub'Eau, eaufrance.fr • Source : BDLISA, BRGM et Sandre.

Les deux dépôts sont publiés sous licence MIT. Elle couvre le code produit, non les données consultées : chaque source conserve ses propres conditions d'usage.

A.3 Le cheminement de l'évapotranspiration dans l'entrepôt

Une précision s'impose, car la correction ne consiste pas à remplacer une valeur en cours de route. Les deux grandeurs coexistent, et leurs trajectoires diffèrent.

La variable brute d'ERA5 est **ingérée telle quelle** en couche Bronze, avec pour seule opération la conversion des mètres en millimètres. La couche Silver se contente de la typer : aucun calcul n'y est fait, conformément au principe énoncé au chapitre 3.

C'est en couche Gold, dans le modèle de grille mensuelle, que tout se joue. L'évapotranspiration de référence n'y est pas dérivée de la variable brute : elle est **calculée à partir d'une autre source**, les statistiques journalières de température issues du second chemin d'ingestion. La formule de Hargreaves est appliquée jour par jour, puis cumulée sur le mois. La variable brute, elle, est conservée dans une colonne distincte de la même table.

Table A.4 – Le cheminement des deux grandeurs d'évapotranspiration, couche par couche.

Couche	Colonne	Contenu
Bronze	potential_evaporation	Variable ERA5 brute, convertie en millimètres. Aucune interprétation.
Silver	potential_evaporation	La même, typée. Toujours aucun calcul.
Gold	etp_totale	Évapotranspiration de référence , calculée par Hargreaves depuis les températures journalières. C'est cette colonne qui est consommée.
Gold	bilan_hydrique	Précipitation moins etp_totale. Le SPEI en découle.
Gold	etp_pev_era5	La variable brute cumulée, conservée pour la traçabilité et la comparaison. À ne pas consommer.
Gold, chaîne station	potential_evaporation	La variable brute, propagée telle quelle jusqu'aux chroniques de station. C'est elle qui alimente les modèles métier, et c'est là que se situe l'incohérence exposée en section 4.4.

Conserver les deux colonnes côte à côte a un intérêt qui dépasse la traçabilité : c'est ce qui a rendu la mesure possible. Les valeurs de 818 et 1 756 millimètres par an comparées plus haut sont issues d'une simple requête sur cette table, et non d'un calcul externe. Elle se rejoue telle quelle, à condition que la période sur laquelle la mesure a porté, de 2015 à 2025, soit chargée : la profondeur de la grille climatique est un paramètre d'ingestion, pas une propriété de la table.

A.4 Volumétrie des indicateurs climatiques

Table A.5 – Volumétrie des indicateurs climatiques produits.

Mailles de la grille nationale	11 496
Valeurs d'indices produites	41 960 400
Fenêtres d'agrégation	1, 3, 6 et 12 mois
Période de référence	1991–2020
Échelle de classement	7 classes
Couples maille-mois de la comparaison d'évapotranspiration	30 888
Mailles comparées lors du changement de loi	35 614

A.5 Glossaire

Table A.6 – Glossaire des termes employés dans ce rapport.

Terme	Définition
Architecture médaillon	Organisation d'un entrepôt en couches de qualité croissante : données brutes, données nettoyées, données analytiques
BDLISA	Référentiel hydrogéologique français décrivant les entités aquifères
Contrefactuel	Explication de la forme « quelle modification minimale des entrées changerait la sortie de telle manière »
ETP / ET0	Évapotranspiration potentielle ; évapotranspiration de référence au sens de la FAO-56
Hypertable	Table partitionnée dans le temps, permettant compression et interrogation efficace sur de grands volumes de séries
Idempotence	Propriété d'un traitement dont la réexécution ne modifie pas le résultat
IPS	Indicateur piézométrique standardisé, position du mois courant par rapport à sa normale saisonnière
L-moments	Statistiques d'ordre linéaires servant à ajuster une loi de probabilité, dont τ_3 mesure l'asymétrie
McKee (classes de)	Échelle à sept classes de sévérité associée aux indices standardisés
Modèle TFN	Modèle à fonction de transfert et bruit : le niveau simulé est la somme de convolutions des forçages par des réponses impulsionnelles calibrées
Piézométrie	Mesure du niveau des nappes d'eau souterraine
SPI / STI / SPEI	Indices standardisés de précipitation, de température et de bilan hydrique
SSFI	Indice standardisé de débit, équivalent de l'IPS pour les cours d'eau
STOWA	Standard néerlandais d'évaluation de la qualité des modèles TFN, en quatre critères
Valeurs de Shapley	Méthode d'attribution répartissant la contribution des entrées à une prédiction sur des bases axiomatiques

B Revue des outils retenus

Les trois critères de sélection sont exposés au chapitre 3. Cette annexe en donne l'application, outil par outil, avec ce qui a été écarté dans chaque cas.

B.1 Ingestion : dlt

Interroger une interface web publique paraît trivial jusqu'à ce qu'on le fasse sérieusement. Il faut paginer, réessayer sur erreur serveur avec une temporisation croissante, découvrir le schéma des colonnes, créer les tables, insérer par lots et suivre l'état des chargements. **dlt** [15] prend en charge la seconde moitié de cette liste : on déclare une ressource, la bibliothèque crée et fait évoluer les tables, charge par lots et tient l'historique des chargements.

La première moitié a dû être écrite. Les particularités des interfaces Hub'Eau décrites au chapitre 2, pagination par en-tête de lien, plafonds non documentés, conventions qui changent d'un point d'accès à l'autre, ne se laissent pas absorber par un mécanisme générique. Un client dédié d'environ quatre cents lignes porte donc la pagination, les tentatives successives avec temporisation exponentielle et bruitage, et les garde-fous contre les boucles infinies. C'est un enseignement en soi : l'outil a économisé le travail répétitif de chargement, pas l'adaptation aux caprices de la source.

Deux familles d'alternatives ont été écartées. Tout écrire, chargement et gestion des schémas compris, aurait doublé ce volume sans intérêt propre. Déployer une plateforme d'intégration complète, du type de celles qui s'administrent par interface graphique, aurait imposé un service supplémentaire à maintenir et une configuration hors du dépôt, donc non versionnée, pour quatre sources seulement. **dlt** occupe l'espace intermédiaire : une bibliothèque, dans le code, versionnée avec lui.

B.2 Transformation : dbt

Le choix déterminant est ici de transformer **dans la base** plutôt qu'en mémoire. Avec des centaines de millions de lignes, charger les données dans un tableau Python n'est pas une option, alors que le moteur de base de données sait le faire sur place.

dbt [14] est le standard de fait de cette approche, au point d'avoir donné son nom à un métier, l'*analytics engineering*. Sa maturité et sa diffusion sont précisément ce qu'on recherche pour un socle destiné à durer. Il apporte quatre mécanismes : chaque transformation est un fichier SQL versionné, l'ordre d'exécution se déduit automatiquement des références entre modèles, les tests de qualité se déclarent à côté du modèle qu'ils vérifient, et la documentation se génère. Un bénéfice secondaire compte autant que les autres : les transformations restent lisibles par un hydrogéologue ou un analyste, ce qu'un script Python de plusieurs centaines de lignes n'aurait pas été.

B.3 Orchestration : Dagster

Un ordonnanceur classique raisonne en tâches : exécuter A, puis B, à trois heures du matin. **Dagster** [13] raisonne en *actifs* : on déclare qu'une table doit exister et être à jour, et l'outil détermine ce qu'il faut exécuter pour cela.

La différence est concrète sur cette chaîne. Elle permet de partitionner l'ingestion par année et de rejouer une seule année, de déclencher la transformation quand la donnée arrive plutôt qu'à heure fixe, et de voir d'un coup d'œil quelles tables sont fraîches et lesquelles ne le sont pas. Airflow, l'ordonnanceur historique du domaine, aurait imposé de décrire ces dépendances à la main et de

maintenir un second graphe en parallèle de celui de dbt, alors que l'intégration est ici native. Un simple ordonnanceur système, quant à lui, n'offre ni reprise partielle, ni traçabilité, ni limitation de concurrence, trois besoins dont la suite de ce chapitre montre qu'ils se sont révélés indispensables.

B.4 Stockage : PostgreSQL, TimescaleDB et PostGIS

Le besoin dictait le choix. Ce travail exige simultanément deux capacités : interroger efficacement des séries temporelles longues, et effectuer des jointures spatiales pour rattacher chaque station à sa maille climatique. **PostgreSQL** [34] est le seul moteur courant qui réunisse les deux dans un même produit, grâce à **TimescaleDB** [41] pour le partitionnement temporel et la compression, et à **PostGIS** [33] pour les index et opérateurs géospatiaux. PostGIS est d'ailleurs la référence du géospatial libre, employée bien au-delà du monde de la recherche.

S'y ajoutent trois propriétés qui pesaient lourd dans un contexte de recherche publique : aucun coût de licence, un déploiement sur le serveur du laboratoire donc aucune dépendance à un fournisseur ni facturation à la requête, et une interface SQL que tout le monde sait déjà interroger. Un entrepôt hébergé dans le nuage aurait apporté une élasticité inutile à cette échelle, en échange d'un budget récurrent et d'une adhérence contractuelle. Un stockage en fichiers colonnaires, plus léger, ne fournissait ni les jointures spatiales indexées ni la mise à jour incrémentale dont la chaîne a besoin.

B.5 Synthèse des choix

Table B.1 – Synthèse des outils retenus et des alternatives écartées.

Rôle	Retenu	Écarté, et pourquoi
Ingestion	dlt	Tout écrire, chargement et schémas compris ; plateforme d'intégration administrée (service en plus, configuration hors dépôt)
Transformation	dbt	Scripts Python (ne passent pas à l'échelle, illisibles pour les métiers)
Orchestration	Dagster	Airflow (dépendances à décrire à la main, second graphe à maintenir) ; ordonnanceur système (ni reprise, ni traçabilité)
Stockage	PostgreSQL	Entrepôt hébergé (coût récurrent, adhérence) ; fichiers colonnaires (pas de jointure spatiale indexée)
Séries temporelles	TimescaleDB	Partitionnement manuel (à écrire et à maintenir)
Géospatial	PostGIS	Calculs de distance en Python (lents, non indexés)
Déploiement	Docker Compose	Kubernetes (surdimensionné pour un serveur)

Le même raisonnement a présidé aux choix de la plateforme, présentés aux chapitres 6 et 7 : Pastas est la référence de la communauté hydrogéologique pour les modèles à fonction de transfert, Darts unifie sous une seule interface des architectures de prévision qu'il aurait fallu intégrer une à une, MLflow et Optuna sont les outils les plus répandus pour, respectivement, tracer des expériences et optimiser des hyperparamètres. Dans chaque cas, le critère est le même : un successeur doit pouvoir reprendre le travail sans apprendre un outil que personne n'utilise.

Références

- [1] T. AKIBA, S. SANO, T. YANASE, T. OHTA et M. KOYAMA. “Optuna : a next-generation hyperparameter optimization framework”. In : *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2019, p. 2623-2631.
- [2] R. G. ALLEN, L. S. PEREIRA, D. RAES et M. SMITH. *Crop evapotranspiration : guidelines for computing crop water requirements*. FAO Irrigation and Drainage Paper 56. Rome : Organisation des Nations unies pour l'alimentation et l'agriculture, 1998.
- [3] E. ATES, B. AKSAR, V. J. LEUNG et A. K. COSKUN. “Counterfactual explanations for multivariate time series”. In : *International Conference on Applied Artificial Intelligence (ICAPAI)*. IEEE, 2021, p. 1-8. DOI : [10.1109/ICAPAI49758.2021.9462056](https://doi.org/10.1109/ICAPAI49758.2021.9462056).
- [4] S. BEGUERÍA et S. M. VICENTE-SERRANO. *SPEI : calculation of the standardised precipitation-evapotranspiration index*. Paquet R, fonction `parglo` d'ajustement de la logistique généralisée. 2023. URL : <https://cran.r-project.org/package=SPEI> (visité le 26/08/2026).
- [5] J. BENTO, P. SALEIRO, A. F. CRUZ, M. A. T. FIGUEIREDO et P. BIZARRO. “TimeSHAP : explaining recurrent models through sequence perturbations”. In : *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 2021, p. 2565-2573. DOI : [10.1145/3447548.3467166](https://doi.org/10.1145/3447548.3467166).
- [6] BRGM. *JUNON : des jumeaux numériques au service des ressources naturelles*. Programme scientifique, Bureau de recherches géologiques et minières. 2023. URL : <https://www.brgm.fr/fr/programme-scientifique/junon-jumeaux-numeriques-au-service-ressources-naturelles> (visité le 26/08/2026).
- [7] BRGM. *Lancement du programme JUNON en région Centre-Val de Loire*. Communiqué de presse. 2023. URL : <https://www.brgm.fr/fr/actualite/communiquer-presse/lancement-programme-junon-centre-val-loire> (visité le 26/08/2026).
- [8] BRGM. *EROS : modèle hydrologique global multi-bassins*. Logiciel, Bureau de recherches géologiques et minières. 2026. URL : <https://www.brgm.fr/fr/logiciel/eros-logiciel-modelisation-hydrologique-semi-globale-bassin-versant-decoupe-sous-bassins> (visité le 26/08/2026).
- [9] BRGM. *GARDÉNIA : modèle global à réservoirs pour la simulation des débits et des niveaux de nappe*. Logiciel, Bureau de recherches géologiques et minières. 2026. URL : <https://www.brgm.fr/fr/logiciel/gardenia-logiciel-modelisation-hydrologique-globale-bassin-versant> (visité le 26/08/2026).
- [10] BRGM et SANDRE. *BDLISA : base de données des limites des systèmes aquifères*. Référentiel hydrogéologique français. 2026. URL : <https://bdlisa.eaufrance.fr/> (visité le 26/08/2026).
- [11] R. A. COLLENTUR, M. BAKKER, R. CALJÉ, S. A. KLOP et F. SCHAARS. “Pastas : open source software for the analysis of groundwater time series”. In : *Groundwater* 57.6 (2019), p. 877-885. DOI : [10.1111/gwat.12925](https://doi.org/10.1111/gwat.12925).
- [12] COPERNICUS CLIMATE CHANGE SERVICE. *Climate Data Store : ERA5-Land hourly data from 1950 to present*. Centre européen pour les prévisions météorologiques à moyen terme. 2026. URL : <https://cds.climate.copernicus.eu/> (visité le 26/08/2026).

- [13] DAGSTER LABS. *Dagster : an orchestrator for data assets*. Logiciel, version 1.11. 2026. URL : <https://dagster.io/> (visité le 26/08/2026).
- [14] DBT LABS. *dbt : data build tool*. Logiciel, version 1.7. 2026. URL : <https://www.getdbt.com/> (visité le 26/08/2026).
- [15] DLTHUB. *dlt : data load tool, a Python library for declarative data ingestion*. Logiciel, version 0.4. 2026. URL : <https://dlthub.com/> (visité le 26/08/2026).
- [16] ECMWF. *ERA5-Land : data documentation*. Base de connaissances du Centre européen pour les prévisions météorologiques à moyen terme. Définit l'évaporation potentielle d'ERA5-Land comme une évaporation en nappe d'eau libre, distincte de celle d'ERA5. 2026. URL : <https://confluence.ecmwf.int/display/CKB/ERA5-Land%5C%3A+data+documentation> (visité le 27/08/2026).
- [17] W. FALCON et THE PYTORCH LIGHTNING TEAM. *PyTorch Lightning*. Logiciel. 2019. URL : <https://lightning.ai/> (visité le 26/08/2026).
- [18] G. H. HARGREAVES et Z. A. SAMANI. "Reference crop evapotranspiration from temperature". In : *Applied Engineering in Agriculture* 1.2 (1985), p. 96-99. DOI : [10.13031/2013.26773](https://doi.org/10.13031/2013.26773).
- [19] H. HERSBACH et al. "The ERA5 global reanalysis". In : *Quarterly Journal of the Royal Meteorological Society* 146.730 (2020), p. 1999-2049.
- [20] J. HERZEN et al. "Darts : user-friendly modern machine learning for time series". In : *Journal of Machine Learning Research* 23.124 (2022), p. 1-6.
- [21] J. R. M. HOSKING. "L-moments : analysis and estimation of distributions using linear combinations of order statistics". In : *Journal of the Royal Statistical Society, Series B* 52.1 (1990), p. 105-124. DOI : [10.1111/j.2517-6161.1990.tb01775.x](https://doi.org/10.1111/j.2517-6161.1990.tb01775.x).
- [22] S. HOYER et J. HAMMAN. *xarray : N-D labeled arrays and datasets in Python*. Journal of Open Research Software, 5(1), 10. 2017. URL : <https://xarray.dev/> (visité le 26/08/2026).
- [23] T. KLINKA. *Note sur l'utilisation de l'IPS (Indicateur Piézométrique Standardisé) : Bulletin de Situation Hydrogéologique*. Note technique BRGM/RP-67249-FR. BRGM, nov. 2016. URL : <https://infoterre.brgm.fr/rapports/RP-67249-FR.pdf> (visité le 27/08/2026).
- [24] N. KOKHLIKYAN et al. *Captum : a unified and generic model interpretability library for PyTorch*. 2020. arXiv : [2009.07896](https://arxiv.org/abs/2009.07896). URL : <https://captum.ai/> (visité le 26/08/2026).
- [25] LIFAT. *Projet JUNON (2022-2026), volets DATA, PREDICTION et jumeaux numériques*. Laboratoire d'informatique fondamentale et appliquée de Tours, université de Tours. 2022. URL : <https://lifat.univ-tours.fr/projects/regional/recent/bdtin/2022-2026-junon-project> (visité le 26/08/2026).
- [26] B. LIM, S. Ö. ARIK, N. LOEFF et T. PFISTER. "Temporal fusion transformers for interpretable multi-horizon time series forecasting". In : *International Journal of Forecasting* 37.4 (2021), p. 1748-1764. DOI : [10.1016/j.ijforecast.2021.03.012](https://doi.org/10.1016/j.ijforecast.2021.03.012).
- [27] S. M. LUNDBERG et S.-I. LEE. "A unified approach to interpreting model predictions". In : *Advances in Neural Information Processing Systems* 30. 2017, p. 4765-4774.
- [28] T. B. MCKEE, N. J. DOESKEN et J. KLEIST. "The relationship of drought frequency and duration to time scales". In : *Proceedings of the 8th Conference on Applied Climatology*. Anaheim, Californie, 1993, p. 179-184.

- [29] META OPEN SOURCE. *React 19 : a JavaScript library for building user interfaces*. Logiciel. 2026. URL : <https://react.dev/> (visité le 26/08/2026).
- [30] MÉTÉO-FRANCE. *SAFRAN : système d'analyse atmosphérique à méso-échelle sur la France*. Réanalyse météorologique sous licence, non redistribuable. 2026.
- [31] J. MUÑOZ-SABATER et al. "ERA5-Land : a state-of-the-art global reanalysis dataset for land applications". In : *Earth System Science Data* 13.9 (2021), p. 4349-4383.
- [32] OFFICE FRANÇAIS DE LA BIODIVERSITÉ. *Hub'Eau : les API du système d'information sur l'eau*. Services web *niveaux_nappes* et *hydrometrie*. 2026. URL : <https://hubeau.eaufrance.fr/> (visité le 26/08/2026).
- [33] POSTGIS PROJECT. *PostGIS : spatial and geographic objects for PostgreSQL*. Logiciel. 2026. URL : <https://postgis.net/> (visité le 26/08/2026).
- [34] POSTGRESQL GLOBAL DEVELOPMENT GROUP. *PostgreSQL 16*. Système de gestion de base de données relationnelle. 2026. URL : <https://www.postgresql.org/> (visité le 26/08/2026).
- [35] S. RAMÍREZ. *FastAPI : a modern, fast web framework for building APIs with Python*. Logiciel. 2026. URL : <https://fastapi.tiangolo.com/> (visité le 26/08/2026).
- [36] N. RINGUET. *hubeau_data_integration : entrepôt de données hydro-climatiques*. Dépôt logiciel public, licence MIT. 2026. URL : https://github.com/xairon/hubeau_data_integration (visité le 26/08/2026).
- [37] N. RINGUET. *time-serie-explo : plateforme d'exploration, de modélisation et de prévision piézométrique*. Dépôt logiciel public, licence MIT. 2026. URL : <https://github.com/xairon/time-serie-explo> (visité le 26/08/2026).
- [38] J.-J. SEGUIN. *Proposition d'un indicateur piézométrique standardisé pour le Bulletin de Situation Hydrologique « Nappes »*. Rapport final BRGM/RP-64147-FR. Étude réalisée dans le cadre de la convention ONEMA-BRGM. BRGM, juin 2015. URL : <http://infoterre.brgm.fr/rapports/RP-64147-FR.pdf> (visité le 27/08/2026).
- [39] J.-J. SEGUIN et T. KLINKA. *Index Piézométrique Standardisé (IPS) : bilans et comparaisons avec l'indicateur du BSH*. Note technique BRGM/RP-67251-FR. BRGM, nov. 2016. URL : <http://infoterre.brgm.fr/rapports/RP-67251-FR.pdf> (visité le 27/08/2026).
- [40] M. SUNDARARAJAN, A. TALY et Q. YAN. "Axiomatic attribution for deep networks". In : *Proceedings of the 34th International Conference on Machine Learning*. 2017, p. 3319-3328.
- [41] TIMESCALE. *TimescaleDB : time-series extension for PostgreSQL*. Logiciel. 2026. URL : <https://www.tigerdata.com/> (visité le 26/08/2026).
- [42] S. M. VICENTE-SERRANO, S. BEGUERÍA et J. I. LÓPEZ-MORENO. "A multiscalar drought index sensitive to global warming : the standardized precipitation evapotranspiration index". In : *Journal of Climate* 23.7 (2010), p. 1696-1718.
- [43] J. VON ASMUTH et al. *Handleiding tijdreeksanalyse*. Rapp. tech. 2021-32. Manuel de référence de l'analyse de séries temporelles pour la gestion des eaux souterraines, et critères d'acceptation des modèles. Amersfoort, Pays-Bas : Stichting Toegepast Onderzoek Waterbeheer (STOWA), 2021.
- [44] S. WACHTER, B. MITTELSTADT et C. RUSSELL. "Counterfactual explanations without opening the black box : automated decisions and the GDPR". In : *Harvard Journal of Law and Technology* 31.2 (2018), p. 841-887.

- [45] Z. WANG, I. MILIOU, I. SAMSTEN et P. PAPAPETROU. “Counterfactual explanations for time series forecasting”. In : *IEEE International Conference on Data Mining (ICDM)*. 2023, p. 1391-1396.
- [46] M. ZAHARIA et al. “Accelerating the machine learning lifecycle with MLflow”. In : *IEEE Data Engineering Bulletin* 41.4 (2018), p. 39-45.