



Un socle de données et une plateforme d'expérimentation

Pour la prévision explicable des niveaux de nappe

Nicolas Ringuet

LIFAT, université de Tours

Projet PRÉDICTION, ARD CVL JUNON

28 août 2026

Avec le soutien de la Région Centre-Val de Loire



Le sujet, et pourquoi il a fallu commencer ailleurs

Le sujet assigné portait sur l'**explicabilité des modèles de prévision** appliqués aux nappes. La motivation est opérationnelle : une prévision qu'on ne sait pas justifier ne sera pas retenue à l'appui d'un arrêté de restriction d'usage.

Il s'est heurté à un obstacle matériel. La donnée hydrologique française est publique, mais éparpillée entre des services qui s'ignorent.

On n'explique pas un modèle qu'on n'a pas pu entraîner.

Construire le socle est devenu le premier travail. Ce qui suit décrit ce qu'il permet, et ce qu'il n'établit pas.

QT1 Un entrepôt unifiant les sources ouvertes du jumeau numérique.

QT2 Une plateforme pour constituer des jeux, entraîner, comparer et expliquer.

QR1 Les méthodes d'attribution sont-elles exploitables par un expert du domaine ?

QR2 Les contrefactuels produisent-ils des scénarios pertinents ?

Quatre obstacles entre la donnée publique et l'apprentissage

1. Aucune jointure entre les compartiments

Niveaux, débits et climat sont publiés par des services sans clé commune. Rien ne rattache un piézomètre à la maille climatique qui le force, alors que c'est exactement ce couple que consomme un modèle multivarié.

2. Un historique non consolidé

1967 pour les chroniques, 1950 pour le climat, et aucun service ne les consolide.

Sources : Hub'Eau (piézométrie, hydrométrie), Copernicus ERA5-Land (climat), BDLISA (référentiel hydrogéologique).

3. Des conventions de lecture hétérogènes

Flux cumulés et grandeurs instantanées d'une réanalyse ne s'agrègent pas de la même façon. Une lecture naïve produit des séries fausses sans qu'aucune erreur ne soit signalée.


4. Aucun indicateur normalisé

Un niveau de 12,4 m n'est ni haut ni bas dans l'absolu. Il l'est relativement à ce que l'ouvrage observe habituellement à cette période.

L'entrepôt : trois couches, une garantie par couche

hubeau_data_integration ■ *PostgreSQL, TimescaleDB, PostGIS*

Hub'Eau ■ *ERA5-Land* ■ *BDLISA*



Ne jamais perdre la donnée reçue

La couche brute n'interprète rien. Toute décision appartient aux couches suivantes, où elle est lisible et rejouable. C'est la condition pour qu'une expérience soit reproductible.


Rendre le filtrage vérifiable

Les lignes écartées sont écrites à part avec le motif de leur exclusion : une station absente d'un jeu se distingue par une requête d'une station éliminée par un critère trop strict. Le schéma des tables finales est le seul contrat que connaît un consommateur.

658 M lignes brutes ■ 8 traitements planifiés
■ 3 capteurs

L'ingestion est planifiée, la transformation déclenchée par événement.

Le cœur de l'entrepôt : rattacher chaque station à son climat



grille 0,1°, PostGIS, plus proche voisin

Effectuée une fois, matérialisée : le niveau et son forçage figurent ensuite sur la même ligne, au même jour.

Deux précautions, dont une invisible

L'emprise s'arrête à la métropole : les stations ultramarines sont ingérées **sans forçage climatique**, et doivent être écartées.

Le piège des coordonnées

Une même maille écrite 48,1° d'un côté et 48,099 999 999 999 95 de l'autre fait deux points distincts : la grille se dédouble sans que rien ne le signale. Les coordonnées sont arrondies au pas natif partout où elles servent de clé, et un test garde l'invariant.

Enrichissement hydrogéologique

Les entités BDLISA rattachées aux stations donnent la nature de l'aquifère. Le référentiel ne porte pas la profondeur : c'est une indication, pas une certitude.

Des mesures aux indicateurs comparables

Par station : l'indicateur piézométrique standardisé

La méthode n'a pas été inventée ici : elle reprend celle que le BRGM a proposée pour le Bulletin de situation hydrologique. Caractère mensuel, minimum de quinze années par mois et sept classes sont repris tels quels.

Reprendre une méthode publiée plutôt qu'en définir une ajustée à nos données est un choix de **comparabilité** : les valeurs restent lisibles par les équipes qui diffusent déjà cet indicateur.

Écart assumé : référence 1991–2020 au lieu de 1981–2010, pour s'aligner sur la normale de l'OMM et sur la chaîne climatique.

Sur grille : trois indices, quatre fenêtres

Pour chaque maille de $0,1^\circ$, sur 1, 3, 6 et 12 mois, correspondant à des inerties différentes du système hydrologique.

Indice	Grandeur	Loi
SPI	Précipitation	Gamma
STI	Température	Normale
SPEI	P moins ETP	Logistique généralisée

La loi de l'article fondateur du SPEI ne s'ajustait que sur 74,6 % du domaine, pour une raison structurelle : elle ne représente qu'un sens d'asymétrie. La loi de l'implémentation de référence porte la couverture à 100 %.

Un arbitrage qui décidait de la justesse de tout l'aval

Le calcul était juste, le code sans faute, la grandeur employée ne l'était pas

ERA5-Land publie une variable nommée « évaporation potentielle ». La documentation du produit en fait une **évaporation en nappe d'eau libre**, du type mesuré sur un bac. Le bilan hydrique a besoin d'autre chose : l'évapotranspiration de référence de la FAO, celle d'un gazon ras bien alimenté en eau.

L'écart s'explique physiquement. Une nappe d'eau n'oppose aucune résistance de surface au passage de la vapeur et réfléchit peu le rayonnement ; un couvert végétal ferme ses stomates et renvoie près du quart de l'énergie reçue.

Variable brute ERA5-Land	1 756 mm an ⁻¹
Référence FAO, calculée	818 mm an ⁻¹
Rapport	× 2,15

La première place **l'intégralité du territoire en déficit hydrique permanent**, années pluvieuses comprises, ce qui est physiquement faux. La seconde est dans l'intervalle des références publiées pour la France.

Seule la confrontation aux ordres de grandeur connus pouvait le révéler. Aucun test logiciel ne détecte ce genre de défaut.

Les indicateurs produits sont vérifiés, contre un critère fixé d'avance

Un indice standardisé doit, par construction, suivre approximativement une loi normale centrée réduite *sur sa propre période de référence*. C'est une propriété vérifiable.

Le critère d'acceptation a été fixé **avant** la mesure : moyenne à $\pm 0,05$, écart-type à $\pm 0,05$, saturation aux bornes sous 1 %. Fixer le seuil avant de mesurer évite de l'ajuster au résultat obtenu.

Indice	Moyenne	Écart-type	Saturation
SPI	-0,008 à 0,002	0,985 à 1,031	0,05 à 0,51 %
STI	0,000	0,983	0,00 à 0,04 %
SPEI	0,004 à 0,006	0,999 à 1,013	0,012 à 0,035 %

41 960 400 valeurs, 11 496 mailles, quatre fenêtres. Critère satisfait partout.

Un signal, pas un artefact

La moyenne du SPEI sur un mois décroît de décennie en décennie :

Années 1990	+0,038
Années 2000	+0,007
Années 2010	-0,016
Depuis 2020	-0,117

Cette évolution avait été **anticipée avant d'être mesurée**, ce qui la distingue d'une dérive de méthode. Elle traduit un assèchement.


L'indicateur tel qu'il sort de l'entrepôt



Dix ans d'indice piézométrique standardisé sur un ouvrage, en pas mensuel, rangé dans les sept classes de la méthode du BRGM. La mesure brute ne disait rien ; l'indice situe chaque mois par rapport à la distribution propre de la station. On y lit un déficit qui s'installe de fin 2018 à 2024, puis l'épisode de recharge de 2024 qui atteint la classe extrême haute. C'est cette grandeur, et non le niveau brut, dans laquelle une cible contrefactuelle peut s'énoncer.

La plateforme : une architecture qui survit à son interface

time-serie-explo ■ *React, FastAPI, bibliothèque métier Python*



La contrainte structurante


La bibliothèque métier **ne dépend ni du service applicatif ni de l'interface web**.

Pourquoi c'est déterminant

Préparation des données, calibration, entraînement, attribution et contrefactuels s'exécutent indifféremment depuis le service web, depuis un script ou depuis un carnet de calcul. Les méthodes développées ne sont pas prisonnières de l'application : si l'interface était abandonnée, elles resteraient utilisables.

Trois environnements séparés, production, calcul sur processeur graphique et développement, avec leurs propres volumes et bases.

L'Observatoire : la couverture nationale, animée




Nappes et rivières de 2000 à 2026,
saison par saison.

Chaque pastille porte le nombre de stations de son groupe et la couleur de leur classe de situation.

Le compteur du bas donne l'assiette réelle : 2 610 piézomètres classés sur 22 407 recensés, 2 170 stations hydrométriques sur 6 253. Les stations non classées le sont faute d'historique suffisant, et cela se voit.

Situer une station, avant de la modéliser



Deux publics

Les **hydrogéologues** situent une station dans son contexte : quelle nappe, comment elle se comporte face à ses voisines. Les **modélisateurs** repèrent les chroniques trop courtes ou perturbées par un pompage, avant d'entraîner.

Une règle de conception

*Soit un indicateur standardisé, soit
une valeur réelle affichée comme telle.
Jamais un intermédiaire inventé.*

Épieds-en-Beauce : indicateur 0,41, classe « normal », 112,01 contre 112,10 habituellement en août sur la référence 1991–2020, 12 050 mesures sur soixante ans, et les quinze stations de la même entité BDLISA avec leur classe.

Croiser le niveau et le climat, sur la même page



Le contexte climatique de la station : SPI sur trois mois depuis dix ans, coloré par classe, et les cumuls glissants comparés à la normale 1991–2020. Ici -41 % sur trois mois.



La comparaison interannuelle : cinq années superposées mois par mois. C'est ce geste, fait à la main sur plusieurs sources, que l'Observatoire remplace par une sélection.

Le laboratoire de modèles métier : construire la référence

Sans référence, une performance ne signifie rien


Ce que le modèle apporte

Le niveau simulé est la somme de contributions obtenues par convolution du forçage avec une **fonction de réponse impulsionnelle** calibrée. Cette fonction est l'objet d'intérêt hydrogéologique : sa forme dit comment l'aquifère amortit et retarde le signal climatique, son intégrale de combien le niveau varie pour une sollicitation donnée. Ce ne sont pas des paramètres opaques, ce sont des grandeurs qui s'interprètent, et qui sortent de la calibration avec leur erreur type.

PARAMÈTRES DU MODÈLE		
Nom	Optimal	Erreur-type
recharge_A	1.633165	0.041378
recharge_n	0.844127	0.013584
recharge_a	146.982374	7.224866
recharge_f	-0.924230	0.028925
linear_trend_a	-0.000133	0.000006

recharge_A est le gain, recharge_a le temps caractéristique en jours, recharge_n la forme de la réponse Gamma, recharge_f le coefficient d'évapotranspiration. Quatre modèles de recharge, cinq formes de réponse, deux modèles de bruit et deux solveurs sont combinables.

Calibrer, puis valider sur une période réservée



	NSE	KGE	EVP	RMSE
Calibration 1994–2017	0,754	0,800	75,5 %	1,119
Validation 2017–2026	0,765	0,892	79,5 %	1,161


La validation ne se dégrade pas : la structure n'a pas absorbé le bruit de la période de calibration. Le trait vertical marque la bascule entre les deux périodes.

Une station, non un résultat d'évaluation.

Diagnostiquer : ce que le modèle ne capte pas



Les résidus, contre six tests dont le verdict est affiché en clair. Ici quatre échouent : l'ajustement est bon, la structure résiduelle ne l'est pas. C'est le point de départ de l'enrichissement du modèle, non un rejet.



Un modèle peut être juste en moyenne et faux sur la dynamique

Les signatures hydrologiques comparent l'observé (bleu) au simulé (orange) sur des grandeurs que l'hydrogéologue reconnaît : saisonnalité de Pardé, amplitude saisonnière, vitesses de montée et de descente, constantes de tarissement et de récupération.

Vingt-neuf signatures sont calculées, avec le rapport simulé sur observé pour chacune.

Comparer les structures plutôt qu'en choisir une

Résultats de la calibration automatique					
8 configurations testées en 31,2 s					
Configuration	NSE	RMSE	KGE	STOWA	Temps
✓ Linear / Gamma	0,589	0,4744	0,717	Partiel	3,3 s
Linear / Gamma / ArNoiseModel	0,528	0,5085	0,639	Partiel	8,0 s
Linear / Gamma / ArNoiseModel	0,523	0,5113	0,588	Partiel	5,6 s
Linear / Exponential	0,491	0,5281	0,590	Partiel	2,0 s
Linear / Gamma	0,483	0,5325	0,787	Partiel	4,0 s
Linear / Exponential / ArNoiseModel	0,391	0,5777	0,444	Partiel	3,9 s
Linear / Exponential	0,310	0,6151	0,375	Partiel	1,6 s
Linear / Exponential / ArNoiseModel	0,017	0,7340	-0,151	Partiel	2,7 s

Huit configurations calibrées en 31,2 s sur une station, sur la période de calibration. Le verdict STOWA occupe sa propre colonne parce qu'il ne se déduit pas de l'erreur : son troisième critère écarte les modèles dont la mémoire excède la période observée, et ici aucune configuration ne le satisfait entièrement alors que la meilleure atteint un NSE de 0,589. Les modèles calés restent en galerie, de sorte que la comparaison se relit sans être refaite.

L'apport hydrogéologique inscrit dans le code

Une connaissance qui ne s'obtient pas par validation croisée

Famille	Réponse	Justification
Alluvial	Exponentielle	Réponse rapide, système simple
Sédimentaire poreux	Gamma	Réponse intermédiaire
Craie, double porosité	Gamma	Forte inertie
Sédimentaire fracturé	Gamma	Recharge complexe
Karstique	Double exp.	Deux temps : conduits et matrice
Socle, montagne	Gamma	Recharge non linéaire
Volcanique	Gamma	Système hétérogène
Composite	4 paramètres	Milieu hétérogène

Le cas karstique

Un karst se comporte comme deux réservoirs couplés : des conduits qui réagissent en heures, une matrice qui réagit en mois. Une réponse à un seul temps caractéristique ne peut pas représenter cette dualité.

Ces configurations amorcent la recherche, elles ne la contraignent pas : une grille de référence est évaluée en parallèle, de sorte qu'une station atypique n'est jamais enfermée dans la recommandation de sa famille.

Le laboratoire d'apprentissage : rendre les comparaisons possibles

Un catalogue sous interface unique


Douze architectures : attention (*temporal fusion transformer*), décomposition par blocs (N-BEATS, N-HiTS), récurrentes, convolutives, et récentes à faible coût (TiDE, DLinear). Les modèles linéaires sont des références exigeantes : une architecture lourde qui ne les dépasse pas doit être écartée, et les avoir dans le même outil évite la comparaison biaisée par des conditions expérimentales différentes.

The screenshot displays the ARD JUNON platform interface with the following details:

- Modèle:** NHITS · 04312X0039/F · multivarié (MAE=0.8844)
- JEU DE DONNÉES:** Plage de test: 01/08/2021 — 09/05/2026
- MODÈLE:** Type: single, Entrée: 365 jours, Horizon: 30 jours
- Configuration:** single, Jun 04, 2026
- Station(s):** 04312X0039/F
- Jeu de données:** 04312X0039_F_20260604_142131
- Variables:** niveau_nappe_eau + temperature_2m, total_precipitation, potential_evaporation
- Métriques:** MAE: 0.8844, RMSE: 1.1441, sMAPE: 0.8409, WAPE: 0.8373
- Hyperparamètres:** (10)


Chaque exécution est enregistrée avec ses paramètres et ses métriques : architecture, jeu de données horodaté et sa période, covariables retenues, fenêtre d'entrée et horizon. Sans cela, comparer deux expériences séparées de quelques semaines n'est pas défendable.

Prévoir : une fenêtre glissante sur la période réservée



Le jeu de test entier, de 2021 à 2026, que le modèle n'a jamais vu. La zone claire est la fenêtre d'entrée, 365 jours de contexte ; la bande ocre est l'horizon de prévision, 30 jours. Les deux se déplacent ensemble sur toute la période, ce qui évite de conclure d'une fenêtre unique et bien choisie.


Lire ce que vaut une prévision



La fenêtre de près, prévision contre observations. L'erreur absolue moyenne vaut 0,045 m et le biais 0,027 m sur trente points, mais c'est la dernière ligne qui se commente : 7,8 % de l'écart interquartile de la série. Une erreur en mètres ne veut rien dire tant qu'elle n'est pas rapportée à l'amplitude de l'ouvrage. Une fenêtre sur une station, non un résultat d'évaluation : aucune campagne comparative n'a été conduite.

Expliquer : sur quoi le modèle s'appuie

Cinq familles réunies pour être confrontées, non pour l'exhaustivité



Des méthodes reposant sur des principes différents et qui convergent donnent une explication crédible ; leur divergence signale une explication fragile, information qu'une méthode unique aurait masquée.

Quatre des cinq familles sont atteignables depuis l'interface. Les poids d'attention (en grisé) existent en bibliothèque et en API, mais aucun composant de l'interface ne les sollicite.

Expliquer : que se passerait-il dans d'autres conditions

Le contrefactuel doit rester physiquement possible, sinon il ne vaut rien

Le problème

Modifier librement les entrées jusqu'à atteindre la cible produit des scénarios corrects au sens de l'optimisation et **physiquement absurdes** : de l'air réchauffé sans évaporation supplémentaire, une saison qui n'existe nulle part.

Pourquoi une pénalité ne suffit pas

Un expert rejette un scénario qui viole un peu les relations physiques aussi sûrement qu'un scénario qui les viole beaucoup. Ce n'est pas une grandeur continue pour lui, c'est un test de recevabilité.

Deux réponses de natures différentes

PhysCF, conçue au cours de ces travaux, change d'espace de recherche : sept paramètres de régime climatique, l'évapotranspiration étant calculée depuis la température. Plausibilité garantie *par construction*.

CoMTE cherche dans l'historique une période réellement observée. Plausibilité garantie *par la provenance*.

Une réponse énonçable

« Il aurait fallu des hivers un cinquième plus humides et un climat plus frais d'un degré. »

Chaque scénario est rejoué dans un modèle métier indépendant, et rejeté s'il fait trop diverger les deux.

Un scénario prospectif en pratique

Scénarios rapides (Sédimentaire (poreux))

Forage d'eau potable
Pompage constant à 200 m³/j

Sécheresse estivale
-30 % de précipitations juin-septembre

Irrigation saisonnière
Pompage agricole 200 m³/j (avril-septembre)

Sécheresse prolongée
-20 % de précipitations + +10 % d'ETP

Pompage industriel
Pompage constant à 100 m³/j

Tendance climatique
-3 cm/an de baisse + +5 % d'ETP

Les scénarios préconfigurés, dont les débits sont proposés d'après la famille d'aquifère de la station : forage d'eau potable, irrigation saisonnière, pompage industriel, sécheresses, tendance climatique.

Un stress, pas une entrée libre

Le scénario se construit sur des *stress* physiques et une fonction de réponse calibrée, plutôt que par perturbation libre des entrées.

Des bornes dérivées du modèle

« Quel débit est plausible ici ? » n'a pas de réponse universelle. La plage proposée, 30 à 400 m³/j pour cet ouvrage, est estimée depuis la réponse indicielle du modèle lui-même.

Deux travaux personnels menés en marge

Deux questions que la plateforme posait sans pouvoir y répondre

physcf : évaluer la méthode hors de l'application

La plateforme mêle l'instrument et le cas. Un prototype séparé isole PhysCF sur quatre stations couvrant le gradient réactif vers inertiel, avec sa méthode de référence et ses mesures.

Cadre, opérateurs, optimisation et validation croisée acquis. Protocole d'évaluation écrit.

La campagne n'a pas été conduite, et corriger le forçage d'évapotranspiration la précède.

Apache 2.0, sur github.com/xairon :
physcf et aida_embedding_benchmark

aida_embedding_benchmark : que retient-on d'une chronique ?

Sept encodeurs, 5 116 stations, validation croisée par département. Vingt-neuf descripteurs métier devancent l'apprentissage contrastif sur le seul niveau.

Le résultat qui engage la plateforme

Ajouter les covariables climatiques brutes améliore la classification, et pour la mauvaise raison :

Gain de précision équilibrée	0,059 à 0,146
Gain de R^2 sur la latitude	0,488 à 0,633

Deux stations voisines partagent leur maille : le forçage inscrit de la géographie dans la représentation. Mesuré au quart de degré, l'entrepôt produit au dixième.

Ce qui est acquis, ce qui ne l'est pas, par quoi commencer

Acquis

- entrepôt national reprenable, indicateurs validés contre un critère fixé d'avance ;
- plateforme traçable, cœur réutilisable hors de l'application ;
- référence métier interprétable, paramétrée par famille d'aquifère ;
- deux méthodes contrefactuelles contraintes, vérifiables contre un modèle indépendant.

Non établi

- aucun classement des architectures de prévision : les campagnes ont validé le dispositif, pas comparé les méthodes ;
- aucune évaluation des contrefactuels : le protocole est écrit, la campagne reste à conduire ;
- la page qui pilote les contrefactuels n'est pas branchée dans l'interface ;

Par quoi commencer

1. aligner le forçage d'évapotranspiration de la chaîne station : il conditionne toute interprétation physique ;
2. brancher la route de l'interface contrefactuelle ;
3. exécuter la campagne comparative, stratifiée par famille d'aquifère ;
4. adapter les configurations d'apprentissage par famille d'aquifère.

Sujets ouverts avec le BRGM :
nappe-rivière, double porosité,
nappes captives.