

ARD JUNON - Prédiction

ST3.2 Explicabilité et interprétabilité dans les modèles prédictifs
profonds de séries temporelles

N. Labroche, N. Ringuet, E. Doumard, M. Gol Pour

LIFAT

Université de Tours

`nicolas.labroche@univ-tours.fr`

27 août 2026

Résumé

Résumé — L'intégration de modèles d'intelligence artificielle dans le cadre du projet JUNON et le développement de jumeaux numériques en hydrogéologie soulèvent la question fondamentale de leur fiabilité. Au-delà des métriques de performance classiques, il est crucial de garantir que les prédictions s'appuient sur des facteurs physiques cohérents. Ce travail explore l'apport des méthodes d'explicabilité (XAI) pour répondre à cet enjeu à travers deux axes de recherche principaux. D'une part, nous étudions l'adaptation des approches d'attribution de caractéristiques aux séries temporelles multivariées afin de permettre aux experts d'évaluer la qualité décisionnelle des modèles. D'autre part, nous évaluons l'apport des explications contrefactuelles pour simuler des scénarios d'action (comme l'impact de la variation

des précipitations sur les niveaux piézométriques) et analyser la faisabilité des scénarios générés. Pour soutenir ces travaux, un environnement applicatif complet a été développé. Il intègre un entrepôt unifié agrégeant diverses données ouvertes (météo, Hub'Eau, piézométrie) et une plateforme web interactive. Cet outil permet la constitution de jeux de données, l'exécution et la comparaison de modèles prédictifs et mécanistiques, ainsi que l'extraction d'explications, posant ainsi les bases des développements futurs menés entre le BRGM et le LIFAT.

Mots-clés : Intelligence Artificielle Explicable (XAI), Jumeau Numérique, Hydrogéologie, Séries Temporelles Multivariées, Explications Contrefactuelles, Attribution de Caractéristiques.

Table des matières

1	Introduction et Contexte	5
1.1	Problématique	5
1.2	Objectifs	5
2	Développements techniques et environnement applicatif	8
2.1	Le verrou levé : une donnée ouverte mais non exploitable en l'état	8
2.2	QT1 : un entrepôt de données hydro-climatiques unifié	9
2.2.1	Architecture en trois couches	9
2.2.2	Le rattachement climatique	10
2.2.3	Des mesures aux indicateurs normalisés	11
2.2.4	Deux arbitrages méthodologiques	12
2.2.5	Garanties d'exploitation et reproductibilité	13
2.3	QT2 : une plateforme d'exploration, de modélisation et d'explication	14
2.3.1	Une contrainte d'architecture posée d'emblée	14
2.3.2	L'Observatoire : explorer avant de modéliser	14
2.3.3	Le laboratoire de modèles mécanistiques : construire la référence	15
2.3.4	Le laboratoire d'apprentissage profond	17
2.3.5	Les modules d'explication	18
2.4	État de mise à disposition	20
3	État de l'Art	21
3.1	Explicabilité pour la prédiction de séries temporelles	21
3.2	Explications contrefactuelles pour la prédiction	22
3.3	Méthodes contrefactuelles connexes et inférence causale	22
3.4	Synthèse et positionnement	23
3.5	Positionnement du cas hydrogéologique	23
4	Méthodologie et Approche Proposée	25
4.1	Architecture du dispositif d'évaluation	25
4.2	Spécification de la cible contrefactuelle	26
4.3	Dimensions d'évaluation retenues	26
4.4	Protocole expérimental	28
4.5	Ce que le protocole ne tranche pas	29
5	Résultats et Analyse	30
5.1	Validation du socle de données	30
5.2	Une incohérence de forçage qui limite l'interprétation du référent	31
5.3	État de l'outillage au regard des deux questions de recherche	31
5.4	Ce qui n'est pas établi	32

5.5 Analyse	33
6 Conclusion et Perspectives	34
Références	37

1 Introduction et Contexte

1.1 Problématique

L'ARD JUNON vise à développer un Pôle de recherche et d'excellence sur l'utilisation de l'Intelligence Artificielle dans les problématiques environnementales en région Centre Val de Loire. Ce projet fondateur s'intéresse notamment à la création de Jumeaux Numériques de Plaine qui augmenteront les capacités de suivi et de prédiction des ressources naturelles régionales. A cette fin, JUNON focalise notamment son attention sur l'eau (quantité et qualité) ainsi que sur les flux de gaz et la qualité de l'air à l'interface des sols, considérant ces deux ressources (Eau et Air) comme prioritaires pour les populations et acteurs économiques locaux [32].

Plus précisément, notre contribution se place dans le cadre du projet **Prédiction** qui vise la mise en place de nouveaux modèles d'IA prédictives multi-sources et explicables pour l'analyse et le suivi des données environnementales. On vise en particulier à répondre à la tâche 4 des Jumeaux Numériques en se concentrant en priorité sur la prédiction quantitative du niveau de l'eau dans la Plaine et notamment la prédiction des variations du niveau des nappes phréatiques.

Au sein de ce projet Prédiction, ce rapport présente le travail réalisé dans la tâche 3.2 intitulée : “*Explicabilité et interprétabilité dans les modèles prédictifs profonds de séries temporelles*”. C'est un travail effectué en commun entre le LIFAT : N. Labroche, N. Ringuet, E. Doumard, M. Gol Pour et le BRGM : H. Breuillard.

1.2 Objectifs

Dans le cadre du projet JUNON, l'usage de modèles d'intelligence artificielle soulève plusieurs questions fondamentales. En premier lieu, il convient d'évaluer la précision prédictive de ces modèles complexes en comparaison des approches mécanistiques traditionnelles. En second lieu, il est essentiel de vérifier si leurs décisions s'appuient sur des critères physiquement cohérents du point de vue hydrogéologique. Dès lors que cette pertinence est établie, ces critères peuvent-ils être exploités pour simuler différents scénarios d'évolution et ainsi jouer pleinement le rôle d'un jumeau numérique ? Notre hypothèse repose sur l'apport de l'explicabilité de l'IA (*eXplainable Artificial Intelligence* – XAI) [38, 43] pour répondre à ces enjeux.

À ce titre, nous formalisons deux questions de recherche principales.

Attribution de caractéristiques (*Feature Attribution*) – Les approches par attribution de caractéristiques, adaptées aux séries temporelles [56, 47], permettent d'identifier les variables et fenêtres temporelles contribuant le plus fortement à la prédiction du modèle. Des évolutions récentes comme TSHAP [45] ou Vector-SHAP [10] cherchent précisément à passer à l'échelle sur ces structures de données complexes.

Question de Recherche 1 (QR1) *Dans notre contexte, ces méthodes d’attribution de caractéristiques sont-elles adaptées au traitement de séries temporelles multivariées ? Est-il possible de les coupler à des interfaces de visualisation interactive afin d’offrir aux experts du domaine un moyen efficace de contrôler la qualité décisionnelle des modèles, au-delà des seuls indicateurs de performance prédictive usuels ?*

Explications contrefactuelles – Les explications contrefactuelles [9, 21, 40] indiquent les modifications minimales nécessaires sur les données d’entrée pour infléchir la décision du modèle. Appliquées aux séries temporelles, ces approches permettent d’évaluer la pertinence de scénarios prédictifs [67, 15, 30]. Elles s’inscrivent directement dans la philosophie d’un jumeau numérique, par exemple en simulant l’impact d’une modification des régimes de précipitation sur le niveau piézométrique prédit d’un bassin.

Question de Recherche 2 (QR2) *Les différentes approches contrefactuelles pour séries temporelles produisent-elles toutes des explications pertinentes pour notre cas d’usage ? Selon quelles dimensions (faisabilité, plausibilité, métriques quantitatives) convient-il d’évaluer la qualité des contrefactuels générés, et existe-t-il une méthode optimale pour le cadre applicatif d’un jumeau numérique ?*

Développements techniques et environnement applicatif

Afin de soutenir ces travaux de recherche sur l’explicabilité appliquée aux séries temporelles multivariées [48, 29], nous avons développé au préalable un environnement de mise en œuvre synthétisant plusieurs enjeux du projet JUNON. La plateforme logicielle produite intègre un ensemble de fonctionnalités socles destinées à appuyer ces recherches ainsi que leurs développements futurs. Elle répond notamment aux deux verrous techniques suivants :

Question Technique 1 (QT1) Concevoir et déployer un entrepôt de données unifié synthétisant l’ensemble des sources de données ouvertes nécessaires au Jumeau Numérique (données météorologiques, API Hub’Eau, réseaux de mesure piézométrique et bases de données géoréférencées).

Question Technique 2 (QT2) Développer une application Web interactive facilitant la constitution de jeux de données, l’exécution de modèles prédictifs de l’état de l’art, et la visualisation des prédictions. L’outil permet également d’identifier les fenêtres temporelles et variables critiques (QR1), d’intégrer des modèles mécanistiques de référence (tels que *Pastas*) pour étalonner les modèles d’IA, et enfin d’exécuter des modules d’explications (QR2).

Remarque : L'intégration complète des composants avancés liés à la question QR2 constitue un travail en cours, dont le déploiement se poursuivra dans le cadre des partenariats à venir entre le BRGM et le LIFAT (notamment au travers du projet ANR AIDA).

Ce rapport se compose de plusieurs sections. La section 2 détaille le travail de préparation des données au sein d'un nouvel entrepôt de données et présente les différents modules applicatifs développés pour former l'ossature de notre plateforme d'évaluation. La section 3 présente les principaux modèles d'explications utilisés dans notre plateforme en mettant plus particulièrement l'accent sur les méthodes contrefactuelles existantes pour la prédiction de séries temporelles multivariées. La section 4 formalise le protocole selon lequel ces méthodes doivent être comparées sur le cas hydrogéologique : le choix du modèle à expliquer, la spécification de la cible contrefactuelle, les dimensions d'évaluation retenues et le traitement statistique des classements. La section 5 rend compte de l'état d'avancement de cette évaluation : elle établit ce que la plateforme permet aujourd'hui de mesurer, expose les résultats de validation déjà obtenus sur les briques dont dépend le protocole, et délimite explicitement ce qui n'est pas encore établi, la comparaison quantitative des familles de contrefactuels restant à conduire. Enfin, la section 6 propose une conclusion de l'ensemble de ce travail et présente des pistes de poursuites de collaboration autour d'une sélection de questions de recherche.

2 Développements techniques et environnement applicatif

Les deux questions de recherche posées en section 1 supposent un préalable qui n'était pas disponible au démarrage de la tâche : un jeu de données hydro-climatique consolidé, des modèles entraînés dessus, et une référence mécanistique pour les étalonner. On n'explique pas un modèle qu'on n'a pas pu entraîner, et on ne compare pas deux explications produites sur deux préparations de données différentes. Cette section décrit le socle construit pour lever ce préalable, en réponse aux questions techniques QT1 et QT2.

2.1 Le verrou levé : une donnée ouverte mais non exploitable en l'état

La donnée hydrologique française est publique et de bonne qualité. Les niveaux de nappe et les débits sont exposés par les interfaces Hub'Eau du système d'information sur l'eau [46], le référentiel hydrogéologique BDLISA décrit les entités aquifères et leur superposition [8], et le forçage climatique est disponible par la réanalyse ERA5-Land distribuée par Copernicus [23, 42, 12]. Quatre obstacles séparent néanmoins cette disponibilité d'un usage en apprentissage automatique.

Le premier est l'absence de jointure entre les compartiments. Les niveaux, les débits et le climat sont publiés par des services qui s'ignorent, sans clé commune : rien ne rattache un piézomètre à la maille climatique qui le force. Or c'est précisément ce couple, niveau et forçage sur la même ligne au même jour, que consomme un modèle de prévision multivariée. Le second est la volumétrie et la fragmentation de l'historique, qui remonte à 1967 pour les chroniques et à 1950 pour le climat, et qu'aucun service ne consolide. Le troisième tient aux conventions de lecture des sources, qui ne sont pas homogènes : flux cumulés et grandeurs instantanées d'une réanalyse ne s'agrègent pas de la même façon, et une lecture naïve produit des séries fausses sans qu'aucune erreur ne soit signalée. Le quatrième est l'absence d'indicateur normalisé : une mesure brute ne dit rien de la situation qu'elle décrit tant qu'elle n'est pas rapportée à sa distribution de référence, et aucun des services amont ne fournit cette normalisation.

Le socle décrit ci-après traite ces quatre points. Il se compose de deux dépôts logiciels publics et indépendants, l'entrepôt `hubeau_data_integration` [54] qui répond à QT1, et la plateforme `time-serie-explo` [55] qui répond à QT2. Le second lit le premier en SQL et n'en connaît rien d'autre que le schéma de ses tables finales.

2.2 QT1 : un entrepôt de données hydro-climatiques unifié

2.2.1 Architecture en trois couches

La donnée traverse trois couches de qualité croissante, matérialisées par trois schémas distincts d'une même base PostgreSQL [50], selon le patron dit *médaille* représenté figure 1. Le principe est de ne jamais perdre la donnée telle qu'elle a été reçue, et de rendre chaque transformation ultérieure explicite, versionnée et rejouable, condition nécessaire pour qu'une expérience d'apprentissage soit reproductible.




Figure 1 – Les trois couches de l'entrepôt. La donnée brute n'est jamais écrasée, et les lignes écartées au nettoyage sont conservées à part avec le motif de leur exclusion : le filtrage se vérifie par une requête au lieu d'être silencieux.

L'ingestion est assurée par dlt [18], complété d'un client HTTP dédié qui porte la pagination, les tentatives successives avec temporisation exponentielle et les garde-fous contre les boucles infinies, les interfaces Hub'Eau ne se laissant pas absorber par un mécanisme générique. Les fichiers NetCDF d'ERA5-Land ne sont jamais archivés en base : ils sont téléchargés en stockage temporaire, extraits en mémoire avec xarray [26] et insérés directement. Deux chemins d'ingestion coexistent pour cette source, l'un pour les séries issues du pas de 0h UTC, l'autre pour les statistiques journalières de température agrégées localement sur les vingt-quatre pas horaires, parce que flux cumulés et grandeurs instantanées ne se lisent pas de la même manière. La couche brute compte de l'ordre de 658 000 000 lignes.

Les transformations sont écrites en SQL et orchestrées par dbt [14], exécutées dans la base plutôt qu'en mémoire, ce qui est la seule option viable à cette volumétrie. La couche intermédiaire type, nettoie et déduplique, et sa caractéristique déterminante n'est pas le nettoyage mais sa traçabilité : les lignes écartées ne disparaissent pas, elles sont écrites dans un schéma dédié avec le motif de leur exclusion, de sorte qu'une station absente d'un jeu d'apprentissage se distingue par une requête d'une station éliminée par un critère trop strict. Les modèles de séries temporelles sont incrémentaux, avec une fenêtre de recouvrement de sept jours qui absorbe les corrections tardives publiées par les producteurs.

L'orchestration est confiée à Dagster [13], avec une distinction assumée entre ce qui est planifié et ce qui est déclenché par événement. L'ingestion est planifiée, huit traitements couvrant la mise à jour quotidienne des chroniques et du climat, le rafraîchissement mensuel du référentiel et le recalcul hebdomadaire des références statistiques. La transformation est déclenchée : trois capteurs lancent la chaîne dès que de nouvelles données brutes sont disponibles, ce qui évite le défaut classique des chaînes entièrement planifiées, où la transformation s'exécute à heure fixe sur des données parfois absentes et produit des résultats partiels sans que rien ne le signale.

2.2.2 Le rattachement climatique

C'est dans la couche analytique que se résout le verrou central. Chaque station piézométrique ou hydrométrique est associée à sa maille ERA5 la plus proche par une jointure spatiale du plus proche voisin exécutée par PostGIS [49]. Cette opération, effectuée une fois et matérialisée, transforme deux jeux de données étrangers l'un à l'autre en une chronique unique où le niveau et son forçage climatique figurent sur la même ligne, au même jour. Les faits journaliers sont stockés en *hypertables* TimescaleDB [61] compressées, forme de partitionnement temporel qui maintient les performances d'interrogation sur plusieurs dizaines de millions de lignes.

Deux précautions s'y attachent, et la seconde conditionne la validité des jeux de données produits. La première tient à l'emprise : la grille ingérée couvre un rectangle allant de 41° à 51,5° de latitude et de -5,5° à 10° de longitude, soit la France métropolitaine et la Corse. Les stations ultramarines sont donc bien ingérées avec leurs mesures, mais sans aucun forçage climatique associé, et doivent être écartées explicitement de toute modélisation. La seconde porte sur les coordonnées elles-mêmes, qui servent de clé de jointure : une même maille écrite avec deux précisions flottantes différentes, 48,1° d'un côté et 48,099 999 999 999 95 de l'autre, fait deux points distincts pour la base, et la grille se dédouble sans que rien ne le signale. Les coordonnées sont donc arrondies au pas natif de la grille, 0,1°, ce qui est sans perte puisque c'est la résolution réelle du produit, et l'arrondi s'applique partout où elles servent de clé. Un test automatique garde l'invariant.

L'enrichissement hydrogéologique rattache enfin les entités BDLISA aux stations, ce qui

rend disponible la nature de l'aquifère observé, information que les modèles mécanistiques de la section 2.3.3 exploitent pour se paramétrer. Ce rattachement appelle une réserve : le référentiel décrit les entités et leur ordre de superposition mais ne porte pas leur profondeur, de sorte que déterminer laquelle un piézomètre capte réellement reste approximatif. L'information fournie est une indication utile, pas une caractérisation certaine de l'ouvrage.

2.2.3 Des mesures aux indicateurs normalisés

Un niveau piézométrique de 12,4 m n'est ni haut ni bas dans l'absolu : il l'est relativement à ce que l'ouvrage observe habituellement à cette période de l'année. L'entrepôt produit donc deux familles d'indices standardisés, calculés selon le principe commun d'ajustement d'une loi de probabilité sur la série de référence puis de projection sur une loi normale centrée réduite.

Les indices *par station* situent le mois courant par rapport à sa normale saisonnière, sur la fenêtre de référence 1991-2020 retenue par l'Organisation météorologique mondiale et par le BRGM. Toutes les stations ne disposant pas de trente années d'historique, la sélection de fenêtre se dégrade par paliers déclarés, la normale 1991-2020 si au moins quinze années sont disponibles, sinon la meilleure fenêtre trentenaire alignée sur les décennies, sinon l'historique complet, le palier retenu étant inscrit dans une colonne accompagnant chaque valeur. Si aucun mois n'est exploitable, l'indice prend la valeur *inconnu* plutôt qu'une classe fabriquée.

Les indices *sur grille* sont calculés pour chaque maille de $0,1^\circ$ sur quatre fenêtres d'agrégation de 1, 3, 6 et 12 mois correspondant à des inerties différentes du système hydrologique, et emploient l'échelle à sept classes de McKee [36]. Le tableau 1 en donne les trois grandeurs et la loi ajustée pour chacune.

Table 1 – Les trois indices climatiques sur grille et la loi ajustée pour chacun.

Indice	Grandeur	Ajustement
SPI	Précipitation	Loi gamma, mélangée à la probabilité de cumul nul
STI	Température	Loi normale (score centré réduit)
SPEI	Précipitation moins évapotranspiration	Loi logistique généralisée

Ces indicateurs sont candidats comme variables d'entrée des modèles de prévision et servent par ailleurs de vocabulaire commun avec les équipes opérationnelles du BRGM, qui les emploient déjà pour le suivi de la situation des nappes.

2.2.4 Deux arbitrages méthodologiques

Deux décisions structurantes ont dû être prises lors de la construction de ces indices, et elles sont rapportées ici parce qu'elles conditionnent la validité de tout ce qui s'appuie sur l'entrepôt.

Le premier arbitrage porte sur l'évapotranspiration, grandeur d'entrée du bilan hydrique. ERA5-Land fournit directement une variable nommée *évaporation potentielle*, dont l'emploi paraît naturel. Elle décrit pourtant une autre surface : la documentation du produit en fait une évaporation en nappe d'eau libre, du type mesuré sur un bac [12], là où l'évapotranspiration de référence de la FAO-56 [2] décrit un gazon ras bien alimenté en eau. L'écart s'explique physiquement : une nappe d'eau n'oppose aucune résistance de surface au passage de la vapeur et réfléchit peu le rayonnement, quand un couvert végétal ferme ses stomates et renvoie près du quart de l'énergie reçue. Mesuré sur 30 888 couples maille-mois entre 2015 et 2025, le rapport vaut $2,15 : 1\,756 \text{ mm an}^{-1}$ contre 818 mm an^{-1} pour la référence calculée, cette dernière valeur se situant dans l'intervalle des références publiées pour la France, 700 à 900 mm an^{-1} . Employée dans un indice de bilan hydrique, la variable brute place l'intégralité du territoire en déficit permanent, y compris les années humides, ce qui est physiquement faux. Il n'y a d'erreur nulle part : la variable d'ERA5-Land est juste pour ce qu'elle décrit et hors sujet pour l'usage visé. C'est donc l'évapotranspiration de référence, calculée en couche analytique à partir des températures journalières, qui alimente les indices climatiques.

Le choix de la route de calcul est une seconde décision, qu'il faut distinguer de la première. La méthode de référence de la FAO-56, Penman-Monteith, demande le rayonnement net, le déficit de pression de vapeur et le vent à 2 m. ERA5-Land publie de quoi construire les trois, et ces variables n'ont pas été ingérées : c'est un choix de périmètre, non une indisponibilité, leur acquisition supposant un flux horaire supplémentaire par variable. La formule de Hargreaves [22] retenue à la place est l'équation 52 de la FAO-56 et n'exige que les températures journalières, le rayonnement au sommet de l'atmosphère se calculant analytiquement depuis la latitude et le jour de l'année. Elle produit la même grandeur par une route moins exigeante, et un peu moins bien : la FAO-56 documente qu'elle sous-estime au-delà de 3 m s^{-1} de vent et surestime en forte humidité. La conséquence est une perte de précision bornée sur une entrée, non une grandeur fausse.

Cet arbitrage ne vaut à ce jour que pour la chaîne climatique sur grille. La chaîne des stations expose encore la variable brute, et ce sont donc les modèles mécanistiques de la section 2.3.3 qui reçoivent un forçage environ deux fois trop élevé, $1\,839 \text{ mm an}^{-1}$ mesuré en base. Ce que cet écart change pour les calibrations n'a pas été évalué, aucune campagne comparant les deux forçages sur un échantillon de stations n'ayant été conduite. La conséquence pour le présent rapport doit être énoncée sans détour : les calibrations mécanistiques restent exploitables pour la prévision, mais leurs paramètres ne s'interprètent

pas physiquement tant que ce forçage n'a pas été corrigé, ce qui limite d'autant la portée d'une explication adossée à ces paramètres.

Le second arbitrage porte sur la loi ajustée pour le SPEI. La formulation de l'article fondateur [63] emploie une loi log-logistique qui, appliquée à la grille française, ne s'ajuste que sur 74,6 % des combinaisons de maille, de mois et de fenêtre. L'instrumentation des rejets a montré que la cause était unique et structurelle : cette loi ne représente qu'un sens d'asymétrie, mesuré par le rapport de L-moments τ_3 [25], et la totalité des rejets vient de là. L'implémentation de référence distribuée par les auteurs de la méthode [4] emploie quant à elle la logistique généralisée, qui accepte les deux sens ; c'est elle qui a été retenue. Les deux lois étant équivalentes par reparamétrage, les valeurs restent inchangées partout où la première fonctionnait, ce qui a été vérifié à un écart maximal de 0,000 sur 35 614 mailles, et la couverture passe à 100 %.

2.2.5 Garanties d'exploitation et reproductibilité

Trois propriétés décident de la confiance que l'on peut accorder à un jeu de données partagé, et elles ont été éprouvées en exploitation réelle plutôt que vérifiées sur le papier. L'**idempotence** : relancer une ingestion sur une période déjà chargée ne duplique rien, les lignes de la plage visée étant supprimées avant l'ajout des nouvelles. La **reprise** : le chargement initial complet, qui se compte en jours, est interruptible et redémarrable, son avancement étant persisté en base. La **maîtrise de la concurrence** : les exécutions sont contraintes par clés plutôt que globalement sérialisées, de sorte qu'un rechargement historique n'affame jamais la mise à jour quotidienne.

Deux règles complètent ce dispositif, dirigées contre les défaillances qui ne s'annoncent pas, c'est-à-dire les cas où une chaîne s'exécute, se déclare réussie et livre un résultat faux. Les garanties d'unicité sont portées par le schéma de la base quand c'est possible et par l'orchestration quand ce ne l'est pas, jamais par l'hypothèse implicite que deux traitements ne se croiseront pas. Et la surveillance porte sur la fraîcheur des données plutôt que sur le succès des exécutions : comparer la date maximale présente en base à celle réellement disponible chez le fournisseur est la seule vérification qui détecte une ingestion figée sur une réponse périmée.

L'ensemble est conteneurisé et se déploie par Docker Compose, versions figées dans les images, avec des configurations séparées de production et de bac à sable. Les volumes de données sont déclarés en dehors du cycle de vie de la pile, ce qui rend impossible leur destruction par une commande d'arrêt. La procédure de restauration a été vérifiée de bout en bout sur un entrepôt représentatif, 4,5 GB et quinze tables dont six hypertables à chunks compressés, et la documentation d'installation a été éprouvée en repartant d'une machine vierge.

2.3 QT2 : une plateforme d’exploration, de modélisation et d’explication

2.3.1 Une contrainte d’architecture posée d’emblée

La plateforme comporte trois couches, une interface web en React [37], un service applicatif FastAPI [52] et une bibliothèque métier en Python. La contrainte structurante porte sur la troisième : **la bibliothèque métier ne dépend ni du service applicatif ni de l’interface web** (figure 2).




Figure 2 – Architecture de la plateforme. La bibliothèque métier est appellable depuis le service web, un script ou un carnet de calcul, sans modification. C’est cette propriété qui rend les méthodes d’explication réutilisables au-delà de l’application qui les héberge.

Cette règle a une conséquence déterminante pour un travail de recherche. Le code de préparation des données, de calibration des modèles mécanistiques, d’entraînement, d’attribution et de génération de contrefactuels s’exécute indifféremment depuis le service web, depuis un script ou depuis un carnet de calcul. Les méthodes développées pour QR1 et QR2 ne sont donc pas prisonnières de l’application : elles restent utilisables dans un protocole expérimental hors interface, ce qui est la condition pour qu’une évaluation comparative puisse être conduite dessus.

2.3.2 L’Observatoire : explorer avant de modéliser

Le premier module donne à voir la donnée consolidée. Il répond à deux besoins distincts : celui des hydrogéologues, qui ont besoin de situer une station dans son contexte, et celui des modélisateurs, qui doivent choisir leurs cas d’étude en connaissance de cause, une chronique

trop courte, trop lacunaire ou visiblement perturbée par un pompage ne faisant pas un bon cas d'apprentissage. L'interface s'organise en deux volets communicants, l'exploration spatiale des stations sur fond cartographique avec superposition des entités aquifères, et l'exploration de la grille climatique nationale depuis 1950.

Une règle de conception a structuré ce module et mérite d'être rapportée, parce qu'elle relève directement de la problématique d'explicabilité : *soit un indicateur réellement standardisé, soit une valeur réelle affichée comme telle, jamais un intermédiaire inventé*. Concrètement, les indices standardisés sont cartographiés sur l'échelle à sept classes et les grandeurs journalières brutes sur une échelle absolue, mais les cumuls mensuels absolus ne sont pas proposés comme couches cartographiques : les cartographier supposerait un seuillage, donc une norme implicite qui, n'étant pas une référence statistique établie, serait une invention de l'outil. L'utilisateur lirait une carte de sécheresse là où il n'y a qu'un choix de bornes. Refuser cette couche coûte une fonctionnalité apparente et évite une erreur d'interprétation systématique.

L'Observatoire recalcule par ailleurs le moins possible : ses points d'accès lisent les tables analytiques de l'entrepôt plutôt que de refaire le calcul, de sorte que la valeur affichée est exactement celle qui a été validée en amont.

2.3.3 Le laboratoire de modèles mécanistiques : construire la référence

La question QT2 demande explicitement d'intégrer des modèles mécanistiques de référence pour étalonner les modèles d'IA. Ce module y répond, et son antériorité sur le laboratoire d'apprentissage est délibérée pour trois raisons. Sans référence, une performance ne signifie rien : une architecture profonde qui n'égale pas un modèle à quelques paramètres ne mérite pas d'être déployée. Le modèle mécanistique est interprétable par construction, et fournit donc un point d'ancrage aux explications produites sur un modèle appris. Enfin, c'est le langage des interlocuteurs, le BRGM développant et employant sa propre famille de modèles à réservoirs, GARDÉNIA [7] pour la simulation des niveaux et des débits d'un bassin et EROS [6] pour les relations entre bassins.

L'approche retenue est celle des modèles *transfer function-noise*, mise en œuvre par la bibliothèque Pastas [11]. Le niveau simulé y est la somme des contributions de plusieurs facteurs de forçage, chaque contribution étant obtenue par convolution du forçage avec une fonction de réponse impulsionnelle dont la forme et les paramètres sont calibrés, un modèle de bruit rendant compte de la structure résiduelle. L'intérêt pour la problématique posée est direct : la fonction de réponse **est** l'objet d'intérêt hydrogéologique, sa forme disant comment l'aquifère amortit et retarde le signal climatique, et son intégrale de combien le niveau varie pour une sollicitation donnée. Ce ne sont pas des paramètres opaques mais des grandeurs qui s'interprètent, et c'est ce qui en fait un étalon utilisable pour juger une explication produite sur un modèle profond.

La plateforme donne accès à quatre modèles de recharge, cinq formes de réponse

impulsionnelle, deux modèles de bruit et deux solveurs, combinables librement. Un mécanisme de calibration automatique construit une grille de configurations candidates, calibre chacune et les classe, non pas sur un unique indicateur d'erreur mais sur les quatre critères d'acceptation STOWA [64], standard néerlandais d'évaluation des modèles TFN : variance expliquée au-dessus d'un seuil, résidus aléatoires vérifiés par un test de séquences, temps de réponse à 95 % de la réponse indicelle inférieur à la moitié de la période de calibration, et gain statistiquement significatif. Le troisième critère capture une erreur fréquente et discrète, celle d'un modèle affichant une excellente variance expliquée tout en ayant ajusté une dynamique lente que la période d'observation ne permet pas de contraindre.

La grille n'explore pas l'espace des configurations à l'aveugle : elle est amorcée par des configurations recommandées selon la nature de l'aquifère observé, lue dans le référentiel BDLISA rattaché à la station par l'entrepôt (tableau 2). Cette table est le produit direct des échanges avec l'expertise hydrogéologique du BRGM et traduit en choix de modélisation ce qu'un spécialiste sait du comportement de chaque milieu. Le cas karstique en est l'illustration la plus parlante : un système karstique se comporte comme deux réservoirs couplés, des conduits qui réagissent en quelques heures et une matrice qui réagit en mois, dualité qu'une réponse impulsionnelle à un seul temps caractéristique ne peut pas représenter. Ces configurations amorcent la recherche sans la contraindre, une grille de référence étant systématiquement évaluée en parallèle.

Table 2 – Configurations de modélisation recommandées par famille d'aquifère, issues des échanges avec l'expertise hydrogéologique du BRGM.

Famille	Réponse	Bruit	Justification hydrogéologique
Alluvial	Exponentielle	AR	Réponse rapide, temps de réponse court, système simple
Sédimentaire poreux	Gamma	AR	Réponse intermédiaire
Sédimentaire, double porosité (craie)	Gamma	AR	Forte inertie, temps de réponse long
Sédimentaire fracturé	Gamma	AR	Recharge complexe, modèle de recharge flexible
Karstique	Double exponentielle	ARMA	Deux temps de réponse : conduits et matrice
Socle, montagne	Gamma	AR	Fracturé, recharge non linéaire
Volcanique	Gamma	AR	Système hétérogène
Composite	Quatre paramètres	ARMA	Milieu hétérogène, modèle flexible

Le modèle calibré n'est enfin pas seulement descriptif : il permet de répondre à des questions de la forme *que se passerait-il si*, qui sont précisément celles des gestionnaires et celles auxquelles QR2 s'adresse. Quatre types de modification sont outillés, l'ajout d'un prélèvement synthétique suivant des profils réalistes par type d'usage, l'import d'une chronique de prélèvement réelle, une tendance climatique et une mise à l'échelle d'un forçage existant. Un mécanisme de bornes adaptatives estime le rabattement attendu à partir de la réponse indicielle du modèle lui-même et en dérive des bornes physiquement plausibles pour guider la saisie, de sorte que l'utilisateur n'est ni laissé libre de simuler un pompage qui viderait la nappe en un mois, ni contraint par une borne arbitraire identique partout. Ce mécanisme préfigure, dans le cadre mécanistique, la contrainte de plausibilité que la section 2.3.5 impose aux contrefactuels appris.

2.3.4 Le laboratoire d'apprentissage profond

Prévoir un niveau de nappe est un problème de série temporelle multivariée avec covariables exogènes, la cible étant le niveau et les entrées la précipitation, la température et l'évapotranspiration. Les difficultés propres au domaine sont connues : inertie très variable d'un aquifère à l'autre, non-stationnarité liée aux prélèvements, lacunes d'observation, événements extrêmes rares donc sous-représentés dans l'apprentissage. La littérature propose de nombreuses architectures [48, 29, 66] et aucune ne s'impose a priori ; la question pratique n'est donc pas quel modèle choisir mais comment mettre en place un dispositif permettant de trancher, et de rejouer la comparaison quand les données changent.

La plateforme donne accès à une douzaine d'architectures issues de la bibliothèque Darts [24], couvrant les grandes familles de l'état de l'art : à mécanisme d'attention avec le *temporal fusion transformer* [33] et le transformeur classique, à décomposition par blocs avec N-BEATS et N-HiTS, récurrentes avec LSTM et GRU, convolutives, et récentes à faible coût avec TiDE, TSMixer, DLinear et NLinear. L'inclusion des dernières est délibérée : les modèles linéaires ou quasi linéaires constituent des références exigeantes sur les séries temporelles, et disposer de la référence faible dans le même outil que le modèle sophistiqué évite la comparaison biaisée par des conditions expérimentales différentes.

Le protocole vise trois propriétés. La traçabilité d'abord : chaque exécution d'entraînement est enregistrée dans MLflow [71] avec ses paramètres, ses métriques, ses artefacts et le modèle produit, les jeux de données préparés et les modèles entraînés faisant l'objet de registres distincts, de sorte qu'un résultat puisse être rattaché sans ambiguïté au couple exact qui l'a produit. Sans ce mécanisme, une comparaison entre deux expériences menées à quelques semaines d'intervalle n'est pas défendable, et l'évaluation comparative envisagée en section 4 en dépend entièrement. La séparation entre l'entraînement et l'interface ensuite : le code d'entraînement n'a aucune connaissance de l'interface qui l'observe, il écrit son avancement dans un fichier d'état que la couche de présentation lit indépendamment, ce qui permet de suivre dans l'interface un entraînement lancé depuis un script. La conduite

d'expériences longues enfin, appuyée sur PyTorch Lightning [19] avec arrêt anticipé et suivi de l'évolution des pertes.

La comparaison d'architectures n'ayant de sens que si chacune est évaluée dans une configuration raisonnable, Optuna [1] est intégré pour la recherche automatisée d'hyperparamètres, avec un échantillonnage guidé par les essais déjà évalués. Des configurations prêtes à l'emploi ont par ailleurs été définies par cas d'usage métier plutôt que par architecture, prévision piézométrique à sept, trente et quatre-vingt-dix jours et prévision de débit à quatorze jours, chacune fixant une architecture et un jeu d'hyperparamètres cohérents. Ces configurations sont des points de départ raisonnables et non des réglages optimisés pour une station donnée, ce que la documentation énonce explicitement. Les échanges avec les hydrogéologues ont montré que cette réserve n'est pas de pure forme : la réponse d'un aquifère à la pluie varie fortement selon sa nature, les cycles observés allant de l'annuel au pluriannuel, de sorte que la profondeur d'historique en entrée, l'horizon de prévision pertinent et le pas d'agrégation devraient être choisis par famille d'aquifère, comme le sont déjà les configurations mécanistiques. Cette adaptation n'a pas été faite pour les modèles appris et constitue vraisemblablement le premier gain à aller chercher.

2.3.5 Les modules d'explication

Une prévision de niveau de nappe n'est mobilisable pour décider que si l'on peut dire sur quoi elle repose, et l'interlocuteur d'un modèle de nappe est un hydrogéologue qui n'accordera sa confiance qu'à des explications compatibles avec sa compréhension du système. Le laboratoire outille trois questions, dont les deux premières correspondent directement à QR1 et QR2.

Sur quoi le modèle s'appuie-t-il (QR1) – Cinq familles d'attribution complémentaires sont mises en œuvre : l'importance par perturbation, dans la lignée des approches par substitut local [53], les valeurs de Shapley [34] et leur variante pour séries temporelles [5], les attributions par gradients [60, 28], les poids d'attention pour les architectures qui en possèdent, et la décomposition du signal en tendance, saisonnalité et résidu. Les réunir dans un même outil ne vise pas l'exhaustivité mais la **confrontation** : des méthodes reposant sur des principes différents et qui convergent donnent une explication crédible, tandis que leur divergence signale une explication fragile, information qu'une méthode unique aurait masquée. Chacune est couplée à une visualisation qui projette l'attribution sur le plan variable-temps, ce qui est la forme sous laquelle un hydrogéologue peut la confronter à sa connaissance des temps de réponse de l'aquifère. Quatre des cinq familles sont atteignables depuis l'interface, dans le panneau d'explicabilité de la page de prévision : perturbation, valeurs de Shapley, gradients et décomposition du signal. Les poids d'attention font exception, le calcul et le point d'accès existant sans qu'aucun composant de l'interface ne les sollicite. C'est l'élément de réponse que la plateforme apporte à la seconde moitié de

QR1, l'évaluation de cette forme de restitution auprès des experts restant à conduire.

Que se passerait-il dans d'autres conditions (QR2) – Cette question relève des explications contrefactuelles, formalisées par Wachter *et al.* [65] et transposées depuis peu à la prévision de séries temporelles [67]. Elle a demandé un développement propre, parce que la réponse directe ne vaut rien dans ce domaine. Laisser un algorithme modifier librement les entrées jusqu'à ce que la prévision atteigne la cible produit des scénarios corrects au sens de l'optimisation et physiquement absurdes : de l'air réchauffé sans évaporation supplémentaire, une pluie incohérente d'un jour au suivant, une saison qui n'existe nulle part. Les hydrogéologues y ont substitué deux exigences, le respect du bilan de masse et la cohérence avec les échelles de temps auxquelles un aquifère réagit. C'est exactement la difficulté que la littérature désigne sous le terme de plausibilité et que la section 3 discute.

Deux méthodes sont implémentées, de natures délibérément différentes. La première, désignée ici PhysCF, traduit ces exigences en renonçant à perturber les entrées valeur par valeur : elle ne règle que sept paramètres décrivant un régime climatique, un facteur de pluie par saison, un décalage de température, un décalage du calendrier et un résidu d'évaporation étroitement borné. L'évapotranspiration n'y est pas libre, elle est calculée à partir de la température au taux d'environ 7% par degré, ordre de grandeur tiré de la relation de Clausius-Clapeyron. Le scénario reste donc cohérent par construction plutôt que redressé après coup, et la réponse s'énonce dans les termes du métier : *il aurait fallu des hivers un cinquième plus humides et un climat plus frais d'un degré*. La seconde, adaptée de CoMTE [3], répond à la même question en allant chercher dans l'historique une période réellement observée plutôt qu'en construisant un climat, ce qui donne un point de comparaison de nature différente : la plausibilité y est garantie par la provenance et non par la paramétrisation. Chaque scénario produit est enfin rejoué dans un modèle mécanistique calibré indépendamment, celui de la section 2.3.3 ; s'il fait diverger les deux modèles bien plus qu'ils ne divergeaient sur la situation observée, il est rejeté. Ce test de cohérence croisée est le mécanisme de validation que la plateforme apporte en propre, et il est indépendant de la méthode de génération employée, donc applicable à toute méthode qu'on y intégrerait.

L'état d'exposition de ces développements doit être énoncé précisément, car il conditionne l'usage qu'un expert peut en faire. Les deux méthodes et leur validation croisée sont livrées dans la bibliothèque métier et exposées par l'API, où chacune dispose de son point d'accès. Elles ne sont en revanche **pas atteignables depuis l'interface** : la page qui les pilote existe dans le dépôt, avec son sélecteur de cible et sa vue de comparaison, mais elle n'est déclarée dans aucune route de l'application, et le laboratoire d'intelligence artificielle n'expose que ses quatre onglets de données, d'entraînement, de prévision et de modèles. Les contrefactuels ne s'exécutent donc aujourd'hui que par l'API ou par un carnet de calcul. Le branchement est un travail court, puisque tout ce que cette page appelle fonctionne, mais il n'a pas été fait et il conditionne l'usage de ces méthodes par un

non-développeur.

Cette chronique est-elle seulement explicable par le climat – La troisième question renverse la perspective. Une chronique qu’aucun modèle climatique ne reproduit n’est pas nécessairement mal modélisée : elle peut porter la trace d’un prélèvement, que le forçage climatique ne contient pas. Le problème est non supervisé, faute d’historique étiqueté. La démarche part des résidus d’un modèle mécanistique calibré pour isoler des périodes tenues pour non perturbées, puis croise deux lectures indépendantes dont les verdicts sont fusionnés. L’explicabilité y joue un rôle inhabituel : elle ne justifie pas une prédiction, elle détecte une dérive de ce sur quoi le modèle s’appuie, signe que le régime du système a changé. L’annotation qui en résulte sert à écarter les stations impropres à l’apprentissage, et conditionne donc la constitution de l’échantillon sur lequel une évaluation comparative pourrait porter.

2.4 État de mise à disposition

Les deux dépôts sont publics sous licence MIT, l’entrepôt [54] et la plateforme [55], chacun portant sa documentation d’installation, éprouvée depuis une machine vierge, et son manuel d’exploitation. Reprendre ces développements ne suppose ni demande d’accès ni contact préalable. La plateforme est déployée, l’interface sur l’infrastructure mutualisée de l’établissement et le calcul sur un serveur équipé d’un processeur graphique, mais son usage demeure à ce jour circonscrit au cercle du projet, l’accès étant nominatif et les comptes créés par un administrateur.

Une limite d’ingénierie doit être signalée à quiconque reprend ces travaux. La suite de tests de la plateforme compte 552 tests dont 547 passent, mais aucun ne s’exécute automatiquement : les chaînes d’intégration des deux dépôts ne comportent que des étapes de construction et de déploiement, sans étape de test. Les cinq cas non passants sont documentés et aucun ne signale un défaut applicatif, mais un contrat exécutable important, celui qui garantit que la classification en sept classes est identique dans les deux dépôts, n’est de fait garanti que par la discipline de celui qui lance les tests. C’est le premier correctif à apporter.

3 État de l'Art

La prédiction de séries temporelles (*time-series forecasting*) constitue la brique centrale de nombreuses applications guidées par les données, de la santé et des réseaux énergétiques jusqu'à la surveillance industrielle et les sciences de l'environnement. Dans ces contextes applicatifs, l'objectif ne réside plus uniquement dans l'obtention de prévisions précises, mais également dans la compréhension de la dynamique décisionnelle du modèle : comment parvient-il à une prédiction donnée, et quelles modifications permettraient d'atteindre une trajectoire future plus idéale ? Cette exigence d'explicabilité est d'autant plus critique dans le cadre de la prédiction de séries temporelles multivariées, où la variable cible dépend conjointement de son propre historique, de covariables externes, de décalages temporels (*lags*) et d'interactions croisées entre variables.

Bien que l'avènement des modèles d'apprentissage profond ait nettement amélioré les performances prédictives [48, 29, 66, 35], ces architectures demeurent de véritables « boîtes noires » difficiles à interpréter pour les experts métier.

3.1 Explicabilité pour la prédiction de séries temporelles

Les modèles profonds de prédiction se sont imposés en raison de leur capacité à capturer des dépendances temporelles non linéaires et des interactions complexes entre variables [48, 29, 66]. Dans un cadre multivarié, cette puissance d'expression s'avère particulièrement pertinente dès lors que la cible dépend de plusieurs covariables observées au cours du temps. Néanmoins, cette complexité altère la lisibilité des prédictions.

Pour y remédier, la majorité des méthodes d'explicabilité développées pour les séries temporelles reposent sur l'attribution d'importance (*feature attribution*) ou la saillance (*saliency*). Ces approches cherchent à mesurer la contribution relative des variables, des pas de temps ou des sous-séquences à la décision finale [56, 47, 45, 10]. À titre d'exemple, l'approche *Series Saliency* apprend un masque explicatif sur les dimensions temporelles et thématiques afin de conjuguer prédiction et interprétabilité [47]. De même, des adaptations de SHAP ont été formulées spécifiquement pour le traitement des séries temporelles en classification, régression et prédiction [45, 10].

Si ces méthodes d'attribution sont précieuses pour identifier les zones critiques sur lesquelles le modèle concentre son attention, elles souffrent d'un manque d'actionnabilité. Elles n'indiquent pas à l'utilisateur comment le signal d'entrée (historique ou variables exogènes) devrait être altéré pour obtenir un comportement prédictif souhaité. Cette limite constitue la motivation première de l'étude des explications contrefactuelles.

3.2 Explications contrefactuelles pour la prédiction

Une explication contrefactuelle cherche l'altération minimale à appliquer aux données d'entrée afin de conduire le modèle vers une sortie cible prédéfinie. Dans la littérature générale de l'IA explicable (XAI), l'évaluation de ces explications s'appuie habituellement sur des critères tels que la validité, la proximité, la parcimonie (*sparsity*), l'actionnabilité et la plausibilité [21, 40]. Appliqués aux séries temporelles, ces critères doivent intégrer une contrainte supplémentaire liée à la structure temporelle : la modification contrefactuelle doit non seulement rester proche de l'entrée originale, mais également préserver la cohérence temporelle et inter-variables.

Toutefois, la formulation d'explications contrefactuelles en prédiction s'avère nettement plus complexe qu'en classification. En classification, le résultat visé correspond à une classe discrète. En prédiction, la sortie est continue et s'étend souvent sur un horizon multi-pas : la cible souhaitée peut alors prendre la forme d'une trajectoire exacte, d'un intervalle d'acceptabilité ou du résultat d'une intervention ciblée. La littérature existante présente une grande diversité d'approches :

- **Approches par bornes et intervalles :** *ForecastCF* [67] est l'un des premiers travaux à avoir formalisé l'explication contrefactuelle pour la prédiction en définissant la cible sous forme de bornes inférieure et supérieure sur l'horizon de prévision. *COMET* [68] étend ce principe au cadre multivarié (pour la prédiction du glucose) en y intégrant des contraintes du domaine métier (écrêtage, limites d'activité et contraintes sur l'historique), démontrant ainsi que la validité seule ne suffit pas si l'explication n'est pas réaliste sur le plan applicatif.
- **Approches par trajectoire cible :** À l'inverse, des méthodes comme *CET-X* [27] visent une trajectoire cible exacte en modifiant prioritairement les variables exogènes pour forcer la prédiction à s'en rapprocher.
- **Approches fondées sur des valeurs extrêmes ou la recherche heuristique :** *DiffusionCF* [17] traite la prédiction de valeurs extrêmes en s'appuyant sur la théorie des valeurs extrêmes pour définir une cible contrefactuelle non critique. Enfin, d'autres travaux combinent causalité au sens de Granger, régression quantile et algorithmes génétiques pour générer des scénarios futurs plausibles [72].

3.3 Méthodes contrefactuelles connexes et inférence causale

Au-delà de la prédiction multi-pas, d'autres approches contrefactuelles ont été développées pour des tâches connexes sur séries temporelles. *CounTS* [70] propose un modèle auto-interprétable reposant sur l'inférence contrefactuelle (abduction, action, prédiction). *NTD-CFE* [59] s'appuie sur l'apprentissage par renforcement sans accès au jeu d'entraînement (*model-agnostic*). D'autres travaux adressent spécifiquement la classification de

séries temporelles [15], la génération de contrefactuels rares/épars [30] ou la détection d'anomalies [58]. Bien qu'apportant des concepts utiles en matière d'actionnabilité et de sobriété, ces méthodes ne sont pas directement configurées pour évaluer des modèles de prédiction multivariés multi-horizons.

Il convient également de distinguer ces méthodes d'explication des travaux issus de l'inférence causale et du contrôle synthétique (tels que TGV-CRN, CDA, MVDLM ou la modélisation sous contraintes d'injection d'eau) [20, 39, 31, 69]. Ces derniers s'attachent à estimer l'effet réel d'une intervention physique ou d'une politique de traitement au cours du temps. À l'opposé, les explications contrefactuelles *post-hoc* cherchent à expliquer le fonctionnement d'un modèle d'IA déjà entraîné en identifiant les ajustements d'entrée nécessaires pour satisfaire une contrainte prédictive donnée.

3.4 Synthèse et positionnement

En résumé, la littérature sur les contrefactuels appliqués à la prédiction reste morcelée. Les méthodes diffèrent non seulement par leurs stratégies d'optimisation, mais aussi par la définition de la tâche, la façon dont la prédiction souhaitée est spécifiée (trajectoire exacte vs bornes), les variables autorisées à la modification, et les métriques d'évaluation retenues. Ce manque de standardisation rend la comparaison directe complexe et souligne le besoin de benchmarks unifiés pour évaluer le comportement des différentes familles d'explications contrefactuelles face à un même problème de prédiction multivariée.

3.5 Positionnement du cas hydrogéologique

Le cas d'usage traité ici se place à l'intersection de plusieurs des familles qui précèdent, et s'en écarte sur deux points qu'il faut expliciter avant d'aborder le protocole d'évaluation.

Il relève d'abord des approches par bornes plutôt que par trajectoire exacte. La question posée par un gestionnaire de la ressource n'est pas *quelle chronique exacte de pluie aurait produit ce niveau*, mais *quel régime climatique aurait suffi à ramener la nappe au-dessus du seuil d'alerte*. La cible naturelle est donc un domaine d'acceptabilité sur l'horizon de prévision, formulation qui rejoint celle de *ForecastCF* [67], et le seuil se lit sur l'échelle standardisée à sept classes plutôt que sur une valeur absolue de niveau, laquelle n'est pas comparable d'un ouvrage à l'autre.

Il impose ensuite une contrainte de plausibilité plus forte que la proximité géométrique usuelle, et de même nature que celle qui a conduit *COMET* [68] à intégrer des limites de domaine. Les variables d'entrée ne sont pas indépendantes : la température, l'évapotranspiration et, dans une moindre mesure, la précipitation sont liées par des relations physiques que toute perturbation libre viole immédiatement. Une explication contrefactuelle qui réchauffe l'air sans augmenter l'évaporation est valide au sens de l'optimisation et sans valeur pour un hydrogéologue. C'est ce constat qui a motivé le développement décrit en

section 2.3.5, où la plausibilité est obtenue soit par une paramétrisation à faible dimension respectant ces relations, soit par la recherche d'un analogue réellement observé dans l'historique, dans la lignée des approches par instances [15, 3].

Il se distingue enfin des travaux d'inférence causale évoqués ci-dessus par la nature de la question posée. On ne cherche pas à estimer l'effet réel d'une intervention sur l'aquifère, ce qui relèverait de la modélisation hydrogéologique et non de la XAI, mais à caractériser ce sur quoi un modèle prédictif appris fonde sa sortie. La disponibilité, dans la plateforme, d'un modèle mécanistique calibré indépendamment sur la même station offre à cet égard une position peu commune dans la littérature XAI : un second modèle, interprétable par construction, contre lequel confronter le contrefactuel produit sur le modèle appris.

4 Méthodologie et Approche Proposée

La section 3 a établi que la comparaison directe des méthodes contrefactuelles pour la prédiction se heurte à une absence de standardisation : les travaux publiés diffèrent par la définition même de la tâche, par la façon de spécifier la sortie souhaitée, par les variables qu'ils autorisent à modifier et par les métriques qu'ils retiennent. La présente section fixe donc, pour le cas hydrogéologique, les conventions qui rendent une telle comparaison possible. Elle décrit le dispositif effectivement disponible dans la plateforme, puis le protocole selon lequel l'évaluation doit être conduite.

4.1 Architecture du dispositif d'évaluation

Évaluer une explication suppose trois objets, et non un seul : le jeu de données sur lequel le modèle a été entraîné, le modèle à expliquer, et un référent contre lequel juger l'explication produite. Le socle décrit en section 2 fournit les trois, et c'est ce qui distingue le dispositif d'un banc d'essai générique.

Le **jeu de données** est constitué depuis l'entrepôt, qui garantit que la cible et son forçage climatique proviennent de la même chaîne de transformation et sont validés une seule fois. Cette propriété, invisible dans l'interface, est la condition pour qu'une comparaison entre deux méthodes d'explication porte réellement sur les méthodes et non sur des préparations de données divergentes. La qualification des stations décrite en section 2.3.5, qui écarte les chroniques trop courtes, trop lacunaires ou visiblement influencées par un prélèvement, intervient à ce stade : une explication produite sur un modèle entraîné sur une chronique perturbée par un pompage que le forçage ne contient pas n'est pas interprétable, quelle que soit la qualité de la méthode d'explication.

Le **modèle à expliquer** est l'une des architectures profondes du catalogue, entraînée et enregistrée dans le registre d'expériences avec ses paramètres et ses métriques. La traçabilité n'est pas ici un confort d'ingénierie : une explication n'a de sens que rattachée sans ambiguïté au couple exact jeu de données et point de sauvegarde qui l'a produite, et l'absence de ce rattachement est l'un des motifs récurrents d'incomparabilité entre travaux publiés.

Le **référent** est le modèle mécanistique calibré indépendamment sur la même station (section 2.3.3). C'est l'élément le moins commun du dispositif. La plupart des protocoles d'évaluation de contrefactuels ne disposent que du modèle expliqué lui-même et doivent donc juger l'explication à l'aune de propriétés intrinsèques, distance à l'instance d'origine, nombre de variables modifiées, appartenance au support des données. Disposer d'un second modèle du même phénomène, interprétable par construction et calibré sans jamais voir le premier, permet une vérification d'un autre ordre, développée plus bas.

4.2 Spécification de la cible contrefactuelle

La sortie d'un modèle de prévision piézométrique est continue et multi-pas, ce qui laisse ouverte la façon de spécifier ce que l'explication doit atteindre. Trois formulations sont retenues, par ordre de proximité croissante avec la question métier.

La première est la **cible par bornes** sur l'horizon de prévision, dans la formulation de *ForecastCF* [67] : la trajectoire contrefactuelle doit rester dans un couloir défini par une borne inférieure et une borne supérieure. C'est la formulation la plus générale et la seule qui permette de comparer une méthode issue de la littérature à une méthode développée ici sans avantager l'une des deux.

La deuxième est la **cible par classe standardisée**, qui exploite l'indicateur produit par l'entrepôt : la trajectoire contrefactuelle doit conduire la station à sortir d'une classe de sécheresse donnée. Cette formulation a deux vertus. Elle est comparable d'un ouvrage à l'autre, ce qu'une borne exprimée en mètres n'est pas, un même niveau absolu n'ayant pas la même signification sur deux piézomètres différents. Et elle correspond au vocabulaire déjà employé par les équipes opérationnelles, ce qui est la condition pour qu'une explication soit lisible par son destinataire réel.

La troisième est la **cible par intervention**, où l'on fixe non pas la sortie mais la variable autorisée à changer, et où l'on demande de quelle amplitude. C'est la forme que prend la question dans un comité sécheresse : *quel cumul de pluie sur les trois prochains mois ramènerait cette nappe en situation normale*. Elle restreint le contrefactuel à une seule dimension d'entrée et rend la réponse directement actionnable, au prix d'une validité plus difficile à atteindre, la cible pouvant être hors d'atteinte pour toute valeur admissible de la variable choisie.

4.3 Dimensions d'évaluation retenues

Les critères usuels de la littérature XAI, validité, proximité, parcimonie, actionnabilité et plausibilité [21, 40, 41], sont conservés et complétés de deux dimensions propres au cas traité. Le tableau 3 les récapitule avec le mode de mesure retenu pour chacune.

Table 3 – Dimensions d'évaluation d'une explication contrefactuelle sur le cas hydrogéologique, et mode de mesure retenu pour chacune.

Dimension	Ce qu'elle mesure	Mode de mesure
Validité	La prévision issue de l'entrée modifiée atteint effectivement la cible	Taux de succès sur l'échantillon
Proximité	L'entrée modifiée reste proche de l'entrée observée	Distance normalisée par variable
Parcimonie	Peu de variables et de pas de temps sont modifiés	Nombre de variables touchées, étendue temporelle
Plausibilité physique	Les relations entre variables sont préservées	Écart au taux de Clausius-Clapeyron, bilan de masse
Actionnabilité	Le scénario s'énonce dans le vocabulaire du métier	Réductible ou non à un petit nombre de grandeurs interprétables
Cohérence croisée	Le scénario ne fait pas diverger le modèle appris du modèle mécanistique	Écart entre les deux modèles sur le contrefactuel, rapporté à leur écart sur l'observé
Coût	Le calcul reste compatible d'un usage interactif	Temps de génération par instance

Les deux dernières lignes appellent un commentaire. La **cohérence croisée** est le mécanisme de validation que la plateforme apporte en propre. Un contrefactuel est un point sur lequel aucune observation n'existe, par construction : on ne peut donc pas vérifier qu'il est correct, seulement qu'il n'est pas absurde. Le confronter à un second modèle du même phénomène, calibré indépendamment et interprétable, fournit ce contrôle négatif : si deux modèles qui s'accordaient sur la situation observée divergent fortement

sur le scénario proposé, c'est que ce scénario sort du domaine où l'un des deux au moins reste valide. Le critère est indépendant de la méthode de génération, donc applicable uniformément à toutes les méthodes comparées, y compris celles importées de la littérature. Il ne mesure pas la qualité d'une explication au sens où l'entendrait un utilisateur, il élimine des explications qu'aucun utilisateur ne devrait recevoir.

Le **coût** n'est pas une dimension cosmétique. La question QR1 porte sur le couplage à des interfaces de visualisation interactive, et une méthode dont la génération se compte en minutes ne se couple à rien d'interactif, quelles que soient ses qualités par ailleurs. Le distinguer explicitement évite de comparer des méthodes qui ne s'adressent pas au même usage.

Ces dimensions ne sont pas indépendantes et ne se résument pas en un score unique. La littérature d'évaluation des explications sur séries temporelles multivariées le documente : les classements obtenus varient selon la métrique retenue [57], et une lecture causale des méthodes d'attribution montre que certaines mesurent une propriété différente de celle qu'on leur prête [62]. Le protocole rapporte donc les dimensions séparément, et l'arbitrage entre elles relève du cas d'usage plutôt que d'une agrégation arbitraire.

4.4 Protocole expérimental

L'**échantillon** de stations doit être stratifié par famille d'aquifère selon la typologie du tableau 2, et non tiré uniformément. Le motif est hydrogéologique : la réponse d'un aquifère au forçage climatique va de la quasi-instantanéité pour un système alluvial à plusieurs années pour une craie inertielle, et une méthode contrefactuelle qui excelle sur les secondes peut échouer sur les premières. Un classement établi sur un échantillon uniforme refléterait surtout la composition du réseau de mesure français. Chaque station retenue doit par ailleurs avoir passé la qualification décrite en section 2.3.5 et disposer d'un modèle mécanistique satisfaisant les quatre critères STOWA, faute de quoi le référent n'en est pas un.

Le **découpage temporel** sépare une période de calibration et d'entraînement d'une période d'évaluation postérieure, appliquée identiquement au modèle appris et au modèle mécanistique. L'exigence est ici plus stricte que dans un protocole de prévision ordinaire : le modèle mécanistique servant de référent, toute fuite d'information entre les deux périodes contaminerait la vérification de cohérence croisée en plus des métriques de prévision.

Les **méthodes comparées** couvrent au minimum une méthode par famille identifiée en section 3 : une approche par bornes issue de la littérature, une approche par instances cherchant un analogue observé, et l'approche par paramétrisation physique développée ici. Une référence naïve doit être incluse, consistant à perturber les entrées sans aucune contrainte de plausibilité jusqu'à atteindre la cible. Son rôle est le même que celui des modèles linéaires dans le catalogue de prévision : elle borne par le haut la validité

atteignable et par le bas la plausibilité, et une méthode contrainte qui ne la dépasse sur aucune dimension utile ne mérite pas son surcoût.

Le **traitement statistique** des résultats suit la pratique établie pour la comparaison de plusieurs méthodes sur plusieurs jeux de données [16]. Chaque méthode est classée sur chaque station pour chaque dimension, un test de Friedman établit s'il existe une différence significative entre les méthodes, et le test post-hoc de Nemenyi [44] identifie les paires effectivement séparables, le résultat se lisant sur un diagramme de différence critique. Ce choix est délibérément conservateur : avec un échantillon de stations qui restera modeste au regard du nombre de méthodes comparées, une comparaison par moyennes de métriques donnerait un classement apparent que le nombre d'observations ne soutient pas.

Un point demande enfin d'être fixé avant la mesure plutôt qu'après. Les seuils d'acceptation de chaque dimension, en particulier celui de la cohérence croisée qui décide du rejet d'un scénario, doivent être arrêtés avant l'exécution du protocole. C'est la règle qui a été appliquée à la validation des indicateurs de l'entrepôt, rapportée en section 5.1, et elle vaut ici pour la même raison : fixer un seuil après avoir vu les résultats revient à ajuster le critère à ce qu'on a obtenu.

4.5 Ce que le protocole ne tranche pas

Deux limites doivent être énoncées avec le protocole, parce qu'elles en délimitent la portée.

La première est que la mesure de la plausibilité physique proposée ici est une mesure de *non-violation de contraintes connues*, pas une mesure de réalisme climatique. Un scénario peut respecter le bilan de masse et le taux de Clausius-Clapeyron tout en décrivant une succession de saisons qu'aucune circulation atmosphérique ne produit. Une évaluation plus exigeante supposerait de confronter le scénario à une distribution de régimes climatiques observés ou simulés, ce qui excède le cadre de la tâche et rejoint les approches par instances, dont c'est précisément la garantie native.

La seconde est que ce protocole évalue des propriétés mesurables d'une explication, non son utilité pour son destinataire. Or la question de savoir ce qu'est une bonne explication ne se réduit pas à ces propriétés, comme l'établit la littérature issue des sciences sociales [38] et comme le rappellent les revues d'évaluation de la XAI [43]. Répondre pleinement à la seconde moitié de QR1, qui porte sur la capacité des experts à contrôler la qualité décisionnelle d'un modèle, suppose un protocole avec des hydrogéologues, distinct de celui décrit ici et qui reste à construire.

5 Résultats et Analyse

Cette section rend compte de l'état d'avancement de la tâche. Elle rapporte les résultats effectivement établis, qui portent sur les briques dont dépend le protocole de la section 4, et délimite ensuite ce qui ne l'est pas. Cette séparation est explicite parce que l'enjeu de la tâche 3.2 est la fiabilité des explications : un rapport qui présenterait comme acquis un classement de méthodes non mesuré illustrerait exactement le défaut qu'il prétend traiter.

5.1 Validation du socle de données

Le protocole de la section 4 repose sur des indicateurs standardisés, employés à la fois comme variables d'entrée possibles et comme formulation de la cible contrefactuelle. Leur justesse conditionne donc celle de tout ce qui s'appuie dessus, et elle a été vérifiée.

Un indice standardisé doit, par construction, suivre approximativement une loi normale centrée réduite sur sa propre période de référence. Le critère d'acceptation a été fixé *avant* la mesure : moyenne voisine de zéro à $\pm 0,05$, écart-type voisin de un à $\pm 0,05$, et taux de saturation aux bornes inférieur à 1 %. La mesure porte sur 41 960 400 valeurs couvrant 11 496 mailles.

Table 4 – Vérification des indices produits sur leur propre période de référence, 41 960 400 valeurs couvrant 11 496 mailles. Le critère d'acceptation avait été fixé avant la mesure.

Indice	Fenêtres	Moyenne	Écart-type	Médiane	Saturation
SPI	1/3/6/12	-0,008 à +0,002	0,985 à 1,031	0,00 à 0,04	0,05 à 0,51 %
STI	1/3/6/12	0,000	0,983	-0,09 à -0,02	0,00 à 0,04 %
SPEI	1/3/6/12	+0,004 à +0,006	0,999 à 1,013	0,01 à 0,03	0,012 à 0,035 %

Les trois indices satisfont le critère sur les quatre fenêtres d'agrégation, et la couverture du SPEI est uniforme à 100 % après le changement de loi rapporté en section 2.2.4, ce qui signifie que la calibration n'est pas seulement préservée mais mesurée sur l'ensemble du domaine.

Deux lectures de ces indices doivent être écartées, et elles sont consignées ici parce que l'erreur correspondante est naturelle. La classe *normale* ne couvre pas la proportion théorique : elle représente 54,8 % des valeurs au lieu des 59,9 % attendus d'une gaussienne, alors même que l'écart-type vaut 1,008, la distribution conservant des épaules légèrement plus lourdes. Cet écart est une propriété de la transformation au voisinage des bornes de classe, sans conséquence opérationnelle, et il ne doit pas être lu comme une anomalie de sécheresse. La décroissance décennale du SPEI, en revanche, est un signal climatique et non une dérive de méthode : la moyenne sur fenêtre d'un mois décroît de manière monotone, +0,038 dans les années 1990, +0,007 dans les années 2000, -0,016 dans les années 2010,

−0,117 depuis 2020. Cette évolution avait été anticipée avant d’être mesurée, ce qui la distingue d’un artefact d’ajustement.

5.2 Une incohérence de forçage qui limite l’interprétation du référent

Le dispositif de la section 4 fait du modèle mécanistique le référent contre lequel juger les explications produites sur un modèle appris. Une incohérence de la chaîne de données en limite aujourd’hui la portée, et elle doit être rapportée ici plutôt que dissimulée dans les annexes techniques, parce qu’elle porte directement sur la validité du protocole.

Le forçage d’évapotranspiration transporté par la chaîne des stations est la variable brute d’ERA5-Land et non l’évapotranspiration de référence, soit environ le double de la grandeur attendue, $1\,839\text{ mm an}^{-1}$ mesuré en base contre 818 mm an^{-1} pour la référence. La correction n’est pas un changement de colonne : la chaîne station ne transporte que la température moyenne, alors que la formule de Hargreaves exige aussi les extrêmes journaliers, de sorte qu’il faudrait les y ajouter, recalculer l’évapotranspiration au pas journalier, propager le résultat dans deux tables partitionnées et recalibrer les modèles existants. Ce que cet écart change pour les calibrations n’a pas été évalué : aucune campagne comparant les deux forçages sur un échantillon de stations n’a été conduite, et l’ampleur de l’effet reste donc inconnue.

La conséquence pour la tâche 3.2 est directe. Les calibrations mécanistiques restent utilisables pour la prévision et pour le test de cohérence croisée, qui compare deux modèles entre eux et non un paramètre à sa valeur physique. En revanche, les paramètres de ces modèles, temps de réponse et gain, ne s’interprètent pas physiquement tant que ce forçage n’est pas corrigé. Toute lecture hydrogéologique d’une fonction de réponse calibrée, et donc toute explication qui s’appuierait sur elle pour justifier une prévision, est suspendue à cette correction. C’est le premier chantier que ces travaux laissent à leur suite, et il est prioritaire sur toute campagne d’évaluation.

5.3 État de l’outillage au regard des deux questions de recherche

Le tableau 5 récapitule ce que le socle apporte à chaque question et ce qui manque encore. La colonne d’état est délibérément sévère : *outillé* signifie que les moyens existent, pas qu’un résultat a été produit, et la mention *exposé* distingue ce qu’un utilisateur peut atteindre depuis l’application de ce qui ne s’exécute que par l’API ou un carnet de calcul.

Table 5 – État d’avancement au regard des questions de recherche et des questions techniques.

Question	Ce qui a été produit	État
QT1	Entrepôt unifié, quatre sources jointes, indicateurs standardisés validés, chaîne idempotente et reprenable, déploiement conteneurisé	atteint
QT2	Observatoire, laboratoire mécanistique, catalogue d’architectures profondes, traçabilité des expériences, modules d’explication	atteint
QR1	Cinq familles d’attribution mises en œuvre et confrontables entre elles, restitution sur le plan variable-temps ; quatre d’entre elles accessibles dans l’interface	outillé, exposé, non évalué
QR2	Deux méthodes contrefactuelles de natures différentes, test de cohérence croisée contre un modèle indépendant, protocole de comparaison formalisé	outillé, non exposé dans l’interface, non mesuré

5.4 Ce qui n’est pas établi

Quatre choses que le lecteur pourrait attendre ne figurent pas dans ce rapport, et il faut dire pourquoi.

Le **pilotage des contrefactuels depuis l’interface** n’est pas livré. La page correspondante existe dans le dépôt et l’API répond, mais aucune route de l’application n’y mène, de sorte que les méthodes de la section 2.3.5 restent hors de portée d’un utilisateur non développeur. C’est un défaut de branchement, court à corriger, et non une lacune de méthode ; il est signalé ici parce qu’il change ce que la plateforme permet aujourd’hui de faire, et parce qu’il conditionne toute évaluation associant des hydrogéologues.

Le **classement des architectures de prévision** sur le cas hydrogéologique n’est pas établi. Les campagnes d’entraînement conduites au cours des travaux ont servi à valider le dispositif et à orienter les développements ; les jeux de données préparés et les points de sauvegarde ont été purgés des dépôts lors de la passation. Reconstituer a posteriori un tableau de performances à partir de souvenirs ne serait pas un résultat scientifique. La campagne qui opposerait les modèles appris aux modèles mécanistiques sur un échantillon stratifié reste donc à conduire, et l’outillage nécessaire est en place pour la mener.

La **comparaison quantitative des familles de contrefactuels** n’est pas davantage établie. Les deux méthodes décrites en section 2.3.5 sont opérationnelles et mettent en œuvre l’exigence de plausibilité formulée par les hydrogéologues, mais aucune évaluation

n'a été conduite, sur aucun échantillon, selon aucune des dimensions du tableau 3. Le protocole de la section 4 est le livrable de cette partie de la tâche : il fixe les conventions qui manquaient, il n'en rapporte pas encore l'application. Anticiper son résultat reviendrait à préjuger de ce que la mesure doit trancher.

L'évaluation de la restitution auprès des experts, enfin, qui constitue la seconde moitié de QR1, n'a pas été conduite. Les visualisations existent et ont été construites en dialogue avec les hydrogéologues du BRGM, mais aucun protocole d'évaluation avec utilisateurs n'a été mis en place. C'est une question distincte des précédentes, qui relève de méthodes d'évaluation propres et qui ne se déduit d'aucune métrique calculable sur les explications elles-mêmes.

5.5 Analyse

Le principal enseignement de cette première phase n'est pas d'ordre algorithmique. Il tient à ce que le cas hydrogéologique a révélé des exigences que la littérature XAI sur séries temporelles ne traite qu'incidemment.

La première est que la **plausibilité n'est pas une contrainte de régularisation**. Les formulations usuelles la traitent comme un terme supplémentaire de la fonction objectif, pondéré contre la validité et la proximité. Sur des variables climatiques liées par des relations physiques, cette approche produit des scénarios qui violent ces relations d'autant moins que le poids est élevé, mais qui les violent toujours un peu, et un hydrogéologue rejette un scénario qui les viole un peu aussi sûrement qu'un scénario qui les viole beaucoup. C'est ce constat qui a conduit à changer d'espace de recherche plutôt qu'à ajuster une pondération, en optimisant sur sept paramètres de régime climatique au lieu de la série d'entrée elle-même. Le prix est une perte d'expressivité, et l'évaluation prévue doit précisément mesurer si cette perte coûte en validité ce qu'elle rapporte en plausibilité.

La deuxième est que la **spécification de la cible engage le domaine et non seulement la méthode**. Exprimer la cible en niveau absolu rend les stations incomparables, alors que l'exprimer en classe standardisée les rend comparables et rejoint le vocabulaire des utilisateurs. Ce choix, qui paraît secondaire, détermine ce qu'un classement de méthodes signifiera : deux méthodes évaluées sur des cibles formulées différemment ne sont pas comparables, ce qui est l'une des causes du morcellement constaté en section 3.

La troisième est la valeur du **second modèle**. Le test de cohérence croisée n'est pas une métrique de plus : c'est le seul contrôle disponible sur un point où aucune observation n'existe. Sa disponibilité tient entièrement au fait que le socle a été construit en commençant par la modélisation mécanistique plutôt que par l'apprentissage profond, décision qui paraissait alors relever de la prudence méthodologique et qui s'avère fournir l'instrument de vérification dont la partie XAI avait besoin.

6 Conclusion et Perspectives

La tâche 3.2 posait deux questions de recherche sur l'explicabilité des modèles prédictifs profonds de séries temporelles, appliquées à la prévision du niveau des nappes. L'instruction de ces questions a fait apparaître un préalable qui n'était pas anticipé et qui a orienté une part importante du travail : la donnée hydrologique française, quoique publique et de bonne qualité, n'était pas exploitable en l'état pour l'apprentissage automatique, faute de jointure entre les compartiments, de consolidation de l'historique et d'indicateurs normalisés.

Le premier acquis est donc la levée de ce verrou. L'entrepôt répondant à QT1 agrège quatre sources ouvertes en une chaîne idempotente, reprenable et déployable, expose des chroniques où le niveau et son forçage climatique figurent sur la même ligne au même jour, et produit une famille d'indicateurs standardisés dont la justesse a été vérifiée contre un critère fixé avant la mesure. La plateforme répondant à QT2 y ajoute l'exploration cartographique, un laboratoire de modèles mécanistiques calibrés selon les critères STOWA et paramétrés par famille d'aquifère, un catalogue d'architectures de prévision profonde sous traçabilité d'expériences, et les modules d'explication. Ce que cette chaîne change se mesure à une chose : obtenir soixante ans de niveaux de nappe joints à leur climat demandait plusieurs semaines de préparation, c'est aujourd'hui une requête.

Le deuxième acquis porte sur QR1. Cinq familles d'attribution sont mises en œuvre, dont quatre accessibles dans l'interface, non pour l'exhaustivité mais pour la confrontation : leur convergence rend une explication crédible, leur divergence signale une explication fragile, information qu'une méthode unique aurait masquée. La restitution projette l'attribution sur le plan variable-temps, forme sous laquelle un hydrogéologue peut la confronter à sa connaissance des temps de réponse de l'aquifère. La question de savoir si ce dispositif permet effectivement aux experts de contrôler la qualité décisionnelle d'un modèle reste ouverte : elle appelle un protocole avec utilisateurs qui n'a pas été conduit.

Le troisième acquis porte sur QR2, et il est double. Il a d'abord fallu constater que la formulation standard du problème contrefactuel ne convient pas au domaine : une perturbation libre des entrées produit des scénarios valides au sens de l'optimisation et physiquement absurdes, et traiter la plausibilité comme un terme de régularisation ne suffit pas, parce qu'un scénario qui viole un peu les relations physiques est rejeté aussi sûrement qu'un scénario qui les viole beaucoup. Deux méthodes de natures différentes ont donc été implémentées, l'une par paramétrisation à faible dimension d'un régime climatique, l'autre par recherche d'un analogue réellement observé, et un test de cohérence croisée contre un modèle mécanistique calibré indépendamment permet de rejeter un scénario sortant du domaine de validité. Ce test est le seul contrôle disponible sur un point où, par construction, aucune observation n'existe, et il est indépendant de la méthode de génération, donc applicable à toute méthode qu'on intégrerait au dispositif. Ces développements sont livrés en bibliothèque et exposés par l'API, mais la page qui devait les mettre à portée

d'un hydrogéologue n'est branchée dans aucune route de l'application : ils ne s'exécutent aujourd'hui que par l'API ou par un carnet de calcul.

Ce qui n'est pas acquis a été énoncé en section 5 et mérite d'être répété ici : ni le classement des architectures de prévision sur le cas hydrogéologique, ni la comparaison quantitative des familles de contrefactuels selon les dimensions retenues n'ont été mesurés. Le livrable de cette partie de la tâche est le protocole qui rend ces mesures possibles et comparables, non leur résultat.

Perspectives

Cinq chantiers se dégagent, par ordre de priorité.

Le premier est correctif et conditionne les autres. Le forçage d'évapotranspiration de la chaîne des stations doit être remplacé par l'évapotranspiration de référence, ce qui suppose de transporter les extrêmes journaliers de température jusqu'à cette chaîne, de recalculer la grandeur au pas journalier et de recalibrer les modèles existants. Tant que ce n'est pas fait, les paramètres des modèles mécanistiques n'ont pas d'interprétation physique directe, et aucune explication ne peut s'appuyer sur eux pour justifier une prévision.

Le deuxième est le branchement de l'interface contrefactuelle, sans lequel aucune évaluation associant des hydrogéologues n'est possible. La page et ses composants existent, l'API répond, seule la déclaration de route manque.

Le troisième est l'exécution du protocole de la section 4, sur un échantillon stratifié par famille d'aquifère, avec la référence naïve incluse et le traitement statistique par diagramme de différence critique. C'est de cette campagne que dépend la réponse à QR2, et l'outillage nécessaire est en place.

Le quatrième est l'extension du cadre à la prévision probabiliste. Les méthodes mises en œuvre expliquent une prévision ponctuelle, alors que la décision opérationnelle porte sur un risque de franchissement de seuil, donc sur une distribution. Des travaux récents formulent la saillance contrefactuelle pour des modèles de régression probabiliste [51], et le catalogue d'architectures de la plateforme comporte déjà des modèles produisant des quantiles, ce qui rend cette extension accessible sans reconstruction du socle.

Le cinquième est l'adaptation des configurations d'apprentissage par famille d'aquifère. La profondeur d'historique en entrée, l'horizon de prévision pertinent et le pas d'agrégation devraient être choisis selon la nature de la nappe, comme ils le sont déjà côté mécanistique. C'est vraisemblablement le premier gain de performance à aller chercher, et il conditionne la qualité des modèles sur lesquels porteront les explications.

Trois sujets identifiés avec les hydrogéologues du BRGM restent par ailleurs ouverts et dépassaient le périmètre de la tâche : l'étude des échanges nappe-rivière et du soutien d'étiage, la caractérisation de la double porosité, et la définition d'un indicateur de situation pour les nappes captives, l'indicateur standardisé existant n'ayant été conçu que pour

les nappes libres. Ils sont consignés ici parce qu'ils viennent des experts du domaine et constituent des points d'entrée pour la suite.

L'ensemble de ces développements est public sous licence MIT [54, 55], documenté et déployable depuis une machine vierge, de sorte que les partenariats à venir entre le BRGM et le LIFAT, notamment dans le cadre du projet ANR AIDA, disposent d'un socle qu'ils n'auront pas à reconstruire.

Références

- [1] T. AKIBA, S. SANO, T. YANASE, T. OHTA et M. KOYAMA. “Optuna : a next-generation hyperparameter optimization framework”. In : *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2019, p. 2623-2631.
- [2] R. G. ALLEN, L. S. PEREIRA, D. RAES et M. SMITH. *Crop evapotranspiration : guidelines for computing crop water requirements*. FAO Irrigation and Drainage Paper 56. Rome : Organisation des Nations unies pour l'alimentation et l'agriculture, 1998.
- [3] E. ATES, B. AKSAR, V. J. LEUNG et A. K. COSKUN. “Counterfactual explanations for multivariate time series”. In : *International Conference on Applied Artificial Intelligence (ICAPAI)*. IEEE, 2021, p. 1-8.
- [4] S. BEGUERÍA et S. M. VICENTE-SERRANO. *SPEI : calculation of the standardised precipitation-evapotranspiration index*. Paquet R, fonction `parglo` d'ajustement de la logistique généralisée. 2023. URL : <https://cran.r-project.org/package=SPEI> (visité le 26/08/2026).
- [5] J. BENTO, P. SALEIRO, A. F. CRUZ, M. A. T. FIGUEIREDO et P. BIZARRO. “Time-SHAP : explaining recurrent models through sequence perturbations”. In : *Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 2021, p. 2565-2573.
- [6] BRGM. *EROS : modèle hydrologique global multi-bassins*. Logiciel, Bureau de recherches géologiques et minières. 2026. URL : <https://www.brgm.fr/fr/logiciel/eros-logiciel-modelisation-hydrologique-semi-globale-bassin-versant-decoupe-sous-bassins> (visité le 26/08/2026).
- [7] BRGM. *GARDÉNIA : modèle global à réservoirs pour la simulation des débits et des niveaux de nappe*. Logiciel, Bureau de recherches géologiques et minières. 2026. URL : <https://www.brgm.fr/fr/logiciel/gardenia-logiciel-modelisation-hydrologique-globale-bassin-versant> (visité le 26/08/2026).
- [8] BRGM et SANDRE. *BDLISA : base de données des limites des systèmes aquifères*. Référentiel hydrogéologique français. 2026. URL : <https://bdlisa.eaufrance.fr/> (visité le 26/08/2026).
- [9] R. M. J. BYRNE. “Counterfactuals in Explainable Artificial Intelligence (XAI) : Evidence from Human Reasoning”. In : *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence*. International Joint Conferences on Artificial Intelligence Organization, 2019, p. 6276-6282. DOI : [10.24963/ijcai.2019/876](https://doi.org/10.24963/ijcai.2019/876).

- [10] J. E. CHOI, J. W. SHIN et D. W. SHIN. “Vector SHAP Values for Machine Learning Time Series Forecasting”. In : *Journal of Forecasting* 44.2 (2025), p. 635-645. DOI : [10.1002/for.3220](https://doi.org/10.1002/for.3220).
- [11] R. A. COLLENTEUR, M. BAKKER, R. CALJÉ, S. A. KLOP et F. SCHAARS. “Pastas : open source software for the analysis of groundwater time series”. In : *Groundwater* 57.6 (2019), p. 877-885.
- [12] COPERNICUS CLIMATE CHANGE SERVICE. *Climate Data Store : ERA5-Land hourly data from 1950 to present*. Centre européen pour les prévisions météorologiques à moyen terme. 2026. URL : <https://cds.climate.copernicus.eu/> (visité le 26/08/2026).
- [13] DAGSTER LABS. *Dagster : an orchestrator for data assets*. Logiciel, version 1.11. 2026. URL : <https://dagster.io/> (visité le 26/08/2026).
- [14] DBT LABS. *dbt : data build tool*. Logiciel, version 1.7. 2026. URL : <https://www.getdbt.com/> (visité le 26/08/2026).
- [15] E. DELANEY, D. GREENE et M. T. KEANE. “Instance-Based Counterfactual Explanations for Time Series Classification”. In : *Case-Based Reasoning Research and Development*. Springer, 2021, p. 32-47. DOI : [10.1007/978-3-030-86957-1_3](https://doi.org/10.1007/978-3-030-86957-1_3).
- [16] J. DEMŠAR. “Statistical Comparisons of Classifiers over Multiple Data Sets”. In : *Journal of Machine Learning Research* 7.1 (2006), p. 1-30. URL : <https://www.jmlr.org/papers/v7/demsar06a.html>.
- [17] Y. DENG, A. H. GALIB, P.-N. TAN et L. LUO. “Unraveling Block Maxima Forecasting Models with Counterfactual Explanation”. In : *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. ACM, 2024, p. 562-573. DOI : [10.1145/3637528.3671923](https://doi.org/10.1145/3637528.3671923).
- [18] DLTHUB. *dlt : data load tool, a Python library for declarative data ingestion*. Logiciel, version 0.4. 2026. URL : <https://dlthub.com/> (visité le 26/08/2026).
- [19] W. FALCON et THE PYTORCH LIGHTNING TEAM. *PyTorch Lightning*. Logiciel. 2019. URL : <https://lightning.ai/> (visité le 26/08/2026).
- [20] K. FUJII, K. TAKEUCHI, A. KURIBAYASHI, N. TAKEISHI, Y. KAWAHARA et K. TAKEDA. “Estimating Counterfactual Treatment Outcomes Over Time in Complex Multiagent Scenarios”. In : *IEEE Transactions on Neural Networks and Learning Systems* (2024), p. 1-15. DOI : [10.1109/TNNLS.2024.3361166](https://doi.org/10.1109/TNNLS.2024.3361166).
- [21] R. GUIDOTTI. “Counterfactual Explanations and How to Find Them : Literature Review and Benchmarking”. In : *Data Mining and Knowledge Discovery* 38.5 (2024), p. 2770-2824. DOI : [10.1007/s10618-022-00831-6](https://doi.org/10.1007/s10618-022-00831-6).

- [22] G. H. HARGREAVES et Z. A. SAMANI. “Reference crop evapotranspiration from temperature”. In : *Applied Engineering in Agriculture* 1.2 (1985), p. 96-99.
- [23] H. HERSBACH et al. “The ERA5 global reanalysis”. In : *Quarterly Journal of the Royal Meteorological Society* 146.730 (2020), p. 1999-2049.
- [24] J. HERZEN et al. “Darts : user-friendly modern machine learning for time series”. In : *Journal of Machine Learning Research* 23.124 (2022), p. 1-6.
- [25] J. R. M. HOSKING. “L-moments : analysis and estimation of distributions using linear combinations of order statistics”. In : *Journal of the Royal Statistical Society, Series B* 52.1 (1990), p. 105-124.
- [26] S. HOYER et J. HAMMAN. *xarray : N-D labeled arrays and datasets in Python*. Journal of Open Research Software, 5(1), 10. 2017. URL : <https://xarray.dev/> (visité le 26/08/2026).
- [27] K. KINJO. *Counterfactual Explanation for Multivariate Time Series Forecasting with Exogenous Variables*. 2025. arXiv : 2511.06906 [cs.LG].
- [28] N. KOKHLIKYAN et al. *Captum : a unified and generic model interpretability library for PyTorch*. 2020. arXiv : 2009.07896. URL : <https://captum.ai/> (visité le 26/08/2026).
- [29] X. KONG et al. “Deep Learning for Time Series Forecasting : A Survey”. In : *International Journal of Machine Learning and Cybernetics* (2025). DOI : 10.1007/s13042-025-02560-w.
- [30] J. LANG, M. A. GIESE, W. ILG et S. OTTE. “Generating Sparse Counterfactual Explanations for Multivariate Time Series”. In : *Discovery Science*. Springer, 2023, p. 180-195. DOI : 10.1007/978-3-031-44223-0_15.
- [31] K. LI, G. TIERNEY, C. HELLMAYR et M. WEST. *Compositional Dynamic Modeling for Causal Prediction in Multivariate Time Series*. 2024. arXiv : 2406.02320 [stat.ME].
- [32] LIFAT. *Projet JUNON (2022–2026), volets DATA, PREDICTION et jumeaux numériques*. Laboratoire d’informatique fondamentale et appliquée de Tours, université de Tours. 2022. URL : <https://lifat.univ-tours.fr/projects/regional/recent/bdtin/2022-2026-junon-project> (visité le 26/08/2026).
- [33] B. LIM, S. Ö. ARIK, N. LOEFF et T. PFISTER. “Temporal fusion transformers for interpretable multi-horizon time series forecasting”. In : *International Journal of Forecasting* 37.4 (2021), p. 1748-1764.
- [34] S. M. LUNDBERG et S.-I. LEE. “A unified approach to interpreting model predictions”. In : *Advances in Neural Information Processing Systems* 30. 2017, p. 4765-4774.

- [35] C. LV, Y. WANG, D. HAN, X. ZHENG, X. HUANG et D. LI. “Efficient and Effective Time-Series Forecasting with Spiking Neural Networks”. In : *Proceedings of the 41st International Conference on Machine Learning*. T. 235. Proceedings of Machine Learning Research. PMLR, 2024.
- [36] T. B. MCKEE, N. J. DOESKEN et J. KLEIST. “The relationship of drought frequency and duration to time scales”. In : *Proceedings of the 8th Conference on Applied Climatology*. Anaheim, Californie, 1993, p. 179-184.
- [37] META OPEN SOURCE. *React 19 : a JavaScript library for building user interfaces*. Logiciel. 2026. URL : <https://react.dev/> (visité le 26/08/2026).
- [38] T. MILLER. “Explanation in Artificial Intelligence : Insights from the Social Sciences”. In : *Artificial Intelligence* 267 (2019), p. 1-38. DOI : [10.1016/j.artint.2018.07.007](https://doi.org/10.1016/j.artint.2018.07.007).
- [39] C. MIN, G. WEN, J. YUAN, J. YI et X. GUO. *Domain Adaptation for Industrial Time-Series Forecasting via Causal Inference*. 2024. arXiv : [2407.14214](https://arxiv.org/abs/2407.14214) [cs.LG].
- [40] C. MOREIRA, Y.-L. CHOU, C. HSIEH, C. OUYANG, J. PEREIRA et J. JORGE. “Benchmarking Instance-Centric Counterfactual Algorithms for XAI : From White Box to Black Box”. In : *ACM Computing Surveys* 57.6 (2025), p. 1-37. DOI : [10.1145/3672553](https://doi.org/10.1145/3672553).
- [41] R. K. MOTHILAL, A. SHARMA et C. TAN. “Explaining machine learning classifiers through diverse counterfactual explanations”. In : *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*. 2020, p. 607-617.
- [42] J. MUÑOZ-SABATER et al. “ERA5-Land : a state-of-the-art global reanalysis dataset for land applications”. In : *Earth System Science Data* 13.9 (2021), p. 4349-4383.
- [43] M. NAUTA et al. “From Anecdotal Evidence to Quantitative Evaluation Methods : A Systematic Review on Evaluating Explainable AI”. In : *ACM Computing Surveys* 55.13s (2023), p. 1-42. DOI : [10.1145/3583558](https://doi.org/10.1145/3583558).
- [44] P. B. NEMENYI. “Distribution-free Multiple Comparisons”. Thèse de doct. Princeton University, 1963.
- [45] T. L. NGUYEN et G. IFRIM. “TSHAP : Fast and Exact SHAP for Explaining Time Series Classification and Regression”. In : *Machine Learning and Knowledge Discovery in Databases. Research Track*. Springer, 2025, p. 60-77. DOI : [10.1007/978-3-032-06078-5_4](https://doi.org/10.1007/978-3-032-06078-5_4).
- [46] OFFICE FRANÇAIS DE LA BIODIVERSITÉ. *Hub'Eau : les API du système d'information sur l'eau*. Services web *niveaux_nappes* et *hydrometrie*. 2026. URL : <https://hubeau.eaufrance.fr/> (visité le 26/08/2026).

- [47] Q. PAN, W. HU et N. CHEN. “Two Birds with One Stone : Series Saliency for Accurate and Interpretable Multivariate Time Series Forecasting”. In : *Proceedings of the Thirtieth International Joint Conference on Artificial Intelligence*. International Joint Conferences on Artificial Intelligence Organization, 2021, p. 2884-2891. DOI : [10.24963/ijcai.2021/397](https://doi.org/10.24963/ijcai.2021/397).
- [48] F. PETROPOULOS et al. “Forecasting : Theory and Practice”. In : *International Journal of Forecasting* 38.3 (2022), p. 705-871. DOI : [10.1016/j.ijforecast.2021.11.001](https://doi.org/10.1016/j.ijforecast.2021.11.001).
- [49] POSTGIS PROJECT. *PostGIS : spatial and geographic objects for PostgreSQL*. Logiciel. 2026. URL : <https://postgis.net/> (visité le 26/08/2026).
- [50] POSTGRESQL GLOBAL DEVELOPMENT GROUP. *PostgreSQL 16*. Système de gestion de base de données relationnelle. 2026. URL : <https://www.postgresql.org/> (visité le 26/08/2026).
- [51] C. RAMAN, A. NONNEMAKER, A. VILLEGAS-MORCILLO, H. HUNG et M. LOOG. “Why Did This Model Forecast This Future? Information-Theoretic Saliency for Counterfactual Explanations of Probabilistic Regression Models”. In : *Advances in Neural Information Processing Systems*. T. 36. 2023.
- [52] S. RAMÍREZ. *FastAPI : a modern, fast web framework for building APIs with Python*. Logiciel. 2026. URL : <https://fastapi.tiangolo.com/> (visité le 26/08/2026).
- [53] M. T. RIBEIRO, S. SINGH et C. GUESTRIN. ““Why should I trust you ?” : Explaining the predictions of any classifier”. In : *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, p. 1135-1144.
- [54] N. RINGUET. *hubeau_data_integration : entrepôt de données hydro-climatiques*. Dépôt logiciel public, licence MIT. 2026. URL : https://github.com/xairon/hubeau_data_integration (visité le 26/08/2026).
- [55] N. RINGUET. *time-serie-explo : plateforme d’exploration, de modélisation et de prévision piézométrique*. Dépôt logiciel public, licence MIT. 2026. URL : <https://github.com/xairon/time-serie-explo> (visité le 26/08/2026).
- [56] A. SAADALLAH, M. JAKOBS et K. MORIK. “Explainable Online Deep Neural Network Selection Using Adaptive Saliency Maps for Time Series Forecasting”. In : *Machine Learning and Knowledge Discovery in Databases*. Springer, 2021, p. 404-420. DOI : [10.1007/978-3-030-86486-6_25](https://doi.org/10.1007/978-3-030-86486-6_25).
- [57] D. I. SERRAMAZZA, T. T. NGUYEN, T. L. NGUYEN et G. IFRIM. *Evaluating Explanation Methods for Multivariate Time Series Classification*. 2023. arXiv : [2308.15223](https://arxiv.org/abs/2308.15223) [cs.LG].

- [58] A. SRINIVASAN, V. SINGAPURA RAVI, J. C. ANDRESEN et A. HOLST. “Counterfactual Explanation for Auto-Encoder Based Time-Series Anomaly Detection”. In : *PHM Society European Conference*. T. 8. 2024, p. 1-9. DOI : [10.36001/phme.2024.v8i1.4087](https://doi.org/10.36001/phme.2024.v8i1.4087).
- [59] X. SUN, R. AOKI et K. H. WILSON. “No D_{train} : Model-Agnostic Counterfactual Explanations Using Reinforcement Learning”. In : *Transactions on Machine Learning Research* (2025). Published June 2025.
- [60] M. SUNDARARAJAN, A. TALY et Q. YAN. “Axiomatic attribution for deep networks”. In : *Proceedings of the 34th International Conference on Machine Learning*. 2017, p. 3319-3328.
- [61] TIMESCALE. *TimescaleDB : time-series extension for PostgreSQL*. Logiciel. 2026. URL : <https://www.tigerdata.com/> (visité le 26/08/2026).
- [62] E. VAREILLE, A. ABBAS, M. LINARDI et V. CHRISTOPHIDES. “Evaluating Explanation Methods of Multivariate Time Series Classification Through Causal Lenses”. In : *2023 IEEE International Conference on Data Science and Advanced Analytics (DSAA)*. IEEE. 2023.
- [63] S. M. VICENTE-SERRANO, S. BEGUERÍA et J. I. LÓPEZ-MORENO. “A multiscalar drought index sensitive to global warming : the standardized precipitation evapotranspiration index”. In : *Journal of Climate* 23.7 (2010), p. 1696-1718.
- [64] J. VON ASMUTH et al. *Handleiding tijdreeksanalyse*. Rapp. tech. 2021-32. Manuel de référence de l’analyse de séries temporelles pour la gestion des eaux souterraines, et critères d’acceptation des modèles. Amersfoort, Pays-Bas : Stichting Toegepast Onderzoek Waterbeheer (STOWA), 2021.
- [65] S. WACHTER, B. MITTELSTADT et C. RUSSELL. “Counterfactual explanations without opening the black box : automated decisions and the GDPR”. In : *Harvard Journal of Law and Technology* 31.2 (2018), p. 841-887.
- [66] Y. WANG et al. *Deep Time Series Models : A Comprehensive Survey and Benchmark*. 2024. arXiv : [2407.13278](https://arxiv.org/abs/2407.13278) [cs.LG].
- [67] Z. WANG, I. MILIOU, I. SAMSTEN et P. PAPAPETROU. “Counterfactual explanations for time series forecasting”. In : *IEEE International Conference on Data Mining (ICDM)*. 2023, p. 1391-1396.
- [68] Z. WANG, I. SAMSTEN, I. MILIOU et P. PAPAPETROU. “COMET : Constrained Counterfactual Explanations for Patient Glucose Multivariate Forecasting”. In : *2024 IEEE 37th International Symposium on Computer-Based Medical Systems (CBMS)*. IEEE. 2024, p. 502-507. DOI : [10.1109/CBMS61543.2024.00089](https://doi.org/10.1109/CBMS61543.2024.00089).

- [69] G. WEN, C. MIN, Q. ZHANG et G. LIAO. “Dynamical Counterfactual Inference Under Time-Series Model for Waterflooding Oilfield”. In : *Petroleum* 11 (2025), p. 113-124. DOI : [10.1016/j.petlm.2024.11.001](https://doi.org/10.1016/j.petlm.2024.11.001).
- [70] J. YAN et H. WANG. “Self-Interpretable Time Series Prediction with Counterfactual Explanations”. In : *Proceedings of the 40th International Conference on Machine Learning*. T. 202. Proceedings of Machine Learning Research. PMLR, 2023, p. 39110-39125.
- [71] M. ZAHARIA et al. “Accelerating the machine learning lifecycle with MLflow”. In : *IEEE Data Engineering Bulletin* 41.4 (2018), p. 39-45.
- [72] G. ZUIN et A. VELOSO. “Navigating Time’s Possibilities : Plausible Counterfactual Explanations for Multivariate Time-Series Forecast Through Genetic Algorithms”. In : *2024 IEEE 23rd International Conference on Trust, Security and Privacy in Computing and Communications (TrustCom)*. IEEE. 2024, p. 2575-2582. DOI : [10.1109/TrustCom63139.2024.00359](https://doi.org/10.1109/TrustCom63139.2024.00359).